



UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

**Uma Análise Comparativa entre Inferência
Frequentista e Bayesiana em Modelos de Regressão
Aplicados à Aprovação de Empréstimos**

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Ago/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Aplicados à Aprovação de Empréstimos

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Ago/2026

RESUMO

reavaliar os resumos, quando o trabalho estiver concluído

Este trabalho tem como objetivo comparar as abordagens de inferência frequentista e bayesiana no contexto de modelos de classificação aplicados à predição da aprovação de empréstimos bancários. O foco principal do estudo está na análise das diferenças conceituais, inferenciais e preditivas entre essas duas abordagens estatísticas, utilizando um conjunto de dados reais como estudo de caso para a aplicação dos modelos.

Inicialmente, são discutidos os fundamentos teóricos das abordagens frequentista e bayesiana, destacando suas principais características, pressupostos e formas de interpretação dos parâmetros. Em seguida, realiza-se uma análise exploratória dos dados com o objetivo de compreender a estrutura das variáveis e subsidiar a construção dos modelos, sem que a análise dos dados constitua o foco central do trabalho.

Na etapa de modelagem, são ajustados modelos de classificação sob as perspectivas frequentista e bayesiana, permitindo a comparação entre as abordagens quanto ao desempenho preditivo, à interpretação dos coeficientes estimados e à quantificação da incerteza associada às estimativas. A avaliação dos modelos é realizada por meio de métricas adequadas de classificação, possibilitando uma análise sistemática das diferenças e semelhanças entre os métodos.

Por fim, os resultados obtidos evidenciam as vantagens e limitações de cada abordagem no contexto de problemas de classificação binária, contribuindo para uma compreensão mais aprofundada das implicações práticas e metodológicas da escolha entre inferência frequentista e bayesiana em aplicações de análise de risco de crédito e ciência de dados.

Palavras-chave: regressão estatística; inferência frequentista; inferência bayesiana; modelos preditivos; análise de risco de crédito.

ABSTRACT

This study aims to compare frequentist and Bayesian inference approaches in the context of regression models applied to the prediction of loan approval decisions. The main focus of the research lies in analyzing the conceptual, inferential, and predictive differences between these two statistical paradigms, using a real-world dataset as a case study for model application.

Initially, the theoretical foundations of frequentist and Bayesian approaches are discussed, highlighting their main characteristics, assumptions, and parameter interpretation frameworks. Subsequently, an exploratory analysis of the data is conducted in order to understand the structure of the variables and support model development, without making the data analysis itself the central focus of the study.

In the modeling stage, regression models are fitted under both frequentist and Bayesian perspectives, allowing for a comparative evaluation in terms of predictive performance, coefficient interpretation, and uncertainty quantification associated with the estimates. Model performance is assessed using appropriate classification metrics, enabling a systematic comparison between the two approaches.

Finally, the results highlight the strengths and limitations of each statistical approach in the context of binary classification problems, contributing to a deeper understanding of the practical and methodological implications of choosing between frequentist and Bayesian inference in credit risk analysis and data science applications.

Keywords: frequentist inference; Bayesian inference; regression models; predictive modeling; credit risk analysis.

Índice

1	[TBD] Introdução	7
2	[TO DO] Referencial Teórico	7
2.1	[TO DO] Fundamentos de Probabilidade e Inferência Estatística	8
2.2	[TO DO] Problemas de Classificação em Aprendizado Estatístico	8
2.3	[TO DO] Avaliação de Modelos de Classificação	8
2.4	[TO DO] Regressão Logística Frequentista	8
2.5	[TO DO] Inferência Bayesiana	9
2.6	[TO DO] Regressão Logística Bayesiana	9
2.7	[TO DO] Aplicações em Risco de Crédito e Finanças	10
3	[WIP] Metodologia	10
3.1	[REVISÃO] Descrição dos Dados	11
3.2	[TBD] Pré-processamento	12
3.2.1	[REVISÃO] Verificação da Estrutura de dados e tratamento de valores ausentes	12
3.2.2	[REVISÃO] Outliers	12
3.2.3	[REVISÃO] Codificação de variáveis categóricas	13
3.2.4	[TO DO] Padronização de variáveis numéricas	14
3.2.5	[TO DO] Estratégia de Modelagem	14
3.3	[TO DO] Modelos Avaliados	16
4	[WIP] Resultados	16
4.1	[REVISÃO] Análise Exploratória	16
4.1.1	Estatísticas univariadas	16
4.1.2	Análise da variável resposta e relações com as variáveis preditoras .	18
4.1.3	Análise de correlação entre variáveis numéricas	20
4.1.4	Análise de outliers e dispersão	23
4.2	[REVISÃO] Pré processamento	25
4.2.1	[REVISÃO] Verificação de valores ausentes e duplicatas	25
4.2.2	[REVISÃO] Tratamento de inconsistências e outliers	25
4.2.3	[REVISÃO] Seleção de variáveis e análise de correlação	26

4.2.4	[REVISÃO] Codificação e padronização de variáveis	26
4.2.5	[REVISÃO] Separação treino/teste	27
4.3	[WIP] Modelagem e Avaliação	27
4.3.1	[WIP] Modelo Frequentista	27
4.3.2	[TBD] Modelo Bayesiano	35
4.4	[TBD] Desempenho Preditivo	35
4.5	[TBD] Interpretação dos Modelos	35
5	[TBD] Discussão	35
6	[TBD] Conclusão	35
	Referências	36

Legenda de status do documento

- **[TBD]** → tópico ainda indefinido; estrutura ou escopo em discussão
- **[TO DO]** → tópico planejado, ainda não iniciado
- **[WIP]** → em desenvolvimento
- **[DRAFT]** → versão preliminar do texto
- **[CHECK]** → verificação pendente (conceitos, dados, código ou referências)
- **[REVISÃO]** → versão completa, pronta para avaliação
- **[AJUSTAR]** → ajustes finos de redação, figuras ou formatação (após revisão)
- **[FINAL]** → versão definitiva (após revisão e ajustes finais)

estou colocando comentários em vermelho para destacar pontos a revisar ou expandir

1 [TBD] Introdução

- Contexto de risco de crédito (motivação do trabalho)
- Importância de modelos estatísticos na decisão financeira (com referencias de estudos anteriores)
- Diferença conceitual entre abordagem frequentista e bayesiana
- Motivação do estudo
- Objetivo geral (resumida)
- indicar as técnicas Estatísticas/Computacionais que serão utilizadas para a resolução do problema.
- Estrutura do trabalho (Este trabalho está assim organizado: Na Seção 2 apresentamos.... A Seção 3 trata de...)

2 [TO DO] Referencial Teórico

um dos principais capítulos, já que o foco do trabalho é a comparação entre abordagens.

2.1 [TO DO] Fundamentos de Probabilidade e Inferência Estatística

- Probabilidade como frequência vs probabilidade como grau de crença
- Variáveis aleatórias e distribuições
- Teorema de Bayes
- Conceito de incerteza estatística
- Inferência como problema de estimação

2.2 [TO DO] Problemas de Classificação em Aprendizado Estatístico

- Classificação binária
- Função de perda e decisão
- Separabilidade linear e não linear
- Overfitting e generalização (preparando terreno para problemas de crédito, onde a separação perfeita é improvável e o trade-off entre viés e variância é crucial)
- Probabilidades preditas vs. classes previstas
- Threshold de decisão e custo de erro

2.3 [TO DO] Avaliação de Modelos de Classificação

- Desbalanceamento de classes (muito comum em dados de crédito, mas não no dataset atual)
- Matriz de confusão
- Accuracy, Precision, Recall, F1-score
- Curvas Precision–Recall
- Curva ROC e AUC
- Trade-off entre sensibilidade e especificidade
- Custo assimétrico de erros (FP vs FN)

2.4 [TO DO] Regressão Logística Frequentista

- Formulação do modelo

- Assumptions do modelo (e.g., independência, linearidade no logit, ausência de multicolinearidade)
- Parametrização e interpretação
- Interpretação dos coeficientes
- Função logística
- Estimação por máxima verossimilhança (e a função de verossimilhança)
- Testes de hipótese
- Intervalos de confiança
- Odds e odds ratio
- Limitações da abordagem frequentista

2.5 [TO DO] Inferência Bayesiana

- Teorema de Bayes aplicado à estatística
- diferenças conceituais
- parâmetros como variáveis aleatórias
- Priors, likelihood e posterior
- Incerteza e distribuição posterior
- Vantagens da abordagem bayesiana
- Atualização sequencial da evidência
- Interpretação probabilística
- controle de sobreajuste (...) **Encaixar o que mais fizer sentido aqui.**

2.6 [TO DO] Regressão Logística Bayesiana

(sempre traçando paralelos com a versão frequentista)

- Formulação do modelo probabilístico
- Escolha de priors
- Inferência via MCMC / aproximações variacionais
- Diagnóstico de convergência (R-hat, traceplots)
- Intervalos credíveis
- Sensibilidade a priors

- Robustez em pequenas amostras
- Interpretação dos coeficientes sob posterior
- Comparação direta de MLE e MAP MAP- Maximum-a-Posteriori MLE- maximum likelihood estimation (...) **Encaixar o que mais fizer sentido aqui.**

2.7 [TO DO] Aplicações em Risco de Crédito e Finanças

Não estender muito, acho que 1 página já deve ser suficiente, o foco é a comparação

(Contextualização)

- Modelos de scoring de crédito
- Variáveis financeiras e risco
- Decisão de concessão de empréstimos
- Uso das probabilidades preditas para gestão de risco
- Transparência e interpretabilidade
- Em problemas de concessão de empréstimos, a incerteza é tão importante quanto a previsão.
- O enfoque bayesiano permite incorporar conhecimento prévio do risco.
- O enfoque frequentista fornece base tradicional de modelos de scoring.
- A comparação entre ambas abordagens permite avaliar robustez das decisões.

3 [WIP] Metodologia

Aqui entra o dataset como aplicação, não como foco teórico.

3.1 [REVISÃO] Descrição dos Dados

Os modelos desenvolvidos neste trabalho utilizam o Loan Approval Dataset, uma base de dados pública disponibilizada na plataforma Kaggle (Grewal (2026)). A variável alvo é binária, indicando o status de aprovação do empréstimo. A Tabela 1 apresenta uma descrição detalhada das variáveis presentes no conjunto de dados.

Tabela 1: Descrição das variáveis do dataset

Feature	Descrição
No_of_dependents	Número de dependentes do solicitante
Education	Nível de escolaridade (Graduate / Not Graduate)
Self_employed	Autônomo (Yes / No)
Income_annum	Renda anual
Loan_amount	Valor do empréstimo
Loan_term	Prazo em anos
Cibil_score	Score de crédito
Residential_assets_value	Bens residenciais
Commercial_assets_value	Bens comerciais
Luxury_assets_value	Bens de luxo
Bank_asset_value	Ativos bancários
Loan_status	Variável alvo (Approved/Rejected)

Por se tratar de um dataset estruturado especificamente para fins de aprendizado de máquina e análise estatística, ele oferece um cenário controlado, permitindo focar na sensibilidade dos modelos aos preditores e na quantificação da incerteza sem as inconsistências típicas de bases de dados administrativas brutas.

3.2 [TBD] Pré-processamento

3.2.1 [REVISÃO] Verificação da Estrutura de dados e tratamento de valores ausentes

Inicialmente, foi realizada a inspeção da estrutura do banco de dados, com o objetivo de confirmar a consistência dos tipos das variáveis e a adequação do formato dos dados às técnicas de modelagem adotadas. Essa análise compreendeu a identificação das classes das variáveis, a distinção entre atributos numéricos e categóricos e a validação da variável resposta quanto à sua natureza e domínio.

A variável dependente, correspondente ao status do empréstimo, foi confirmada como binária, atendendo às premissas dos modelos de regressão logística. As variáveis explicativas foram classificadas conforme sua natureza (contínua ou categórica), possibilitando a aplicação apropriada de procedimentos de codificação e padronização quando necessário.

Por fim, a presença de valores ausentes foi avaliada por meio da função `is.na()`, com sumarização via `colSums(is.na())`. Não foram identificadas observações faltantes no conjunto de dados, eliminando a necessidade de técnicas de imputação e evitando a introdução de incerteza adicional ou viés sistemático no processo de estimação.

3.2.2 [REVISÃO] Outliers

A identificação de valores atípicos (`outliers`) nas variáveis numéricas foi realizada por meio do critério do intervalo interquartil (`Interquartile Range`, `IQR`), amplamente utilizado em estatística descritiva por sua robustez em relação a distribuições assimétricas e à presença de valores extremos.

Para cada variável contínua, foram calculados o primeiro quartil Q_1 e o terceiro quartil Q_3 , definindo-se o intervalo interquartil como

$$\text{IQR} = Q_3 - Q_1 \quad (1)$$

Os limites inferior e superior para identificação de outliers são definidos como

$$L = Q_1 - 1.5 \cdot \text{IQR} \quad (2)$$

$$U = Q_3 + 1.5 \cdot \text{IQR} \quad (3)$$

Esse procedimento foi empregado exclusivamente com finalidade exploratória, visando caracterizar a distribuição das variáveis e avaliar a presença de valores extremos potencialmente influentes. Não foi realizada a exclusão automática de observações, de modo a preservar a integridade do conjunto de dados e permitir que os modelos estatísticos capturassem adequadamente a heterogeneidade inerente aos dados financeiros.

O fator 1.5 no critério do IQR foi proposto por Tukey (1977) como um compromisso empírico entre robustez e sensibilidade, sendo amplamente adotado na literatura por sua boa performance em distribuições assimétricas e com caudas longas, como é típico em dados financeiros.

No contexto de análise de risco de crédito, a presença de valores extremos pode refletir perfis legítimos de alto patrimônio ou elevado risco, sendo crucial que os modelos estatísticos sejam capazes de acomodar essa variabilidade sem que a remoção indiscriminada de outliers elimine informação relevante para a tarefa de classificação.

3.2.3 [REVISÃO] Codificação de variáveis categóricas

Para viabilizar a inclusão de variáveis qualitativas nos modelos de regressão, foi aplicada a técnica de One-Hot Encoding. Este procedimento consiste na transformação de variáveis categóricas nominais em um conjunto de variáveis indicadoras (binárias), onde o valor 1 representa a presença da categoria e 0 a sua ausência.

Para a implementação, utilizou-se a função `dummy_cols` do pacote `fastDummies`, parametrizada com o argumento `remove_first_dummy = TRUE`. Esta etapa é metodologicamente crítica para mitigar a armadilha da variável dummy (multicolinearidade perfeita), que ocorre quando as variáveis indicadoras são linearmente dependentes, impossibilitando a estimação única dos parâmetros por métodos de máxima verossimilhança ou por algoritmos

de amostragem bayesiana. Com a remoção da primeira categoria, o modelo estabelece uma base de comparação necessária para a interpretação dos coeficientes estimados.

3.2.4 [TO DO] Padronização de variáveis numéricas

Para assegurar a estabilidade numérica dos algoritmos de estimação e permitir a comparabilidade entre os coeficientes do modelo, as variáveis quantitativas foram submetidas ao processo de padronização (Standardization). Inicialmente, realizou-se a coerção dos dados para o tipo numérico e, em seguida, aplicou-se a transformação de escala centralizada na média com unidade de desvio padrão. A fórmula utilizada para a padronização de cada variável X é dada por

$$z_i = \frac{x_i - \mu}{\sigma} \quad (4)$$

onde x_i representa o valor original da variável, μ é a média amostral e σ é o desvio padrão amostral. Essa transformação resulta em variáveis com média zero e desvio padrão um. Com todas as variáveis na mesma escala, os coeficientes estimados tornam-se comparáveis entre si, permitindo identificar quais preditores exercem maior impacto relativo sobre a probabilidade de aprovação do empréstimo.

Na inferência frequentista, evita que variáveis com grandes magnitudes (como Renda Anual) dominem a função de verossimilhança em detrimento de variáveis com escalas menores. Na inferência bayesiana, facilita a amostragem das distribuições posteriores pelos algoritmos de Cadeias de Markov via Monte Carlo (MCMC), tornando a busca no espaço de parâmetros mais eficiente.

3.2.5 [TO DO] Estratégia de Modelagem

- Separação treino/teste
- Validação cruzada (se usar)
- Métricas escolhidas

3.2.5.1 [REVISÃO] Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta $Y = \text{loan_status}$.

Essa estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1). \quad (5)$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não viesada do erro de generalização, reduzindo o risco de sobreajuste (overfitting) e vazamento de informação.

3.2.5.2 Métricas de avaliação

3.2.5.2.1 Ajuste do modelo

- Deviance
- AIC
- BIC
- Teste da razão de verossimilhança

3.2.5.2.2 Avaliação preditiva

A avaliação dos modelos de classificação foi realizada por meio de métricas adequadas para problemas de classificação binária, considerando a distribuição das classes e a importância relativa dos erros de classificação. As métricas selecionadas incluem: - ROC-AUC (Área sob a curva ROC) - Curva Precision-Recall e AUC-PR - Curva Sensibilidade (Recall) e Especificidade - Matriz de confusão - Accuracy, Precision, Recall e F1-score

3.3 [TO DO] Modelos Avaliados

- Regressão logística frequentista
- Regressão logística bayesiana (e deixa uma subseção “Modelos adicionais”, caso queira)

4 [WIP] Resultados

4.1 [REVISÃO] Análise Exploratória

A análise exploratória tem como finalidade compreender a estrutura dos dados, identificar padrões gerais, possíveis assimetrias, outliers e relações preliminares entre variáveis. Essa etapa é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

O conjunto de dados é composto por 4269 observações e 13 variáveis, incluindo a variável resposta `loan_status`, que indica se o empréstimo foi aprovado ou rejeitado. As variáveis preditoras incluem informações como renda anual, pontuação de crédito (`cibil_score`), nível educacional, entre outras características dos solicitantes.

4.1.1 Estatísticas univariadas

A Tabela 2 apresenta as principais estatísticas descritivas das variáveis numéricas do conjunto de dados, incluindo média, mediana, valor mínimo e máximo. Em média, os solicitantes apresentam aproximadamente 2 a 3 dependentes, renda anual em torno de 5 milhões e solicitam empréstimos próximos a 15 milhões. O prazo médio dos empréstimos é de cerca de 11 anos, enquanto o score de crédito médio está próximo de 600 pontos. Esses valores sugerem uma população com perfil financeiro intermediário, mas com ampla variabilidade entre indivíduos, com desvios-padrão elevados.

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
no_of_dependents	2.5	3	0	5	1.7
income_annum	5.05912e+06	5.1e+06	200000	9.9e+06	2.80684e+06
loan_amount	1.51335e+07	1.45e+07	300000	3.95e+07	9.04336e+06
loan_term	10.9	10	2	20	5.71
cibil_score	599.94	600	300	900	172.43
residential_assets_value	7.47262e+06	5.6e+06	-100000	2.91e+07	6.50364e+06
commercial_assets_value	4.97316e+06	3.7e+06	0	1.94e+07	4.38897e+06
luxury_assets_value	1.51263e+07	1.46e+07	300000	3.92e+07	9.10375e+06
bank_asset_value	4.97669e+06	4.6e+06	0	1.47e+07	3.25019e+06

A Tabela 3 apresenta a distribuição das variáveis categóricas do conjunto de dados. Observa-se que as categorias analisadas exibem distribuições globalmente equilibradas, sem predominância acentuada de um único grupo, o que contribui para a estabilidade estatística e reduz potenciais vieses na etapa de modelagem.

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
no_of_dependents	0	712	16.68
no_of_dependents	1	697	16.33
no_of_dependents	2	708	16.58
no_of_dependents	3	727	17.03
no_of_dependents	4	752	17.62
no_of_dependents	5	673	15.76
education	Graduate	2144	50.22
education	Not Graduate	2125	49.78
self_employed	No	2119	49.64
self_employed	Yes	2150	50.36

As variáveis financeiras apresentam elevada amplitude e distribuição aproximadamente

uniforme dentro de seus intervalos observados. Embora os desvios-padrão sejam elevados em termos absolutos, a análise gráfica feita na Figura 1 não indica forte assimetria ou concentração modal acentuada. Esse comportamento sugere heterogeneidade na amostra, mas com dispersão relativamente equilibrada ao longo do espaço amostral.

Além disso, `cibil_score` apresenta uma distribuição relativamente mais concentrada em torno da mediana, o que sugere menor variabilidade na avaliação de crédito em comparação com as variáveis patrimoniais. Esse comportamento pode indicar que o score de crédito atua como uma variável estabilizadora no processo de decisão de concessão de empréstimos.


Outro ponto relevante é a presença de valores mínimos negativos em `residential_assets_value`, o que pode indicar inconsistências de registro ou tratamentos contábeis específicos no conjunto de dados. Esse tipo de característica pode afetar a modelagem, exigindo atenção em etapas de pré-processamento, especialmente em modelos sensíveis à escala e à interpretação econômica das variáveis.

4.1.2 Análise da variável resposta e relações com as variáveis preditoras


Na Figura 2, observa-se a distribuição da variável resposta `loan_status`, indicando que aproximadamente 62.22% dos empréstimos foram aprovados, enquanto 37.78% foram rejeitados. Essa proporção sugere um desequilíbrio moderado na classe alvo, o que pode influenciar a escolha de métricas de avaliação e estratégias de modelagem.

A Figura 3 apresenta a estimativa de densidade para as variáveis numéricas do conjunto de dados, segmentadas pelo status de aprovação do empréstimo (Rejeitado ou Aprovado). Observa-se que a variável `cibil_score` é a que apresenta a separação mais nítida entre as classes: candidatos com scores mais baixos (aproximadamente abaixo de 600) concentram-se majoritariamente no grupo de rejeitados, enquanto scores elevados mostram uma densidade quase exclusiva de aprovações.


Em contraste, variáveis como `income_annum` e os diferentes tipos de ativos Figura 3 exibem distribuições sobrepostas e visualmente semelhantes entre as duas classes. Tal sobreposição indica que, isoladamente, essas variáveis possuem menor poder discriminatório, o que exigirá dos modelos de regressão a identificação de correlações mais complexas ou efeitos multivariados para contribuir com a predição. No que tange ao `loan_term`, nota-se uma




(a) Distribuição da renda anual




(b) Distribuição do valor do empréstimo




(c) Distribuição do prazo




(d) Distribuição do CIBIL score




(e) Distribuição dos ativos residenciais



(f) Distribuição dos ativos comerciais



(g) Distribuição dos bens de luxo



(h) Distribuição dos ativos bancários

Figura 1: Distribuição das principais variáveis numéricas do conjunto de dados




Figura 2: Distribuição da aprovação de empréstimos

ligeira predominância de rejeições em prazos muito curtos, enquanto os prazos mais longos apresentam uma distribuição mais equilibrada entre os grupos.

A Figura 4 apresenta a distribuição das frequências absolutas para as variáveis categóricas Nível educacional, Trabalho autônomo e Número de dependentes, segmentadas pelo status de aprovação. Diferente do observado na variável `cibil_score`, as variáveis categóricas exibem uma distribuição notavelmente homogênea entre as classes. Observa-se que a proporção entre empréstimos aprovados e rejeitados mantém-se praticamente constante, independentemente de o candidato ser graduado ou não, ou de possuir trabalho autônomo. No que tange ao número de dependentes, o comportamento é análogo: não há uma categoria específica (de 0 a 5 dependentes) que apresente uma vantagem ou desvantagem desproporcional na aprovação do crédito. Sob a ótica da modelagem estatística, essa independência aparente sugere que tais variáveis podem apresentar coeficientes com menor magnitude ou maior incerteza .

4.1.3 Análise de correlação entre variáveis numéricas

A matriz de correlação (Figura 5) revela associações relevantes entre as variáveis financeiras do conjunto de dados. Observa-se forte correlação entre renda anual (`income_annum`) e valor do empréstimo (`loan_amount`), bem como entre essas variáveis e os ativos patrimoniais, especialmente ativos de luxo e ativos bancários, indicando que essas medidas capturam




Figura 3: Distribuição das variáveis numéricas por status de aprovação do empréstimo




Figura 4: Distribuição das variáveis categóricas segundo o status do empréstimo

aspectos relacionados da condição financeira dos solicitantes. As correlações entre os diferentes tipos de ativos são positivas e moderadas, sugerindo coerência interna do perfil patrimonial, sem redundância perfeita entre as variáveis.

Por outro lado, o prazo do empréstimo (`loan_term`) apresenta correlação praticamente nula com as demais variáveis, indicando independência em relação ao perfil financeiro. De forma semelhante, o `cibil_score` exibe correlações muito fracas com renda, ativos e valor do empréstimo, sugerindo que essa variável representa uma dimensão distinta de risco de crédito, relevante para a classificação, mas não diretamente associada ao nível de riqueza.

A presença de correlações elevadas entre algumas variáveis explicativas indica potencial multicolinearidade, aspecto que deve ser considerado na etapa de modelagem, especialmente na interpretação dos coeficientes da regressão logística.




Figura 5: Mapa de calor da correlação entre variáveis numéricas

4.1.4 Análise de outliers e dispersão

Complementarmente à análise de densidade, a Figura 6 apresenta os boxplots das mesmas variáveis, permitindo uma inspeção detalhada da dispersão, mediana e presença de valores atípicos (outliers). É notável que, novamente, a variável `cibil_score` destaca-se por apresentar uma separação clara entre as medianas dos grupos Rejeitado e Aprovado, com uma dispersão significativamente menor nos aprovados, reforçando o observado na Figura 3. Essa característica sugere que o `cibil_score` é um preditor robusto e com alta capacidade discriminatória para a classificação de risco de crédito.

Para as demais variáveis numéricas (como `loan_amount`, `income_annum` e os valores dos diferentes ativos) os boxplots confirmam a semelhança entre as distribuições dos grupos, com medianas e IQRs altamente sobrepostos. Essa característica reforça a hipótese de que tais variáveis, por si só, possuem baixo poder discriminatório para a classificação. A identificação de valores atípicos, especialmente em `residential_assets_value` e `commercial_assets_value`, é um aspecto relevante para a modelagem: enquanto a inferência frequentista pode exigir o tratamento ou a robustez de estimadores frente a esses pontos, a abordagem bayesiana oferece a vantagem de modelar a incerteza desses outliers através de distribuições de cauda longa, permitindo uma avaliação mais flexível do impacto desses casos nos parâmetros estimados.

A presença de valores atípicos, particularmente em variáveis relacionadas a ativos patrimoniais, é corroborada quantitativamente pela Tabela 4, que apresenta o número e o percentual de observações classificadas como outliers segundo o critério do intervalo interquartil. Esses valores extremos refletem a heterogeneidade típica de dados financeiros e possuem implicações diretas para a modelagem estatística. Enquanto abordagens frequentistas podem demandar procedimentos de tratamento ou estimadores robustos para mitigar a influência desses pontos, modelos bayesianos permitem incorporar explicitamente essa incerteza por meio de distribuições com caudas mais pesadas, oferecendo maior flexibilidade na avaliação do impacto dos outliers sobre os parâmetros estimados.




Figura 6: Boxplots das variáveis numéricas por status de aprovação do empréstimo

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR

Feature	Outliers	Percentual
bank_asset_value	5	0.0011712
cibil_score	0	0.0000000
commercial_assets_value	37	0.0086671
income_annum	0	0.0000000
loan_amount	0	0.0000000
loan_term	0	0.0000000
luxury_assets_value	0	0.0000000
residential_assets_value	52	0.0121808

4.2 [REVISÃO] Pré processamento

4.2.1 [REVISÃO] Verificação de valores ausentes e duplicatas

Inicialmente, foi realizada a verificação da presença de valores ausentes e observações duplicadas no conjunto de dados. Não foram identificados missing values em nenhuma das variáveis, o que dispensou a aplicação de técnicas de imputação e evitou a introdução de incerteza adicional ou viés sistemático no processo de modelagem. Adicionalmente, não foram detectadas observações duplicadas, assegurando que cada registro corresponda a uma unidade amostral distinta e contribuindo para a validade das estimativas inferenciais.

4.2.2 [REVISÃO] Tratamento de inconsistências e outliers

Observa-se que aproximadamente 0.01% dos solicitantes apresentam valores negativos para ativos residenciais, correspondendo a um contingente residual de observações atípicas. Esses valores não possuem interpretação econômica direta no contexto da variável analisada e podem estar associados a inconsistências de registro ou a particularidades não representativas do perfil financeiro da amostra. Considerando o caráter marginal dessas observações e seu potencial de introduzir ruído na estimação dos parâmetros, optou-se por removê-las do conjunto de dados, sem prejuízo à representatividade da amostra ou

à validade inferencial dos modelos ajustados. A exclusão resultou na remoção de 28 observações.

Não foi aplicado tratamento automático de outliers, uma vez que valores extremos são esperados em dados financeiros e podem conter informação relevante para a classificação do risco de crédito.

4.2.3 [REVISÃO] Seleção de variáveis e análise de correlação

A Figura 5 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas. Observou-se a presença de correlações elevadas entre variáveis associadas à escala de renda e patrimônio, como renda anual, valor do empréstimo e ativos financeiros, comportamento esperado em bases de dados financeiras.

Apesar dessas correlações, optou-se por não remover variáveis nesta etapa, uma vez que correlação elevada não implica, necessariamente, multicolinearidade prejudicial à estimação, e tais variáveis podem conter informação complementar relevante para a classificação do risco de crédito.

4.2.4 [REVISÃO] Codificação e padronização de variáveis

Com o objetivo de tornar os dados adequados à aplicação de modelos de regressão logística, foi realizado um processo de codificação das variáveis categóricas e padronização das variáveis numéricas. As variáveis categóricas consideradas no estudo incluem: o nível educacional (Graduate / Not Graduate) e a condição de trabalho autônomo (Yes/No). Essas variáveis foram tratadas por meio de one-hot encoding, convertendo cada categoria em variáveis indicadoras binárias. Para evitar problemas de multicolinearidade perfeita, uma categoria de referência foi removida em cada conjunto de dummies.

As variáveis numéricas foram padronizadas utilizando o método standard. Essa etapa garante que todas as variáveis estejam na mesma escala, facilitando a convergência dos algoritmos de estimação e permitindo uma interpretação mais comparável dos coeficientes estimados.

Ressalta-se que a padronização não altera a informação contida nos dados, mas apenas sua escala, sendo especialmente relevante em modelos que utilizam métodos de otimização numérica e em abordagens bayesianas, nas quais a escolha de distribuições a priori é sensível à magnitude dos parâmetros.

4.2.5 [REVISÃO] Separação treino/teste

O conjunto de dados foi dividido aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação à variável resposta (`loan_status`). Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.3 [WIP] Modelagem e Avaliação

4.3.1 [WIP] Modelo Frequentista

Call:

```
glm(formula = loan_status ~ ., family = binomial(link = "logit"),
     data = treino)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
(Intercept)	-1.82901	0.13732	-13.319	< 2e-16	***
no_of_dependents	0.07698	0.06896	1.116	0.264	
income_annum	1.72713	0.29252	5.904	3.54e-09	***
loan_amount	-1.44130	0.19212	-7.502	6.27e-14	***
loan_term	0.89979	0.07540	11.934	< 2e-16	***
cibil_score	-4.27739	0.16860	-25.369	< 2e-16	***

Tabela 5: Estimativas do modelo de regressão logística: coeficientes, odds ratios e intervalos de confiança de 95%.

Tabela 6: Estimativas do modelo de regressão logística.

Variável	Beta	StdErr	z	p-valor	OR	IC 95% -	IC 95% +
(Intercept)	-1.83	0.14	-13.32	0.00	0.16	0.12	0.21
no_of_dependents	0.08	0.07	1.12	0.26	1.08	0.94	1.24
income_annum	1.73	0.29	5.90	0.00	5.62	3.18	10.03
loan_amount	-1.44	0.19	-7.50	0.00	0.24	0.16	0.34
loan_term	0.90	0.07	11.93	0.00	2.46	2.13	2.86
cibil_score	-4.28	0.17	-25.37	0.00	0.01	0.01	0.02
residential_assets_value	-0.01	0.09	-0.14	0.89	0.99	0.83	1.18
commercial_assets_value	-0.04	0.09	-0.48	0.63	0.96	0.81	1.14
luxury_assets_value	-0.19	0.18	-1.02	0.31	0.83	0.58	1.19
bank_asset_value	-0.19	0.13	-1.47	0.14	0.83	0.65	1.06
'education_Not Graduate'	0.06	0.14	0.47	0.64	1.07	0.81	1.40
self_employed_Yes	-0.09	0.14	-0.68	0.50	0.91	0.70	1.19

```

residential_assets_value -0.01233    0.09019   -0.137    0.891
commercial_assets_value -0.04204    0.08831   -0.476    0.634
luxury_assets_value     -0.18698    0.18309   -1.021    0.307
bank_asset_value        -0.18645    0.12697   -1.468    0.142
`education_Not Graduate` 0.06477    0.13790    0.470    0.639
self_employed_Yes       -0.09346    0.13788   -0.678    0.498

```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

```

Null deviance: 4185.9  on 3180  degrees of freedom
Residual deviance: 1384.1  on 3169  degrees of freedom
AIC: 1408.1

```

Number of Fisher Scoring iterations: 7

4.3.1.1 Avaliação do ajuste e propriedades estatísticas do modelo

O modelo de regressão logística foi estimado por máxima verossimilhança, tendo como variável resposta o status do empréstimo e como variáveis explicativas os atributos socioeconômicos e financeiros do solicitante. A Tabela 5 apresenta as estimativas dos coeficientes, erros-padrão, estatísticas z e respectivos valores-p.

O modelo apresentou redução substancial da deviance, passando de 4185.9 no modelo nulo para 1384.1 no modelo ajustado, com critério de informação de Akaike (AIC) igual a 1408.1, indicando que a inclusão das variáveis explicativas contribui significativamente para a explicação da variável resposta. Adicionalmente, foi calculado o Critério de Informação Bayesiano (BIC), cujo valor foi de 1480.9.

O BIC impõe uma penalização mais severa à complexidade do modelo do que o AIC, sendo particularmente informativo em amostras de maior dimensão. O valor obtido sugere que a especificação adotada mantém um equilíbrio adequado entre qualidade de ajuste e parcimônia, reforçando a robustez do modelo sob um critério mais conservador.

Entre as variáveis analisadas, `income_annum`, `loan_amount`, `loan_term` e `cibil_score` mostraram-se estatisticamente significativas ao nível de 1%. O coeficiente associado à renda anual (`income_annum`) é positivo, indicando que maiores níveis de renda aumentam a probabilidade de aprovação do empréstimo, mantendo-se as demais variáveis constantes. Em contrapartida, o valor solicitado (`loan_amount`) apresenta coeficiente negativo, sugerindo que empréstimos de maior montante estão associados a uma menor probabilidade de aprovação, refletindo maior percepção de risco por parte da instituição financeira.

O prazo do empréstimo (`loan_term`) possui coeficiente positivo e estatisticamente significativo, indicando que prazos mais longos tendem a aumentar a chance de aprovação, possivelmente por reduzirem o valor das parcelas e, conseqüentemente, o risco de inadimplência. A variável `cibil_score` destaca-se como o preditor mais relevante do modelo, apresentando coeficiente negativo de grande magnitude e elevada significância estatística. Esse resultado sugere forte associação entre o score de crédito e a decisão de concessão, reforçando seu papel central na avaliação de risco.

As demais variáveis, incluindo número de dependentes, valores de ativos (residenciais, comerciais, de luxo e bancários), nível educacional e status de trabalho autônomo, não apresentaram significância estatística aos níveis usuais. Esse resultado sugere que, uma vez controladas as variáveis centrais de renda, score de crédito, valor do empréstimo e

prazo, tais características adicionam informação marginal limitada para a classificação do risco de crédito neste conjunto de dados.

O intercepto negativo e estatisticamente significativo reflete a probabilidade basal de aprovação quando todas as variáveis explicativas estão em seus valores de referência, reforçando a necessidade da presença de características financeiras favoráveis para aumentar a chance de concessão do crédito.

Como as variáveis quantitativas foram padronizadas, os coeficientes estimados e seus respectivos Odds Ratios devem ser interpretados como o efeito associado a um aumento de um desvio padrão na variável explicativa, mantendo-se as demais constantes. Essa transformação permite a comparabilidade direta da magnitude dos efeitos entre variáveis originalmente medidas em escalas distintas. Portanto, um aumento de um desvio padrão na renda anual está associado a um aumento de 5.624 vezes na odds de aprovação do empréstimo, enquanto um aumento de um desvio padrão no valor do empréstimo reduz as odds em 0.237 vezes, e assim por diante para as demais variáveis.

O teste da razão de verossimilhança confirmou que o modelo ajustado apresenta desempenho estatisticamente superior ao modelo sem covariáveis ($\chi^2 = 2801.8$, $df = 11$, $p < 0,001$), evidenciando que o conjunto de variáveis explicativas contribui de forma significativa para a modelagem da probabilidade de aprovação do empréstimo.

4.3.1.2 Desempenho preditivo

4.3.1.2.1 Avaliação do classificador a partir das probabilidades estimadas

A capacidade discriminatória do modelo foi avaliada por meio da Área sob a Curva ROC (AUC), métrica amplamente utilizada em problemas de classificação binária por ser independente da escolha de um limiar de decisão e por avaliar diretamente a qualidade das probabilidades estimadas.

A AUC pode ser interpretada como a probabilidade de que o modelo atribua uma probabilidade maior a uma observação pertencente à classe positiva do que a uma observação da classe negativa, escolhidas aleatoriamente. Valores de AUC próximos de 1 indicam




Figura 7: Curvas ROC para os conjuntos de treino e teste

excelente poder discriminatório, enquanto valores próximos de 0,5 sugerem desempenho equivalente ao acaso.

Os resultados indicam $AUC = 0.97$ no conjunto de treino e $AUC = 0.97$ no conjunto de teste. A proximidade entre esses valores sugere que o modelo apresenta excelente capacidade de discriminação, mantendo desempenho consistente fora da amostra utilizada para estimação dos parâmetros.

Além disso, a ausência de queda relevante da AUC do treino para o teste indica baixo indício de sobreajuste (overfitting), reforçando a robustez do modelo no que diz respeito à ordenação correta das probabilidades preditas. Esse comportamento é particularmente relevante no contexto da análise de risco de crédito, em que a correta hierarquização dos indivíduos segundo o risco é mais importante do que decisões baseadas em um único ponto de corte.

Complementarmente à análise por meio da curva ROC, avaliou-se o desempenho do modelo utilizando a curva Precision–Recall (PR), a qual é particularmente informativa em contextos de classes desbalanceadas ou quando o interesse principal está na qualidade das previsões da classe positiva.




Figura 8: Curvas Precision-Recall para os conjuntos de treino e teste

Enquanto a curva ROC avalia a relação entre sensibilidade e especificidade, a curva Precision-Recall enfatiza o compromisso entre precisão (precision) — a proporção de observações corretamente classificadas como positivas entre todas as classificadas como positivas — e revocação (recall ou sensibilidade) — a proporção de positivos corretamente identificados. Dessa forma, a AUC-PR fornece uma medida mais direta da utilidade prática das probabilidades estimadas quando o custo de falsos positivos é relevante, como no contexto de concessão de crédito.

A área sob a curva Precision-Recall foi calculada separadamente para os conjuntos de treino e teste, resultando em $\text{AUC-PR} = 0.94$ no conjunto de treino e $\text{AUC-PR} = 0.951$ no conjunto de teste. Esses valores elevados indicam que o modelo apresenta alta capacidade de manter níveis simultaneamente elevados de precisão e revocação, mesmo quando se exige maior rigor na identificação da classe positiva.

De forma consistente com os resultados observados na curva ROC, a similaridade entre as AUC-PR dos conjuntos de treino e teste sugere boa capacidade de generalização e estabilidade do modelo fora da amostra de estimação. Ademais, o desempenho superior na métrica Precision-Recall reforça a adequação do modelo para aplicações em risco de

crédito, nas quais decisões baseadas em probabilidades bem calibradas são preferíveis à simples classificação binária.

Setting levels: control = 0, case = 1




Figura 9: Curvas Sensibilidade-Especificidade em função do limiar de decisão

A escolha do limiar de corte da probabilidade foi baseada na análise conjunta da sensibilidade e da especificidade do classificador, como podemos ver na Figura 9. Para isso, foram avaliados os valores dessas métricas ao longo de todo o intervalo de limiares possíveis, construindo-se curvas de sensibilidade e especificidade em função do limiar de decisão.

O ponto de corte ótimo foi definido a partir da maximização do índice de Youden (Youden (1950)), que busca simultaneamente maximizar a taxa de verdadeiros positivos e a taxa de verdadeiros negativos. Esse critério fornece um equilíbrio entre erros de classificação dos dois tipos, evitando a adoção arbitrária do valor padrão de 0,5.

O limiar selecionado (0.275) foi então utilizado para a construção da matriz de confusão e para o cálculo das métricas de desempenho no conjunto de teste.

Tabela 9: Métricas de desempenho do modelo de regressão logística para os conjuntos de treino e teste

Conjunto	Accuracy	Precision	Recall	Specificity	F1	AUC_ROC	AUC_PR
Treino	0.91	0.82	0.97	0.87	0.89	0.97	0.94
Teste	0.92	0.85	0.97	0.88	0.90	0.97	0.95

4.3.1.2.2 Avaliação do desempenho classificatório sob limiar de decisão

Tabela 7: Matriz de confusão do modelo de regressão logística (conjunto de treino)

	0	1
0	1756	35
1	254	1136

Tabela 8: Matriz de confusão do modelo de regressão logística (conjunto de teste)

	0	1
0	555	15
1	75	415

Após a definição do limiar de decisão, as previsões probabilísticas foram convertidas em classes, permitindo a construção das matrizes de confusão para os conjuntos de treino e teste (Tabelas Tabela 7 e Tabela 8).

A partir dessas matrizes, foram calculadas métricas clássicas de desempenho, incluindo acurácia, precisão, sensibilidade, especificidade e F1-score, cujos valores estão sumarizados na (**metrics-freq?**).

Adicionalmente, métricas independentes do limiar de decisão, como AUC-ROC e AUC-PR, foram reportadas para avaliar a qualidade global das probabilidades estimadas.

- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada)

4.3.2 [TBD] Modelo Bayesiano

- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada) ->avaliação do impacto

4.4 [TBD] Desempenho Preditivo

- Tabela comparativa
- Curvas ROC
- Métricas

4.5 [TBD] Interpretação dos Modelos

- Coeficientes frequentistas
- Distribuições posteriores bayesianas
- Comparação de incerteza

5 [TBD] Discussão

- Diferenças conceituais observadas
- Robustez dos resultados
- Interpretabilidade
- Incerteza
- Aplicabilidade prática

6 [TBD] Conclusão

- Síntese dos resultados
- Quando usar frequentista vs bayesiano
- Limitações

Breve explicação do problema, com principais resultados e propostas futuras

Referências

GREWAL, Rohit. **Loan Approval Dataset**. Disponível em: <<https://www.kaggle.com/datasets/rohitgrewal/loan-approval-dataset>>. Acesso em: 11 mar. 2026.

TUKEY, John W. **Exploratory Data Analysis**. Reading, MA: Addison-Wesley, 1977.

YOUDEM, W. J. [Index for Rating Diagnostic Tests](#). **Cancer**, v. 3, n. 1, p. 32–35, 1950.