



UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

**Uma Análise Comparativa entre Inferência
Frequentista e Bayesiana em Modelos de Regressão
Binária Aplicada a Risco de Crédito**

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Ago/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Binária Aplicada a Risco de Crédito

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Ago/2026

RESUMO

reavaliar os resumos, quando o trabalho estiver concluído

Este trabalho tem como objetivo comparar as abordagens de inferência frequentista e bayesiana no contexto de modelos de classificação. O foco principal do estudo está na análise das diferenças conceituais, inferenciais e preditivas entre essas duas abordagens estatísticas, utilizando um conjunto de dados reais como estudo de caso para a aplicação dos modelos.

Inicialmente, são discutidos os fundamentos teóricos das abordagens frequentista e bayesiana, destacando suas principais características, pressupostos e formas de interpretação dos parâmetros. Em seguida, realiza-se uma análise exploratória dos dados com o objetivo de compreender a estrutura das variáveis e subsidiar a construção dos modelos, sem que a análise dos dados constitua o foco central do trabalho.

Na etapa de modelagem, são ajustados modelos de classificação sob as perspectivas frequentista e bayesiana, permitindo a comparação entre as abordagens quanto ao desempenho preditivo, à interpretação dos coeficientes estimados e à quantificação da incerteza associada às estimativas. A avaliação dos modelos é realizada por meio de métricas adequadas de classificação, possibilitando uma análise sistemática das diferenças e semelhanças entre os métodos.

Por fim, os resultados obtidos evidenciam as vantagens e limitações de cada abordagem no contexto de problemas de classificação binária, contribuindo para uma compreensão mais aprofundada das implicações práticas e metodológicas da escolha entre inferência frequentista e bayesiana em aplicações de análise de risco de crédito e ciência de dados.

Palavras-chave: regressão estatística; inferência frequentista; inferência bayesiana; modelos preditivos; análise de risco de crédito.

ABSTRACT

This study aims to compare frequentist and Bayesian inference approaches in the context of regression models applied to the prediction of loan approval decisions.

Keywords: frequentist inference; Bayesian inference; regression models; predictive modeling; credit risk analysis.

Índice

1	[TBD] Introdução	6
2	[TO DO] Referencial Teórico	6
2.1	[TO DO] Fundamentos de Probabilidade e Inferência Estatística	7
2.1.1	[TO DO] Variáveis Aleatórias e Distribuições de Probabilidade	7
2.1.2	[TO DO] Inferência Estatística	7
2.1.3	[TO DO] Interpretações da probabilidade	8
2.1.4	[TO DO] Teorema de Bayes	9
2.2	[TO DO] Problemas de Classificação em Aprendizado Estatístico	9
2.2.1	[TO DO] Classificação binária e probabilística	9
2.2.2	[TO DO] Função de perda e decisão	9
2.3	[TO DO] Avaliação de Modelos de Classificação	9
2.4	[TO DO] Regressão Logística Frequentista	10
2.4.1	[TO DO] Formulação do modelo	10
2.4.2	[TO DO] Interpretação dos coeficientes	10
2.4.3	[TO DO] Diagnóstico e qualidade do ajuste	10
2.4.4	[TO DO]	11
2.5	[TO DO] Inferência Bayesiana	11
2.5.1	[TO DO] Priori	11
2.5.2	[TO DO] Posteriori	11
2.5.3	[TO DO] Atualização bayesiana e incerteza	11
2.6	[TO DO] Regressão Logística Bayesiana	11
2.6.1	[TO DO] Formulação do modelo	11
2.7	[TO DO] Aplicações em Risco de Crédito e Finanças/Saude	12
3	[WIP] Metodologia	12
3.1	[REVISÃO-1] Descrição dos Dados	12
3.1.1	Descrição: Loan Approval Dataset	12
3.1.2	Descrição: Dataset de Inadimplência de Cartões de Crédito	13
3.2	[TBD] Análise Exploratória	15
3.3	[REVISÃO-1] Pré-processamento	15

3.3.1	[REVISÃO-1] Estrutura de dados e tratamento de valores ausentes	15
3.3.2	[REVISÃO-1] Outliers	16
3.3.3	[REVISÃO-1] Correlação	17
3.3.4	[REVISÃO-1] Codificação de variáveis categóricas	17
3.3.5	[REVISÃO-1] Padronização de variáveis numéricas	18
3.3.6	[REVISÃO-1] Divisão entre treino e teste	18
3.4	[TO DO] Modelos Avaliados	19
3.4.1	[TBD] Regressão logística frequentista	19
3.4.2	[TBD] Regressão logística bayesiana	19
3.4.3	[TO DO] Métricas de avaliação	19
4	[WIP] Resultados	20
4.1	[REVISÃO-1] Análise Exploratória	20
4.1.1	Dataset de empréstimos	20
4.1.2	Dataset de Inadimplência	28
4.1.3	[REVISÃO-1] Separação treino/teste	37
4.2	[WIP] Modelagem e Avaliação	37
4.2.1	[REVISÃO-1] Modelo Frequentista	37
4.2.2	[TBD] Modelo Bayesiano	38
5	[TBD] Discussão	38
6	[TBD] Conclusão	38
	Referências	39

Legenda de status do documento

- **[TBD]** → tópico ainda indefinido; estrutura ou escopo em discussão
- **[TO DO]** → tópico planejado, ainda não iniciado
- **[WIP]** → em desenvolvimento
- **[DRAFT]** → versão preliminar do texto
- **[CHECK]** → verificação pendente (conceitos, dados, código ou referências)
- **[REVISÃO]** → versão completa, pronta para avaliação
 - **[REVISÃO-1]** → para uma primeira versão
- **[AJUSTAR]** → ajustes finos de redação, figuras ou formatação (após revisão)
- **[FINAL]** → versão definitiva (após revisão e ajustes finais)

dúvidas, pendências, decisões em aberto comentários editoriais e lembretes

1 [TBD] Introdução

- Contexto de risco de crédito (motivação do trabalho)
- Importância de modelos estatísticos na decisão financeira (com referencias de estudos anteriores)
- Diferença conceitual entre abordagem frequentista e bayesiana
- Motivação do estudo
- Objetivo geral (resumida)
- indicar as técnicas Estatísticas/Computacionais que serão utilizadas para a resolução do problema.
- Estrutura do trabalho (Este trabalho está assim organizado: Na Seção 2 apresentamos.... A Seção 3 trata de...)

2 [TO DO] Referencial Teórico

um dos principais capítulos, já que o foco do trabalho é a comparação entre abordagens.

2.1 [TO DO] Fundamentos de Probabilidade e Inferência Estatística

2.1.1 [TO DO] Variáveis Aleatórias e Distribuições de Probabilidade

A formalização da incerteza em experimentos aleatórios ocorre por meio de variáveis aleatórias, que representam os resultados de um espaço amostral em uma escala numérica. Essa estrutura fundamenta o tratamento quantitativo de dados e a construção de modelos de probabilidade, servindo de base tanto para a inferência frequentista quanto para a abordagem bayesiana.

As variáveis aleatórias são classificadas em discretas ou contínuas, a depender da natureza de seu suporte. As discretas assumem valores em conjuntos finitos ou enumeráveis, como a decisão de aprovação de crédito ou o número de ocorrências de inadimplência. Já as contínuas podem assumir qualquer valor em intervalos reais, como a renda dos proponentes ou o tempo até o default. A incerteza inerente a essas variáveis é formalizada por distribuições de probabilidade: no domínio discreto, pela função de massa de probabilidade e, no contínuo, pela função densidade de probabilidade. Tais funções não apenas sintetizam a natureza probabilística das variáveis, mas viabilizam o cálculo de medidas fundamentais, como esperança, variância e probabilidades condicionais, elementos centrais para a modelagem de risco. A escolha apropriada de distribuições de probabilidade é fundamental para capturar a variabilidade dos dados observados e para a construção de modelos inferenciais capazes de quantificar a incerteza associada às previsões.

2.1.2 [TO DO] Inferência Estatística

A inferência estatística reúne os métodos que permitem extrair conclusões sobre uma população ampla a partir de uma amostra reduzida. Na prática, quando não é viável analisar cada indivíduo ou produto de um grupo inteiro, utilizamos os dados amostrais para realizar estimativas e previsões, fundamentadas em modelos que conectam o que observamos aos parâmetros que desejamos descobrir.

O elemento central desse processo é a aceitação da incerteza. Como os dados estão sujeitos a variações e erros de medição, a inferência utiliza estruturas probabilísticas para descrever o comportamento da população (o conjunto total de elementos) com base na amostra,

que é o subconjunto efetivamente analisado. Como a população é quase sempre muito maior que a amostra, as conclusões obtidas não são certas absolutas, mas sim afirmações probabilísticas. O processo consiste em utilizar uma amostra aleatória para testar o modelo estatístico que representa a população, acompanhando cada conclusão de uma medida que quantifica o seu grau de confiabilidade. Esse caminho envolve escolher um modelo adequado para o fenômeno e deduzir informações sobre seus parâmetros desconhecidos.

2.1.3 [TO DO] Interpretações da probabilidade

A noção de probabilidade ocupa um papel central na inferência estatística, sendo a base para quantificar e interpretar a incerteza. Atualmente, essa análise é conduzida por dois grandes paradigmas, o frequentista e o bayesiano, que se distinguem essencialmente na interpretação do conceito de probabilidade e no tratamento da incerteza dos parâmetros.

Na abordagem frequentista, também chamada de clássica, a probabilidade é entendida a partir da repetição de um experimento sob as mesmas condições. Dentro dessa visão, a probabilidade é vista como uma característica objetiva do processo que gera os dados, e não como algo que depende do observador. Os dados coletados são tratados como realizações aleatórias, enquanto os parâmetros do modelo estatístico que descreve a população são considerados valores fixos, ainda que desconhecidos. Assim, a incorporação de novas observações não altera diretamente o conceito de probabilidade, mas contribui para estimativas mais precisas desses parâmetros por meio de métodos inferenciais.

Já na abordagem bayesiana, a probabilidade assume um papel mais amplo. Ela passa a representar o grau de confiança em uma afirmação, levando em conta as informações disponíveis. Nesse contexto, a probabilidade pode ser atribuída não apenas a eventos observáveis, mas também a hipóteses e parâmetros do modelo. Os parâmetros populacionais desconhecidos são tratados como variáveis aleatórias, cuja incerteza é descrita por distribuições de probabilidade. Além disso, é possível incorporar conhecimento prévio ao processo inferencial por meio de distribuições a priori. À medida que novos dados são observados, esse conhecimento é atualizado de forma sistemática pelo teorema de Bayes, resultando em uma distribuição a posteriori que reflete tanto as informações anteriores quanto a evidência empírica fornecida pelos dados.

- Probabilidade frequentista Definição como limite de frequências relativas Parâmetros como valores fixos desconhecidos Dados como realizadores aleatórios
- Probabilidade como grau de crença (bayesiana) Probabilidade como medida de incerteza subjetiva/coerente Parâmetros como variáveis aleatórias

2.1.4 [TO DO] Teorema de Bayes

Teorema como mecanismo de atualização de crenças Relação entre: priori verossimilhança posteriori Interpretação inferencial, não só matemática

2.2 [TO DO] Problemas de Classificação em Aprendizado Estatístico

2.2.1 [TO DO] Classificação binária e probabilística

2.2.2 [TO DO] Função de perda e decisão

- Separabilidade linear e não linear ### [TO DO] Overfitting e generalização e Trade off viés-variância (preparando terreno para problemas de crédito, onde a separação perfeita é improvável e o trade-off entre viés e variância é crucial) ### [TO DO] Probabilidades preditas vs. classes previstas e Threshold de decisão e custo de erro

2.3 [TO DO] Avaliação de Modelos de Classificação

- Desbalanceamento de classes (muito comum em dados de crédito, mas não no dataset atual) ### [TO DO] Matriz de confusão
- Accuracy, Precision, Recall, F1-score
- Custo assimétrico de erros (FP vs FN) ### [TO DO] Curvas
- Curvas Precision–Recall
- Curva ROC e AUC
- Trade-off entre sensibilidade e especificidade

2.4 [TO DO] Regressão Logística Frequentista

2.4.1 [TO DO] Formulação do modelo

- Assumptions do modelo (e.g., independência, linearidade no logit, ausência de multicolinearidade)
- Parametrização e interpretação
- Interpretação dos coeficientes
- Função logística ### [TO DO] Estimação por máxima verossimilhança (e a função de verossimilhança) A função de verossimilhança é comum na abordagem frequentista e Bayesiana
- Testes de hipótese
- Intervalos de confiança
- Limitações da abordagem frequentista

2.4.2 [TO DO] Interpretação dos coeficientes

- Odds e odds ratio

2.4.3 [TO DO] Diagnóstico e qualidade do ajuste

- Análise de Resíduos
- Análise de Multicolinearidade
- Fisher Scoring

2.4.4 [TO DO]

2.5 [TO DO] Inferência Bayesiana

2.5.1 [TO DO] Priori

2.5.2 [TO DO] Posteriori

2.5.3 [TO DO] Atualização bayesiana e incerteza

- Teorema de Bayes aplicado à estatística
- diferenças conceituais
- parametros como variáveis aleatórias
- Priors, likelihood e posterior
- Incerteza e distribuição posterior
- Vantagens da abordagem bayesiana
- Atualização sequencial da evidência
- Interpretação probabilística
- controle de sobreajuste (...)

2.6 [TO DO] Regressão Logística Bayesiana

(sempre traçando paralelos com a versão frequentista, principalmente os tópicos)

2.6.1 [TO DO] Formulação do modelo

- Formulação do modelo probabilístico ### [TO DO] Escolha de priors ### [TO DO] Inferência
- via MCMC ### [TO DO] Diagnóstico de convergência
- (R-hat, traceplots)
- Intervalos de credibilidade
- Sensibilidade a priors
- Robustez em pequenas amostras
- Interpretação dos coeficientes sob posterior

- Comparação direta de MLE- maximum likelihood estimation e MAP- Maximum-a-Posteriori

(...)

2.7 [TO DO] Aplicações em Risco de Crédito e Finanças/Saude

Não estender muito, acho que 1 página já deve ser suficiente

(Contextualização)

- Modelos de scoring de crédito
- Variáveis financeiras e risco
- Decisão de concessão de empréstimos
- Uso das probabilidades preditas para gestão de risco
- Transparência e interpretabilidade
- Em problemas de concessão de empréstimos, a incerteza é tão importante quanto a previsão.
- O enfoque bayesiano permite incorporar conhecimento prévio do risco.
- O enfoque frequentista fornece base tradicional de modelos de scoring.
- A comparação entre ambas abordagens permite avaliar robustez das decisões.

3 [WIP] Metodologia

3.1 [REVISÃO-1] Descrição dos Dados

3.1.1 Descrição: Loan Approval Dataset

Os modelos desenvolvidos neste trabalho utilizam dois conjuntos de dados públicos. O primeiro conjunto de dados é o Loan Approval Dataset, disponibilizado na plataforma Kaggle (Grewal (2026)), que contém informações socioeconômicas e de crédito de clientes

solicitando empréstimos. A variável resposta é binária, indicando se o empréstimo foi aprovado ou rejeitado. A Tabela 1 apresenta uma descrição detalhada de todas as variáveis preditoras incluídas no conjunto de dados.

Tabela 1: Descrição das variáveis do dataset de emprestimos

Feature	Descrição
num_dependentes	Número de dependentes do solicitante
escolaridade	Nível de escolaridade (Graduate / Not Graduate)
autonomo	Autônomo (Yes / No)
renda_anual	Renda anual
valor_emprestimo	Valor do empréstimo
prazo_anos	Prazo em anos
score_credito	Score de crédito
ativos_residenciais	Bens residenciais, em valor monetário
ativos_comerciais	Bens comerciais, em valor monetário
ativos_luxo	Bens de luxo, em valor monetário
ativos_bancarios	Ativos bancários, em valor monetário
status	Variável alvo (Approved = 1/Rejected = 0)

Por se tratar de um dataset estruturado especificamente para fins de aprendizado de máquina e análise estatística, ele oferece um cenário controlado, permitindo focar na sensibilidade dos modelos aos preditores e na quantificação da incerteza sem as inconsistências típicas de bases de dados administrativas brutas.

3.1.2 Descrição: Dataset de Inadimplência de Cartões de Crédito

Como segundo conjunto de dados, este trabalho também utiliza o `Default of Credit Card Clients Dataset`, originalmente disponibilizado por Yeh e Lien (Yeh; Lien (2009)) e atualmente mantido no UCI Machine Learning Repository (Lichman (2013)). O conjunto reúne informações de clientes de cartão de crédito em Taiwan, abrangendo o período de abril a setembro de 2005, incluindo variáveis demográficas, dados financeiros, histórico de pagamentos e valores de fatura. A variável alvo é binária, denotada por `PD30` (Probability

of Default in 30 days), a qual indica a ocorrência de inadimplência no horizonte de 30 dias — operacionalmente definida, neste conjunto de dados, como a inadimplência observada no mês subsequente. Assim, embora PD30 seja um conceito probabilístico no contexto de risco de crédito, neste estudo ela é observada como uma variável indicadora, assumindo valor 1 quando ocorre inadimplência e 0 caso contrário.

A inclusão deste segundo conjunto de dados tem dois objetivos principais: (i) avaliar a capacidade de generalização dos modelos desenvolvidos em um domínio distinto de crédito, e (ii) comparar o desempenho preditivo e a interpretabilidade de diferentes abordagens de modelagem e estratégias de seleção de variáveis. A Tabela 2 apresenta uma descrição detalhada das variáveis presentes neste conjunto de dados, incluindo informações demográficas, financeiras e comportamentais dos clientes.

Tabela 2: Descrição das variáveis do dataset de inadimplência

Feature	Descrição
<code>id_cliente</code>	Identificador único de cada cliente
<code>limite_credito</code>	Limite de crédito concedido ao cliente (inclui crédito individual e suplementar)
<code>sexo</code>	Sexo do cliente (1 = masculino, 2 = feminino)
<code>escolaridade</code>	Nível de escolaridade (1 = pós-graduação, 2 = universidade, 3 = ensino médio, 4 = outros)
<code>estado_civil</code>	Estado civil (1 = casado, 2 = solteiro, 3 = outros)
<code>idade</code>	Idade do cliente, em anos
<code>atraso_pagto_0</code>	Status de atraso no pagamento no mês 09/2005
<code>atraso_pagto_2</code>	Status de atraso no pagamento no mês 08/2005
<code>atraso_pagto_3</code>	Status de atraso no pagamento no mês 07/2005
<code>atraso_pagto_4</code>	Status de atraso no pagamento no mês 06/2005
<code>atraso_pagto_5</code>	Status de atraso no pagamento no mês 05/2005
<code>atraso_pagto_6</code>	Status de atraso no pagamento no mês 04/2005
<code>fatura_valor_1</code>	Valor da fatura no mês 09/2005 (NT dollar)
<code>fatura_valor_2</code>	Valor da fatura no mês 08/2005 (NT dollar)
<code>fatura_valor_3</code>	Valor da fatura no mês 07/2005 (NT dollar)
<code>fatura_valor_4</code>	Valor da fatura no mês 06/2005 (NT dollar)

Feature	Descrição
fatura_valor_5	Valor da fatura no mês 05/2005 (NT dollar)
fatura_valor_6	Valor da fatura no mês 04/2005 (NT dollar)
pagto_valor_1	Valor pago no mês 09/2005 (NT dollar)
pagto_valor_2	Valor pago no mês 08/2005 (NT dollar)
pagto_valor_3	Valor pago no mês 07/2005 (NT dollar)
pagto_valor_4	Valor pago no mês 06/2005 (NT dollar)
pagto_valor_5	Valor pago no mês 05/2005 (NT dollar)
pagto_valor_6	Valor pago no mês 04/2005 (NT dollar)
PD30	Indicador binário de inadimplência no mês seguinte (1 = sim, 0 = não)

3.2 [TBD] Análise Exploratória

Apenas se tivermos tempo

3.3 [REVISÃO-1] Pré-processamento

3.3.1 [REVISÃO-1] Estrutura de dados e tratamento de valores ausentes

Inicialmente, foi realizada a inspeção da estrutura do banco de dados, com o objetivo de confirmar a consistência dos tipos das variáveis e a adequação do formato dos dados às técnicas de modelagem adotadas. Essa análise compreendeu a identificação das classes das variáveis, a distinção entre atributos numéricos e categóricos e a validação da variável resposta quanto à sua natureza e domínio.

Por fim, a presença de valores ausentes foi avaliada por meio da função `is.na()`, com sumarização via `colSums(is.na())`. Não foram identificadas observações faltantes no conjunto de dados, eliminando a necessidade de técnicas de imputação e evitando a introdução de incerteza adicional ou viés sistemático no processo de estimação.

3.3.2 [REVISÃO-1] Outliers

A identificação de valores atípicos (*outliers*) nas variáveis numéricas foi realizada por meio do critério do intervalo interquartil (*Interquartile Range*, IQR), amplamente utilizado em estatística descritiva por sua robustez em relação a distribuições assimétricas e à presença de valores extremos.

Para cada variável contínua, o primeiro quartil Q_1 e o terceiro quartil Q_3 foram calculados. Definindo o intervalo interquartil como

$$\text{IQR} = Q_3 - Q_1 \quad (1)$$

Os limites inferior e superior para identificação de outliers são definidos como

$$L = Q_1 - 1.5 \cdot \text{IQR} \quad (2)$$

$$U = Q_3 + 1.5 \cdot \text{IQR} \quad (3)$$

Esse procedimento foi empregado exclusivamente com finalidade exploratória, visando caracterizar a distribuição das variáveis e avaliar a presença de valores extremos potencialmente influentes. Não foi realizada a exclusão automática de observações, de modo a preservar a integridade do conjunto de dados e permitir que os modelos estatísticos capturassem adequadamente a heterogeneidade inerente aos dados financeiros.

O fator 1.5 no critério do IQR foi proposto por Tukey (1977) como um compromisso empírico entre robustez e sensibilidade, sendo amplamente adotado por sua boa performance em distribuições assimétricas e com caudas longas, como é típico em dados financeiros.

No contexto de análise de risco de crédito, a presença de valores extremos pode refletir perfis legítimos de alto patrimônio ou elevado risco, sendo crucial que os modelos estatísticos sejam capazes de acomodar essa variabilidade sem que a remoção indiscriminada de outliers elimine informação relevante para a tarefa de classificação.

3.3.3 [REVISÃO-1] Correlação

A análise de correlação entre as variáveis numéricas foi conduzida com o objetivo de investigar associações lineares e identificar potenciais indícios de multicolinearidade entre os preditores candidatos ao modelo de regressão logística. As correlações foram estimadas por meio do coeficiente de correlação de Pearson, apropriado para avaliar associações lineares entre variáveis contínuas. O cálculo foi realizado utilizando observações completas.

Os resultados foram sintetizados em uma matriz de correlação, posteriormente representada graficamente por meio de um mapa de calor (*heatmap*), no qual a intensidade e o sinal das correlações são indicados por uma escala de cores contínua. Essa etapa teve caráter exploratório e diagnóstico, servindo como subsídio para a avaliação de possíveis problemas de multicolinearidade na etapa de modelagem, especialmente no que se refere à estabilidade e interpretação dos coeficientes da regressão logística.

3.3.4 [REVISÃO-1] Codificação de variáveis categóricas

Para possibilitar a inclusão de variáveis qualitativas nos modelos de regressão, foi aplicada a transformação dessas variáveis em variáveis indicadoras (binárias). Nesse procedimento, cada categoria de uma variável nominal é representada por uma coluna específica, assumindo valor 1 quando a categoria está presente na observação e 0 caso contrário.

(EDITAR DEPOIS) Para a implementação, utilizou-se a função `dummy_cols` do pacote `fastDummies`, parametrizada com o argumento `remove_first_dummy = TRUE`. Esta etapa é metodologicamente crítica para mitigar a armadilha da variável *dummy* (multicolinearidade perfeita), que ocorre quando as variáveis indicadoras são linearmente dependentes, impossibilitando a estimativa dos parâmetros por métodos de máxima verossimilhança ou por algoritmos de amostragem bayesiana. Com a remoção da primeira categoria, o modelo estabelece uma base de comparação necessária para a interpretação dos coeficientes estimados. Essas variáveis são comumente chamadas de dummies por atuarem como substitutos numéricos simplificados (fictícios) de conceitos abstratos.

3.3.5 [REVISÃO-1] Padronização de variáveis numéricas

Para assegurar a estabilidade numérica dos algoritmos de estimação e permitir a comparabilidade entre os coeficientes do modelo, as variáveis quantitativas foram submetidas ao processo de padronização (*Standardization*). Inicialmente, realizou-se a conversão dos dados para o tipo numérico e, em seguida, aplicou-se a transformação de escala centralizada na média com unidade de desvio padrão. A fórmula utilizada para a padronização de cada variável X é dada por

$$z_i = \frac{x_i - \bar{x}}{S} \quad (4)$$

onde x_i representa o valor original da variável, $\bar{x}$ é a média amostral e S é o desvio padrão amostral. Essa transformação resulta em variáveis com média zero e desvio padrão um. Com todas as variáveis na mesma escala, os coeficientes estimados tornam-se comparáveis entre si, permitindo identificar quais preditores exercem maior impacto relativo sobre a probabilidade de aprovação do empréstimo.

3.3.6 [REVISÃO-1] Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta $Y = \text{status}$. Essa estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1). \quad (5)$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não enviesada do erro de generalização, reduzindo o risco de sobreajuste (*overfitting*) e vazamento de informação.

3.4 [TO DO] Modelos Avaliados

3.4.1 [TBD] Regressão logística frequentista

3.4.2 [TBD] Regressão logística bayesiana

3.4.3 [TO DO] Métricas de avaliação

3.4.3.1 [TO DO] Métricas: Ajuste do modelo

citamos quais vamos usar, deixar a teoria para o referencial teórico

- Deviance
- AIC
- BIC
- Teste da razão de verossimilhança
- Fisher Scoring
- FIV
- Análise de resíduos

3.4.3.2 [TO DO] Métricas: Avaliação preditiva

A avaliação dos modelos de classificação foi realizada por meio de métricas adequadas para problemas de classificação binária, considerando a distribuição das classes e a importância relativa dos erros de classificação. As métricas selecionadas incluem:

- ROC-AUC (Área sob a curva ROC)
- Curva Precision-Recall e AUC-PR
- Curva Sensibilidade (Recall) e Especificidade
- (Índice de Youden)
- Matriz de confusão
- Accuracy, Precision, Recall e F1-score

4 [WIP] Resultados

4.1 [REVISÃO-1] Análise Exploratória

A análise exploratória é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

4.1.1 Dataset de empréstimos

O conjunto de dados é composto por 4269 observações e 13 variáveis, incluindo a variável resposta `status`, que indica se o empréstimo foi aprovado ou rejeitado. As variáveis preditoras incluem informações como renda anual, pontuação de crédito, nível educacional, entre outras características dos solicitantes.

4.1.1.1 [REVISÃO-1] Estatísticas univariadas


A Tabela 3 apresenta as principais estatísticas descritivas das variáveis numéricas do conjunto de dados, incluindo média, mediana, valor mínimo e máximo. Em média, os solicitantes apresentam aproximadamente 2 a 3 dependentes, renda anual em torno de 5 milhões e solicitam empréstimos próximos a 15 milhões. O prazo médio dos empréstimos é de cerca de 11 anos, enquanto o score de crédito médio está próximo de 600 pontos. Esses valores sugerem uma população com perfil financeiro intermediário, mas com ampla variabilidade entre indivíduos, com desvios-padrão elevados.

Tabela 3: Estatísticas descritivas das variáveis numéricas do conjunto de dados.


	mean	median	min	max	std
num_dependentes	2.5	3	0	5	1.7
renda_anual	5.05912e+06	5.1e+06	200000	9.9e+06	2.80684e+06
valor_emprestimo	1.51335e+07	1.45e+07	300000	3.95e+07	9.04336e+06
prazo_anos	10.9	10	2	20	5.71
score_credito	599.94	600	300	900	172.43
ativos_residenciais	7.47262e+06	5.6e+06	-100000	2.91e+07	6.50364e+06

Tabela 3: Estatísticas descritivas das variáveis numéricas do conjunto de dados.


	mean	median	min	max	std
ativos_comerciais	4.97316e+06	3.7e+06	0	1.94e+07	4.38897e+06
ativos_luxo	1.51263e+07	1.46e+07	300000	3.92e+07	9.10375e+06
ativos_bancarios	4.97669e+06	4.6e+06	0	1.47e+07	3.25019e+06




(a) Distribuição da renda anual




(b) Distribuição do valor do empréstimo




(c) Distribuição do prazo




(d) Distribuição do CIBIL score




(e) Distribuição dos ativos residenciais



(f) Distribuição dos ativos comerciais



(g) Distribuição dos bens de luxo



(h) Distribuição dos ativos bancários

Figura 1: Distribuição das principais variáveis numéricas do conjunto de dados

Na Figura 1 são apresentadas as distribuições das variáveis numéricas analisadas. As variáveis (a) Renda Anual, (c) Prazo do Empréstimo e (d) Score exibem distribuições

relativamente homogêneas, sem concentração acentuada em intervalos específicos. Esse padrão sugere que o conjunto de dados contempla uma ampla variedade de perfis de clientes, não havendo predominância excessiva de indivíduos com renda muito elevada ou muito baixa, nem de faixas específicas de score de crédito.

Para a variável Prazo do Empréstimo (c), observa-se a presença de picos discretos ao longo da distribuição, o que é esperado, dado que prazos de empréstimo são usualmente definidos em valores inteiros de anos.

Em contraste, as variáveis (e) Ativos Residenciais, (f) Ativos Comerciais, (g) Bens de Luxo e (h) Ativos Bancários apresentam acentuada assimetria à direita, indicando que a maioria dos indivíduos possui ativos de menor valor, enquanto uma parcela reduzida concentra patrimônios significativamente mais elevados.

podemos tratar com transformações logarítmicas ou Box-Cox, mas deixei quieto por enquanto, usaria apenas na frequentista

A (b) Distribuição do valor do empréstimo se mantém constante até um certo patamar (em torno de 20 milhões) e depois sofre uma queda acentuada. Indicando que o banco tem um limite de crédito comum para a maioria dos clientes, e empréstimos acima desse valor são exceções ou exigem critérios muito mais rígidos, tornando-os menos frequentes.

Outro ponto relevante é a presença de valores negativos em `residential_assets_value`, como podemos ver em Tabela 3, o que pode indicar inconsistências de registro ou tratamentos contábeis específicos no conjunto de dados. Esse tipo de característica pode afetar a modelagem, exigindo atenção em etapas de pré-processamento.

A Tabela 4 apresenta a distribuição das variáveis categóricas do conjunto de dados. Observa-se que as categorias analisadas exibem distribuições globalmente equilibradas, sem predominância acentuada de um único grupo, o que contribui para a estabilidade estatística e reduz potenciais vieses na etapa de modelagem.

Tabela 4: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
num_dependentes	0	712	16.68
num_dependentes	1	697	16.33

Tabela 4: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
num_dependentes	2	708	16.58
num_dependentes	3	727	17.03
num_dependentes	4	752	17.62
num_dependentes	5	673	15.76
escolaridade	Graduate	2144	50.22
escolaridade	Not Graduate	2125	49.78
autonomo	No	2119	49.64
autonomo	Yes	2150	50.36

4.1.1.2 [REVISÃO-1] Análise da variável resposta e relações com as variáveis preditoras

Na Figura 2, observa-se a distribuição da variável resposta **status**, indicando que aproximadamente 62.22% dos empréstimos foram aprovados, enquanto 37.78% foram rejeitados. Essa proporção sugere um desequilíbrio leve na classe alvo.




Figura 2: Distribuição da aprovação de empréstimos

A Figura 3 apresenta a estimativa de densidade para as variáveis numéricas do conjunto de dados, segmentadas pelo status de aprovação do empréstimo (Rejeitado ou Aprovado).

Observa-se que a variável `score_credito` é a que apresenta a separação mais nítida entre as classes: candidatos com scores mais baixos (aproximadamente abaixo de 600) concentram-se majoritariamente no grupo de rejeitados, enquanto scores elevados mostram uma densidade quase exclusiva de aprovações.

No que tange ao prazo do empréstimo (`loan_term`), nota-se uma ligeira predominância de rejeições em prazos muito curtos, enquanto os prazos mais longos apresentam uma distribuição mais equilibrada entre os grupos. Em contraste, o restante das variáveis exibem distribuições sobrepostas e visualmente semelhantes entre as duas classes. Tal sobreposição indica que, isoladamente, essas variáveis possuem menor poder discriminatório, o que exigirá dos modelos de regressão a identificação de correlações mais complexas ou efeitos multivariados para contribuir com a predição.




Figura 3: Distribuição das variáveis numéricas por status de aprovação do empréstimo

A Figura 4 apresenta a distribuição das frequências absolutas para as variáveis categóricas Nível educacional, Trabalho autônomo e Número de dependentes, segmentadas pelo status de aprovação. Observa-se que a proporção entre empréstimos aprovados e rejeitados mantém-se praticamente constante, independentemente de o candidato ser graduado ou

não, ou de possuir trabalho autônomo. No que tange ao número de dependentes, o comportamento é análogo: não há uma categoria específica (de 0 a 5 dependentes) que apresente uma vantagem ou desvantagem desproporcional na aprovação do crédito. Sob a ótica da modelagem estatística, essa independência aparente sugere que tais variáveis podem apresentar coeficientes com menor magnitude ou maior incerteza .




Figura 4: Distribuição das variáveis categóricas segundo o status do empréstimo

4.1.1.3 [REVISÃO-1] Análise de correlação entre variáveis numéricas

A matriz de correlação (Figura 5) revela associações relevantes entre as variáveis numéricas do conjunto de dados. Observa-se forte correlação entre renda anual e valor do empréstimo, bem como entre essas variáveis e os ativos patrimoniais, especialmente ativos de luxo e ativos bancários, indicando que essas medidas capturam aspectos relacionados da condição financeira dos solicitantes. As correlações entre os diferentes tipos de ativos são positivas e moderadas, sugerindo coerência interna do perfil patrimonial, sem redundância perfeita entre as variáveis.

Por outro lado, o prazo do empréstimo apresenta correlação praticamente nula com as demais variáveis, indicando independência em relação ao perfil financeiro. De forma

semelhante, o `score_credito` exibe correlações muito fracas com `renda`, `ativos` e `valor do empréstimo`, sugerindo que essa variável representa uma dimensão distinta de risco de crédito, relevante para a classificação, mas não diretamente associada ao nível de riqueza.

A presença de correlações elevadas entre algumas variáveis explicativas indica potencial multicolinearidade, aspecto que deve ser considerado na etapa de modelagem, especialmente na interpretação dos coeficientes da regressão logística.




Figura 5: Mapa de calor da correlação entre variáveis numéricas

4.1.1.4 [REVISÃO-1] Análise de outliers

A presença de valores atípicos, particularmente em variáveis relacionadas a ativos patrimoniais, é corroborada quantitativamente pela Tabela 5, que apresenta o número e o percentual de observações classificadas como outliers segundo o critério do intervalo interquartil. Esses valores extremos refletem a heterogeneidade típica de dados financeiros e possuem implicações diretas para a modelagem estatística. Enquanto abordagens frequentistas podem demandar procedimentos de tratamento ou estimadores robustos para mitigar a influência desses pontos, modelos bayesianos permitem incorporar explicitamente

essa incerteza por meio de distribuições com caudas mais pesadas, oferecendo maior flexibilidade na avaliação do impacto dos outliers sobre os parâmetros estimados.

Tabela 5: Número e percentual de outliers identificados pelo critério do IQR

Feature	Outliers	Percentual
ativos_bancarios	5	0.0011712
ativos_comerciais	37	0.0086671
ativos_luxo	0	0.0000000
ativos_residenciais	52	0.0121808
prazo_anos	0	0.0000000
renda_anual	0	0.0000000
score_credito	0	0.0000000
valor_emprestimo	0	0.0000000

4.1.1.5 [REVISÃO-1] Pré processamento

4.1.1.5.1 [REVISÃO-1] Verificação de valores ausentes e observações duplicadas

Inicialmente, foi realizada a verificação da presença de valores ausentes e observações duplicadas no conjunto de dados. Não foram identificados valores faltantes em nenhuma das variáveis, o que dispensou a aplicação de técnicas de imputação e evitou a introdução de incerteza adicional ou viés sistemático no processo de modelagem. Adicionalmente, não foram detectadas observações duplicadas, assegurando que cada registro corresponda a uma unidade amostral distinta e contribuindo para a validade das estimativas inferenciais.

4.1.1.6 [REVISÃO-1] Tratamento de inconsistências e outliers

Observa-se que aproximadamente 0.01% dos solicitantes apresentam valores negativos para ativos residenciais, correspondendo a um contingente residual de observações atípicas. Esses valores não possuem interpretação econômica direta no contexto da variável analisada e podem estar associados a inconsistências de registro ou a particularidades não representativas do perfil financeiro da amostra. Considerando o caráter marginal dessas observações e seu potencial de introduzir ruído na estimação dos parâmetros, optou-se

por removê-las do conjunto de dados, sem prejuízo à representatividade da amostra ou à validade inferencial dos modelos ajustados. A exclusão resultou na remoção de 28 observações.

Não foi aplicado tratamento automático de outliers, uma vez que valores extremos são esperados em dados financeiros e podem conter informação relevante para a classificação do risco de crédito.

4.1.1.7 [REVISÃO-1] Seleção de variáveis e análise de correlação

A Figura 5 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas. Observou-se a presença de correlações elevadas entre variáveis associadas à escala de renda e patrimônio, como renda anual, valor do empréstimo e ativos financeiros, comportamento esperado em bases de dados financeiras.

Apesar dessas correlações, optou-se por não remover variáveis nesta etapa, mantendo todas as variáveis numéricas disponíveis para a modelagem. Essa decisão foi motivada pelo interesse em avaliar o impacto de cada variável no modelo de regressão logística.

4.1.2 Dataset de Inadimplência

O conjunto de dados de inadimplência é composto por 30000 observações e 25 variáveis, incluindo a variável resposta PD30, que indica se As variáveis preditoras incluem informações como renda anual, pontuação de crédito, nível educacional, entre outras características dos solicitantes.

4.1.2.1 [WIP] Estatísticas univariadas

A Tabela 6 evidencia uma população heterogênea de clientes de cartão de crédito, com ampla variabilidade tanto nas características demográficas quanto nas variáveis financeiras, o que também pode ser visto no dataset de empreitimos. O limite médio de crédito é de aproximadamente NT\$ 167 mil, com mediana inferior (NT\$ 140 mil), indicando assimetria à direita e a presença de clientes com limites substancialmente mais elevados, o que é reforçado pelo alto desvio padrão. A idade média dos clientes é de cerca de 35 anos, com concentração em adultos jovens e de meia-idade. As variáveis categóricas

codificadas numericamente, como sexo, escolaridade e estado civil, apresentam baixa variabilidade relativa, refletindo uma distribuição razoavelmente equilibrada entre suas categorias principais.

No que diz respeito ao comportamento de pagamento, as variáveis de atraso (`atraso_pagto_0` a `atraso_pagto_6`) apresentam médias próximas de zero e medianas iguais a zero, sugerindo que a maioria dos clientes não apresenta atraso significativo nos pagamentos, embora existam casos extremos de inadimplência prolongada (até oito meses). Os valores de fatura e de pagamento exibem grande dispersão (que pode ser vista na Figura 6), com médias substancialmente superiores às medianas, o que indica distribuições fortemente assimétricas e a presença de outliers. Ademais, a ocorrência de valores negativos nas faturas é consistente com ajustes, estornos ou créditos no sistema de faturamento. Em conjunto, esses resultados reforçam a complexidade do perfil financeiro dos clientes e justificam o uso de técnicas de modelagem robustas à assimetria, à presença de valores extremos e à heterogeneidade dos dados monetários expressos em dólares taiwaneses (NT\$).

Tabela 6: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
<code>limite_credito</code>	167484	140000	10000	1e+06	129748
<code>sexo</code>	1.6	2	1	2	0.49
<code>escolaridade</code>	1.85	2	0	6	0.79
<code>estado_civil</code>	1.55	2	0	3	0.52
<code>idade</code>	35.49	34	21	79	9.22
<code>atraso_pagto_0</code>	-0.02	0	-2	8	1.12
<code>atraso_pagto_2</code>	-0.13	0	-2	8	1.2
<code>atraso_pagto_3</code>	-0.17	0	-2	8	1.2
<code>atraso_pagto_4</code>	-0.22	0	-2	8	1.17
<code>atraso_pagto_5</code>	-0.27	0	-2	8	1.13
<code>atraso_pagto_6</code>	-0.29	0	-2	8	1.15
<code>fatura_valor_1</code>	51223.3	22381.5	-165580	964511	73635.9
<code>fatura_valor_2</code>	49179.1	21200	-69777	983931	71173.8
<code>fatura_valor_3</code>	47013.2	20088.5	-157264	1.66409e+06	69349.4

Tabela 6: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
fatura_valor_4	43262.9	19052	-170000	891586	64332.9
fatura_valor_5	40311.4	18104.5	-81334	927171	60797.2
fatura_valor_6	38871.8	17071	-339603	961664	59554.1
pagto_valor_1	5663.58	2100	0	873552	16563.3
pagto_valor_2	5921.16	2009	0	1.68426e+06	23040.9
pagto_valor_3	5225.68	1800	0	896040	17607
pagto_valor_4	4826.08	1500	0	621000	15666.2
pagto_valor_5	4799.39	1500	0	426529	15278.3
pagto_valor_6	5215.5	1500	0	528666	17777.5

[	categoria	n	percentual (%)	variavel
0	2	18112	60.37	sexo
1	1	11888	39.63	sexo, categoria
0	2	14030	46.77	escolaridade
1	1	10585	35.28	escolaridade
2	3	4917	16.39	escolaridade
3	5	280	0.93	escolaridade
4	4	123	0.41	escolaridade
5	6	51	0.17	escolaridade
6	0	14	0.05	escolaridade, categoria
0	2	15964	53.21	estado_civil
1	1	13659	45.53	estado_civil
2	3	323	1.08	estado_civil
3	0	54	0.18	estado_civil]




Figura 6: Distribuição das principais variáveis numéricas do conjunto de dados

Tabela 7: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
sexo	1	11888	39.63
sexo	2	18112	60.37
escolaridade	0	14	0.05
escolaridade	1	10585	35.28
escolaridade	2	14030	46.77
escolaridade	3	4917	16.39
escolaridade	4	123	0.41
escolaridade	5	280	0.93
escolaridade	6	51	0.17
estado_civil	0	54	0.18
estado_civil	1	13659	45.53
estado_civil	2	15964	53.21
estado_civil	3	323	1.08

As variáveis categóricas do conjunto de dados descrevem características demográficas relevantes dos clientes de cartão de crédito, em particular sexo, escolaridade e estado civil, e apresentam distribuições assimétricas entre suas categorias.

Em relação ao sexo, codificado como 1 para homens e 2 para mulheres, observa-se predominância de clientes do sexo feminino. Essa assimetria sugere uma maior participação de mulheres na base analisada, o que pode refletir tanto características da população atendida pela instituição financeira quanto critérios históricos de concessão de crédito.

A variável estado civil apresenta maior concentração nas categorias “solteiro” (código 2), com aproximadamente 53,2% dos registros, e “casado” (código 1), com cerca de 45,5%. A categoria “outros” (código 3) representa pouco mais de 1% da amostra, enquanto valores codificados como 0 são residuais, indicando possíveis inconsistências ou registros atípicos. Essa distribuição sugere que a maioria dos clientes pertence a estruturas familiares tradicionais, o que pode ter implicações no perfil de risco e na capacidade de pagamento.

Quanto à escolaridade, a maior parte dos clientes possui nível universitário (código 2) ou

pós-graduação (código 1), seguidos por ensino médio (código 3). As categorias “outros” e “desconhecido” (códigos 4, 5 e 6) são pouco representativas, indicando que a informação de escolaridade é, em geral, bem registrada. A concentração em níveis educacionais mais elevados pode estar associada a maior estabilidade de renda e, potencialmente, a menores níveis de inadimplência, embora essa relação deva ser avaliada empiricamente no processo de modelagem.

4.1.2.2 [WIP] Avaliação da variável resposta




Figura 7: Distribuição da Inadimplência

Na Figura 7, observa-se a distribuição da variável resposta PD30, indicando que aproximadamente 22.12% dos clientes apresentam inadimplência no mês subsequente, enquanto os demais 77.88% correspondem à classe de adimplentes. Esse desbalanceamento de classes é característico de problemas de risco de crédito e deve ser considerado na etapa de modelagem, uma vez que pode influenciar métricas de desempenho e a calibração das probabilidades previstas pelos modelos.

Esse cenário é típico de problemas de credit scoring e caracteriza um contexto de **imbalanced learning**, no qual a classe minoritária (inadimplência) é justamente a de maior interesse analítico.

Nesse tipo de distribuição, métricas globais como acurácia podem ser enganosas, pois modelos que privilegiam a classe majoritária tendem a apresentar desempenho aparentemente

elevado mesmo sem capacidade discriminativa adequada para a classe de interesse. Por essa razão, métricas baseadas em discriminação e equilíbrio entre classes tornam-se mais informativas.

4.1.2.3 [WIP] Análise de correlação entre variáveis numéricas




Figura 8: Mapa de calor da correlação entre variáveis numéricas do conjunto de dados de crédito

A Figura 8 evidencia padrões estruturais importantes entre as variáveis numéricas do conjunto de dados. Observa-se uma forte correlação positiva entre os valores de fatura ao longo dos meses (por exemplo, entre `fatura_valor_1` e `fatura_valor_2`, com correlação próxima de 0,95), indicando alta persistência temporal do saldo devedor dos clientes. Esse comportamento é esperado em dados de crédito, onde o saldo de fatura tende a evoluir de forma gradual ao longo do tempo.

De forma semelhante, as variáveis de atraso de pagamento (`atraso_pago_*`) apresentam correlações moderadas a altas entre si (chegando a valores acima de 0,8), sugerindo forte dependência temporal e possível redundância informacional. Esse padrão é relevante do ponto de vista de modelagem, pois indica potencial multicolinearidade entre variáveis

de comportamento de pagamento, o que pode afetar estimativas em modelos lineares tradicionais e justificar o uso de abordagens regularizadas ou bayesianas mais robustas.

Por outro lado, variáveis como idade e limite de crédito apresentam correlações fracas com a maioria das demais variáveis, sugerindo que carregam informação relativamente independente dentro do conjunto de dados. Já os valores de pagamento (`pagto_valor_*`) mostram correlações baixas entre si e com outras variáveis, indicando maior variabilidade e menor estrutura temporal consistente quando comparados aos saldos de fatura e atrasos de pagamento.

4.1.2.4 [WIP] Análise de outliers

Tabela 8: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
atraso_pagto_0	3130	0.1043333
atraso_pagto_2	4410	0.1470000
atraso_pagto_3	4209	0.1403000
atraso_pagto_4	3508	0.1169333
atraso_pagto_5	2968	0.0989333
atraso_pagto_6	3079	0.1026333
fatura_valor_1	2400	0.0800000
fatura_valor_2	2395	0.0798333
fatura_valor_3	2469	0.0823000
fatura_valor_4	2622	0.0874000
fatura_valor_5	2725	0.0908333
fatura_valor_6	2693	0.0897667
idade	272	0.0090667
limite_credito	167	0.0055667
pagto_valor_1	2745	0.0915000
pagto_valor_2	2714	0.0904667
pagto_valor_3	2598	0.0866000
pagto_valor_4	2994	0.0998000

Tabela 8: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
pagto_valor_5	2945	0.0981667
pagto_valor_6	2958	0.0986000

Os resultados da detecção de outliers (Tabela 8) pelo critério do IQR indicam um padrão bastante consistente com a natureza dos dados financeiros analisados. Observa-se que as variáveis relacionadas ao histórico de atraso de pagamento (**atraso_pagto_***) apresentam as maiores proporções de outliers, variando aproximadamente entre 9,9% e 14,7% das observações. Esse comportamento é esperado, uma vez que essas variáveis são discretas e assimétricas por construção, refletindo estados de atraso que podem se concentrar em valores extremos (como atrasos elevados em determinados meses).

As variáveis de valores de fatura (**fatura_valor_***) e de pagamento (**pagto_valor_***) também apresentam proporções relevantes de outliers, em torno de 8% a 9%. Isso é típico em dados financeiros de crédito, nos quais distribuições são fortemente assimétricas à direita, com uma pequena parcela de clientes concentrando valores elevados de consumo e pagamento. Nesse contexto, esses “outliers” não necessariamente representam erros ou anomalias, mas sim a própria heterogeneidade do comportamento financeiro da população.

Em contraste, variáveis como idade e limite de crédito apresentam proporções muito baixas de outliers (inferiores a 1%), sugerindo distribuições mais estáveis e próximas de um comportamento aproximadamente simétrico ou moderadamente disperso. Esse resultado reforça a importância de interpretar outliers sob uma perspectiva contextual: em dados de crédito, valores extremos frequentemente carregam informação relevante sobre risco e capacidade financeira, não devendo ser removidos automaticamente sem análise substantiva.

4.1.3 [REVISÃO-1] Separação treino/teste

Os conjuntos de dados foram divididos aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação às variáveis resposta. Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.2 [WIP] Modelagem e Avaliação

4.2.1 [REVISÃO-1] Modelo Frequentista

4.2.1.1 [REVISÃO-1] Avaliação do ajuste e propriedades estatísticas do modelo

O modelo de regressão logística foi estimado por máxima verossimilhança, tendo como variável resposta o status do empréstimo e como variáveis explicativas os atributos socioeconômicos e financeiros do solicitante.

4.2.1.2 [REVISÃO-1] Desempenho preditivo

4.2.1.2.1 [REVISÃO-1] Avaliação do classificador a partir das probabilidades estimadas

para o default: Em particular, a ROC-AUC é útil por avaliar a capacidade do modelo em ordenar corretamente observações positivas e negativas, sendo menos sensível ao desbalanceamento de classes. No entanto, ela ainda não captura diretamente assimetrias entre erros do tipo falso positivo e falso negativo em termos práticos.

Assim, métricas como balanced acurácia, F1-score e Matthews Correlation Coefficient (MCC) são particularmente relevantes neste contexto. A balanced acurácia corrige o viés da acurácia tradicional ao considerar igualmente sensibilidade e especificidade; o F1-score enfatiza o equilíbrio entre precisão e recall da classe minoritária; e o MCC

fornece uma medida global mais robusta, especialmente adequada para cenários com forte desbalanceamento, por incorporar todos os elementos da matriz de confusão de forma simétrica.

4.2.1.2.2 [REVISÃO-1] Avaliação do desempenho classificatório sob limiar de decisão

4.2.2 [TBD] Modelo Bayesiano

- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada) ->avaliação do impacto

5 [TBD] Discussão

- Comparação dos modelos
- Diferenças conceituais observadas
- Robustez dos resultados
- Interpretabilidade
- Incerteza
- Aplicabilidade prática

6 [TBD] Conclusão

- Síntese dos resultados
- Quando usar frequentista vs bayesiano
- Limitações

Breve explicação do problema, com principais resultados e propostas futuras

Referências

GREWAL, Rohit. **Loan Approval Dataset**. Disponível em: <<https://www.kaggle.com/datasets/rohitgrewal/loan-approval-dataset>>. Acesso em: 11 mar. 2026.

LICHMAN, M. **UCI Machine Learning Repository**. University of California, Irvine, School of Information; Computer Science; <http://archive.ics.uci.edu/ml>, 2013.

TUKEY, John W. **Exploratory Data Analysis**. Reading, MA: Addison-Wesley, 1977.

YEH, I.-C.; LIEN, C.-H. **The Default of Credit Card Clients Dataset**. <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients>, 2009.