



UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

**Uma Análise Comparativa entre Inferência
Frequentista e Bayesiana em Modelos de Regressão
Aplicados à Aprovação de Empréstimos**

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Ago/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Aplicados à Aprovação de Empréstimos

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Ago/2026

RESUMO

reavaliar os resumos, quando o trabalho estiver concluído

Este trabalho tem como objetivo comparar as abordagens de inferência frequentista e bayesiana no contexto de modelos de classificação aplicados à predição da aprovação de empréstimos bancários. O foco principal do estudo está na análise das diferenças conceituais, inferenciais e preditivas entre essas duas abordagens estatísticas, utilizando um conjunto de dados reais como estudo de caso para a aplicação dos modelos.

Inicialmente, são discutidos os fundamentos teóricos das abordagens frequentista e bayesiana, destacando suas principais características, pressupostos e formas de interpretação dos parâmetros. Em seguida, realiza-se uma análise exploratória dos dados com o objetivo de compreender a estrutura das variáveis e subsidiar a construção dos modelos, sem que a análise dos dados constitua o foco central do trabalho.

Na etapa de modelagem, são ajustados modelos de classificação sob as perspectivas frequentista e bayesiana, permitindo a comparação entre as abordagens quanto ao desempenho preditivo, à interpretação dos coeficientes estimados e à quantificação da incerteza associada às estimativas. A avaliação dos modelos é realizada por meio de métricas adequadas de classificação, possibilitando uma análise sistemática das diferenças e semelhanças entre os métodos.

Por fim, os resultados obtidos evidenciam as vantagens e limitações de cada abordagem no contexto de problemas de classificação binária, contribuindo para uma compreensão mais aprofundada das implicações práticas e metodológicas da escolha entre inferência frequentista e bayesiana em aplicações de análise de risco de crédito e ciência de dados.

Palavras-chave: regressão estatística; inferência frequentista; inferência bayesiana; modelos preditivos; análise de risco de crédito.

ABSTRACT

This study aims to compare frequentist and Bayesian inference approaches in the context of regression models applied to the prediction of loan approval decisions.

Keywords: frequentist inference; Bayesian inference; regression models; predictive modeling; credit risk analysis.

Índice

1	[TBD] Introdução	6
2	[TO DO] Referencial Teórico	6
2.1	[TO DO] Fundamentos de Probabilidade e Inferência Estatística	7
2.2	[TO DO] Problemas de Classificação em Aprendizado Estatístico	7
2.3	[TO DO] Avaliação de Modelos de Classificação	7
2.4	[TO DO] Regressão Logística Frequentista	7
2.5	[TO DO] Inferência Bayesiana	8
2.6	[TO DO] Regressão Logística Bayesiana	8
2.7	[TO DO] Aplicações em Risco de Crédito e Finanças	9
3	[WIP] Metodologia	10
3.1	[REVISÃO-1] Descrição dos Dados	10
3.1.1	[REVISÃO-1] Outliers	11
3.1.2	[TDB] Correlação	12
3.1.3	[REVISÃO-1] Codificação de variáveis categóricas	12
3.1.4	[REVISÃO-1] Padronização de variáveis numéricas	12
3.1.5	[REVISÃO-1] Divisão entre treino e teste	13
3.2	[TO DO] Modelos Avaliados	14
3.2.1	[TBD] Regressão logística frequentista	14
3.2.2	[TBD] Regressão logística bayesiana	14
3.2.3	[TO DO] Métricas de avaliação	14
4	[WIP] Resultados	15
4.1	[REVISÃO-1] Análise Exploratória	15
4.1.1	[REVISÃO-1] Estatísticas univariadas	15
4.1.2	[REVISÃO-1] Análise da variável resposta e relações com as variáveis preditoras	18
4.1.3	[REVISÃO-1] Análise de correlação entre variáveis numéricas	19
4.1.4	[REVISÃO-1] Análise de outliers	22
4.2	[REVISÃO-1] Pré processamento	22
4.2.1	[REVISÃO-1] Verificação de valores ausentes e observações duplicadas	22

4.2.2	[REVISÃO-1] Tratamento de inconsistências e outliers	23
4.2.3	[REVISÃO-1] Seleção de variáveis e análise de correlação	23
4.2.4	[REVISÃO-1] Codificação e padronização de variáveis	24
4.2.5	[REVISÃO-1] Separação treino/teste	24
4.3	[WIP] Modelagem e Avaliação	25
4.3.1	[REVISÃO-1] Modelo Frequentista	25
4.3.2	[TBD] Modelo Frequentista Alternativo	34
4.3.3	[TBD] Modelo Bayesiano	35
5	[TBD] Discussão	35
6	[TBD] Conclusão	35
	Referências	35

Legenda de status do documento

- **[TBD]** → tópico ainda indefinido; estrutura ou escopo em discussão
- **[TO DO]** → tópico planejado, ainda não iniciado
- **[WIP]** → em desenvolvimento
- **[DRAFT]** → versão preliminar do texto
- **[CHECK]** → verificação pendente (conceitos, dados, código ou referências)
- **[REVISÃO]** → versão completa, pronta para avaliação
 - **[REVISÃO-1]** → para uma primeira versão
- **[AJUSTAR]** → ajustes finos de redação, figuras ou formatação (após revisão)
- **[FINAL]** → versão definitiva (após revisão e ajustes finais)

dúvidas, pendências, decisões em aberto comentários editoriais e lembretes

Controle de versões - v1 – Análise

1 [TBD] Introdução

- Contexto de risco de crédito (motivação do trabalho)
- Importância de modelos estatísticos na decisão financeira (com referências de estudos anteriores)
- Diferença conceitual entre abordagem frequentista e bayesiana
- Motivação do estudo
- Objetivo geral (resumida)
- indicar as técnicas Estatísticas/Computacionais que serão utilizadas para a resolução do problema.
- Estrutura do trabalho (Este trabalho está assim organizado: Na Seção 2 apresentamos.... A Seção 3 trata de...)

2 [TO DO] Referencial Teórico

um dos principais capítulos, já que o foco do trabalho é a comparação entre abordagens.

2.1 [TO DO] Fundamentos de Probabilidade e Inferência Estatística

- Probabilidade como frequência vs probabilidade como grau de crença
- Variáveis aleatórias e distribuições
- Teorema de Bayes
- Conceito de incerteza estatística
- Inferência como problema de estimação

2.2 [TO DO] Problemas de Classificação em Aprendizado Estatístico

- Classificação binária
- Função de perda e decisão
- Separabilidade linear e não linear
- Overfitting e generalização (preparando terreno para problemas de crédito, onde a separação perfeita é improvável e o trade-off entre viés e variância é crucial)
- Probabilidades preditas vs. classes previstas
- Threshold de decisão e custo de erro

2.3 [TO DO] Avaliação de Modelos de Classificação

- Desbalanceamento de classes (muito comum em dados de crédito, mas não no dataset atual)
- Matriz de confusão
- Accuracy, Precision, Recall, F1-score
- Curvas Precision–Recall
- Curva ROC e AUC
- Trade-off entre sensibilidade e especificidade
- Custo assimétrico de erros (FP vs FN)

2.4 [TO DO] Regressão Logística Frequentista

- Formulação do modelo

- Assumptions do modelo (e.g., independência, linearidade no logit, ausência de multicolinearidade)
- Parametrização e interpretação
- Interpretação dos coeficientes
- Função logística
- Estimação por máxima verossimilhança (e a função de verossimilhança)
- Testes de hipótese
- Intervalos de confiança
- Odds e odds ratio
- Limitações da abordagem frequentista
- Análise de Resíduos
- Análise de Multicolinearidade
- Fisher Scoring

2.5 [TO DO] Inferência Bayesiana

- Teorema de Bayes aplicado à estatística
- diferenças conceituais
- parametros como variáveis aleatórias
- Priors, likelihood e posterior
- Incerteza e distribuição posterior
- Vantagens da abordagem bayesiana
- Atualização sequencial da evidência
- Interpretação probabilística
- controle de sobreajuste (...)

2.6 [TO DO] Regressão Logística Bayesiana

(sempre traçando paralelos com a versão frequentista)

- Formulação do modelo probabilístico
- Escolha de priors
- Inferência via MCMC / aproximações variacionais

- Diagnóstico de convergência (R-hat, traceplots)
- Intervalos credíveis
- Sensibilidade a priors
- Robustez em pequenas amostras
- Interpretação dos coeficientes sob posterior
- Comparação direta de MLE- maximum likelihood estimation e MAP- Maximum-a-Posteriori

(...)

2.7 [TO DO] Aplicações em Risco de Crédito e Finanças

Não estender muito, acho que 1 página já deve ser suficiente

(Contextualização)

- Modelos de scoring de crédito
- Variáveis financeiras e risco
- Decisão de concessão de empréstimos
- Uso das probabilidades preditas para gestão de risco
- Transparência e interpretabilidade
- Em problemas de concessão de empréstimos, a incerteza é tão importante quanto a previsão.
- O enfoque bayesiano permite incorporar conhecimento prévio do risco.
- O enfoque frequentista fornece base tradicional de modelos de scoring.
- A comparação entre ambas abordagens permite avaliar robustez das decisões.

3 [WIP] Metodologia

3.1 [REVISÃO-1] Descrição dos Dados

Os modelos desenvolvidos neste trabalho utilizam o Loan Approval Dataset, uma base de dados pública disponibilizada na plataforma Kaggle (Grewal (2026)). A variável alvo é binária, indicando o status de aprovação do empréstimo. A Tabela 1 apresenta uma descrição detalhada das variáveis presentes no conjunto de dados.

Tabela 1: Descrição das variáveis do dataset

Feature	Descrição
No_of_dependents	Número de dependentes do solicitante
Education	Nível de escolaridade (Graduate / Not Graduate)
Self_employed	Autônomo (Yes / No)
Income_annum	Renda anual
Loan_amount	Valor do empréstimo
Loan_term	Prazo em anos
Cibil_score	Score de crédito
Residential_assets_value	Bens residenciais
Commercial_assets_value	Bens comerciais
Luxury_assets_value	Bens de luxo
Bank_asset_value	Ativos bancários
Loan_status	Variável alvo (Approved/Rejected)

Por se tratar de um dataset estruturado especificamente para fins de aprendizado de máquina e análise estatística, ele oferece um cenário controlado, permitindo focar na sensibilidade dos modelos aos preditores e na quantificação da incerteza sem as inconsistências típicas de bases de dados administrativas brutas. ## [TBD] Análise Exploratória **teríamos que ter uma seção de EDA? se sim, encaixar aqui** ## [REVISÃO-1] Pré-processamento ### [REVISÃO-1] Estrutura de dados e tratamento de valores ausentes Inicialmente, foi realizada a inspeção da estrutura do banco de dados, com o objetivo de confirmar a consistência dos tipos das variáveis e a adequação do formato dos dados às técnicas de

modelagem adotadas. Essa análise compreendeu a identificação das classes das variáveis, a distinção entre atributos numéricos e categóricos e a validação da variável resposta quanto à sua natureza e domínio.

Por fim, a presença de valores ausentes foi avaliada por meio da função `is.na()`, com sumarização via `colSums(is.na())`. Não foram identificadas observações faltantes no conjunto de dados, eliminando a necessidade de técnicas de imputação e evitando a introdução de incerteza adicional ou viés sistemático no processo de estimação.

3.1.1 [REVISÃO-1] Outliers

A identificação de valores atípicos (*outliers*) nas variáveis numéricas foi realizada por meio do critério do intervalo interquartil (*Interquartile Range*, IQR), amplamente utilizado em estatística descritiva por sua robustez em relação a distribuições assimétricas e à presença de valores extremos.

Para cada variável contínua, o primeiro quartil Q_1 e o terceiro quartil Q_3 foram calculados. Definindo o intervalo interquartil como

$$\text{IQR} = Q_3 - Q_1 \quad (1)$$

Os limites inferior e superior para identificação de outliers são definidos como

$$L = Q_1 - 1.5 \cdot \text{IQR} \quad (2)$$

$$U = Q_3 + 1.5 \cdot \text{IQR} \quad (3)$$

Esse procedimento foi empregado exclusivamente com finalidade exploratória, visando caracterizar a distribuição das variáveis e avaliar a presença de valores extremos potencialmente influentes. Não foi realizada a exclusão automática de observações, de modo a preservar a integridade do conjunto de dados e permitir que os modelos estatísticos capturassem adequadamente a heterogeneidade inerente aos dados financeiros.

O fator 1.5 no critério do IQR foi proposto por Tukey (1977) como um compromisso empírico entre robustez e sensibilidade, sendo amplamente adotado por sua boa performance em distribuições assimétricas e com caudas longas, como é típico em dados financeiros.

No contexto de análise de risco de crédito, a presença de valores extremos pode refletir perfis legítimos de alto patrimônio ou elevado risco, sendo crucial que os modelos estatísticos sejam capazes de acomodar essa variabilidade sem que a remoção indiscriminada de outliers elimine informação relevante para a tarefa de classificação.

3.1.2 [TDB] Correlação

no minimo citar a correlação de pearson como avaliação

3.1.3 [REVISÃO-1] Codificação de variáveis categóricas

Para viabilizar a inclusão de variáveis qualitativas nos modelos de regressão, foi aplicada a técnica de One-Hot Encoding. Este procedimento consiste na transformação de variáveis categóricas nominais em um conjunto de variáveis indicadoras (binárias), onde o valor 1 representa a presença da categoria e 0 a sua ausência.

Para a implementação, utilizou-se a função `dummy_cols` do pacote `fastDummies`, parametrizada com o argumento `remove_first_dummy = TRUE`. Esta etapa é metodologicamente crítica para mitigar a armadilha da variável *dummy* (multicolinearidade perfeita), que ocorre quando as variáveis indicadoras são linearmente dependentes, impossibilitando a estimativa dos parâmetros por métodos de máxima verossimilhança ou por algoritmos de amostragem bayesiana. Com a remoção da primeira categoria, o modelo estabelece uma base de comparação necessária para a interpretação dos coeficientes estimados. Essas variáveis são comumente chamadas de dummies por atuarem como substitutos numéricos simplificados (fictícios) de conceitos abstratos.

3.1.4 [REVISÃO-1] Padronização de variáveis numéricas

Para assegurar a estabilidade numérica dos algoritmos de estimação e permitir a comparabilidade entre os coeficientes do modelo, as variáveis quantitativas foram submetidas

ao processo de padronização (*Standardization*). Inicialmente, realizou-se a conversão dos dados para o tipo numérico e, em seguida, aplicou-se a transformação de escala centralizada na média com unidade de desvio padrão. A fórmula utilizada para a padronização de cada variável X é dada por

$$z_i = \frac{x_i - \mu}{\sigma} \quad (4)$$

onde x_i representa o valor original da variável, μ é a média amostral e σ é o desvio padrão amostral. Essa transformação resulta em variáveis com média zero e desvio padrão um. Com todas as variáveis na mesma escala, os coeficientes estimados tornam-se comparáveis entre si, permitindo identificar quais preditores exercem maior impacto relativo sobre a probabilidade de aprovação do empréstimo.

3.1.5 [REVISÃO-1] Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta $Y=\text{loan_status}$. Essa estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1). \quad (5)$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não enviesada do erro de generalização, reduzindo o risco de sobreajuste (*overfitting*) e vazamento de informação.

3.2 [TO DO] Modelos Avaliados

3.2.1 [TBD] Regressão logística frequentista

3.2.2 [TBD] Regressão logística bayesiana

3.2.3 [TO DO] Métricas de avaliação

3.2.3.1 [TO DO] Métricas: Ajuste do modelo

citamos quais vamos usar, deixar a teoria para o referencial teorico

- Deviance
- AIC
- BIC
- Teste da razão de verossimilhança
- Fisher Scoring
- FIV
- Análise de resíduos

3.2.3.2 [TO DO] Métricas: Avaliação preditiva

A avaliação dos modelos de classificação foi realizada por meio de métricas adequadas para problemas de classificação binária, considerando a distribuição das classes e a importância relativa dos erros de classificação. As métricas selecionadas incluem:

- ROC-AUC (Área sob a curva ROC)
- Curva Precision-Recall e AUC-PR
- Curva Sensibilidade (Recall) e Especificidade
- (Índice de Youden)
- Matriz de confusão
- Accuracy, Precision, Recall e F1-score

4 [WIP] Resultados

4.1 [REVISÃO-1] Análise Exploratória

A análise exploratória é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

O conjunto de dados é composto por 4269 observações e 13 variáveis, incluindo a variável resposta `loan_status`, que indica se o empréstimo foi aprovado ou rejeitado. As variáveis preditoras incluem informações como renda anual, pontuação de crédito, nível educacional, entre outras características dos solicitantes.

4.1.1 [REVISÃO-1] Estatísticas univariadas

A Tabela 2 apresenta as principais estatísticas descritivas das variáveis numéricas do conjunto de dados, incluindo média, mediana, valor mínimo e máximo. Em média, os solicitantes apresentam aproximadamente 2 a 3 dependentes, renda anual em torno de 5 milhões e solicitam empréstimos próximos a 15 milhões. O prazo médio dos empréstimos é de cerca de 11 anos, enquanto o score de crédito médio está próximo de 600 pontos. Esses valores sugerem uma população com perfil financeiro intermediário, mas com ampla variabilidade entre indivíduos, com desvios-padrão elevados.

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
no_of_dependents	2.5	3	0	5	1.7
income_annum	5.05912e+06	5.1e+06	200000	9.9e+06	2.80684e+06
loan_amount	1.51335e+07	1.45e+07	300000	3.95e+07	9.04336e+06
loan_term	10.9	10	2	20	5.71
cibil_score	599.94	600	300	900	172.43
residential_assets_value	7.47262e+06	5.6e+06	-100000	2.91e+07	6.50364e+06
commercial_assets_value	4.97316e+06	3.7e+06	0	1.94e+07	4.38897e+06
luxury_assets_value	1.51263e+07	1.46e+07	300000	3.92e+07	9.10375e+06

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
bank_asset_value	4.97669e+06	4.6e+06	0	1.47e+07	3.25019e+06

Na Figura 1 são apresentadas as distribuições das variáveis numéricas analisadas. As variáveis (a) Renda Anual, (c) Prazo do Empréstimo e (d) CIBIL Score exibem distribuições relativamente homogêneas, sem concentração acentuada em intervalos específicos. Esse padrão sugere que o conjunto de dados contempla uma ampla variedade de perfis de clientes, não havendo predominância excessiva de indivíduos com renda muito elevada ou muito baixa, nem de faixas específicas de score de crédito.

Para a variável Prazo do Empréstimo (c), observa-se a presença de picos discretos ao longo da distribuição, o que é esperado, dado que prazos de empréstimo são usualmente definidos em valores inteiros de anos.


Em contraste, as variáveis (e) Ativos Residenciais, (f) Ativos Comerciais, (g) Bens de Luxo e (h) Ativos Bancários apresentam acentuada assimetria à direita, indicando que a maioria dos indivíduos possui ativos de menor valor, enquanto uma parcela reduzida concentra patrimônios significativamente mais elevados.

podemos tratar com transformações logarítmicas ou Box-Cox, mas deixei quieto por enquanto, usaria apenas na frequentista


A (b) Distribuição do valor do empréstimo se mantém constante até um certo patamar (em torno de 20 milhões) e depois sofre uma queda acentuada. Indicando que o banco tem um limite de crédito comum para a maioria dos clientes, e empréstimos acima desse valor são exceções ou exigem critérios muito mais rígidos, tornando-os menos frequentes.

Outro ponto relevante é a presença de valores negativos em `residential_assets_value`, como podemos ver em Tabela 2, o que pode indicar inconsistências de registro ou tratamentos contábeis específicos no conjunto de dados. Esse tipo de característica pode afetar a modelagem, exigindo atenção em etapas de pré-processamento.


A Tabela 3 apresenta a distribuição das variáveis categóricas do conjunto de dados. Observa-se que as categorias analisadas exibem distribuições globalmente equilibradas,




(a) Distribuição da renda anual




(b) Distribuição do valor do empréstimo




(c) Distribuição do prazo




(d) Distribuição do CIBIL score




(e) Distribuição dos ativos residenciais



(f) Distribuição dos ativos comerciais



(g) Distribuição dos bens de luxo



(h) Distribuição dos ativos bancários

Figura 1: Distribuição das principais variáveis numéricas do conjunto de dados

sem predominância acentuada de um único grupo, o que contribui para a estabilidade estatística e reduz potenciais vieses na etapa de modelagem.

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
no_of_dependents	0	712	16.68
no_of_dependents	1	697	16.33
no_of_dependents	2	708	16.58
no_of_dependents	3	727	17.03
no_of_dependents	4	752	17.62
no_of_dependents	5	673	15.76
education	Graduate	2144	50.22
education	Not Graduate	2125	49.78
self_employed	No	2119	49.64
self_employed	Yes	2150	50.36

4.1.2 [REVISÃO-1] Análise da variável resposta e relações com as variáveis preditoras

Na Figura 2, observa-se a distribuição da variável resposta `loan_status`, indicando que aproximadamente 62.22% dos empréstimos foram aprovados, enquanto 37.78% foram rejeitados. Essa proporção sugere um desequilíbrio leve na classe alvo.

A Figura 3 apresenta a estimativa de densidade para as variáveis numéricas do conjunto de dados, segmentadas pelo status de aprovação do empréstimo (Rejeitado ou Aprovado). Observa-se que a variável `cibil_score` é a que apresenta a separação mais nítida entre as classes: candidatos com scores mais baixos (aproximadamente abaixo de 600) concentram-se majoritariamente no grupo de rejeitados, enquanto scores elevados mostram uma densidade quase exclusiva de aprovações.

No que tange ao prazo do empréstimo (`loan_term`), nota-se uma ligeira predominância de rejeições em prazos muito curtos, enquanto os prazos mais longos apresentam uma distribuição mais equilibrada entre os grupos. Em contraste, o restante das variáveis exibem




Figura 2: Distribuição da aprovação de empréstimos

distribuições sobrepostas e visualmente semelhantes entre as duas classes. Tal sobreposição indica que, isoladamente, essas variáveis possuem menor poder discriminatório, o que exigirá dos modelos de regressão a identificação de correlações mais complexas ou efeitos multivariados para contribuir com a predição.

A Figura 4 apresenta a distribuição das frequências absolutas para as variáveis categóricas Nível educacional, Trabalho autônomo e Número de dependentes, segmentadas pelo status de aprovação. Observa-se que a proporção entre empréstimos aprovados e rejeitados mantém-se praticamente constante, independentemente de o candidato ser graduado ou não, ou de possuir trabalho autônomo. No que tange ao número de dependentes, o comportamento é análogo: não há uma categoria específica (de 0 a 5 dependentes) que apresente uma vantagem ou desvantagem desproporcional na aprovação do crédito. Sob a ótica da modelagem estatística, essa independência aparente sugere que tais variáveis podem apresentar coeficientes com menor magnitude ou maior incerteza .

4.1.3 [REVISÃO-1] Análise de correlação entre variáveis numéricas

A matriz de correlação (Figura 5) revela associações relevantes entre as variáveis numéricas do conjunto de dados. Observa-se forte correlação entre renda anual (`income_annum`) e valor do empréstimo (`loan_amount`), bem como entre essas variáveis e os ativos patrimoniais, especialmente ativos de luxo e ativos bancários, indicando que essas medidas capturam




Figura 3: Distribuição das variáveis numéricas por status de aprovação do empréstimo




Figura 4: Distribuição das variáveis categóricas segundo o status do empréstimo

aspectos relacionados da condição financeira dos solicitantes. As correlações entre os diferentes tipos de ativos são positivas e moderadas, sugerindo coerência interna do perfil patrimonial, sem redundância perfeita entre as variáveis.

Por outro lado, o prazo do empréstimo (`loan_term`) apresenta correlação praticamente nula com as demais variáveis, indicando independência em relação ao perfil financeiro. De forma semelhante, o `cibil_score` exibe correlações muito fracas com renda, ativos e valor do empréstimo, sugerindo que essa variável representa uma dimensão distinta de risco de crédito, relevante para a classificação, mas não diretamente associada ao nível de riqueza.

A presença de correlações elevadas entre algumas variáveis explicativas indica potencial multicolinearidade, aspecto que deve ser considerado na etapa de modelagem, especialmente na interpretação dos coeficientes da regressão logística.




Figura 5: Mapa de calor da correlação entre variáveis numéricas

4.1.4 [REVISÃO-1] Análise de outliers

A presença de valores atípicos, particularmente em variáveis relacionadas a ativos patrimoniais, é corroborada quantitativamente pela Tabela 4, que apresenta o número e o percentual de observações classificadas como outliers segundo o critério do intervalo interquartil. Esses valores extremos refletem a heterogeneidade típica de dados financeiros e possuem implicações diretas para a modelagem estatística. Enquanto abordagens frequentistas podem demandar procedimentos de tratamento ou estimadores robustos para mitigar a influência desses pontos, modelos bayesianos permitem incorporar explicitamente essa incerteza por meio de distribuições com caudas mais pesadas, oferecendo maior flexibilidade na avaliação do impacto dos outliers sobre os parâmetros estimados.

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR

Feature	Outliers	Percentual
bank_asset_value	5	0.0011712
cibil_score	0	0.0000000
commercial_assets_value	37	0.0086671
income_annum	0	0.0000000
loan_amount	0	0.0000000
loan_term	0	0.0000000
luxury_assets_value	0	0.0000000
residential_assets_value	52	0.0121808

4.2 [REVISÃO-1] Pré processamento

4.2.1 [REVISÃO-1] Verificação de valores ausentes e observações duplicadas

Inicialmente, foi realizada a verificação da presença de valores ausentes e observações duplicadas no conjunto de dados. Não foram identificados valores faltantes em nenhuma das variáveis, o que dispensou a aplicação de técnicas de imputação e evitou a introdução de incerteza adicional ou viés sistemático no processo de modelagem. Adicionalmente, não

foram detectadas observações duplicadas, assegurando que cada registro corresponda a uma unidade amostral distinta e contribuindo para a validade das estimativas inferenciais.

4.2.2 [REVISÃO-1] Tratamento de inconsistências e outliers

Observa-se que aproximadamente 0.01% dos solicitantes apresentam valores negativos para ativos residenciais, correspondendo a um contingente residual de observações atípicas. Esses valores não possuem interpretação econômica direta no contexto da variável analisada e podem estar associados a inconsistências de registro ou a particularidades não representativas do perfil financeiro da amostra. Considerando o caráter marginal dessas observações e seu potencial de introduzir ruído na estimação dos parâmetros, optou-se por removê-las do conjunto de dados, sem prejuízo à representatividade da amostra ou à validade inferencial dos modelos ajustados. A exclusão resultou na remoção de 28 observações.

Não foi aplicado tratamento automático de outliers, uma vez que valores extremos são esperados em dados financeiros e podem conter informação relevante para a classificação do risco de crédito.

4.2.3 [REVISÃO-1] Seleção de variáveis e análise de correlação

A Figura 5 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas. Observou-se a presença de correlações elevadas entre variáveis associadas à escala de renda e patrimônio, como renda anual, valor do empréstimo e ativos financeiros, comportamento esperado em bases de dados financeiras.

Apesar dessas correlações, optou-se por não remover variáveis nesta etapa, uma vez que correlação elevada não implica, necessariamente, multicolinearidade prejudicial à estimação, e tais variáveis podem conter informação complementar relevante para a classificação do risco de crédito.

4.2.4 [REVISÃO-1] Codificação e padronização de variáveis

Com o objetivo de tornar os dados adequados à aplicação de modelos de regressão logística, foi realizado um processo de codificação das variáveis categóricas e padronização das variáveis numéricas. As variáveis categóricas consideradas no estudo incluem: o nível educacional (Graduate / Not Graduate) e a condição de trabalho autônomo (Yes/No). Essas variáveis foram tratadas por meio de **one-hot encoding**, convertendo cada categoria em variáveis indicadoras binárias. Para evitar problemas de multicolinearidade perfeita, uma categoria de referência foi removida em cada conjunto de **dummies**.

As variáveis numéricas foram padronizadas utilizando o método standard. Essa etapa garante que todas as variáveis estejam na mesma escala, facilitando a convergência dos algoritmos de estimação e permitindo uma interpretação mais comparável dos coeficientes estimados.

Ressalta-se que a padronização não altera a informação contida nos dados, mas apenas sua escala, sendo especialmente relevante em modelos que utilizam métodos de otimização numérica e em abordagens bayesianas, nas quais a escolha de distribuições a priori é sensível à magnitude dos parâmetros.

4.2.5 [REVISÃO-1] Separação treino/teste

O conjunto de dados foi dividido aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação à variável resposta (`loan_status`). Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.3 [WIP] Modelagem e Avaliação

4.3.1 [REVISÃO-1] Modelo Frequentista

4.3.1.1 [REVISÃO-1] Avaliação do ajuste e propriedades estatísticas do modelo

Tabela 5: Medidas de ajuste do modelo de regressão logística

Medida	Valor
Null deviance	4185.873
Residual deviance	1384.101
Δ Deviance (LR)	2801.773
gl (diferença)	11.000
p-valor (teste qui-quadrado)	0.000
AIC	1408.101
BIC	1480.880
Número de iterações (Fisher scoring)	7.000

O modelo de regressão logística foi estimado por máxima verossimilhança, tendo como variável resposta o status do empréstimo e como variáveis explicativas os atributos socioeconômicos e financeiros do solicitante.

A Tabela 5 possui métricas de ajuste do modelo. O algoritmo de Fisher scoring convergiu após 7 iterações, indicando estabilidade na estimação dos parâmetros do modelo. É possível observar que o modelo apresentou redução substancial da deviance, passando de 4185.9 no modelo nulo para 1384.1 no modelo ajustado, com critério de informação de Akaike (AIC) igual a 1408.1, indicando que a inclusão das variáveis explicativas contribuiu significativamente para a explicação da variável resposta.

Adicionalmente, foi calculado o Critério de Informação Bayesiano (BIC), cujo valor foi de 1480.9. O BIC impõe uma penalização mais severa à complexidade do modelo do que o AIC, sendo particularmente informativo em amostras de maior dimensão. O valor obtido sugere que a especificação adotada mantém um equilíbrio adequado entre qualidade de ajuste e parcimônia, reforçando a robustez do modelo sob um critério mais conservador.

Tabela 6: Estimativas do modelo de regressão logística

Variável	Beta	StdErr	z	p-valor	OddsRatio
(Intercept)	-1.83	0.14	-13.32	0.00	0.16
no_of_dependents	0.08	0.07	1.12	0.26	1.08
income_annum	1.73	0.29	5.90	0.00	5.62
loan_amount	-1.44	0.19	-7.50	0.00	0.24
loan_term	0.90	0.07	11.93	0.00	2.46
cibil_score	-4.28	0.17	-25.37	0.00	0.01
residential_assets_value	-0.01	0.09	-0.14	0.89	0.99
commercial_assets_value	-0.04	0.09	-0.48	0.63	0.96
luxury_assets_value	-0.19	0.18	-1.02	0.31	0.83
bank_asset_value	-0.19	0.13	-1.47	0.14	0.83
‘education_Not Graduate’	0.06	0.14	0.47	0.64	1.07
self_employed_Yes	-0.09	0.14	-0.68	0.50	0.91

O teste da razão de verossimilhança confirmou que o modelo ajustado apresenta desempenho estatisticamente superior ao modelo sem covariáveis ($\chi^2 = 2801.8$, $df = 11$, $p < 0,001$), evidenciando que o conjunto de variáveis explicativas contribui de forma significativa para a modelagem da probabilidade de aprovação do empréstimo.

A Tabela 6 apresenta as estimativas dos coeficientes, erros-padrão, estatísticas z e respectivos valores-p. Entre as variáveis analisadas, `income_annum`, `loan_amount`, `loan_term` e `cibil_score` mostraram-se estatisticamente significativas ao nível de 1%. O coeficiente (Coluna Beta da tabela) associado à renda anual (`income_annum`) é positivo, indicando que maiores níveis de renda aumentam a probabilidade de aprovação do empréstimo, mantendo-se as demais variáveis constantes. Em contrapartida, o valor solicitado (`loan_amount`) apresenta coeficiente negativo, sugerindo que empréstimos de maior montante estão associados a uma menor probabilidade de aprovação, refletindo maior percepção de risco por parte da instituição financeira.

O prazo do empréstimo (`loan_term`) possui coeficiente positivo e estatisticamente significativo, indicando que prazos mais longos tendem a aumentar a chance de aprovação, possivelmente por reduzirem o valor das parcelas e, conseqüentemente, o risco de inadimplência. A variável `cibil_score` destaca-se como o preditor mais relevante do modelo, apresentando coeficiente negativo de grande magnitude e elevada significância estatística. Esse resultado sugere forte associação entre o score de crédito e a decisão de concessão, reforçando seu papel central na avaliação de risco.

As demais variáveis, incluindo número de dependentes, valores de ativos (residenciais, comerciais, de luxo e bancários), nível educacional e status de trabalho autônomo, não apresentaram significância estatística aos níveis usuais. A ausência de significância estatística dessas covariáveis indica que, uma vez controladas as variáveis centrais do modelo, sua contribuição marginal para a verossimilhança do modelo é limitada, não resultando em melhora estatisticamente detectável na capacidade de discriminação do risco de crédito.

O intercepto negativo e estatisticamente significativo reflete a probabilidade basal de aprovação quando todas as variáveis explicativas estão em seus valores de referência, reforçando a necessidade da presença de características financeiras favoráveis para aumentar a chance de concessão do crédito.

Como as variáveis quantitativas foram padronizadas, os coeficientes estimados e seus respectivos *Odds Ratios* (OR) devem ser interpretados como o efeito associado a um aumento de um desvio padrão na variável explicativa, mantendo-se as demais constantes. Essa transformação permite a comparabilidade direta da magnitude dos efeitos entre variáveis originalmente medidas em escalas distintas. Portanto, um aumento de um desvio padrão na renda anual está associado a um aumento de 5.624 vezes na odds de aprovação do empréstimo, enquanto um aumento de um desvio padrão no valor do empréstimo reduz as odds em 0.237 vezes, e assim por diante para as demais variáveis.

Tabela 7: Fatores de Inflação de Variância por feature

	Variavel	VIF
no_of_dependents	no_of_dependents	1.01
income_annum	income_annum	17.97
loan_amount	loan_amount	7.73
loan_term	loan_term	1.26
cibil_score	cibil_score	1.33
residential_assets_value	residential_assets_value	1.69
commercial_assets_value	commercial_assets_value	1.63
luxury_assets_value	luxury_assets_value	7.31
bank_asset_value	bank_asset_value	3.41
education_Not Graduate	education_Not Graduate	1.01

Tabela 7: Fatores de Inflação de Variância por feature

Variavel		VIF
self_employed_Yes	self_employed_Yes	1.01

A Tabela 7 apresenta os fatores de inflação da variância (VIF) para as variáveis explicativas do modelo de regressão logística. O VIF quantifica o quanto a variância do estimador de cada coeficiente é inflacionada devido à correlação linear com as demais covariáveis. Valores próximos de 1 indicam ausência de multicolinearidade, enquanto valores acima de 5 sugerem atenção e valores superiores a 10 são usualmente interpretados como indicativos de multicolinearidade severa.

Observa-se que a maior parte das variáveis apresenta VIFs baixos, próximos de 1, indicando fraca dependência linear entre si. Esse é o caso, por exemplo, de `no_of_dependents`, `loan_term`, `cibil_score`, das variáveis associadas a ativos residenciais e comerciais, bem como das variáveis categóricas relacionadas à escolaridade e ao status de emprego.

Entretanto, duas variáveis merecem destaque. A variável `income_annum` apresenta VIF elevado (17,97), caracterizando multicolinearidade severa, o que indica forte correlação linear com outras covariáveis do modelo. Esse resultado já havia sido observado na análise de correlação de pearson (ver Figura 5), na qual `income_annum` apresentou alta correlação com `loan_amount` e com variáveis patrimoniais. Além disso, as variáveis `loan_amount` (VIF = 7,73) e `luxury_assets_value` (VIF = 7,31) exibem multicolinearidade moderada, acima do limiar usual de 5, sugerindo a presença de sobreposição parcial de informação explicativa no modelo.

podemos remover essas features em uma outra versão do modelo, só teríamos que repetir os resultados, é valido?

A análise de diagnóstico é uma etapa crucial para validar a robustez do modelo de regressão logística e identificar possíveis observações influentes que possam enviesar as estimativas de crédito. A Figura 6 apresenta os gráficos de diagnóstico gerados para o modelo final. Embora a regressão logística não pressuponha a normalidade dos resíduos, uma vez que a variável dependente segue uma distribuição binomial e os parâmetros são estimados




Figura 6: Gráficos de diagnóstico de resíduos do modelo de regressão logística

via Máxima Verossimilhança, a análise dos resíduos de Pearson e resíduos de desvio permite avaliar a qualidade do ajuste.

O gráfico **Residuals vs Fitted** mostra a dispersão dos resíduos de Pearson em relação aos valores preditos. Observa-se uma concentração de resíduos próximos de zero, o que é esperado, todavia, a presença de pontos isolados com valores de resíduos extremamente altos (especialmente os casos 675, 2404 e 3059) indica que o modelo apresenta dificuldades em classificar corretamente determinados perfis de tomadores de empréstimo.

No gráfico **Q-Q Residuals**, o desvio observado nas caudas do gráfico Quantil-Quantil não deve ser interpretado como uma violação de pressuposto, mas sim como um indicativo de que a distribuição dos erros do modelo possui “caudas pesadas”. Isso reforça a existência de outliers ou casos em que a probabilidade prevista pelo modelo diverge drasticamente do desfecho real da aprovação.

Diferente dos modelos lineares clássicos, a regressão logística não assume a homocedasticidade dos resíduos, uma vez que a variância em uma distribuição binomial é intrinsecamente dependente da probabilidade de ocorrência do evento. Contudo, a análise do gráfico **Scale-Location** (Figura 6) permanece relevante para identificar possíveis problemas de

superdispersão ou má especificação do modelo. No presente estudo, a dispersão observada sugere que, embora a heterocedasticidade seja um traço inerente ao método, a presença de observações com resíduos padronizados elevados indica que a variabilidade dos dados de aprovação de crédito pode não estar sendo totalmente capturada pelas variáveis independentes selecionadas.

O gráfico **Residuals vs Leverage** é fundamental para identificar observações que possuem alto “poder de alavancagem”. O ponto 675 destaca-se significativamente por apresentar um resíduo de Pearson padronizado superior a 80. Embora a distância de Cook não indique que este ponto esteja isolado fora dos limites críticos usuais, sua magnitude residual sugere que ele é um caso atípico.

A instabilidade observada nos resíduos (Figura 6) e a presença de valores discrepantes podem estar associadas à existência de multicolinearidade entre as variáveis independentes. Variáveis altamente correlacionadas tendem a inflar a variância dos estimadores, dificultando a convergência do modelo e resultando em previsões menos robustas para perfis de crédito específicos.

Bom, podemos remover as feats mais correlacionadas ou não... e aí repetiríamos a análise ou nem chegamos a avaliar o desempenho desse modelo, seguindo apenas com o outro...

4.3.1.2 [REVISÃO-1] Desempenho preditivo

4.3.1.2.1 [REVISÃO-1] Avaliação do classificador a partir das probabilidades estimadas

A capacidade discriminatória do modelo foi avaliada por meio da Área sob a Curva ROC (ROC-AUC) (Figura 7), métrica amplamente utilizada em problemas de classificação binária por ser independente da escolha de um limiar de decisão e por avaliar diretamente a qualidade das probabilidades estimadas. A AUC pode ser interpretada como a probabilidade de que o modelo atribua uma probabilidade maior a uma observação pertencente à classe positiva do que a uma observação da classe negativa, escolhidas aleatoriamente. Valores de AUC próximos de 1 indicam excelente poder discriminatório, enquanto valores próximos de 0,5 sugerem desempenho equivalente ao acaso.




Figura 7: Curvas ROC para os conjuntos de treino e teste

Os resultados indicam $AUC = 0.97$ no conjunto de treino e $AUC = 0.97$ no conjunto de teste. A proximidade entre esses valores sugere que o modelo apresenta excelente capacidade de discriminação, mantendo desempenho consistente fora da amostra utilizada para estimação dos parâmetros. Além disso, a ausência de queda relevante da AUC do treino para o teste indica baixo indício de sobreajuste (*overfitting*), reforçando a robustez do modelo no que diz respeito à ordenação correta das probabilidades preditas. Esse comportamento é particularmente relevante no contexto da análise de risco de crédito, em que a correta hierarquização dos indivíduos segundo o risco é mais importante do que decisões baseadas em um único ponto de corte.

Complementarmente à análise por meio da curva ROC, avaliou-se o desempenho do modelo utilizando a curva Precision–Recall (PR) (Figura 8), a qual é particularmente informativa em contextos de classes desbalanceadas ou quando o interesse principal está na qualidade das previsões da classe positiva. Enquanto a curva ROC avalia a relação entre sensibilidade e especificidade, a curva Precision–Recall enfatiza o compromisso entre precisão (precision), a proporção de observações corretamente classificadas como positivas entre todas as classificadas como positivas, e recall (sensibilidade), a proporção de positivos corretamente identificados. Dessa forma, a AUC–PR fornece uma medida mais direta




Figura 8: Curvas Precision-Recall para os conjuntos de treino e teste

da utilidade prática das probabilidades estimadas quando o custo de falsos positivos é relevante, como no contexto de concessão de crédito.

A área sob a curva Precision-Recall foi calculada separadamente para os conjuntos de treino e teste, resultando em $\text{AUC-PR} = 0.94$ no conjunto de treino e $\text{AUC-PR} = 0.951$ no conjunto de teste. Esses valores elevados indicam que o modelo apresenta alta capacidade de manter níveis simultaneamente elevados de precisão e revocação, mesmo quando se exige maior rigor na identificação da classe positiva.

De forma consistente com os resultados observados na curva ROC, a similaridade entre as AUC-PR dos conjuntos de treino e teste sugere boa capacidade de generalização e estabilidade do modelo fora da amostra de estimação. Ademais, o desempenho superior na métrica Precision-Recall reforça a adequação do modelo para aplicações em risco de crédito, nas quais decisões baseadas em probabilidades bem calibradas são preferíveis à simples classificação binária.

A escolha do limiar de corte da probabilidade foi baseada na análise conjunta da sensibilidade e da especificidade do classificador, como podemos ver na Figura 9. Para isso, foram avaliados os valores dessas métricas ao longo de todo o intervalo de limiares possíveis,




Figura 9: Curvas Sensibilidade-Especificidade em função do limiar de decisão

construindo-se curvas de sensibilidade e especificidade em função do limiar de decisão.

O ponto de corte ótimo foi definido a partir da maximização do índice de Youden (Youden (1950)), que busca simultaneamente maximizar a taxa de verdadeiros positivos e a taxa de verdadeiros negativos. Esse critério fornece um equilíbrio entre erros de classificação dos dois tipos, evitando a adoção arbitrária do valor padrão de 0,5.

O limiar selecionado (0.275) foi então utilizado para a construção da matriz de confusão e para o cálculo das métricas de desempenho no conjunto de teste.

4.3.1.2.2 [REVISÃO-1] Avaliação do desempenho classificatório sob limiar de decisão

Após a definição do limiar de decisão, as previsões probabilísticas foram convertidas em classes, permitindo a construção das matrizes de confusão para os conjuntos de treino e teste (Tabela 8).

Tabela 8: Matrizes de confusão do modelo de regressão logística (treino e teste)

Treino (classe prevista) Teste (classe prevista)

Tabela 9: Métricas de desempenho do modelo de regressão logística para os conjuntos de treino e teste

Conjunto	Accuracy	Precision	Recall	Specificity	F1	AUC_ROC	AUC_PR
Treino	0.91	0.82	0.97	0.87	0.89	0.97	0.94
Teste	0.92	0.85	0.97	0.88	0.90	0.97	0.95

Classe real	0	1	0	1
0	1756	35	555	15
1	254	1136	75	415

A partir dessas matrizes, foram calculadas métricas clássicas de desempenho, incluindo acurácia, precisão, sensibilidade, especificidade e F1-score, cujos valores estão sumarizados na Tabela 9. Observa-se desempenho consistente entre os conjuntos, com valores semelhantes de acurácia, indicando boa capacidade de generalização.

A sensibilidade (recall) é elevada em ambos os conjuntos, o que é particularmente desejável no contexto de risco de crédito, pois reduz a probabilidade de classificar incorretamente clientes inadimplentes. A precisão e o F1-score também apresentam valores altos e estáveis, sugerindo um bom equilíbrio entre identificação correta da classe positiva e controle de falsos positivos.

As métricas independentes do limiar reforçam esse resultado: a AUC-ROC assume valores próximos de 1 tanto no treino quanto no teste, evidenciando excelente capacidade discriminatória, enquanto a AUC da curva Precision–Recall confirma a robustez do modelo mesmo em um cenário de possível desbalanceamento entre classes.

4.3.2 [TBD] Modelo Frequentista Alternativo

se fizer sentido...

talvez fique longo demais, seria remover as features de `income_annum`, ou até fazer `loan_amount/income_annum` para a razão e avaliar as correlações

4.3.3 [TBD] Modelo Bayesiano

- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada) -> avaliação do impacto

5 [TBD] Discussão

- Comparação dos modelos
- Diferenças conceituais observadas
- Robustez dos resultados
- Interpretabilidade
- Incerteza
- Aplicabilidade prática

6 [TBD] Conclusão

- Síntese dos resultados
- Quando usar frequentista vs bayesiano
- Limitações

Breve explicação do problema, com principais resultados e propostas futuras

Referências

GREWAL, Rohit. **Loan Approval Dataset**. Disponível em: <<https://www.kaggle.com/datasets/rohitgrewal/loan-approval-dataset>>. Acesso em: 11 mar. 2026.

TUKEY, John W. **Exploratory Data Analysis**. Reading, MA: Addison-Wesley, 1977.

YOUDEM, W. J. [Index for Rating Diagnostic Tests](#). **Cancer**, v. 3, n. 1, p. 32–35, 1950.