



UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

**Uma Análise Comparativa entre Inferência
Frequentista e Bayesiana em Modelos de Regressão
Aplicados à Aprovação de Empréstimos**

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Ago/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Aplicados à Aprovação de Empréstimos

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Ago/2026

RESUMO

reavaliar os resumos, quando o trabalho estiver concluído

Este trabalho tem como objetivo comparar as abordagens de inferência frequentista e bayesiana no contexto de modelos de classificação aplicados à predição da aprovação de empréstimos bancários. O foco principal do estudo está na análise das diferenças conceituais, inferenciais e preditivas entre essas duas abordagens estatísticas, utilizando um conjunto de dados reais como estudo de caso para a aplicação dos modelos.

Inicialmente, são discutidos os fundamentos teóricos das abordagens frequentista e bayesiana, destacando suas principais características, pressupostos e formas de interpretação dos parâmetros. Em seguida, realiza-se uma análise exploratória dos dados com o objetivo de compreender a estrutura das variáveis e subsidiar a construção dos modelos, sem que a análise dos dados constitua o foco central do trabalho.

Na etapa de modelagem, são ajustados modelos de classificação sob as perspectivas frequentista e bayesiana, permitindo a comparação entre as abordagens quanto ao desempenho preditivo, à interpretação dos coeficientes estimados e à quantificação da incerteza associada às estimativas. A avaliação dos modelos é realizada por meio de métricas adequadas de classificação, possibilitando uma análise sistemática das diferenças e semelhanças entre os métodos.

Por fim, os resultados obtidos evidenciam as vantagens e limitações de cada abordagem no contexto de problemas de classificação binária, contribuindo para uma compreensão mais aprofundada das implicações práticas e metodológicas da escolha entre inferência frequentista e bayesiana em aplicações de análise de risco de crédito e ciência de dados.

Palavras-chave: regressão estatística; inferência frequentista; inferência bayesiana; modelos preditivos; análise de risco de crédito.

ABSTRACT

This study aims to compare frequentist and Bayesian inference approaches in the context of regression models applied to the prediction of loan approval decisions. The main focus of the research lies in analyzing the conceptual, inferential, and predictive differences between these two statistical paradigms, using a real-world dataset as a case study for model application.

Initially, the theoretical foundations of frequentist and Bayesian approaches are discussed, highlighting their main characteristics, assumptions, and parameter interpretation frameworks. Subsequently, an exploratory analysis of the data is conducted in order to understand the structure of the variables and support model development, without making the data analysis itself the central focus of the study.

In the modeling stage, regression models are fitted under both frequentist and Bayesian perspectives, allowing for a comparative evaluation in terms of predictive performance, coefficient interpretation, and uncertainty quantification associated with the estimates. Model performance is assessed using appropriate classification metrics, enabling a systematic comparison between the two approaches.

Finally, the results highlight the strengths and limitations of each statistical approach in the context of binary classification problems, contributing to a deeper understanding of the practical and methodological implications of choosing between frequentist and Bayesian inference in credit risk analysis and data science applications.

Keywords: frequentist inference; Bayesian inference; regression models; predictive modeling; credit risk analysis.

Índice

1	[TBD] Introdução	7
2	[TO DO] Referencial Teórico	7
2.1	[TO DO] Fundamentos de Probabilidade e Inferência Estatística	8
2.2	[TO DO] Problemas de Classificação em Aprendizado Estatístico	8
2.3	[TO DO] Avaliação de Modelos de Classificação	8
2.4	[TO DO] Regressão Logística Frequentista	8
2.5	[TO DO] Inferência Bayesiana	9
2.6	[TO DO] Regressão Logística Bayesiana	9
2.7	[TO DO] Aplicações em Risco de Crédito e Finanças	10
3	[WIP] Metodologia	10
3.1	[DRAFT] Descrição dos Dados	10
3.2	[TBD] Pré-processamento	11
3.2.1	[TO DO] Verificação da Estrutura de dados e tratamento de valores ausentes	11
3.2.2	[TO DO] Outliers	11
3.2.3	[TO DO] Codificação de variáveis categóricas	12
3.2.4	[TO DO] Padronização de variáveis numéricas	12
3.2.5	[TO DO] Divisão entre treino e teste	12
3.3	[TO DO] Estratégia de Modelagem	13
3.4	[TO DO] Modelos Avaliados	13
4	[WIP] Resultados	13
4.1	[DRAFT] Análise Exploratória	13
4.1.1	Estatísticas univariadas	13
4.1.2	Análise da variável resposta e relações com as variáveis preditoras .	15
4.1.3	Análise de correlação entre variáveis numéricas	18
4.1.4	Análise de outliers e dispersão	20
4.2	[WIP] Pré processamento	21
4.2.1	[DRAFT] Verificação de valores ausentes	21
4.2.2	[DRAFT] Tratamento de inconsistências e outliers	23

4.2.3	[DRAFT] Seleção de variáveis e análise de correlação	23
4.2.4	[DRAFT] Codificação e padronização de variáveis	23
4.2.5	[DRAFT] Separação treino/teste	24
4.3	[WIP] Modelagem e Avaliação	24
4.3.1	[TBD] Modelo Frequentista	24
4.4	[TBD] Interpretação dos Modelos	33
5	[TBD] Discussão	34
6	[TBD] Conclusão	34

Controle de escrita

estou colocando comentários em vermelho para destacar pontos a revisar ou expandir

Controle de Status (uso interno)

- [TBD] -> revisar ainda os tópicos, organizar melhor a estrutura, definir quais análises e gráficos serão feitos, etc.
- [TO DO] -> já tenho uma ideia geral do que quero escrever, já em tópicos, mas ainda não comecei a escrever o texto
- [WIP] -> Em desenvolvimento
- [DRAFT] -> Versão preliminar
- [CHECK] -> verificação pendente (conceito, dados, código, referências)
- [AJUSTAR] -> ajuste fino de redação, figura ou formatação (revisão textual)
- [FINAL] Versão definitiva

1 [TBD] Introdução

- Contexto de risco de crédito (motivação do trabalho)
- Importância de modelos estatísticos na decisão financeira (com referencias de estudos anteriores)
- Diferença conceitual entre abordagem frequentista e bayesiana
- Motivação do estudo
- Objetivo geral (resumida)
- indicar as técnicas Estatísticas/Computacionais que serão utilizadas para a resolução do problema.
- Estrutura do trabalho (Este trabalho está assim organizado: Na Seção 2 apresentamos.... A Seção 3 trata de...)

2 [TO DO] Referencial Teórico

um dos principais capítulos, já que o foco do trabalho é a comparação entre abordagens.

2.1 [TO DO] Fundamentos de Probabilidade e Inferência Estatística

- Probabilidade como frequência vs probabilidade como grau de crença
- Variáveis aleatórias e distribuições
- Teorema de Bayes
- Conceito de incerteza estatística
- Inferência como problema de estimação

2.2 [TO DO] Problemas de Classificação em Aprendizado Estatístico

- Classificação binária
- Função de perda e decisão
- Separabilidade linear e não linear
- Overfitting e generalização (preparando terreno para problemas de crédito, onde a separação perfeita é improvável e o trade-off entre viés e variância é crucial)
- Probabilidades preditas vs. classes previstas
- Threshold de decisão e custo de erro

2.3 [TO DO] Avaliação de Modelos de Classificação

- Desbalanceamento de classes (muito comum em dados de crédito, mas não no dataset atual)
- Matriz de confusão
- Accuracy, Precision, Recall, F1-score
- Curvas Precision–Recall
- Curva ROC e AUC
- Trade-off entre sensibilidade e especificidade
- Custo assimétrico de erros (FP vs FN)

2.4 [TO DO] Regressão Logística Frequentista

- Formulação do modelo

- Assumptions do modelo (e.g., independência, linearidade no logit, ausência de multicolinearidade)
- Parametrização e interpretação
- Interpretação dos coeficientes
- Função logística
- Estimação por máxima verossimilhança (e a função de verossimilhança)
- Testes de hipótese
- Intervalos de confiança
- Odds e odds ratio
- Limitações da abordagem frequentista

2.5 [TO DO] Inferência Bayesiana

- Teorema de Bayes aplicado à estatística
- diferenças conceituais
- parâmetros como variáveis aleatórias
- Priors, likelihood e posterior
- Incerteza e distribuição posterior
- Vantagens da abordagem bayesiana
- Atualização sequencial da evidência
- Interpretação probabilística
- controle de sobreajuste (...) **Encaixar o que mais fizer sentido aqui.**

2.6 [TO DO] Regressão Logística Bayesiana

(sempre traçando paralelos com a versão frequentista) - Formulação do modelo probabilístico - Escolha de priors - Inferência via MCMC / aproximações variacionais - Diagnóstico de convergência (R-hat, traceplots) - Intervalos credíveis - Sensibilidade a priors - Robustez em pequenas amostras - Interpretação dos coeficientes sob posterior - Comparação direta de MLE e MAP MAP- Maximum-a-Posteriori MLE- maximum likelyhood estimation (...) **Encaixar o que mais fizer sentido aqui.**

2.7 [TO DO] Aplicações em Risco de Crédito e Finanças

Não estender muito, acho que 1 página já deve ser suficiente, o foco é a comparação

(Contextualização) - Modelos de scoring de crédito - Variáveis financeiras e risco - Decisão de concessão de empréstimos - Uso das probabilidades preditas para gestão de risco - Transparência e interpretabilidade

- Em problemas de concessão de empréstimos, a incerteza é tão importante quanto a previsão.
- O enfoque bayesiano permite incorporar conhecimento prévio do risco.
- O enfoque frequentista fornece base tradicional de modelos de scoring.
- A comparação entre ambas abordagens permite avaliar robustez das decisões.

3 [WIP] Metodologia

Aqui entra o dataset como aplicação, não como foco teórico.

3.1 [DRAFT] Descrição dos Dados

encaixar a origem dos dados, o contexto de coleta, se tiver...

A base de dados utilizada neste estudo representa um conjunto de solicitações reais de empréstimos, contendo informações financeiras, patrimoniais e socioeconômicas dos solicitantes. Cada observação corresponde a um indivíduo, e o objetivo principal da variável resposta (`loan_status`) é indicar a aprovação ou rejeição do crédito. A Tabela 1 apresenta uma descrição detalhada das variáveis presentes no conjunto de dados.

Tabela 1: Descrição das variáveis do dataset

Feature	Descrição
No_of_dependents	Número de dependentes do solicitante
Education	Nível de escolaridade (Graduate / Not Graduate)
Self_employed	Autônomo (Yes / No)
Income_annum	Renda anual

Feature	Descrição
Loan_amount	Valor do empréstimo
Loan_term	Prazo em anos
Cibil_score	Score de crédito
Residential_assets_value	Bens residenciais
Commercial_assets_value	Bens comerciais
Luxury_assets_value	Bens de luxo
Bank_asset_value	Ativos bancários
Loan_status	Variável alvo (0/1)

3.2 [TBD] Pré-processamento

3.2.1 [TO DO] Verificação da Estrutura de dados e tratamento de valores ausentes

3.2.2 [TO DO] Outliers

ainda falta escrever

Não foi aplicado tratamento automático de outliers. Essa decisão foi motivada pelas seguintes considerações:

Valores extremos são esperados em dados financeiros; Podem representar perfis legítimos de alto patrimônio ou elevado risco de crédito; A remoção indiscriminada poderia eliminar informação relevante para a tarefa de classificação.

Do ponto de vista frequentista, modelos estimados por máxima verossimilhança podem ser sensíveis a observações extremas, uma vez que tais pontos influenciam diretamente o ajuste dos coeficientes. Técnicas adicionais, como regressão robusta ou winsorização, são comumente empregadas para mitigar esse efeito.

Na abordagem bayesiana, a incerteza dos parâmetros é explicitamente modelada por distribuições a posteriori. A utilização de distribuições com caudas mais pesadas, como a distribuição t de Student, permite acomodar valores extremos de forma natural, reduzindo

seu impacto sobre as estimativas centrais sem a necessidade de remoção explícita dos dados.

3.2.3 [TO DO] Codificação de variáveis categóricas

Variáveis categóricas foram transformadas em representações numéricas adequadas à modelagem.

3.2.4 [TO DO] Padronização de variáveis numéricas

As variáveis numéricas foram padronizadas com o objetivo de:

- Facilitar a convergência dos algoritmos de estimação;
- Permitir interpretação comparável dos coeficientes;
- Evitar que variáveis em escalas distintas dominem o processo de ajuste.

3.2.5 [TO DO] Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta $Y = \text{loan_status}$. Essa estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1).$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não viesada do erro de generalização, reduzindo o risco de sobreajuste (overfitting) e vazamento de informação.

3.3 [TO DO] Estratégia de Modelagem

- Separação treino/teste
- Validação cruzada (se usar)
- Métricas escolhidas

3.4 [TO DO] Modelos Avaliados

- Regressão logística frequentista
- Regressão logística bayesiana (e deixa uma subseção “Modelos adicionais”, caso queira)

4 [WIP] Resultados

4.1 [DRAFT] Análise Exploratória

A análise exploratória tem como finalidade compreender a estrutura dos dados, identificar padrões gerais, possíveis assimetrias, outliers e relações preliminares entre variáveis. Essa etapa é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

O conjunto de dados é composto por 4269 observações e 13 variáveis, incluindo a variável resposta `loan_status`, que indica se o empréstimo foi aprovado ou rejeitado. As variáveis preditoras incluem informações como renda anual, pontuação de crédito (`cibil_score`), nível educacional, entre outras características dos solicitantes.

4.1.1 Estatísticas univariadas

A Tabela 2 apresenta as principais estatísticas descritivas das variáveis numéricas do conjunto de dados, incluindo média, mediana, valor mínimo e máximo. Em média, os solicitantes apresentam aproximadamente 2 a 3 dependentes, renda anual em torno de 5 milhões e solicitam empréstimos próximos a 15 milhões. O prazo médio dos empréstimos

é de cerca de 11 anos, enquanto o score de crédito médio está próximo de 600 pontos. Esses valores sugerem uma população com perfil financeiro intermediário, mas com ampla variabilidade entre indivíduos, com desvios-padrão elevados.

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
no_of_dependents	2.5	3	0	5	1.7
income_annum	5.05912e+06	5.1e+06	200000	9.9e+06	2.80684e+06
loan_amount	1.51335e+07	1.45e+07	300000	3.95e+07	9.04336e+06
loan_term	10.9	10	2	20	5.71
cibil_score	599.94	600	300	900	172.43
residential_assets_value	7.47262e+06	5.6e+06	-100000	2.91e+07	6.50364e+06
commercial_assets_value	4.97316e+06	3.7e+06	0	1.94e+07	4.38897e+06
luxury_assets_value	1.51263e+07	1.46e+07	300000	3.92e+07	9.10375e+06
bank_asset_value	4.97669e+06	4.6e+06	0	1.47e+07	3.25019e+06

A Tabela 3 apresenta a distribuição das variáveis categóricas do conjunto de dados. Observa-se que as categorias analisadas exibem distribuições globalmente equilibradas, sem predominância acentuada de um único grupo, o que contribui para a estabilidade estatística e reduz potenciais vieses na etapa de modelagem.

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
no_of_dependents	0	712	16.68
no_of_dependents	1	697	16.33
no_of_dependents	2	708	16.58
no_of_dependents	3	727	17.03
no_of_dependents	4	752	17.62
no_of_dependents	5	673	15.76
education	Graduate	2144	50.22
education	Not Graduate	2125	49.78
self_employed	No	2119	49.64

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
self_employed	Yes	2150	50.36

As variáveis financeiras apresentam elevada amplitude e distribuição aproximadamente uniforme dentro de seus intervalos observados. Embora os desvios-padrão sejam elevados em termos absolutos, a análise gráfica feita na Figura 1 não indica forte assimetria ou concentração modal acentuada. Esse comportamento sugere heterogeneidade na amostra, mas com dispersão relativamente equilibrada ao longo do espaço amostral.


Além disso, `cibil_score` apresenta uma distribuição relativamente mais concentrada em torno da mediana, o que sugere menor variabilidade na avaliação de crédito em comparação com as variáveis patrimoniais. Esse comportamento pode indicar que o score de crédito atua como uma variável estabilizadora no processo de decisão de concessão de empréstimos.

Outro ponto relevante é a presença de valores mínimos negativos em `residential_assets_value`, o que pode indicar inconsistências de registro ou tratamentos contábeis específicos no conjunto de dados. Esse tipo de característica pode afetar a modelagem, exigindo atenção em etapas de pré-processamento, especialmente em modelos sensíveis à escala e à interpretação econômica das variáveis.


4.1.2 Análise da variável resposta e relações com as variáveis preditoras

Na Figura 2, observa-se a distribuição da variável resposta `loan_status`, indicando que aproximadamente 62.22% dos empréstimos foram aprovados, enquanto 37.78% foram rejeitados. Essa proporção sugere um desequilíbrio moderado na classe alvo, o que pode influenciar a escolha de métricas de avaliação e estratégias de modelagem.


A Figura 3 apresenta a estimativa de densidade para as variáveis numéricas do conjunto de dados, segmentadas pelo status de aprovação do empréstimo (Rejeitado ou Aprovado). Observa-se que a variável `cibil_score` é a que apresenta a separação mais nítida entre as




(a) Distribuição da renda anual




(b) Distribuição do valor do empréstimo




(c) Distribuição do prazo




(d) Distribuição do CIBIL score




(e) Distribuição dos ativos residenciais



(f) Distribuição dos ativos comerciais



(g) Distribuição dos bens de luxo



(h) Distribuição dos ativos bancários

Figura 1: Distribuição das principais variáveis numéricas do conjunto de dados




Figura 2: Distribuição da aprovação de empréstimos

classes: candidatos com scores mais baixos (aproximadamente abaixo de 600) concentram-se majoritariamente no grupo de rejeitados, enquanto scores elevados mostram uma densidade quase exclusiva de aprovações.

Em contraste, variáveis como `income_annum` e os diferentes tipos de ativos Figura 3 exibem distribuições sobrepostas e visualmente semelhantes entre as duas classes. Tal sobreposição indica que, isoladamente, essas variáveis possuem menor poder discriminatório, o que exigirá dos modelos de regressão a identificação de correlações mais complexas ou efeitos multivariados para contribuir com a predição. No que tange ao `loan_term`, nota-se uma ligeira predominância de rejeições em prazos muito curtos, enquanto os prazos mais longos apresentam uma distribuição mais equilibrada entre os grupos.

A Figura 4 apresenta a distribuição das frequências absolutas para as variáveis categóricas Nível educacional, Trabalho autônomo e Número de dependentes, segmentadas pelo status de aprovação. Diferente do observado na variável `cibil_score`, as variáveis categóricas exibem uma distribuição notavelmente homogênea entre as classes. Observa-se que a proporção entre empréstimos aprovados e rejeitados mantém-se praticamente constante, independentemente de o candidato ser graduado ou não, ou de possuir trabalho autônomo. No que tange ao número de dependentes, o comportamento é análogo: não há uma categoria específica (de 0 a 5 dependentes) que apresente uma vantagem ou desvantagem desproporcional na aprovação do crédito. Sob a ótica da modelagem estatística, essa independência aparente sugere que tais variáveis podem apresentar coeficientes com menor




Figura 3: Distribuição das variáveis numéricas por status de aprovação do empréstimo

magnitude ou maior incerteza .

4.1.3 Análise de correlação entre variáveis numéricas

A matriz de correlação (Figura 5) revela associações relevantes entre as variáveis financeiras do conjunto de dados. Observa-se forte correlação entre renda anual (`income_annum`) e valor do empréstimo (`loan_amount`), bem como entre essas variáveis e os ativos patrimoniais, especialmente ativos de luxo e ativos bancários, indicando que essas medidas capturam aspectos relacionados da condição financeira dos solicitantes. As correlações entre os diferentes tipos de ativos são positivas e moderadas, sugerindo coerência interna do perfil patrimonial, sem redundância perfeita entre as variáveis.

Por outro lado, o prazo do empréstimo (`loan_term`) apresenta correlação praticamente nula com as demais variáveis, indicando independência em relação ao perfil financeiro. De forma semelhante, o `cibil_score` exibe correlações muito fracas com renda, ativos e valor do empréstimo, sugerindo que essa variável representa uma dimensão distinta de




Figura 4: Distribuição das variáveis categóricas segundo o status do empréstimo

risco de crédito, relevante para a classificação, mas não diretamente associada ao nível de riqueza.

A presença de correlações elevadas entre algumas variáveis explicativas indica potencial multicolinearidade, aspecto que deve ser considerado na etapa de modelagem, especialmente na interpretação dos coeficientes da regressão logística.

	income_annum	loan_amount	loan_term	cibil_score
income_annum	1.000	0.927	0.011	-0.023
loan_amount	0.927	1.000	0.008	-0.017
loan_term	0.011	0.008	1.000	0.008
cibil_score	-0.023	-0.017	0.008	1.000
residential_assets_value	0.637	0.595	0.008	-0.020
commercial_assets_value	0.640	0.603	-0.005	-0.004
luxury_assets_value	0.929	0.861	0.012	-0.029
bank_asset_value	0.851	0.788	0.017	-0.015
	residential_assets_value		commercial_assets_value	

income_annum	0.637	0.640
loan_amount	0.595	0.603
loan_term	0.008	-0.005
cibil_score	-0.020	-0.004
residential_assets_value	1.000	0.415
commercial_assets_value	0.415	1.000
luxury_assets_value	0.591	0.591
bank_asset_value	0.527	0.549
	luxury_assets_value	bank_asset_value
income_annum	0.929	0.851
loan_amount	0.861	0.788
loan_term	0.012	0.017
cibil_score	-0.029	-0.015
residential_assets_value	0.591	0.527
commercial_assets_value	0.591	0.549
luxury_assets_value	1.000	0.789
bank_asset_value	0.789	1.000

4.1.4 Análise de outliers e dispersão

Complementarmente à análise de densidade, a Figura 6 apresenta os boxplots das mesmas variáveis, permitindo uma inspeção detalhada da dispersão, mediana e presença de valores atípicos (outliers). É notável que, novamente, a variável `cibil_score` destaca-se por apresentar uma separação clara entre as medianas dos grupos Rejeitado e Aprovado, com uma dispersão significativamente menor nos aprovados, reforçando o observado na Figura 3. Essa característica sugere que o `cibil_score` é um preditor robusto e com alta capacidade discriminatória para a classificação de risco de crédito.

Para as demais variáveis numéricas (como `loan_amount`, `income_annum` e os valores dos diferentes ativos) os boxplots confirmam a semelhança entre as distribuições dos grupos, com medianas e intervalos interquartílicos (IQR) altamente sobrepostos. Essa característica reforça a hipótese de que tais variáveis, por si sós, possuem baixo poder discriminatório para a classificação. A identificação de valores atípicos, especialmente em




Figura 5: Mapa de calor da correlação entre variáveis numéricas

`residential_assets_value` e `commercial_assets_value`, é um aspecto relevante para a modelagem: enquanto a inferência frequentista pode exigir o tratamento ou a robustez de estimadores frente a esses pontos, a abordagem bayesiana oferece a vantagem de modelar a incerteza desses outliers através de distribuições de cauda longa, permitindo uma avaliação mais flexível do impacto desses casos nos parâmetros estimados.

4.2 [WIP] Pré processamento

4.2.1 [DRAFT] Verificação de valores ausentes

A primeira etapa consistiu na verificação da presença de valores ausentes nas variáveis do conjunto de dados. A ausência de missing values elimina a necessidade de imputação, evitando a introdução de incerteza adicional ou viés sistemático.




Figura 6: Boxplots das variáveis numéricas por status de aprovação do empréstimo

4.2.2 [DRAFT] Tratamento de inconsistências e outliers

Observa-se que aproximadamente 0.01% dos solicitantes apresentam valores negativos para ativos residenciais, correspondendo a um contingente residual de observações atípicas. Esses valores não possuem interpretação econômica direta no contexto da variável analisada e podem estar associados a inconsistências de registro ou a particularidades não representativas do perfil financeiro da amostra. Considerando o caráter marginal dessas observações e seu potencial de introduzir ruído na estimação dos parâmetros, optou-se por removê-las do conjunto de dados, sem prejuízo à representatividade da amostra ou à validade inferencial dos modelos ajustados. A exclusão resultou na remoção de 28 observações.

Não foi aplicado tratamento automático de outliers, uma vez que valores extremos são esperados em dados financeiros e podem conter informação relevante para a classificação do risco de crédito.

4.2.3 [DRAFT] Seleção de variáveis e análise de correlação

A Figura 5 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas. Observou-se a presença de correlações elevadas entre variáveis associadas à escala de renda e patrimônio, como renda anual, valor do empréstimo e ativos financeiros, comportamento esperado em bases de dados financeiras.

Apesar dessas correlações, optou-se por não remover variáveis nesta etapa, uma vez que correlação elevada não implica, necessariamente, multicolinearidade prejudicial à estimação, e tais variáveis podem conter informação complementar relevante para a classificação do risco de crédito.

4.2.4 [DRAFT] Codificação e padronização de variáveis

Com o objetivo de tornar os dados adequados à aplicação de modelos de regressão logística, foi realizado um processo de codificação das variáveis categóricas e padronização das variáveis numéricas. As variáveis categóricas consideradas no estudo incluem: o nível educacional (Graduate / Not Graduate) e a condição de trabalho autônomo (Yes/No).

Essas variáveis foram tratadas por meio de one-hot encoding, convertendo cada categoria em variáveis indicadoras binárias. Para evitar problemas de multicolinearidade perfeita, uma categoria de referência foi removida em cada conjunto de dummies.

As variáveis numéricas foram padronizadas utilizando o método standard. Essa etapa garante que todas as variáveis estejam na mesma escala, facilitando a convergência dos algoritmos de estimação e permitindo uma interpretação mais comparável dos coeficientes estimados.

Ressalta-se que a padronização não altera a informação contida nos dados, mas apenas sua escala, sendo especialmente relevante em modelos que utilizam métodos de otimização numérica e em abordagens bayesianas, nas quais a escolha de distribuições a priori é sensível à magnitude dos parâmetros.

4.2.5 [DRAFT] Separação treino/teste

O conjunto de dados foi dividido aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação à variável resposta (`loan_status`). Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.3 [WIP] Modelagem e Avaliação

4.3.1 [TBD] Modelo Frequentista

```
modelo_logit <- glm(  
  loan_status ~ .,  
  data = treino,  
  family = binomial(link = "logit")  
)
```



```
summary(modelo_logit)
```

Call:

```
glm(formula = loan_status ~ ., family = binomial(link = "logit"),  
     data = treino)
```

Coefficients:

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.82901	0.13732	-13.319	< 2e-16 ***
no_of_dependents	0.07698	0.06896	1.116	0.264
income_annum	1.72713	0.29252	5.904	3.54e-09 ***
loan_amount	-1.44130	0.19212	-7.502	6.27e-14 ***
loan_term	0.89979	0.07540	11.934	< 2e-16 ***
cibil_score	-4.27739	0.16860	-25.369	< 2e-16 ***
residential_assets_value	-0.01233	0.09019	-0.137	0.891
commercial_assets_value	-0.04204	0.08831	-0.476	0.634
luxury_assets_value	-0.18698	0.18309	-1.021	0.307
bank_asset_value	-0.18645	0.12697	-1.468	0.142
`education_Not Graduate`	0.06477	0.13790	0.470	0.639
self_employed_Yes	-0.09346	0.13788	-0.678	0.498

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 4185.9 on 3180 degrees of freedom
Residual deviance: 1384.1 on 3169 degrees of freedom
AIC: 1408.1

Number of Fisher Scoring iterations: 7

```
exp(coef(modelo_logit))
```

(Intercept)	no_of_dependents	income_annum
0.16057175	1.08002394	5.62447745
loan_amount	loan_term	cibil_score
0.23661967	2.45908372	0.01387883
residential_assets_value	commercial_assets_value	luxury_assets_value
0.98774658	0.95882766	0.82945863
bank_asset_value	`education_Not Graduate`	self_employed_Yes
0.82989993	1.06691274	0.91077487

```
exp(confint(modelo_logit))
```

Waiting for profiling to be done...

	2.5 %	97.5 %
(Intercept)	0.122018483	0.20910668
no_of_dependents	0.943574730	1.23666686
income_annum	3.184593766	10.03410852
loan_amount	0.161710828	0.34357645
loan_term	2.126336692	2.85808482
cibil_score	0.009853959	0.01909253
residential_assets_value	0.827500113	1.17873366
commercial_assets_value	0.806438316	1.14029212
luxury_assets_value	0.579134971	1.18766548
bank_asset_value	0.646627846	1.06403124
`education_Not Graduate`	0.814289400	1.39863874
self_employed_Yes	0.694800768	1.19331435

```
# Probabilidades
```

```
prob_treino <- predict(modelo_logit, type = "response")
```

```
prob_teste <- predict(modelo_logit, newdata = teste, type = "response")
```

```

pred_treino <- ifelse(prob_treino >= 0.5, 1, 0)
pred_teste  <- ifelse(prob_teste  >= 0.5, 1, 0)
# Converter para factor com níveis alinhados
pred_treino_fac <- factor(pred_treino, levels = c(0, 1))
pred_teste_fac  <- factor(pred_teste,  levels = c(0, 1))

y_treino_fac <- factor(treino$loan_status, levels = c(0, 1))
y_teste_fac  <- factor(teste$loan_status,  levels = c(0, 1))

```

```

conf_treino <- confusionMatrix(
  data      = pred_treino_fac,
  reference = y_treino_fac,
  positive  = "1"
)

conf_treino

```

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	1884	146
1	126	1025

```

Accuracy : 0.9145
 95% CI : (0.9042, 0.924)
No Information Rate : 0.6319
P-Value [Acc > NIR] : <2e-16

```

```

Kappa : 0.8155

```

```

Mcnemar's Test P-Value : 0.2493

```

Sensitivity : 0.8753
 Specificity : 0.9373
 Pos Pred Value : 0.8905
 Neg Pred Value : 0.9281
 Prevalence : 0.3681
 Detection Rate : 0.3222
 Detection Prevalence : 0.3618
 Balanced Accuracy : 0.9063

 'Positive' Class : 1

```

conf_teste <- confusionMatrix(
  data      = pred_teste_fac,
  reference = y_teste_fac,
  positive  = "1"
)

conf_teste

```

Confusion Matrix and Statistics

	Reference	
Prediction	0	1
0	592	47
1	38	383

Accuracy : 0.9198
 95% CI : (0.9018, 0.9354)
 No Information Rate : 0.5943
 P-Value [Acc > NIR] : <2e-16

Kappa : 0.8331

McNemar's Test P-Value : 0.3855

Sensitivity : 0.8907

Specificity : 0.9397

Pos Pred Value : 0.9097

Neg Pred Value : 0.9264

Prevalence : 0.4057

Detection Rate : 0.3613

Detection Prevalence : 0.3972

Balanced Accuracy : 0.9152

'Positive' Class : 1

```
y_treino_num <- as.numeric(as.character(treino$loan_status))
y_teste_num  <- as.numeric(as.character(teste$loan_status))
roc_treino <- roc(
  response = y_treino_num,
  predictor = prob_treino,
  levels = c(0, 1),
  direction = "<"
)
```

```
roc_teste <- roc(
  response = y_teste_num,
  predictor = prob_teste,
  levels = c(0, 1),
  direction = "<"
)

auc_treino <- auc(roc_treino)
```

```


auc_teste <- auc(roc_teste)

plot(
  roc_treino,
  col = "blue",
  lwd = 2,
  main = "Curvas ROC - Treino vs Teste"
)

plot(
  roc_teste,
  col = "red",
  lwd = 2,
  add = TRUE
)

legend(
  "bottomright",
  legend = c(
    paste0("Treino (AUC = ", round(auc_treino, 3), ")"),
    paste0("Teste (AUC = ", round(auc_teste, 3), ")")
  ),
  col = c("blue", "red"),
  lwd = 2
)

```



```
# Treino
pr_treino <- pr.curve(
  scores.class0 = prob_treino[treino$loan_status == 1],
  scores.class1 = prob_treino[treino$loan_status == 0],
  curve = TRUE
)

# Teste
pr_teste <- pr.curve(
  scores.class0 = prob_teste[teste$loan_status == 1],
  scores.class1 = prob_teste[teste$loan_status == 0],
  curve = TRUE
)

plot(
  pr_treino$curve,
  type = "l",
  col = "blue",
  lwd = 2,
  xlab = "Recall",
```


```

ylab = "Precision",
main = "Precision-Recall Curve - Treino vs Teste"
)

lines(
  pr_teste$curve,
  col = "red",
  lwd = 2
)

legend(
  "bottomleft",
  legend = c(
    paste0("Treino (AUC-PR = ", round(pr_treino$auc.integral, 3), ")"),
    paste0("Teste (AUC-PR = ", round(pr_teste$auc.integral, 3), ")")
  ),
  col = c("blue", "red"),
  lwd = 2
)

```




```
metricas <- data.frame(
  Conjunto = c("Treino", "Teste"),
  Accuracy = c(conf_treino$overall["Accuracy"],
               conf_teste$overall["Accuracy"]),
  Sensitivity = c(conf_treino$byClass["Sensitivity"],
                 conf_teste$byClass["Sensitivity"]),
  Specificity = c(conf_treino$byClass["Specificity"],
                 conf_teste$byClass["Specificity"]),
  AUC = c(auc_treino, auc_teste),
  AUC_PR = c(pr_treino$auc.integral, pr_teste$auc.integral)
)

metricas
```

	Conjunto	Accuracy	Sensitivity	Specificity	AUC	AUC_PR
1	Treino	0.9144923	0.8753202	0.9373134	0.9692150	0.9404202
2	Teste	0.9198113	0.8906977	0.9396825	0.9703433	0.9511620

- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada) ### [TBD] Modelo Bayesiano
- Análise de Sensibilidade à Multicolinearidade (já que temos features com correlação elevada) ->avaliação do impacto ## [TBD] Desempenho Preditivo
- Tabela comparativa
- Curvas ROC
- Métricas

4.4 [TBD] Interpretação dos Modelos

- Coeficientes frequentistas
- Distribuições posteriores bayesianas
- Comparação de incerteza

5 [TBD] Discussão

- Diferenças conceituais observadas
- Robustez dos resultados
- Interpretabilidade
- Incerteza
- Aplicabilidade prática

teste de referencia Silva [1]

6 [TBD] Conclusão

- Síntese dos resultados
- Quando usar frequentista vs bayesiano
- Limitações

Breve explicação do problema, com principais resultados e propostas futuras

Referências

- [1] João Silva. *Introdução à Estatística*. Editora Exemplo, 2020.