

UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Binária Aplicada a Risco de Crédito

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Ago/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Binária Aplicada a Risco de Crédito

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Ago/2026

RESUMO

reavaliar os resumos

Este trabalho tem como objetivo comparar as abordagens de inferência frequentista e bayesiana no contexto de modelos de classificação. O foco principal do estudo está na análise das diferenças conceituais, inferenciais e preditivas entre essas duas abordagens estatísticas, utilizando um conjunto de dados reais como estudo de caso para a aplicação dos modelos.

Inicialmente, são discutidos os fundamentos teóricos das abordagens frequentista e bayesiana, destacando suas principais características, pressupostos e formas de interpretação dos parâmetros. Em seguida, realiza-se uma análise exploratória dos dados com o objetivo de compreender a estrutura das variáveis e subsidiar a construção dos modelos, sem que a análise dos dados constitua o foco central do trabalho.

Na etapa de modelagem, são ajustados modelos de classificação sob as perspectivas frequentista e bayesiana, permitindo a comparação entre as abordagens quanto ao desempenho preditivo, à interpretação dos coeficientes estimados e à quantificação da incerteza associada às estimativas. A avaliação dos modelos é realizada por meio de métricas adequadas de classificação, possibilitando uma análise sistemática das diferenças e semelhanças entre os métodos.

Por fim, os resultados obtidos evidenciam as vantagens e limitações de cada abordagem no contexto de problemas de classificação binária, contribuindo para uma compreensão mais aprofundada das implicações práticas e metodológicas da escolha entre inferência frequentista e bayesiana em aplicações de análise de risco de crédito e ciência de dados.

Palavras-chave: regressão estatística; inferência frequentista; inferência bayesiana; modelos preditivos; análise de risco de crédito.

ABSTRACT

This study aims to compare frequentist and Bayesian inference approaches in the context of regression models applied to the prediction of

Keywords: frequentist inference; Bayesian inference; regression models; predictive modeling; credit risk analysis.

Índice

1 Introdução **6**

1.1 Probabilidade de Inadimplência (PD) . . . 6

1.2 Regressão Logística na Modelagem do Risco de Crédito . . . 7

1.3 Abordagens Inferenciais na Regressão Logística . . . 7

1.4 Delimitação e Objetivos do Estudo . . . 8

2 Referencial Teórico **9**

2.1 Fundamentos de Probabilidade e Inferência Estatística . . . 9

2.1.1 Variáveis Aleatórias e Distribuições de Probabilidade . . . 9

2.1.2 Inferência Estatística . . . 9

2.1.3 Interpretações da probabilidade . . . 10

2.1.4 Teorema de Bayes . . . 11

2.2 Regressão Logística Frequentista . . . 12

2.2.1 Formulação do modelo . . . 12

2.2.2 Interpretação dos coeficientes . . . 14

2.2.3 Função de verossimilhança e estimação por máxima verossimilhança 16

2.2.4 Diagnóstico e qualidade do ajuste . . . 18

2.2.5 Assumptions do modelo . . . 22

2.2.6 Regularização e seleção de variáveis . . . 23

2.3 Regressão Logística Bayesiana . . . 26

2.3.1 Formulação do modelo . . . 26

2.3.2 Escolha de distribuições *a priori* . . . 27

2.3.3 Distribuições *a posteriori* . . . 31

2.3.4 Inferência via MCMC . . . 35

2.4 Avaliação de modelos de classificação . . . 41

2.4.1 Matriz de confusão . . . 41

2.4.2 Comparação entre probabilidades previstas e valores observados . . 43

3 Metodologia **46**

3.1 Descrição dos Dados . . . 46

3.2 Pré-processamento . . . 47

3.2.1 Estrutura de dados e tratamento de valores ausentes 47
3.2.2 Outliers 48
3.2.3 Correlação 49
3.2.4 Padronização de variáveis numéricas 49
3.2.5 Divisão entre treino e teste 50
3.3 Modelos Avaliados 51
3.3.1 Regressão logística frequentista 51
3.3.2 Regressão logística bayesiana 52
3.3.3 Métricas de avaliação 53

4 Resultados **54**
4.1 Análise Exploratória 54
4.1.1 Estatísticas univariadas 54
4.1.2 Avaliação da variável resposta 58
4.1.3 Análise de correlação entre variáveis numéricas 59
4.1.4 Análise de outliers 60
4.2 Pré processamento do dataset 62
4.2.1 Seleção de variáveis e análise de correlação 62
4.2.2 Separação treino/teste 63
4.3 Modelagem e Avaliação 63
4.3.1 Modelagem Frequentista 63
4.3.2 Modelagem Bayesiana 72

5 Discussão **92**
5.1 Sensibilidade às distribuições a priori e o papel do tamanho amostral . . . 92
5.2 Multicolinearidade: tratamento e implicações 93
5.3 Diferenças inferenciais entre as abordagens 94
5.4 Desbalanceamento de classes e limitações práticas 95

6 Conclusão **96**

Referências **98**

1 Introdução

A atividade de concessão de crédito envolve decisões tomadas sob incerteza, nas quais existe sempre a possibilidade de que o tomador não cumpra integralmente suas obrigações financeiras. Esse descumprimento pode manifestar-se na forma de atrasos, pagamentos parciais ou inadimplência total, e está frequentemente associado a mudanças inesperadas nas condições econômicas ou financeiras do indivíduo, como perda de renda, instabilidade profissional ou choques temporários de liquidez. Mesmo tomadores com histórico financeiro consistente não estão imunes a esse tipo de risco ao longo do tempo.

A avaliação do risco de crédito é, portanto, um componente central da gestão financeira das instituições que operam no mercado de empréstimos e concessão de crédito. Do ponto de vista operacional, essa avaliação subsidia decisões relacionadas à aprovação ou rejeição de propostas de crédito, bem como à definição de condições contratuais compatíveis com o nível de risco assumido. Em uma perspectiva mais ampla, a estimativa da probabilidade de inadimplência em nível agregado permite antecipar perdas potenciais e orientar estratégias de alocação de capital, fundamentais para a estabilidade financeira das instituições. Uma concentração excessiva de inadimplência pode comprometer a solvência de intermediários financeiros, tornando indispensável a adoção de mecanismos preventivos de controle e monitoramento do risco.

Nesse cenário, modelos estatísticos têm sido amplamente empregados como ferramentas para quantificar o risco de crédito a partir de informações observáveis sobre os tomadores. Ao relacionar características socioeconômicas, financeiras e comportamentais com a ocorrência de inadimplência, esses modelos permitem estimar probabilidades individuais de default e identificar padrões relevantes para a gestão do portfólio de crédito. Além de contribuir para a redução de perdas esperadas, tais modelos oferecem suporte à tomada de decisão baseada em evidências, reforçando a eficiência e a consistência das políticas de concessão de crédito.

1.1 Probabilidade de Inadimplência (PD)

No contexto da concessão de crédito, a mensuração do risco associado a cada operação exige mais do que a simples distinção entre bons e maus pagadores. É necessário quantificar, de

forma probabilística, a chance de que um tomador venha a entrar em inadimplência dentro de um horizonte de tempo específico. Essa medida é conhecida como `Probability of Default` (PD) e constitui um dos pilares centrais da gestão moderna de risco de crédito.

A PD representa a probabilidade de que um contrato de crédito apresente um evento de default definido previamente, como atraso superior a um determinado número de dias ou a incapacidade total de honrar os pagamentos. Ao contrário de abordagens puramente classificatórias, a modelagem da PD fornece uma escala contínua de risco, permitindo ordenar tomadores de acordo com sua propensão ao default e estabelecer políticas diferenciadas de concessão, precificação e monitoramento. Essa característica torna a PD particularmente relevante tanto para decisões individuais, como a aprovação de um empréstimo, quanto para avaliações agregadas do risco da carteira.

1.2 Regressão Logística na Modelagem do Risco de Crédito

A estimação da probabilidade de inadimplência pode ser conduzida por meio de modelos estatísticos que relacionam uma variável resposta binária a um conjunto de variáveis explicativas. Entre as alternativas disponíveis, a regressão logística destaca-se por sua adequação a esse tipo de problema, uma vez que permite modelar diretamente a probabilidade de ocorrência de um evento, restringindo as estimativas ao intervalo entre zero e um.

No contexto do risco de crédito, essa abordagem possibilita investigar como características demográficas, condições financeiras e histórico de pagamentos estão associados à ocorrência de inadimplência. Além da estimativa das probabilidades individuais, a regressão logística oferece parâmetros interpretáveis, cuja análise permite avaliar a direção e a intensidade das associações entre os preditores e o evento de interesse. Dessa forma, o modelo reúne características relevantes tanto para a investigação inferencial quanto para a construção de ferramentas de classificação e previsão de risco.

1.3 Abordagens Inferenciais na Regressão Logística

A estimação dos parâmetros de um modelo de regressão logística pode ser realizada sob diferentes perspectivas inferenciais, entre as quais se destacam as abordagens frequentista e bayesiana. Embora ambas utilizem a informação contida nos dados para produzir

estimativas e avaliar a incerteza associada aos parâmetros, elas se fundamentam em interpretações distintas da probabilidade e do processo de inferência.

Na perspectiva frequentista, os parâmetros são tratados como quantidades fixas estimadas por máxima verossimilhança, com a incerteza expressa por intervalos de confiança; na bayesiana, são variáveis aleatórias, e a inferência combina a verossimilhança com distribuições a priori para produzir distribuições a posteriori. Os fundamentos e as diferenças conceituais entre essas perspectivas são discutidos em detalhe no Referencial Teórico.

A comparação entre essas perspectivas é particularmente relevante em problemas de risco de crédito, nos quais a qualidade das estimativas e a quantificação da incerteza podem influenciar a interpretação dos fatores associados à inadimplência. Além disso, a abordagem bayesiana permite investigar o efeito de diferentes especificações de distribuições a priori sobre os parâmetros estimados, introduzindo uma dimensão adicional à análise comparativa.

1.4 Delimitação e Objetivos do Estudo

Diante dessas considerações, este trabalho investiga a aplicação de modelos de regressão logística à previsão de inadimplência em cartões de crédito, sob as perspectivas frequentista e bayesiana. Para isso, utiliza-se a base de dados *Default of Credit Card Clients*, que reúne informações de 30.000 clientes e contempla características demográficas, limite de crédito, valores de faturas e histórico de pagamentos. A variável resposta, denominada `PD30`, identifica a ocorrência de inadimplência no mês subsequente, caracterizando um problema de classificação binária.

A questão que orienta a pesquisa é: **em que medida as abordagens frequentista e bayesiana produzem resultados distintos na estimação, interpretação e previsão da inadimplência em cartões de crédito, e como diferentes distribuições a priori influenciam os resultados da inferência bayesiana?**

Assim, o objetivo geral deste trabalho é comparar as abordagens frequentista e bayesiana na modelagem da inadimplência em cartões de crédito por meio da regressão logística, considerando aspectos inferenciais e preditivos.

2 Referencial Teórico

2.1 Fundamentos de Probabilidade e Inferência Estatística

2.1.1 Variáveis Aleatórias e Distribuições de Probabilidade

A formalização da incerteza em experimentos aleatórios ocorre por meio de variáveis aleatórias, que representam os resultados de um espaço amostral em uma escala numérica. Essa estrutura fundamenta o tratamento quantitativo de dados e a construção de modelos de probabilidade, servindo de base para a inferência estatística e machine learning.

As variáveis aleatórias são classificadas em discretas ou contínuas, a depender da natureza de seu suporte. As discretas assumem valores em conjuntos finitos ou enumeráveis, como a decisão de aprovação de crédito ou o número de ocorrências de inadimplência. Já as contínuas podem assumir qualquer valor em intervalos reais, como a renda dos proponentes. A incerteza inerente a essas variáveis é formalizada por distribuições de probabilidade: no domínio discreto, pela função de massa de probabilidade e, no contínuo, pela função densidade de probabilidade. Tais funções não apenas sintetizam a natureza probabilística das variáveis, mas viabilizam o cálculo de medidas fundamentais, como esperança, variância e probabilidades condicionais, elementos centrais para a modelagem de risco. A escolha apropriada de distribuições de probabilidade é fundamental para capturar a variabilidade dos dados observados e para a construção de modelos inferenciais capazes de quantificar a incerteza associada às previsões.

2.1.2 Inferência Estatística

A inferência estatística reúne os métodos que permitem extrair conclusões sobre uma população ampla a partir de uma amostra reduzida. Na prática, quando não é viável analisar cada indivíduo ou produto de um grupo inteiro, utilizamos os dados amostrais para realizar estimativas e previsões, fundamentadas em modelos que conectam o que observamos aos parâmetros que desejamos descobrir.

O elemento central desse processo é a aceitação da incerteza. Como os dados estão sujeitos a variações e erros de medição, a inferência utiliza estruturas probabilísticas para descrever

o comportamento da população (o conjunto total de elementos) com base na amostra, que é o subconjunto efetivamente analisado. Como a população é quase sempre muito maior que a amostra, as conclusões obtidas não são certezas absolutas, mas sim afirmações probabilísticas. O processo consiste em utilizar uma amostra aleatória para testar o modelo estatístico que representa a população, acompanhando cada conclusão de uma medida que quantifica o seu grau de confiabilidade. Esse caminho envolve escolher um modelo adequado para o fenômeno e deduzir informações sobre seus parâmetros desconhecidos.

2.1.3 Interpretações da probabilidade

A noção de probabilidade ocupa um papel central na inferência estatística, sendo a base para quantificar e interpretar a incerteza. Atualmente, essa análise é conduzida por dois grandes paradigmas, o frequentista e o bayesiano, que se distinguem essencialmente na interpretação do conceito de probabilidade e no tratamento da incerteza dos parâmetros.

Na abordagem frequentista, tradicionalmente associada à estatística clássica, a probabilidade é entendida a partir da repetição de um experimento sob as mesmas condições. Dentro dessa visão, a probabilidade é vista como uma característica objetiva do processo que gera os dados, e não como algo que depende do observador. Os dados coletados são tratados como realizações aleatórias, enquanto os parâmetros do modelo estatístico que descreve a população são considerados valores fixos, ainda que desconhecidos. Assim, a incorporação de novas observações não altera diretamente o conceito de probabilidade, mas contribui para estimativas mais precisas desses parâmetros por meio de métodos inferenciais.

Já na abordagem bayesiana, a probabilidade assume um papel mais amplo, sendo interpretada como um grau de crença ou plausibilidade em uma afirmação, condicionado às informações disponíveis. Nesse contexto, probabilidades podem ser atribuídas não apenas a eventos observáveis, mas também a hipóteses e parâmetros do modelo. Os parâmetros desconhecidos são tratados como variáveis aleatórias, cuja incerteza é descrita por distribuições de probabilidade. O conhecimento prévio pode ser incorporado por meio de distribuições a priori e, à medida que novos dados são observados, esse conhecimento é atualizado de forma sistemática pelo teorema de Bayes, resultando em uma distribuição a posteriori que combina informação prévia e evidência empírica.

2.1.4 Teorema de Bayes

O Teorema de Bayes constitui o fundamento da inferência bayesiana, estabelecendo uma regra para atualizar o conhecimento sobre um parâmetro desconhecido à medida que novas evidências são observadas. Diferentemente da abordagem frequentista, na qual os parâmetros são considerados fixos, a inferência bayesiana representa a incerteza sobre esses parâmetros por meio de distribuições de probabilidade.

Matematicamente, o Teorema de Bayes é expresso por:

$$p(\theta \mid y) = \frac{p(y \mid \theta)\, p(\theta)}{p(y)}, \tag{1}$$

em que:

- $p(\theta \mid y)$ é a **distribuição a posteriori**, representando o conhecimento atualizado sobre o parâmetro θ após a observação dos dados y;
- $p(y \mid \theta)$ é a **função de verossimilhança**, que quantifica a probabilidade de observar os dados para um determinado valor do parâmetro;
- $p(\theta)$ é a **distribuição a priori**, responsável por representar o conhecimento ou as crenças existentes sobre o parâmetro antes da observação dos dados;
- $p(y)$ é a **distribuição marginal dos dados**, também denominada evidência, dada por

$$p(y) = \int p(y \mid \theta) p(\theta)\, d\theta, \tag{2}$$

a qual garante que a distribuição a posteriori seja devidamente normalizada, isto é, que sua integral seja igual a um.

Em termos conceituais, o Teorema de Bayes estabelece que a distribuição a posteriori é proporcional ao produto entre a verossimilhança e a distribuição a priori, isto é,

$$p(\theta \mid y) \propto p(y \mid \theta)\, p(\theta), \tag{3}$$

visto que o termo $p(y)$ não depende do parâmetro θ. Na prática, essa forma proporcional é frequentemente utilizada em métodos computacionais de inferência, como os algoritmos de Monte Carlo via Cadeias de Markov (MCMC), nos quais não é necessário calcular explicitamente a constante de normalização.

2.2 Regressão Logística Frequentista

Seja Y a variável resposta, assumindo valor $Y = 1$ quando ocorre inadimplência e $Y = 0$ caso contrário. O objetivo do modelo consiste em estimar a probabilidade condicional de ocorrência desse evento, representada por $P(Y = 1 \mid \theta)$, em que θ denota a probabilidade de inadimplência associada a um determinado tomador. Assumindo que Y segue uma distribuição de Bernoulli, tem-se que $P(Y = 1 \mid \theta) = \theta$, enquanto a probabilidade de não ocorrência do evento é dada por $P(Y = 0 \mid \theta) = 1 - \theta$. Dessa forma, o parâmetro θ corresponde diretamente à Probabilidade de Inadimplência (PD), principal quantidade de interesse na modelagem de risco de crédito.

Diversos modelos podem ser utilizados para estimar essa probabilidade em função das características observadas dos tomadores. Neste trabalho, será empregada a regressão logística, por se tratar de um dos modelos mais difundidos para problemas de resposta binária, oferecendo estimativas probabilísticas de fácil interpretação e ampla aplicação em modelos de credit scoring.

2.2.1 Formulação do modelo

O objetivo da regressão logística consiste, portanto, em modelar a probabilidade de ocorrência do evento de interesse como uma função das variáveis explicativas observadas. Em vez de considerar uma única probabilidade para toda a população, admite-se que cada observação i possui sua própria probabilidade de inadimplência, denotada por θ_i. Dessa forma,

$$Y_i \mid \theta_i \sim \text{Bernoulli}(\theta_i), \tag{4}$$

onde

$$P(Y_i = 1 \mid \theta_i) = \theta_i \qquad \text{e} \qquad P(Y_i = 0 \mid \theta_i) = 1 - \theta_i. \tag{5}$$

O objetivo da regressão logística é modelar a probabilidade θ_i em função das variáveis explicativas. Entretanto, como probabilidades estão restritas ao intervalo $(0, 1)$, não é adequado modelá-las diretamente por meio de uma combinação linear dos preditores. Para contornar essa limitação, utiliza-se uma função de ligação que transforma a probabilidade em uma quantidade definida em toda a reta real. Na regressão logística, essa transformação é realizada pela função logit, definida por

$$\theta = \log\left(\frac{\theta}{1-\theta}\right). \tag{6}$$

A equação acima descreve a transformação da probabilidade para a escala dos logaritmos das chances (log-odds). Como o objetivo do modelo é estimar probabilidades, após modelar essa quantidade como uma função linear das variáveis explicativas aplica-se a transformação inversa da função logit, denominada função logística (ou função sigmoide). Enquanto a função logit transforma probabilidades em valores pertencentes à reta real, a função logística realiza o processo inverso, convertendo o preditor linear em uma probabilidade restrita ao intervalo (0,1). Assim, definindo o preditor linear como

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} \tag{7}$$

em que β_0 representa o intercepto do modelo e β_j $(j = 1, \ldots, p)$ corresponde ao coeficiente associado à variável explicativa x_{ij}. Dessa forma, o preditor linear resume, em um único valor, o efeito conjunto de todas as covariáveis sobre a resposta. Então a probabilidade de ocorrência do evento é dada por

$$\theta_i = \frac{1}{1 + \exp(-\eta_i)}. \tag{8}$$

A Figura 1 ilustra o comportamento da função logística para um modelo com uma única variável preditora, considerando $\beta_0 = 0$ e $\beta_1 = 1$. Observa-se que, à medida que o preditor linear aumenta, a probabilidade do evento cresce, aproximando-se de zero para valores

muito negativos e de um para valores muito positivos. O ponto de inflexão da curva ocorre quando $\eta_i = 0$, situação em que a probabilidade do evento é igual a 0,5.

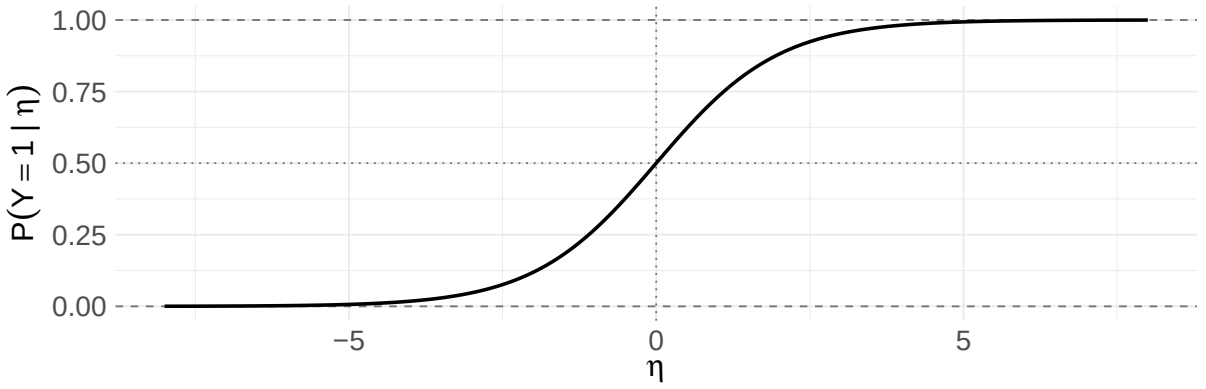


Figura 1: Função logística para um modelo com uma única variável preditora ($\beta_0 = 0$ e $\beta_1 = 1$).

2.2.2 Interpretação dos coeficientes

Como exemplo, considere o seguinte modelo de crédito:

$$\eta = -3 + 0.04 \cdot \text{Score} - 0.8 \cdot \text{Atraso} + 0.2 \cdot \text{Renda}.$$

Para um determinado solicitante, a substituição dos valores observados das variáveis explicativas resulta em um valor para η. Supondo que, para esse indivíduo, obtenha-se $\eta = 1.5$, a função logística fornece a probabilidade estimada de ocorrência do evento como

$$\theta = \frac{1}{1 + \exp(-1.5)} \approx 0.82.$$

Esse exemplo evidencia o funcionamento da regressão logística: inicialmente, as variáveis explicativas são combinadas linearmente para produzir o preditor η; em seguida, a função logística transforma esse valor em uma probabilidade pertencente ao intervalo $(0, 1)$.

Uma das principais vantagens da regressão logística é a possibilidade de interpretar o efeito das variáveis explicativas sobre o risco do evento de interesse. Considerando o preditor linear apresentado na Equação 7, cada coeficiente β_j representa a variação esperada no

logaritmo das chances (*log-odds*) associada ao aumento de uma unidade da variável x_j, mantendo as demais variáveis constantes.

No modelo apresentado anteriormente, o coeficiente associado à variável **Score** é igual a 0.04. Isso significa que, para cada aumento de uma unidade no Score, o preditor linear η aumenta em 0.04, desde que as demais variáveis permaneçam constantes. De forma análoga, cada atraso adicional reduz o preditor linear em 0.8 unidades.

Como a função logística é crescente, coeficientes positivos aumentam a probabilidade estimada do evento, enquanto coeficientes negativos a reduzem. Entretanto, esse efeito não corresponde a um aumento constante da probabilidade. Um mesmo incremento em η pode produzir variações distintas em θ, dependendo da região da curva logística em que a observação se encontra.

Para ilustrar esse comportamento, considere novamente o solicitante para o qual foi obtido $\eta = 1.5$. A probabilidade estimada de inadimplência é dada por

$$\theta = \frac{1}{1 + \exp(-1.5)} \approx 0.818.$$

Suponha agora que o Score desse solicitante aumente em uma unidade. Como o coeficiente associado ao Score é igual a 0.04, o novo preditor linear passa a ser

$$\eta' = 1.5 + 0.04 = 1.54.$$

Aplicando novamente a função logística,

$$\theta' = \frac{1}{1 + \exp(-1.54)} \approx 0.824.$$

Observa-se que o aumento de uma unidade no Score elevou a probabilidade estimada de aproximadamente 81.8% para 82.4%. Esse resultado decorre do fato de que a função logística é estritamente crescente: sempre que o coeficiente de uma variável é positivo, um aumento nessa variável produz um valor maior para o preditor linear η, o que, por sua vez, resulta em uma probabilidade também maior. De forma análoga, quando o coeficiente é

negativo, um aumento na variável reduz o valor de η e, consequentemente, a probabilidade estimada.

É importante destacar, entretanto, que o efeito de uma unidade adicional em uma variável não corresponde a um aumento fixo na probabilidade. Como a transformação entre η e θ é não linear, um mesmo incremento no preditor linear pode produzir variações diferentes na probabilidade. Em geral, mudanças em η têm maior impacto quando a probabilidade está próxima de 0.5 e menor efeito quando ela já se aproxima de 0 ou de 1.

2.2.3 Função de verossimilhança e estimação por máxima verossimilhança

Na abordagem frequentista, os parâmetros da regressão logística são estimados por meio do método de **máxima verossimilhança**. O método procura encontrar o conjunto de parâmetros que torna os dados observados mais prováveis segundo o modelo assumido.

Considerando uma variável resposta binária Y_i, com $Y_i = 1$ representando a ocorrência do evento de interesse (por exemplo, inadimplência), assume-se que cada observação segue uma distribuição Bernoulli:

$$Y_i \sim Bernoulli(p_i) \tag{9}$$

onde p_i representa a probabilidade de ocorrência do evento para o indivíduo i, estimada pela função logística apresentada na Equação 8.

Sob a premissa de que as observações são estatisticamente independentes, a probabilidade conjunta de observar todo o conjunto de dados da variável resposta é obtida pelo produto de suas probabilidades individuais. Essa expressão matemática define a função de verossimilhança ($L(\beta \mid y, X)$) do modelo. Na prática, ela quantifica a plausibilidade de um vetor de coeficientes (β) (as inclinações da reta ou do hiperplano de regressão) ter gerado os valores observados de (y), dado o conhecimento prévio das variáveis explicativas (X). Podendo ser expressa por:

$$L(\beta \mid y, X) = \prod_{i=1}^{n} p_i^{y_i}(1 - p_i)^{1-y_i} \tag{10}$$

A estimação por máxima verossimilhança consiste em encontrar o vetor de parâmetros β que maximiza essa função:

$$\hat{\beta} = \arg\max_{\beta} L(\beta \mid y, X) \tag{11}$$

Em outras palavras, os coeficientes estimados são aqueles que tornam os dados observados mais compatíveis com o modelo probabilístico definido.

Na prática, entretanto, a otimização é realizada utilizando o **logaritmo da função de verossimilhança**, denominado log-verossimilhança:

$$\ell(\beta) = \log L(\beta \mid y, X) \tag{12}$$

A utilização da log-verossimilhança não altera o ponto de máximo da função original, pois o logaritmo é uma transformação monotônica crescente. Portanto, maximizar a verossimilhança é equivalente a maximizar sua versão logarítmica.

Além disso, a transformação apresenta vantagens computacionais importantes. Como a função de verossimilhança envolve o produto de muitas probabilidades menores que um, a multiplicação de diversos termos pode gerar valores numericamente próximos de zero, causando problemas de precisão computacional. Ao aplicar o logaritmo, o produto é convertido em uma soma:

$$\ell(\beta) = \sum_{i=1}^{n} [y_i \log(p_i) + (1 - y_i) \log(1 - p_i)] \tag{13}$$

Essa forma é mais estável numericamente e facilita os procedimentos de otimização utilizados para encontrar os parâmetros do modelo.

É importante destacar que a função de verossimilhança possui papel central tanto na abordagem frequentista quanto na abordagem Bayesiana. A diferença fundamental está na forma como as informações são combinadas. No método frequentista, a verossimilhança é utilizada diretamente para obter uma estimativa pontual dos parâmetros, enquanto na abordagem Bayesiana ela é combinada com uma distribuição a priori por meio do teorema de Bayes, resultando na distribuição posterior dos parâmetros.

No contexto frequentista, após a estimação dos coeficientes, a incerteza dos parâmetros é geralmente avaliada por meio de testes de hipótese e intervalos de confiança. Os testes permitem avaliar, por exemplo, se determinada variável explicativa apresenta evidência estatística de associação com o evento de interesse, enquanto os intervalos de confiança fornecem uma faixa de valores plausíveis para os coeficientes estimados.

Apesar de sua ampla utilização, a abordagem frequentista apresenta algumas limitações. A interpretação dos resultados depende de propriedades assintóticas dos estimadores, ou seja, da aproximação dos resultados quando o tamanho da amostra aumenta. Além disso, os intervalos de confiança e testes de hipótese possuem interpretação baseada no procedimento de amostragem repetida, o que pode ser menos intuitivo em problemas aplicados. Em situações com poucos dados, alta dimensionalidade ou presença de forte regularização, essas propriedades podem ser menos adequadas, motivando a utilização de abordagens alternativas, como a modelagem Bayesiana.

2.2.4 Diagnóstico e qualidade do ajuste

Após a estimação dos parâmetros por máxima verossimilhança, é necessário avaliar se o modelo obtido representa adequadamente os dados observados. A avaliação do modelo normalmente envolve um conjunto de diagnósticos voltados à identificação de observações influentes, problemas de multicolinearidade, adequação do ajuste e comparação entre modelos concorrentes.

2.2.4.1 Análise de resíduos

Embora a regressão logística não apresente resíduos normalmente distribuídos como na regressão linear, diferentes medidas de resíduos podem ser utilizadas para avaliar a adequação do modelo e identificar observações potencialmente problemáticas. Como a variável resposta é binária, assumindo valores 0 ou 1, enquanto o modelo estima probabilidades de ocorrência do evento, os resíduos na regressão logística procuram quantificar a discrepância entre o resultado observado e a probabilidade estimada para cada observação.

Valores de resíduos próximos de zero indicam maior compatibilidade entre os valores observados e as probabilidades estimadas, enquanto valores absolutos elevados podem indicar observações mal ajustadas ou possíveis inconsistências na especificação do modelo. Entretanto, observações discrepantes não devem ser automaticamente removidas, pois podem representar tanto erros nos dados quanto indivíduos com características incomuns, mas relevantes para o fenômeno estudado. Entre as medidas utilizadas para esse diagnóstico destacam-se os resíduos de Pearson e de Deviance.

O resíduo de Pearson mede a diferença entre o valor observado e a probabilidade estimada pelo modelo, padronizada pelo desvio padrão esperado da distribuição Bernoulli:

$$r_i^P = \frac{y_i - p_i}{\sqrt{p_i(1-p_i)}} \tag{14}$$

onde y_i representa o valor observado da variável resposta e p_i corresponde à probabilidade estimada para a observação i. A padronização permite comparar observações com diferentes probabilidades estimadas, sendo que valores absolutos elevados indicam possíveis observações incompatíveis com o ajuste do modelo.

O resíduo de Deviance, por sua vez, avalia a contribuição individual de cada observação para a *deviance* total do modelo, medida baseada na função de verossimilhança que quantifica a discrepância entre o modelo ajustado e um modelo saturado. Assim como no resíduo de Pearson, valores elevados indicam observações que apresentam maior discrepância em relação às previsões do modelo.

Enquanto os resíduos avaliam o ajuste individual das observações, a distância de Cook procura identificar observações influentes, ou seja, aquelas cuja remoção poderia alterar significativamente as estimativas dos coeficientes do modelo. Uma observação influente não necessariamente representa um erro nos dados, podendo indicar um perfil incomum ou pouco representado pelas variáveis explicativas. Em aplicações de crédito, por exemplo, clientes com características atípicas podem refletir situações reais que não devem ser automaticamente excluídas da análise, mas investigadas de forma complementar.

2.2.4.2 Diagnóstico de multicolinearidade

A presença de multicolinearidade entre as variáveis explicativas pode comprometer a interpretação dos coeficientes estimados, aumentando sua variância e tornando as estimativas menos precisas. Embora esse fenômeno não comprometa necessariamente a capacidade preditiva do modelo, pode dificultar a avaliação do efeito individual de cada variável explicativa.

Uma das medidas mais utilizadas para avaliar a multicolinearidade é o `Variance Inflation Factor` (VIF), que quantifica o quanto a variância do coeficiente associado à variável (x_j) é inflada devido à sua correlação linear com as demais variáveis explicativas. O VIF é definido por:

$$VIF_j = \frac{1}{1 - R_j^2} \tag{15}$$

onde R_j^2 corresponde ao coeficiente de determinação obtido ao ajustar uma regressão linear tendo a variável x_j como resposta e as demais variáveis explicativas como preditoras. Esse valor representa a proporção da variabilidade de x_j que pode ser explicada linearmente pelas demais variáveis do modelo. Assim, valores elevados de R_j^2 indicam que x_j contém informações semelhantes às demais variáveis explicativas, resultando em um maior VIF.

Valores de VIF próximos de 1 indicam baixa correlação entre a variável e os demais preditores, enquanto valores elevados sugerem maior grau de multicolinearidade. Embora não exista um limite universalmente aceito, valores superiores a 5 costumam indicar um nível moderado de multicolinearidade, ao passo que valores acima de 10 são frequentemente considerados evidências de forte multicolinearidade.

É importante destacar que a presença de multicolinearidade não implica, necessariamente, que o modelo deva ser descartado ou que as variáveis envolvidas precisem ser removidas. Em muitos problemas aplicados, como na análise de crédito, diferentes indicadores financeiros podem representar aspectos semelhantes do perfil do cliente, sendo naturalmente correlacionados. Nesses casos, o diagnóstico deve ser interpretado em conjunto com os objetivos da análise e com as estratégias de modelagem adotadas. Além disso, em modelos que utilizam técnicas de regularização, parte dos efeitos da multicolinearidade pode ser mitigada pelas penalizações impostas aos coeficientes.

2.2.4.3 Avaliação global do ajuste

A `deviance` é uma medida baseada na função de verossimilhança que quantifica a discrepância entre o modelo ajustado e o modelo saturado, isto é, um modelo que reproduz perfeitamente os dados observados. Dessa forma, valores menores de `deviance` indicam menor discrepância entre as probabilidades estimadas pelo modelo e os valores observados.

Na regressão logística, a `deviance` é frequentemente utilizada para avaliar a contribuição das variáveis explicativas para o ajuste do modelo. A saída dos modelos estimados geralmente apresenta dois valores principais: a `Null deviance`, correspondente ao ajuste de um modelo contendo apenas o intercepto, e a `Residual deviance`, correspondente ao modelo contendo as variáveis explicativas. Assim, uma redução da `deviance` residual em relação à `deviance` nula indica que a inclusão das variáveis explicativas proporciona uma melhora no ajuste em relação ao modelo sem preditores.

A diferença entre esses dois valores está relacionada ao teste da razão de verossimilhança, utilizado para comparar modelos aninhados e avaliar se a inclusão de novas variáveis explicativas produz uma melhora estatisticamente significativa no ajuste. O teste é baseado na diferença entre as log-verossimilhanças dos modelos:

$$D = -2\left[\ell_0 - \ell_1\right] \tag{16}$$

onde ℓ_0 representa a log-verossimilhança do modelo restrito e ℓ_1 a log-verossimilhança do modelo completo. Valores maiores da estatística χ^2 indicam uma maior diferença entre os modelos e, consequentemente, maior evidência de que o modelo completo apresenta melhor ajuste.

Os graus de liberdade associados às deviances também são relevantes para a avaliação do ajuste. Em modelos de regressão logística, os graus de liberdade da deviance residual correspondem à diferença entre o número de observações e o número de parâmetros estimados, enquanto os da deviance nula correspondem ao número de observações menos um, considerando que esse modelo contém apenas o intercepto. Na comparação entre modelos aninhados, a diferença entre seus graus de liberdade representa o número de

parâmetros adicionais introduzidos pelo modelo mais complexo e determina os graus de liberdade da distribuição qui-quadrado utilizada no teste da razão de verossimilhança.

2.2.4.4 Critérios de seleção de modelos

Critérios como o `Akaike Information Criterion` (AIC) e o `Bayesian Information Criterion` (BIC) são utilizados para comparar diferentes especificações de modelo, buscando um equilíbrio entre qualidade do ajuste e complexidade. Ambos são baseados na log-verossimilhança do modelo, mas incorporam uma penalização pelo número de parâmetros estimados, evitando que modelos com maior número de variáveis sejam favorecidos apenas por apresentarem melhor ajuste aos dados.

O AIC é definido por:

$$AIC = -2\ell(\hat{\beta}) + 2k \tag{17}$$

enquanto o BIC é dado por:

$$BIC = -2\ell(\hat{\beta}) + k\log(n) \tag{18}$$

onde $\ell(\hat{\beta})$ representa a log-verossimilhança avaliada nas estimativas de máxima verossimilhança, k corresponde ao número de parâmetros estimados e n representa o tamanho da amostra.

Em ambos os critérios, menores valores indicam modelos preferíveis dentro do conjunto analisado. A principal diferença entre eles está na penalização aplicada à complexidade: o BIC impõe uma penalização maior para modelos com muitos parâmetros, especialmente em amostras grandes, enquanto o AIC tende a favorecer modelos com maior capacidade preditiva.

2.2.5 Assumptions do modelo

A regressão logística, assim como outros modelos estatísticos, depende de um conjunto de hipóteses que garantem a validade das estimativas e das inferências realizadas. Dife-

rentemente da regressão linear, o modelo logístico não assume normalidade dos resíduos ou homocedasticidade, uma vez que a variável resposta é binária. Entretanto, algumas condições são necessárias para que a relação entre as variáveis explicativas e a probabilidade do evento de interesse seja adequadamente representada.

A primeira hipótese está relacionada à independência das observações, assumindo que cada indivíduo da amostra representa uma unidade independente de informação. No contexto de concessão de crédito, isso significa que a probabilidade de inadimplência de um cliente deve ser avaliada sem dependência direta das características de outros clientes presentes na base de dados.

Outra hipótese importante é a existência de uma relação aproximadamente linear entre as variáveis explicativas e o logaritmo das chances (log-odds) do evento. Embora a regressão logística não imponha linearidade entre os preditores e a probabilidade diretamente, ela assume que a combinação linear das variáveis explicativas é capaz de explicar a variação no logit da probabilidade. Dessa forma, efeitos não lineares podem exigir transformações das variáveis, inclusão de termos polinomiais ou utilização de outras estruturas de modelagem.

Também é necessário avaliar a presença de multicolinearidade entre as variáveis explicativas. Quando variáveis altamente correlacionadas são incluídas simultaneamente no modelo, ocorre aumento da variância das estimativas dos coeficientes, dificultando a interpretação individual dos efeitos. Em modelos de risco de crédito, esse problema pode surgir, por exemplo, quando diferentes indicadores financeiros representam informações semelhantes sobre o perfil econômico do cliente. Entretanto, essa limitação pode ser parcialmente reduzida por meio da utilização de métodos de regularização, que introduzem penalizações sobre os coeficientes e podem contribuir para a estabilidade das estimativas em cenários com alta correlação entre preditores. Dessa forma, embora a análise de multicolinearidade permaneça relevante para a compreensão da estrutura dos dados, sua influência sobre o desempenho preditivo do modelo pode ser mitigada pela abordagem de estimação adotada.

2.2.6 Regularização e seleção de variáveis

Apesar da estimação por máxima verossimilhança fornecer estimativas eficientes sob determinadas condições, modelos com grande número de variáveis explicativas podem

apresentar problemas relacionados à multicolinearidade, sobreajuste e dificuldade de interpretação dos coeficientes. Uma alternativa para lidar com esses problemas consiste na utilização de métodos de regularização, que incorporam uma penalização sobre a magnitude dos parâmetros estimados.

Na regressão logística regularizada, a função objetivo deixa de ser apenas a maximização da log-verossimilhança e passa a considerar um termo adicional de penalização:

$$\hat{\beta} = \arg\max_{\beta} \left[\ell(\beta) - \lambda P(\beta)\right] \tag{19}$$

onde $\ell(\beta)$ representa a log-verossimilhança do modelo, λ corresponde ao parâmetro de regularização e $P(\beta)$ representa a penalização aplicada aos coeficientes. Quanto maior o valor de λ, maior a restrição imposta aos parâmetros, reduzindo sua magnitude.

Dois métodos de regularização amplamente utilizados são Ridge e Lasso, que diferem principalmente pelo tipo de penalização aplicada aos coeficientes.

2.2.6.1 Ridge

A regularização Ridge utiliza uma penalização baseada na soma dos quadrados dos coeficientes, também conhecida como penalização L2:

$$P(\beta) = \sum_{j=1}^{p} \beta_j^2 \tag{20}$$

Assim, a estimação Ridge pode ser representada como:

$$\hat{\beta}_{ridge} = \arg\max_{\beta} \left[\ell(\beta) - \lambda \sum_{j=1}^{p} \beta_j^2\right] \tag{21}$$

A penalização quadrática reduz a magnitude dos coeficientes, tornando as estimativas mais estáveis em situações de alta correlação entre as variáveis explicativas. Entretanto, como a penalização é aplicada de forma contínua, os coeficientes tendem a se aproximar de zero, mas raramente assumem exatamente esse valor. Dessa forma, Ridge reduz a influência das variáveis menos relevantes, mas não realiza seleção automática de variáveis.

2.2.6.2 Lasso

A regularização Lasso utiliza uma penalização baseada na soma dos valores absolutos dos coeficientes, conhecida como penalização L1:

$$P(\beta) = \sum_{j=1}^{p} |\beta_j| \tag{22}$$

A estimação Lasso é dada por:

$$\hat{\beta}_{lasso} = \arg\max_{\beta} \left[\ell(\beta) - \lambda \sum_{j=1}^{p} |\beta_j| \right] \tag{23}$$

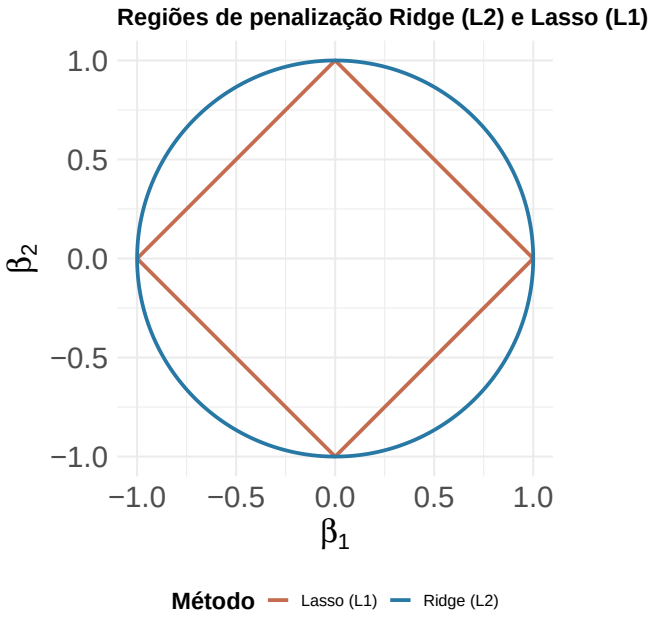


Figura 2: Representação geométrica das regiões de penalização Ridge (L2) e Lasso (L1). A região circular associada à penalização L2 tende a reduzir simultaneamente a magnitude dos coeficientes, enquanto a região em formato de losango da penalização L1 favorece soluções em que alguns coeficientes assumem valor exatamente igual a zero.

A diferença entre as penalizações L1 e L2 pode ser visualizada geometricamente na Figura Figura 2. A penalização Ridge apresenta uma região de restrição circular, enquanto a penalização Lasso possui uma região em formato de losango. Essa diferença geométrica está relacionada ao comportamento dos coeficientes durante a estimação: enquanto a penalização L2 tende a reduzir continuamente a magnitude dos coeficientes, a penalização L1 favorece soluções em que alguns parâmetros assumem valores exatamente iguais a zero.

Dessa forma, o Lasso atua também como um método de seleção de variáveis, removendo preditores com menor contribuição para o modelo.

2.3 Regressão Logística Bayesiana

Enquanto a regressão logística frequentista trata os coeficientes do modelo como parâmetros fixos e desconhecidos, a abordagem Bayesiana considera esses parâmetros como variáveis aleatórias. Dessa forma, é possível incorporar conhecimento prévio sobre os coeficientes por meio de distribuições `a priori`, que representam as crenças existentes antes da observação dos dados.

A inferência Bayesiana consiste em combinar essas informações prévias com a informação contida na amostra, representada pela função de verossimilhança, obtendo-se a distribuição `a posteriori` dos parâmetros. Essa distribuição sintetiza o conhecimento atualizado após a observação dos dados e constitui a base para todas as inferências realizadas no modelo, como estimação dos coeficientes, construção de intervalos de credibilidade e obtenção de probabilidades preditivas.

2.3.1 Formulação do modelo

A estrutura probabilística da regressão logística Bayesiana é a mesma apresentada para a regressão logística frequentista. Assume-se que a variável resposta segue uma distribuição de Bernoulli e que sua probabilidade de ocorrência é relacionada às variáveis explicativas por meio da função logística aplicada ao preditor linear.

A principal diferença entre as duas abordagens está na forma como os coeficientes do modelo são tratados. Na abordagem frequentista, os parâmetros são considerados fixos e desconhecidos, sendo estimados por máxima verossimilhança. Já na abordagem Bayesiana, os coeficientes são tratados como variáveis aleatórias e sua inferência é realizada por meio da distribuição `a posteriori`, obtida pela aplicação do Teorema de Bayes, conforme apresentado na Seção 2.1.4.

Dessa forma, enquanto a abordagem frequentista fornece uma estimativa pontual para cada coeficiente, a regressão logística Bayesiana produz uma distribuição posterior para

cada parâmetro, permitindo quantificar diretamente a incerteza associada às estimativas e realizar inferências probabilísticas sobre os coeficientes do modelo.

2.3.2 Escolha de distribuições *a priori*

Uma das principais características da inferência Bayesiana é a necessidade de especificar distribuições *a priori* para os parâmetros do modelo. Essas distribuições representam o conhecimento disponível sobre os coeficientes antes da observação dos dados e constituem um dos elementos fundamentais da distribuição posterior.

A escolha da distribuição *a priori* depende tanto do conhecimento prévio sobre o problema quanto dos objetivos da análise. Em situações nas quais não há informações prévias relevantes, é comum utilizar distribuições fracamente informativas, que exercem pouca influência sobre as estimativas e permitem que a informação proveniente dos dados tenha maior peso na inferência. Por outro lado, quando existe conhecimento substancial sobre os parâmetros ou quando se deseja incorporar algum tipo de regularização, podem ser utilizadas distribuições com características específicas, capazes de induzir diferentes comportamentos nas estimativas.

Além de representar conhecimento prévio, as distribuições *a priori* desempenham um papel importante na regularização dos modelos Bayesianos. Dependendo da distribuição adotada, pode-se favorecer coeficientes de menor magnitude, reduzir os efeitos da multicolinearidade ou incentivar a seleção automática de variáveis. Dessa forma, a escolha da priori influencia não apenas a inferência estatística, mas também a complexidade e a interpretabilidade do modelo.

2.3.2.1 Priori Normal

Uma das distribuições *a priori* mais utilizadas em regressão logística Bayesiana é a distribuição Normal. Nessa abordagem, assume-se que cada coeficiente do modelo é proveniente de uma distribuição Normal centrada em um valor esperado, geralmente igual a zero:

$$\beta_j \sim \mathcal{N}(\mu, \sigma^2) \tag{24}$$

Na maioria das aplicações, adota-se $\mu = 0$, refletindo a expectativa de que, antes da observação dos dados, não exista evidência de que determinada variável exerça efeito positivo ou negativo sobre a resposta. O parâmetro σ^2 controla o grau de dispersão da distribuição e, consequentemente, a intensidade da informação prévia incorporada ao modelo.

Valores elevados de σ produzem distribuições mais dispersas, permitindo que a informação proveniente dos dados exerça maior influência sobre a distribuição posterior. Por outro lado, valores reduzidos concentram maior massa de probabilidade em torno de zero, favorecendo coeficientes de menor magnitude e restringindo estimativas extremas. Assim, quanto menor o desvio padrão adotado, maior a intensidade da regularização imposta aos parâmetros.

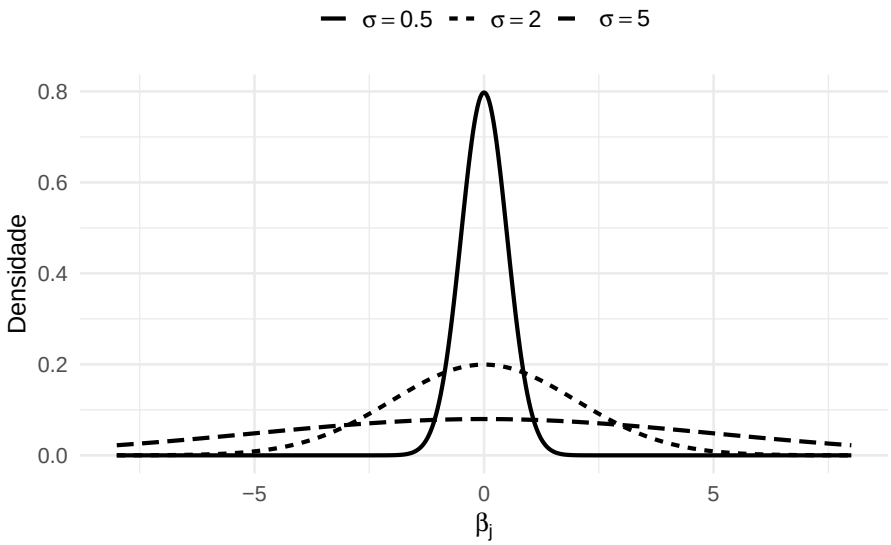


Figura 3: Distribuições Normais a priori com diferentes desvios padrão.

A influência do desvio padrão sobre a distribuição *a priori* pode ser observada na Figura Figura 3. Valores menores de σ concentram maior massa de probabilidade em torno de zero, tornando menos prováveis coeficientes de grande magnitude e aumentando a intensidade da regularização. À medida que o desvio padrão aumenta, a distribuição torna-se mais dispersa, permitindo que os dados exerçam maior influência sobre as estimativas posteriores.

A utilização de uma distribuição Normal como priori estabelece uma relação direta com a regularização Ridge utilizada na abordagem frequentista. Na regressão Ridge, a estimação dos coeficientes é realizada maximizando a função de verossimilhança penalizada, dada

pela Equação 21.

Por sua vez, ao assumir uma distribuição *a priori* Normal,

$$\beta_j \sim \mathcal{N}(0, \sigma^2),$$

o logaritmo da densidade da priori pode ser escrito, desprezando constantes, como:

$$\log p(\beta) \propto -\frac{1}{2\sigma^2} \sum_{j=1}^{p} \beta_j^2. \tag{25}$$

Observa-se que tanto a penalização Ridge quanto o logaritmo da priori Normal contêm um termo quadrático envolvendo os coeficientes do modelo. Assim, embora provenientes de interpretações distintas, uma baseada em penalização e outra na incorporação de uma distribuição `a priori`, ambas favorecem coeficientes de menor magnitude. A principal diferença reside na interpretação: na regressão Ridge, o termo quadrático é introduzido como uma penalização na função objetivo, enquanto na abordagem Bayesiana ele decorre da escolha da distribuição `a priori` para os parâmetros.

Nota-se que existe uma relação inversa entre os parâmetros de regularização: valores menores de σ^2 correspondem a uma priori mais concentrada em torno de zero e, consequentemente, a uma regularização mais intensa, desempenhando papel análogo ao parâmetro de penalização λ da regressão Ridge. Assim, reduzir σ^2 equivale a aumentar a intensidade da regularização.

Assim como a penalização Ridge, a priori Normal reduz a magnitude dos coeficientes estimados, mas não realiza seleção automática de variáveis, uma vez que os parâmetros tendem a permanecer diferentes de zero após a estimação.

2.3.2.2 Priori Laplace

Outra distribuição *a priori* amplamente utilizada em regressão logística Bayesiana é a distribuição Laplace, também conhecida como distribuição de dupla exponencial (*double exponential*). Diferentemente da distribuição Normal, a distribuição Laplace apresenta um pico mais acentuado em torno de zero e caudas mais pesadas, favorecendo coeficientes pequenos sem restringir completamente a ocorrência de valores de maior magnitude.

Matematicamente, a priori Laplace pode ser representada por:

$$\beta_j \sim \text{Laplace}(\mu, b) \tag{26}$$

Em geral, adota-se $\mu = 0$, indicando que, antes da observação dos dados, espera-se que os coeficientes estejam concentrados em torno de zero. O parâmetro b controla a dispersão da distribuição: valores menores de b concentram maior massa de probabilidade em torno de zero, intensificando a regularização, enquanto valores maiores tornam a distribuição mais dispersa e reduzem a influência da informação prévia.

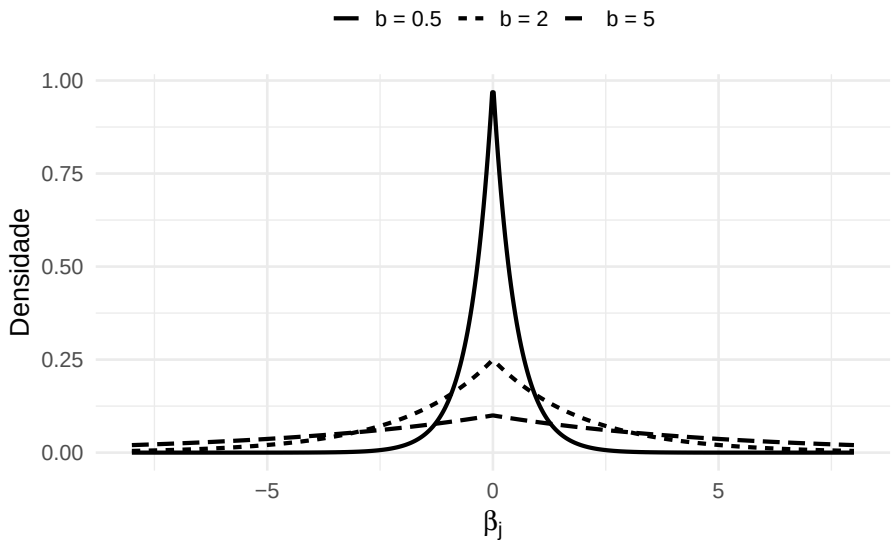


Figura 4: Distribuições Laplace a priori com diferentes parâmetros de escala.

A Figura Figura 4 ilustra o efeito do parâmetro b sobre a distribuição Laplace. À medida que b diminui, a distribuição torna-se mais concentrada em torno de zero, aumentando a probabilidade de coeficientes com pequena magnitude. Em contrapartida, suas caudas permanecem relativamente pesadas quando comparadas às da distribuição Normal, permitindo que coeficientes com efeitos realmente relevantes assumam valores mais elevados quando sustentados pelos dados.

A utilização da distribuição Laplace estabelece uma relação direta com a regularização Lasso empregada na abordagem frequentista. Enquanto o Lasso adiciona uma penalização baseada na soma dos valores absolutos dos coeficientes, conforme apresentado na Equação 23, o logaritmo da densidade da distribuição Laplace pode ser escrito, desprezando constantes, como

$$\log p(\beta) \propto -\frac{1}{b}\sum_{j=1}^{p}|\beta_j|. \tag{27}$$

Observa-se que ambas as expressões apresentam um termo baseado no valor absoluto dos coeficientes. Assim, embora provenientes de interpretações distintas, uma decorrente de uma penalização e outra da especificação de uma distribuição *a priori*, ambas favorecem soluções mais esparsas (*sparse*), nas quais apenas parte das variáveis apresenta efeitos relevantes.

Assim como a regularização Lasso, a priori Laplace promove um encolhimento mais intenso dos coeficientes em direção a zero do que a distribuição Normal. Como consequência, tende a produzir modelos mais parcimoniosos, reduzindo a influência de variáveis com pouca contribuição para a resposta e facilitando a interpretação do modelo.

2.3.2.3 Sensibilidade às distribuições *a priori*

Uma etapa importante da modelagem Bayesiana consiste em avaliar a sensibilidade dos resultados à escolha das distribuições *a priori*. Como a distribuição posterior é obtida pela combinação entre a priori e a verossimilhança, diferentes especificações podem produzir estimativas distintas, especialmente em situações com amostras reduzidas ou baixa quantidade de informação nos dados.

Em geral, quando o conjunto de dados é suficientemente informativo, espera-se que pequenas alterações nas distribuições *a priori* tenham impacto limitado sobre as estimativas posteriores. Por outro lado, diferenças substanciais entre os resultados obtidos com diferentes prioris podem indicar que as inferências são fortemente influenciadas pelas hipóteses iniciais adotadas.

2.3.3 Distribuições *a posteriori*

Na inferência Bayesiana, a distribuição *a posteriori* dos parâmetros é obtida pela combinação entre a distribuição *a priori* e a função de verossimilhança, conforme estabelecido pelo Teorema de Bayes (Seção 2.1.4). Enquanto a distribuição *a priori* representa o conhecimento ou as suposições estabelecidas sobre os parâmetros antes da observação dos dados, a verossimilhança incorpora a informação fornecida pela amostra observada. Dessa

forma, a distribuição *a posteriori* expressa o conhecimento atualizado sobre os parâmetros após considerar as evidências disponíveis.

Formalmente, a distribuição *a posteriori* pode ser expressa por:

$$p(\beta \mid y, X) = \frac{p(y \mid X, \beta)\, p(\beta)}{p(y \mid X)} \tag{28}$$

em que $p(\beta \mid y, X)$ representa a distribuição *a posteriori* dos parâmetros; $p(y \mid X, \beta)$ corresponde à função de verossimilhança; $p(\beta)$ representa a distribuição *a priori*; e $p(y \mid X)$ é a distribuição marginal dos dados, também denominada constante de normalização.

Neste contexto, X representa a matriz de variáveis explicativas, composta pelas características observadas dos indivíduos, enquanto y corresponde ao vetor de observações da variável resposta. O vetor β contém os parâmetros do modelo de regressão logística a serem estimados.

Como o denominador não depende dos parâmetros, a distribuição *a posteriori* pode ser expressa proporcionalmente ao produto entre a verossimilhança e a distribuição *a priori*:

$$p(\beta \mid y, X) \propto p(y \mid X, \beta) p(\beta). \tag{29}$$

Essa relação evidencia que a inferência Bayesiana não considera apenas a informação observada nos dados, mas também as suposições estabelecidas previamente sobre os parâmetros. A influência relativa de cada componente depende, entre outros fatores, da quantidade de informação presente na amostra e da dispersão atribuída às distribuições *a priori*.

Na regressão logística, a distribuição *a priori* é especificada para os coeficientes do modelo, representados por β. Esses parâmetros determinam a relação entre as variáveis explicativas e a probabilidade de ocorrência do evento de interesse. Antes de observar os dados, a distribuição *a priori* estabelece quais valores desses coeficientes são considerados mais ou menos plausíveis. Após a observação da amostra, a função de verossimilhança incorpora as informações fornecidas pelos dados, atribuindo maior suporte aos valores dos parâmetros que resultam em probabilidades mais compatíveis com os resultados observados.

A distribuição *a posteriori* surge, portanto, da combinação dessas duas fontes de informação. Para compreender esse processo, pode-se considerar que a distribuição *a priori* representa uma distribuição inicial de plausibilidade dos parâmetros, enquanto a verossimilhança atua como um mecanismo de atualização, modificando essa distribuição de acordo com a evidência empírica. Assim, valores dos parâmetros que recebem maior suporte tanto da distribuição *a priori* quanto da verossimilhança tendem a apresentar maior concentração de probabilidade na distribuição *a posteriori*.

Essa atualização não corresponde simplesmente à substituição da distribuição *a priori* pelas estimativas obtidas a partir dos dados. Em vez disso, a distribuição *a posteriori* preserva a influência da informação prévia, combinando-a com a evidência observada. A intensidade dessa influência depende da compatibilidade entre as informações fornecidas pela priori e pela verossimilhança, bem como da quantidade de informação disponível na amostra e da dispersão atribuída à distribuição *a priori*.

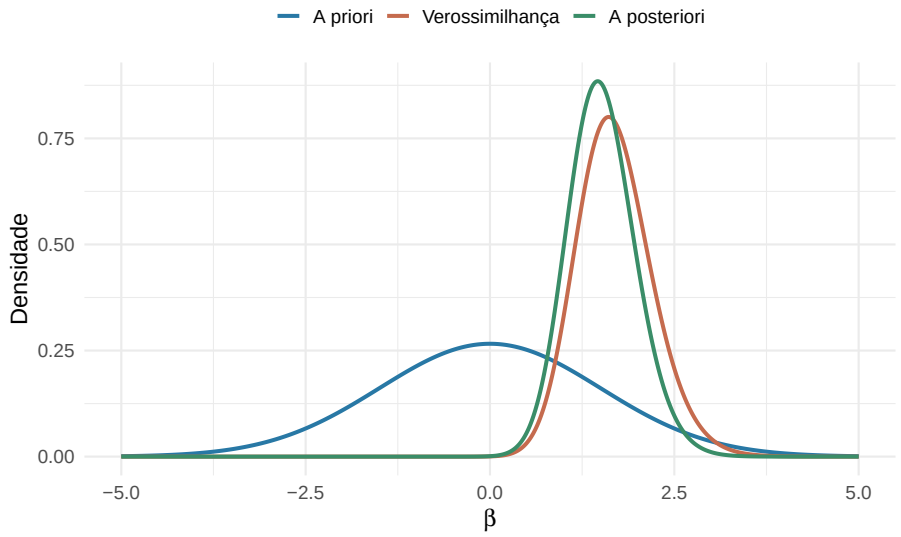


Figura 5: Representação da atualização Bayesiana em um modelo de regressão logística: distribuição a priori, verossimilhança normalizada e distribuição a posteriori.

Para ilustrar o processo de atualização bayesiana, considere um exemplo hipotético em que são observadas 25 ocorrências de um determinado evento em uma amostra de 30 observações. Suponha, inicialmente, que o coeficiente associado a esse evento siga uma distribuição *a priori* Normal, com média zero e desvio-padrão igual a 1,5. Essa especificação expressa uma expectativa inicial de que o efeito seja próximo de zero, embora permita valores positivos e negativos.

A partir dos dados observados, a função de verossimilhança passa a favorecer valores positivos do coeficiente, uma vez que a proporção de ocorrências na amostra é relativamente elevada. Ao combinar essa informação com a distribuição *a priori*, obtém-se a distribuição *a posteriori*, que representa a atualização do conhecimento sobre o parâmetro após a observação dos dados.

Como ilustrado na Figura 5, a distribuição *a posteriori* apresenta uma posição intermediária entre a distribuição *a priori* e a verossimilhança normalizada. Esse resultado evidencia que a inferência bayesiana não considera exclusivamente os dados observados, tampouco mantém inalterada a expectativa inicial: a distribuição *a posteriori* resulta da combinação dessas duas fontes de informação.

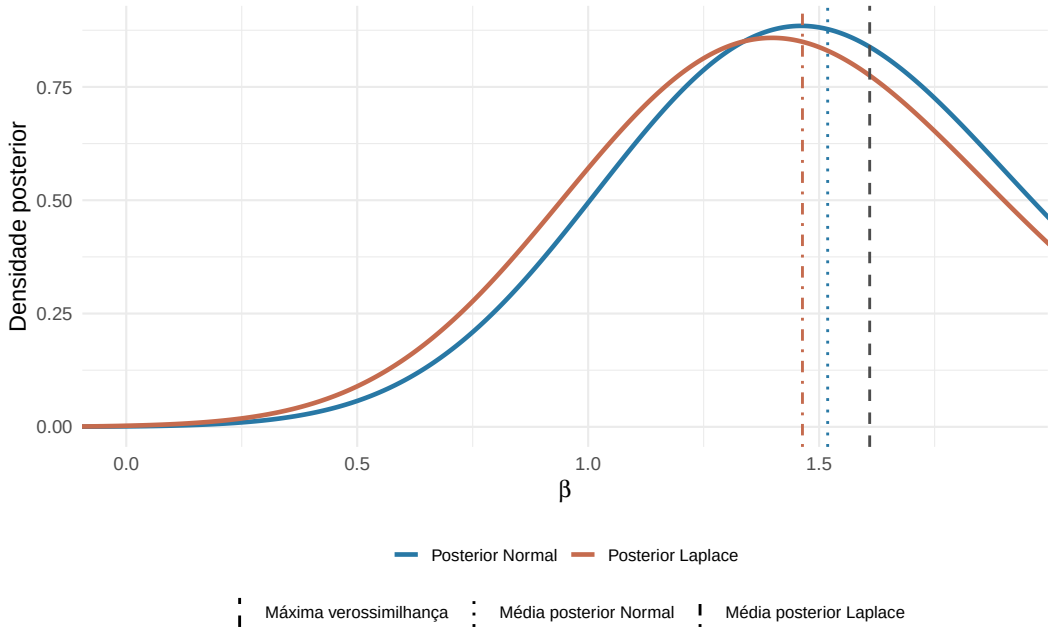


Figura 6: Distribuições posteriores e contração das estimativas em relação à máxima verossimilhança, sob priors Normal e Laplace.

A influência da distribuição *a priori* não se limita à atualização da informação sobre os parâmetros, podendo também afetar a magnitude das estimativas posteriores por meio de um mecanismo de regularização denominado *shrinkage*. Esse fenômeno corresponde à contração dos coeficientes em direção aos valores favorecidos pela distribuição *a priori*. Quando centrada em zero, essa distribuição tende a favorecer estimativas de menor magnitude, sendo a intensidade da contração determinada, entre outros fatores, por sua forma e dispersão. Conforme ilustrado na Figura 6, a incorporação de distribuições *a priori* centradas em zero pode deslocar as estimativas posteriores em direção a esse valor,

em comparação com a estimativa de máxima verossimilhança. Nesse contexto, diferentes especificações podem produzir comportamentos distintos: enquanto a distribuição Normal promove uma regularização mais suave, a distribuição Laplace apresenta maior concentração de probabilidade nas proximidades de zero e caudas mais pesadas, podendo favorecer uma contração mais acentuada de coeficientes de menor magnitude.

A comparação entre essas distribuições permite investigar como diferentes estruturas de informação prévia influenciam as estimativas dos parâmetros e a incerteza posterior. Cabe destacar, entretanto, que a contração dos coeficientes não implica necessariamente que sejam estimados exatamente como zero. Assim, embora a distribuição Laplace possa favorecer estimativas próximas de zero, sua utilização como distribuição *a priori* não corresponde, por si só, à seleção automática de variáveis.

2.3.4 Inferência via MCMC

Embora a distribuição *a posteriori* seja definida matematicamente pela combinação entre a distribuição *a priori* e a função de verossimilhança, sua obtenção analítica nem sempre é possível. Em modelos de regressão logística com múltiplas variáveis explicativas, a integração necessária para determinar a constante de normalização da distribuição *a posteriori* geralmente não possui solução fechada. Consequentemente, torna-se necessário recorrer a métodos computacionais para aproximar essa distribuição.

Neste trabalho, a inferência Bayesiana é realizada por meio de métodos de Monte Carlo via Cadeias de Markov (*Markov Chain Monte Carlo*, MCMC), implementados pela biblioteca `rstanarm` do R, que utiliza o Stan como mecanismo de estimação. Esses métodos permitem obter amostras da distribuição *a posteriori* por meio da construção de cadeias de Markov cuja distribuição estacionária corresponde à distribuição de interesse.

Diferentemente da abordagem frequentista, que geralmente apresenta estimativas pontuais para os parâmetros, os métodos MCMC permitem representar a incerteza associada às estimativas por meio de uma amostra da distribuição *a posteriori*. A partir dessas amostras, podem ser calculadas medidas como médias, medianas, desvios padrão, intervalos de credibilidade e probabilidades posteriores, proporcionando uma descrição mais completa da incerteza sobre os parâmetros do modelo.

Na prática, o procedimento utiliza múltiplas cadeias de Markov, iniciadas em diferentes valores dos parâmetros. Antes da etapa de amostragem utilizada para a inferência, realiza-se um período inicial denominado *warm-up*, durante o qual o algoritmo adapta determinados parâmetros internos para melhorar a eficiência da amostragem. As iterações dessa etapa são descartadas e não são utilizadas no cálculo dos resumos da distribuição *a posteriori*.

Após o período de *warm-up*, são geradas as amostras utilizadas para representar a distribuição *a posteriori*. A qualidade dessas amostras depende da convergência das cadeias e da eficiência com que exploram o espaço paramétrico. Por esse motivo, torna-se necessário avaliar os resultados por meio de diagnósticos específicos, como o fator de redução potencial de escala ($\hat{R}$), o tamanho efetivo da amostra (ESS), a inspeção gráfica das trajetórias das cadeias e os diagnósticos associados ao algoritmo Hamiltoniano de Monte Carlo (*Hamiltonian Monte Carlo*, HMC).

Além de permitir que as cadeias alcancem regiões de maior probabilidade da distribuição *a posteriori*, essa etapa é utilizada para ajustar automaticamente parâmetros internos do algoritmo, como o tamanho do passo (*step size*) e a matriz de massa (*mass matrix*), tornando a amostragem posterior mais eficiente.

Por exemplo, ao executar quatro cadeias com 2.000 iterações cada, sendo as primeiras 1.000 destinadas ao *warm-up*, apenas as 1.000 iterações finais de cada cadeia são utilizadas para a inferência, resultando em um total de 4.000 amostras da distribuição *a posteriori*.

Adicionalmente, a precisão das estimativas obtidas por meio das amostras simuladas pode ser avaliada pelo erro-padrão de Monte Carlo (*Monte Carlo Standard Error*, MCSE). Essa medida quantifica a incerteza numérica decorrente do número finito de amostras utilizadas para aproximar as quantidades de interesse da distribuição *a posteriori*, considerando também a autocorrelação entre as realizações da cadeia. Valores menores de MCSE indicam maior precisão numérica das estimativas, embora sua interpretação deva considerar a escala e a magnitude da quantidade estimada. Diferentemente do fator $\hat{R}$, que auxilia na avaliação da convergência das cadeias, e do ESS, que mensura a quantidade efetiva de informação disponível nas amostras, o MCSE permite avaliar a precisão das estimativas Monte Carlo.

O Stan implementa, por padrão, o algoritmo *No-U-Turn Sampler* (NUTS), uma extensão adaptativa do HMC. Ambos pertencem à família MCMC, cujo objetivo é gerar amostras da distribuição *a posteriori* dos parâmetros.

Em algoritmos clássicos de MCMC, como o Metropolis-Hastings, novas propostas são geradas por pequenos deslocamentos aleatórios em torno da posição atual da cadeia. Embora esse procedimento seja conceitualmente simples, ele tende a explorar a distribuição de forma lenta, produzindo amostras altamente correlacionadas e exigindo um grande número de iterações para representar adequadamente a distribuição *a posteriori*.

O Hamiltonian Monte Carlo busca contornar essa limitação utilizando o gradiente do logaritmo da distribuição a posteriori. Essa informação indica como a densidade varia localmente e é utilizada para construir trajetórias que percorrem a distribuição de maneira eficiente, evitando os pequenos movimentos aleatórios característicos de métodos como o Metropolis-Hastings. Dessa forma, a cadeia consegue explorar regiões de alta probabilidade com deslocamentos mais longos, produzindo amostras menos correlacionadas e acelerando a convergência.

Para construir essas trajetórias, o HMC utiliza conceitos da Mecânica Hamiltoniana, tratando os parâmetros do modelo como se fossem partículas em movimento sob a ação de forças. Embora essa interpretação seja física, sua principal utilidade é fornecer um mecanismo eficiente para explorar distribuições de alta dimensão preservando suas propriedades probabilísticas.

Apesar dessas vantagens, o desempenho do HMC depende da escolha de alguns hiperparâmetros, principalmente o tamanho do passo (*step size*) e o número de passos utilizados para percorrer cada trajetória. Valores inadequados podem tornar a exploração ineficiente ou aumentar significativamente o custo computacional.

O algoritmo NUTS (*No-U-Turn Sampler*) elimina grande parte dessa dificuldade ao adaptar automaticamente o comprimento das trajetórias durante a amostragem. Em vez de definir previamente quantos passos devem ser executados, o algoritmo expande a trajetória até identificar que ela começou a retornar em direção ao ponto de partida, formando um movimento semelhante a um "U". Nesse momento, a trajetória é interrompida, evitando que o algoritmo desperdice iterações percorrendo repetidamente a mesma região da distribuição.

Essa estratégia permite que o Stan explore automaticamente a distribuição *a posteriori* de forma eficiente, reduzindo a necessidade de ajustes manuais e tornando o método adequado para modelos Bayesianos complexos e de alta dimensão.

Ao final da amostragem, obtém-se um conjunto de realizações da distribuição *a posteriori* para cada parâmetro do modelo. Essas amostras constituem a base para todas as inferências realizadas na abordagem Bayesiana, incluindo a estimação dos coeficientes, a construção de intervalos de credibilidade e a avaliação da incerteza associada às previsões.

2.3.4.1 Diagnóstico da convergência

Após a obtenção das amostras da distribuição *a posteriori*, é necessário verificar se o processo de amostragem convergiu adequadamente. A convergência indica que as cadeias de Markov passaram a representar a mesma distribuição *a posteriori*, permitindo que as inferências realizadas sejam consideradas confiáveis. Entre os principais diagnósticos utilizados destacam-se os *traceplots*, o fator de redução potencial ($\hat{R}$) e o tamanho efetivo da amostra (*Effective Sample Size*, ESS).

Os *traceplots* consistem em gráficos que apresentam os valores amostrados para cada parâmetro ao longo das iterações do algoritmo. Espera-se que, após o período de *warm-up*, as diferentes cadeias apresentem boa mistura (mixing), alternando-se livremente em torno da mesma região da distribuição a posteriori. Esse comportamento sugere que a cadeia está explorando adequadamente a distribuição *a posteriori*. Por outro lado, padrões como tendências persistentes, mudanças abruptas ou cadeias que permanecem separadas podem indicar problemas de convergência.

A Figura 7 ilustra dois comportamentos típicos. À esquerda observa-se uma situação de convergência, em que as cadeias apresentam boa mistura (mixing) e exploram a mesma região da distribuição a posteriori. À direita, as cadeias permanecem separadas e apresentam comportamento não estacionário, indicando que a convergência ainda não foi atingida.

O fator de redução potencial, denotado por ($\hat{R}$) e proposto por Gelman e Rubin, compara a variabilidade entre diferentes cadeias com a variabilidade observada dentro de cada cadeia. Quando todas as cadeias convergem para a mesma distribuição, espera-se que essas

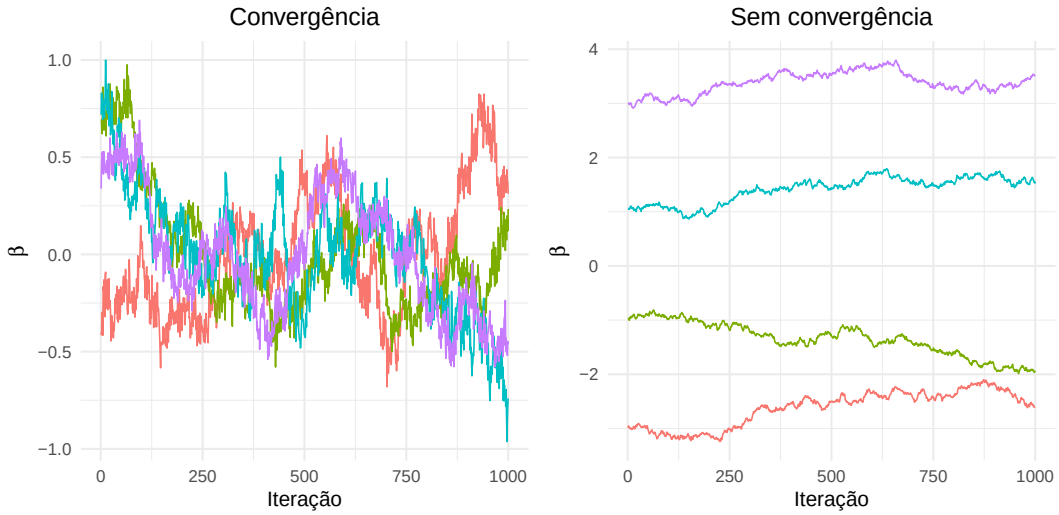


Figura 7: Exemplo ilustrativo de traceplots. À esquerda, cadeias convergidas apresentam boa mistura e exploram a mesma distribuição posterior. À direita, cadeias não convergidas permanecem separadas, indicando problemas de convergência.

variabilidades sejam semelhantes, resultando em valores de $(\hat{R})$ próximos de 1. Na prática, valores inferiores a 1,01 são geralmente considerados indicativos de boa convergência.

Outro diagnóstico importante é o tamanho efetivo da amostra (*Effective Sample Size*, ESS). Embora um algoritmo MCMC possa gerar milhares de amostras, elas não são independentes, pois observações consecutivas tendem a apresentar autocorrelação. O ESS estima quantas amostras independentes seriam equivalentes ao conjunto obtido pelo algoritmo. Assim, valores elevados de ESS indicam que a distribuição *a posteriori* foi explorada de forma eficiente, enquanto valores reduzidos sugerem elevada autocorrelação e a necessidade de aumentar o número de iterações ou investigar possíveis problemas na amostragem.

Adicionalmente, o diagnóstico E-BFMI (Energy Bayesian Fraction of Missing Information) avalia a eficiência da exploração da distribuição de energia pelo algoritmo Hamiltoniano, permitindo identificar possíveis dificuldades na exploração do espaço paramétrico. Valores reduzidos podem indicar problemas na amostragem e a necessidade de investigar a parametrização do modelo ou as configurações do algoritmo.

Neste trabalho, esses diagnósticos foram utilizados conjuntamente para avaliar a convergência das cadeias e a eficiência da amostragem realizada pelo algoritmo NUTS.

2.3.4.2 Inferência posterior

Uma vez verificada a convergência das cadeias, as amostras geradas pelo algoritmo MCMC passam a representar a distribuição *a posteriori* de cada parâmetro do modelo. Diferentemente da abordagem frequentista, em que a inferência é baseada em uma única estimativa pontual dos coeficientes, a abordagem Bayesiana considera toda a distribuição posterior, permitindo quantificar diretamente a incerteza associada às estimativas.

Uma medida frequentemente utilizada para resumir essa distribuição é a média posterior, obtida pela média das amostras geradas para cada parâmetro. Essa quantidade representa o valor esperado do coeficiente após a incorporação simultânea das informações provenientes da distribuição *a priori* e dos dados observados.

Além da média posterior, é comum apresentar intervalos de credibilidade, que descrevem a região da distribuição *a posteriori* onde se concentram os valores mais plausíveis para cada parâmetro. Um intervalo de credibilidade de 95% indica que, dadas as distribuições *a priori* adotadas e os dados observados, existe uma probabilidade de 95% de que o verdadeiro valor do parâmetro pertença ao intervalo obtido.

Em aplicações práticas, também é comum avaliar se o intervalo de credibilidade de um coeficiente contém o valor zero. Quando todo o intervalo permanece acima ou abaixo de zero, há evidências de que o efeito da variável seja predominantemente positivo ou negativo, respectivamente

Essa interpretação difere dos intervalos de confiança utilizados na estatística frequentista. Enquanto o intervalo de confiança está relacionado ao comportamento do procedimento de estimação em repetições hipotéticas do experimento, o intervalo de credibilidade permite fazer afirmações probabilísticas diretamente sobre o parâmetro de interesse.

A interpretação dos coeficientes permanece análoga à da regressão logística frequentista. Cada coeficiente representa a variação esperada no logaritmo das chances (*log-odds*) associada ao aumento de uma unidade da variável explicativa, mantendo-se constantes as demais variáveis do modelo.

2.3.4.3 Avaliação do modelo Bayesiano

Além dos diagnósticos de convergência das cadeias e da interpretação dos parâmetros, modelos bayesianos permitem avaliar sua adequação e capacidade preditiva por meio de critérios baseados na distribuição preditiva posterior.

A verificação preditiva posterior (*Posterior Predictive Check*, PPC) compara características dos dados observados com aquelas obtidas em replicações simuladas a partir do modelo. Essa análise permite avaliar se o modelo consegue reproduzir aspectos relevantes dos dados utilizados no ajuste.

Outro critério é o *Widely Applicable Information Criterion* (WAIC), que estima a capacidade preditiva esperada do modelo, considerando a incerteza dos parâmetros e penalizando sua complexidade efetiva. O WAIC está relacionado à *Expected Log Predictive Density* (ELPD), medida da qualidade preditiva esperada para novas observações, cuja estimativa pode ser obtida a partir dos dados disponíveis.

Neste trabalho, o PPC é utilizado para avaliar a adequação dos modelos bayesianos aos dados observados, enquanto o WAIC é empregado como critério complementar de comparação entre diferentes especificações bayesianas. Já as métricas tradicionais de classificação permitem comparar diretamente os modelos frequentistas e bayesianos.

2.4 Avaliação de modelos de classificação

A avaliação de modelos de classificação binária pode ser realizada por diferentes métricas, cada uma enfatizando um aspecto distinto do desempenho do modelo. Em problemas de concessão de crédito, essa avaliação torna-se particularmente importante, uma vez que diferentes tipos de erro possuem impactos econômicos distintos para a instituição financeira. Dessa forma, a análise do desempenho não deve se restringir a uma única medida, sendo recomendável a utilização de um conjunto de métricas obtidas a partir da matriz de confusão. As métricas abaixo são utilizadas em ambas as abordagens, frequentista e Bayesiana, permitindo comparar o desempenho dos modelos sob diferentes perspectivas.

2.4.1 Matriz de confusão

A matriz de confusão resume a relação entre as classes observadas e as classes previstas pelo modelo, permitindo identificar a quantidade de classificações corretas e incorretas.

Para um problema de classificação binária, ela é composta por quatro elementos:

	Classe prevista: Positiva	Classe prevista: Negativa
Classe observada: Positiva	Verdadeiro Positivo (TP)	Falso Negativo (FN)
Classe observada: Negativa	Falso Positivo (FP)	Verdadeiro Negativo (TN)

A partir desses quatro valores, diversas métricas podem ser calculadas para avaliar diferentes características do modelo.

A acurácia corresponde à proporção total de classificações corretas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{30}$$

Embora seja uma das métricas mais utilizadas, sua interpretação pode ser prejudicada em bases de dados desbalanceadas, nas quais uma das classes é muito mais frequente que a outra.

A sensibilidade (*Recall* ou *True Positive Rate*) mede a capacidade do modelo em identificar corretamente as observações pertencentes à classe positiva:

$$Sensitivity = \frac{TP}{TP + FN} \tag{31}$$

Já a especificidade (*True Negative Rate*) mede a capacidade do modelo em identificar corretamente as observações da classe negativa:

$$Specificity = \frac{TN}{TN + FP} \tag{32}$$

A precisão (*Precision*) representa a proporção de previsões positivas que realmente correspondem à classe positiva:

$$Precision = \frac{TP}{TP + FP} \tag{33}$$

O F1-score combina precisão e sensibilidade por meio da média harmônica entre ambas:

$$F_1 = 2\frac{Precision \times Sensitivity}{Precision + Sensitivity} \tag{34}$$

Como problemas de concessão de crédito frequentemente apresentam desbalanceamento entre clientes adimplentes e inadimplentes, também é comum utilizar a acurácia balanceada, definida como a média entre sensibilidade e especificidade:

$$Balanced\ Accuracy = \frac{Sensitivity + Specificity}{2} \tag{35}$$

Essa métrica reduz o efeito do desbalanceamento das classes, atribuindo a mesma importância ao acerto de ambas.

Outra medida amplamente utilizada é o `Matthews Correlation Coefficient` (MCC), definido por:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \tag{36}$$

O MCC assume valores entre -1 e 1, sendo que valores próximos de 1 indicam classificação perfeita, valores próximos de 0 representam desempenho semelhante ao acaso e valores negativos indicam discordância entre as classes previstas e observadas. Por considerar simultaneamente todos os elementos da matriz de confusão, essa métrica é particularmente útil em problemas com classes desbalanceadas.

2.4.2 Comparação entre probabilidades previstas e valores observados

Embora métricas obtidas a partir da matriz de confusão sejam amplamente utilizadas na avaliação de modelos de classificação, elas dependem da escolha de um ponto de corte para converter probabilidades em classes previstas. Dessa forma, modelos que produzem probabilidades distintas podem apresentar exatamente a mesma matriz de confusão caso utilizem o mesmo limiar de classificação.

Para contornar essa limitação, também são utilizadas métricas que avaliam diretamente as probabilidades estimadas pelo modelo, sem depender de um ponto de corte específico. Entre as mais empregadas destacam-se a curva ROC, a área sob a curva (AUC) e o Log Loss.

2.4.2.1 Curva ROC e AUC

A curva `Receiver Operating Characteristic` (ROC) representa o desempenho do modelo para diferentes valores do ponto de corte utilizado na classificação. Ela é construída relacionando a sensibilidade (*True Positive Rate*) com a taxa de falsos positivos (*False Positive Rate*), definida por:

$$FPR = \frac{FP}{FP + TN} \tag{37}$$

Cada ponto da curva corresponde a um limiar de classificação diferente, permitindo avaliar o compromisso entre identificar corretamente os eventos positivos e evitar classificações incorretas da classe negativa.

Uma forma de resumir a informação da curva ROC é por meio da Área Sob a Curva (*Area Under the Curve*, AUC). Essa medida pode ser interpretada como a probabilidade de o modelo atribuir uma probabilidade de ocorrência maior a uma observação positiva do que a uma observação negativa escolhida aleatoriamente. Valores de AUC próximos de 1 indicam excelente capacidade discriminatória, enquanto valores próximos de 0,5 sugerem desempenho semelhante ao acaso.

2.4.2.2 Log Loss

Enquanto a AUC avalia a capacidade do modelo em discriminar as classes, o Log Loss considera diretamente a qualidade das probabilidades estimadas. Essa métrica é baseada na função de log-verossimilhança e penaliza previsões incorretas, especialmente quando o modelo atribui elevada confiança a uma classificação errada.

O Log Loss é definido por:

$$LogLoss = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)\right] \tag{38}$$

onde y_i representa o valor observado da resposta e p_i corresponde à probabilidade prevista para a observação i.

Valores menores de Log Loss indicam melhor desempenho preditivo, refletindo probabilidades mais compatíveis com os resultados observados. Por utilizar diretamente as probabilidades estimadas, essa métrica é particularmente relevante em modelos probabilísticos, como a regressão logística, tanto na abordagem bayesiana quanto na abordagem frequentista.

2.4.2.3 Índice de Youden

O índice de Youden é uma medida utilizada para identificar um ponto de corte que maximize conjuntamente a sensibilidade e a especificidade de um modelo de classificação. Seu cálculo é definido por:

$$J = \text{Sensibilidade} + \text{Especificidade} - 1$$

O índice varia entre 0 e 1, sendo que valores mais elevados indicam melhor equilíbrio entre a identificação correta das classes positiva e negativa. O ponto de corte que maximiza esse índice corresponde ao limiar que apresenta a maior soma entre sensibilidade e especificidade, considerando diferentes possibilidades de classificação.

Neste trabalho, o índice de Youden é utilizado como critério complementar para investigar os efeitos da alteração do ponto de corte sobre o desempenho dos modelos frequentista e bayesiano, permitindo comparar o equilíbrio entre a identificação de clientes inadimplentes e não inadimplentes.

3 Metodologia

3.1 Descrição dos Dados

Este trabalho utilizou `Default of Credit Card Clients Dataset`, originalmente disponibilizado por Yeh e Lien (Yeh; Lien (2009)) e atualmente mantido no UCI Machine Learning Repository (Lichman (2013)). O conjunto reúne informações de clientes de cartão de crédito em Taiwan, abrangendo o período de abril a setembro de 2005, incluindo variáveis demográficas, dados financeiros, histórico de pagamentos e valores de fatura. A variável alvo é binária, denotada por `PD30` (Probability of Default in 30 days), a qual indica a ocorrência de inadimplência no horizonte de 30 dias, operacionalmente definida, neste conjunto de dados, como a inadimplência observada no mês subsequente. Assim, embora `PD30` seja um conceito probabilístico no contexto de risco de crédito, neste estudo ela é observada como uma variável indicadora, assumindo valor 1 quando ocorre inadimplência e 0 caso contrário.

A Tabela 1 apresenta uma descrição detalhada das variáveis presentes neste conjunto de dados, incluindo informações demográficas, financeiras e comportamentais dos clientes.

Tabela 1: Descrição das variáveis do dataset de inadimplência

Categoria	Variáveis	Descrição
Identificação	`id_cliente`	Identificador único do cliente.
Perfil demográfico	`sexo`, `escolaridade`, `estado_civil`, `idade`	Informações demográficas do cliente.
Crédito	`limite_credito`	Limite de crédito concedido ao cliente (crédito individual e suplementar).

Categoria	Variáveis	Descrição
Histórico de pagamentos	`atraso_pagto_0` a `atraso_pagto_6`	Situação de atraso nos pagamentos entre abril e setembro de 2005. Valores positivos indicam atraso, enquanto valores negativos representam situações especiais, como pagamento antecipado ou ausência de consumo.
Faturas	`fatura_valor_1` a `fatura_valor_6`	Valores das faturas mensais do cartão de crédito, referentes ao período de abril a setembro de 2005 (NT dollar).
Pagamentos	`pagto_valor_1` a `pagto_valor_6`	Valores pagos mensalmente pelo cliente no período de abril a setembro de 2005 (NT dollar).
Variável resposta	`PD30`	Indicador binário de inadimplência no mês subsequente (1 = inadimplente; 0 = adimplente).

3.2 Pré-processamento

3.2.1 Estrutura de dados e tratamento de valores ausentes

Inicialmente, foi realizada a inspeção da estrutura do banco de dados, com o objetivo de confirmar a consistência dos tipos das variáveis e a adequação do formato dos dados às técnicas de modelagem adotadas. Essa análise compreendeu a identificação das classes

das variáveis, a distinção entre atributos numéricos e categóricos e a validação da variável resposta quanto à sua natureza e domínio.

Por fim, a presença de valores ausentes foi avaliada por meio da função `is.na()`, com sumarização via `colSums(is.na())`. Não foram identificadas observações faltantes no conjunto de dados, eliminando a necessidade de técnicas de imputação e evitando a introdução de incerteza adicional ou viés sistemático no processo de estimação.

3.2.2 Outliers

A identificação de valores atípicos (*outliers*) nas variáveis numéricas foi realizada por meio do critério do intervalo interquartil (*Interquartile Range*, IQR), amplamente utilizado em estatística descritiva por sua robustez em relação a distribuições assimétricas e à presença de valores extremos.

Para cada variável contínua, o primeiro quartil Q_1 e o terceiro quartil Q_3 foram calculados. Definindo o intervalo interquartil como

$$\text{IQR} = Q_3 - Q_1 \tag{39}$$

Os limites inferior e superior para identificação de outliers são definidos como

$$L = Q_1 - 1.5 \cdot \text{IQR} \tag{40}$$

$$U = Q_3 + 1.5 \cdot \text{IQR} \tag{41}$$

Esse procedimento foi empregado exclusivamente com finalidade exploratória, visando caracterizar a distribuição das variáveis e avaliar a presença de valores extremos potencialmente influentes. Não foi realizada a exclusão automática de observações, de modo a preservar a integridade do conjunto de dados e permitir que os modelos estatísticos capturassem adequadamente a heterogeneidade inerente aos dados financeiros.

O fator 1.5 no critério do IQR foi proposto por Tukey (1977) como um compromisso empírico entre robustez e sensibilidade, sendo amplamente adotado por sua boa performance em distribuições assimétricas e com caudas longas, como é típico em dados financeiros.

No contexto de análise de risco de crédito, a presença de valores extremos pode refletir perfis legítimos de alto patrimônio ou elevado risco, sendo crucial que os modelos estatísticos sejam capazes de acomodar essa variabilidade sem que a remoção indiscriminada de outliers elimine informação relevante para a tarefa de classificação.

3.2.3 Correlação

A análise de correlação entre as variáveis numéricas foi conduzida com o objetivo de investigar associações lineares e identificar potenciais indícios de multicolinearidade entre os preditores candidatos ao modelo de regressão logística. As correlações foram estimadas por meio do coeficiente de correlação de Pearson, apropriado para avaliar associações lineares entre variáveis contínuas. O cálculo foi realizado utilizando observações completas.

Os resultados foram sintetizados em uma matriz de correlação, posteriormente representada graficamente por meio de um mapa de calor (*heatmap*), no qual a intensidade e o sinal das correlações são indicados por uma escala de cores contínua. Essa etapa teve caráter exploratório e diagnóstico, servindo como subsídio para a avaliação de possíveis problemas de multicolinearidade na etapa de modelagem, especialmente no que se refere à estabilidade e interpretação dos coeficientes da regressão logística.

3.2.4 Padronização de variáveis numéricas

Para assegurar a estabilidade numérica dos algoritmos de estimação e permitir a comparabilidade entre os coeficientes do modelo, as variáveis quantitativas foram submetidas ao processo de padronização (*Standardization*). Inicialmente, realizou-se a conversão dos dados para o tipo numérico e, em seguida, aplicou-se a transformação de escala centralizada na média com unidade de desvio padrão. A fórmula utilizada para a padronização de cada variável X é dada por

$$z_i = \frac{x_i - \bar{x}}{S} \tag{42}$$

onde x_i representa o valor original da variável, $\bar{x}$ é a média amostral e S é o desvio padrão amostral. Essa transformação resulta em variáveis com média zero e desvio padrão um. Com todas as variáveis na mesma escala, os coeficientes estimados tornam-se comparáveis entre si, permitindo identificar quais preditores exercem maior impacto relativo sobre a probabilidade de aprovação do empréstimo.

Quanto ao pré-processamento, a padronização das variáveis numéricas foi aplicada aos modelos com regularização L1 e L2, bem como aos modelos bayesianos. No caso dos modelos frequentistas regularizados, a transformação é necessária para evitar que diferenças nas escalas das variáveis influenciem desproporcionalmente a penalização dos coeficientes. Na abordagem bayesiana, a padronização também favorece a estabilidade numérica e permite especificar distribuições *a priori* em uma escala comum para os coeficientes. Os modelos frequentistas sem regularização foram estimados sem essa transformação, preservando as escalas originais das variáveis explicativas.

3.2.5 Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta Y=`PD30`. Essa estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1). \tag{43}$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não enviesada do erro de generalização, reduzindo o risco de sobreajuste (*overfitting*) e vazamento de informação.

3.3 Modelos Avaliados

3.3.1 Regressão logística frequentista

A modelagem frequentista foi implementada utilizando o ecossistema tidymodels Kuhn; Wickham (2020), um conjunto integrado de pacotes da linguagem R voltado à construção de fluxos de trabalho reprodutíveis para aprendizado estatístico. Essa abordagem permite estruturar de forma padronizada as etapas da modelagem, incluindo o pré-processamento dos dados, a especificação dos modelos, o ajuste, a validação e a avaliação de desempenho.

O pré-processamento foi realizado por meio do pacote recipes, no qual foram definidas as transformações necessárias para cada configuração avaliada. Entre essas etapas destacam-se a codificação das variáveis categóricas em variáveis indicadoras binárias (dummy variables), a normalização dos preditores numéricos quando requerida, a remoção de variáveis específicas e a eliminação de preditores altamente correlacionados. A utilização de recipes garante que as transformações sejam estimadas exclusivamente a partir do conjunto de treinamento e posteriormente aplicadas aos dados de teste, evitando o vazamento de informação (data leakage).

Os modelos e seus respectivos pré-processamentos foram integrados por meio do pacote workflows, permitindo que cada combinação fosse tratada como um fluxo único de modelagem. Para a regressão logística clássica, estimada por máxima verossimilhança, foram avaliadas diferentes especificações de variáveis explicativas, descritas a seguir: - Modelo completo: utilização de todas as variáveis disponíveis como preditoras; - Modelo sem variáveis altamente correlacionadas: remoção automática de preditores numéricos com correlação absoluta superior a 0,75, visando reduzir problemas associados à multicolinearidade. Além da regressão logística clássica, foram avaliadas versões regularizadas utilizando penalizações Lasso (L1) e Ridge (L2). Nesses modelos, os hiperparâmetros de penalização foram selecionados por meio de busca em grade (grid search), utilizando validação cruzada. O pré-processamento dessas especificações compreendeu a codificação das variáveis categóricas e a normalização dos preditores numéricos. A regularização tem como objetivo controlar a magnitude dos coeficientes, reduzir o sobreajuste (overfitting) e potencialmente melhorar a capacidade de generalização dos modelos, especialmente em cenários com elevado número de preditores ou presença de correlação entre variáveis

explicativas.

As diferentes especificações foram utilizadas para avaliar o impacto da seleção de variáveis e da regularização sobre o desempenho preditivo e a interpretabilidade dos coeficientes estimados.

Todas as etapas de treinamento, validação e avaliação foram conduzidas dentro do fluxo de trabalho do tidymodels, buscando garantir consistência entre os modelos comparados e reprodutibilidade dos resultados obtidos.

3.3.2 Regressão logística bayesiana

A regressão logística bayesiana foi implementada utilizando o pacote rstanarm Goodrich et al. (2020), que permite estimar modelos lineares generalizados sob o paradigma bayesiano por meio de MCMC, implementados na plataforma Stan Carpenter et al. (2017). Nesse contexto, a distribuição posterior dos parâmetros é obtida pela combinação entre a verossimilhança dos dados observados e as distribuições a priori especificadas para os coeficientes do modelo.

Os modelos foram ajustados utilizando a função stan_glm(), com família binomial e função de ligação logística (logit). Em todos os ajustes foram utilizadas quatro cadeias independentes de MCMC, permitindo avaliar a convergência das amostras posteriores por meio de diagnósticos específicos, além de obter estimativas da distribuição posterior dos parâmetros.

Foram consideradas duas especificações de distribuições a priori para os coeficientes das variáveis explicativas: Normal e Laplace, ambas centradas em zero e com variância igual a 1. Para a distribuição Normal, foi utilizada localização zero e escala 1. Para a distribuição Laplace, a escala foi definida como $(1/\sqrt{2})$, de modo a igualar sua variância à da distribuição Normal, uma vez que a variância da distribuição Laplace é dada por $(2b^2)$, em que (b) representa seu parâmetro de escala.

Para tornar a comparação entre as especificações bayesianas mais controlada, foram adotadas distribuições a priori Normal e Laplace com variâncias equivalentes. Essa escolha busca estabelecer o mesmo nível de dispersão inicial para os coeficientes, permitindo investigar em que medida as diferenças observadas nas distribuições posteriores decorrem do formato

das distribuições a priori, e não simplesmente de diferentes escalas de dispersão. Embora apresentem variâncias iguais, as distribuições Normal e Laplace possuem características distintas, especialmente em relação à concentração de probabilidade em torno de zero e ao comportamento das caudas. Essas diferenças podem influenciar o mecanismo de regularização e, consequentemente, a magnitude e a dispersão das estimativas posteriores. Assim, a estratégia permite avaliar como diferentes pressupostos distributivos, mantido constante o nível de variabilidade a priori, afetam a inferência sobre os coeficientes do modelo.

Para o intercepto, foi mantida a mesma distribuição a priori Normal, com localização zero e escala 5, em ambas as especificações. Todas as distribuições foram definidas sem ajuste automático de escala ($autoscale = FALSE$).

3.3.3 Métricas de avaliação

3.3.3.1 Métricas de avaliação do ajuste dos modelos

A avaliação do ajuste dos modelos frequentistas foi realizada por meio da deviance residual e nula, dos critérios AIC e BIC, e do teste da razão de verossimilhança, utilizado para comparar especificações aninhadas. A presença de multicolinearidade entre as variáveis explicativas foi investigada por meio do VIF, enquanto a adequação dos modelos também foi examinada por meio da análise de resíduos e da identificação de observações potencialmente influentes.

Para os modelos bayesianos, a qualidade da amostragem foi avaliada por meio de diagnósticos de convergência e eficiência das cadeias, incluindo o $\hat{R}$, o ESS e a inspeção gráfica dos *traceplots*. Adicionalmente, o MCSE foi utilizado para avaliar a precisão numérica das estimativas posteriores, enquanto o E-BFMI foi considerado na avaliação do comportamento do algoritmo HMC. A adequação dos modelos aos dados observados também foi investigada por meio de PPC. A multicolinearidade entre os preditores foi examinada por meio do VIF, considerando a mesma estrutura de variáveis explicativas utilizada na modelagem.

3.3.3.2 Métricas de avaliação preditiva

A avaliação do desempenho preditivo dos modelos de classificação foi realizada por meio de métricas adequadas a problemas de classificação binária, considerando tanto a capacidade de discriminação quanto a qualidade das probabilidades estimadas e o equilíbrio entre os erros de classificação. Foram utilizadas a área sob a curva ROC (ROC-AUC) e a função de perda logarítmica (*Log Loss*) para avaliar, respectivamente, a capacidade de discriminação e a qualidade das probabilidades previstas. Adicionalmente, foram calculadas a sensibilidade (*Recall*), a especificidade, a acurácia (*Accuracy*), a acurácia balanceada (*Balanced Accuracy*), a precisão (*Precision*), a medida F1 (*F1-score*) e o MCC. A matriz de confusão também foi utilizada para sintetizar os resultados das classificações, permitindo identificar os acertos e erros associados a cada classe.

4 Resultados

4.1 Análise Exploratória

A análise exploratória é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

O conjunto de dados de inadimplência é composto por 30000 observações e 24 variáveis, incluindo a variável resposta `PD30`, que indica se As variáveis preditoras incluem informações como renda anual, pontuação de crédito, nível educacional, entre outras características dos solicitantes.

4.1.1 Estatísticas univariadas

A Tabela 2 evidencia uma população heterogênea de clientes de cartão de crédito, com ampla variabilidade tanto nas características demográficas quanto nas variáveis financeiras, o que também pode ser visto no dataset de empretimos. O limite médio de crédito é de aproximadamente NT$ 167 mil, com mediana inferior (NT$ 140 mil), indicando assimetria à direita e a presença de clientes com limites substancialmente mais elevados, o que é reforçado pelo alto desvio padrão. A idade média dos clientes é de cerca de 35 anos, com concentração em adultos jovens e de meia-idade. As variáveis categóricas

codificadas numericamente, como sexo, escolaridade e estado civil, apresentam baixa variabilidade relativa, refletindo uma distribuição razoavelmente equilibrada entre suas categorias principais.

No que diz respeito ao comportamento de pagamento, as variáveis de atraso (`atraso_pagto_0` a `atraso_pagto_6`) apresentam médias próximas de zero e medianas iguais a zero, sugerindo que a maioria dos clientes não apresenta atraso significativo nos pagamentos, embora existam casos extremos de inadimplência prolongada (até oito meses). Os valores de fatura e de pagamento exibem grande dispersão (que pode ser vista na Figura 8), com médias substancialmente superiores às medianas, o que indica distribuições fortemente assimétricas e a presença de outliers. Ademais, a ocorrência de valores negativos nas faturas é consistente com ajustes, estornos ou créditos no sistema de faturamento. Em conjunto, esses resultados reforçam a complexidade do perfil financeiro dos clientes e justificam o uso de técnicas de modelagem robustas à assimetria, à presença de valores extremos e à heterogeneidade dos dados monetários expressos em dólares taiwaneses (NT$).

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
limite_credito	167484	140000	10000	1e+06	129748
sexo	1.6	2	1	2	0.49
escolaridade	1.85	2	0	6	0.79
estado_civil	1.55	2	0	3	0.52
idade	35.49	34	21	79	9.22
atraso_pagto_0	-0.02	0	-2	8	1.12
atraso_pagto_2	-0.13	0	-2	8	1.2
atraso_pagto_3	-0.17	0	-2	8	1.2
atraso_pagto_4	-0.22	0	-2	8	1.17
atraso_pagto_5	-0.27	0	-2	8	1.13
atraso_pagto_6	-0.29	0	-2	8	1.15
fatura_valor_1	51223.3	22381.5	-165580	964511	73635.9
fatura_valor_2	49179.1	21200	-69777	983931	71173.8
fatura_valor_3	47013.2	20088.5	-157264	1.66409e+06	69349.4

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
fatura_valor_4	43262.9	19052	-170000	891586	64332.9
fatura_valor_5	40311.4	18104.5	-81334	927171	60797.2
fatura_valor_6	38871.8	17071	-339603	961664	59554.1
pagto_valor_1	5663.58	2100	0	873552	16563.3
pagto_valor_2	5921.16	2009	0	1.68426e+06	23040.9
pagto_valor_3	5225.68	1800	0	896040	17607
pagto_valor_4	4826.08	1500	0	621000	15666.2
pagto_valor_5	4799.39	1500	0	426529	15278.3
pagto_valor_6	5215.5	1500	0	528666	17777.5

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
sexo	1	11888	39.63
sexo	2	18112	60.37
escolaridade	0	14	0.05
escolaridade	1	10585	35.28
escolaridade	2	14030	46.77
escolaridade	3	4917	16.39
escolaridade	4	123	0.41
escolaridade	5	280	0.93
escolaridade	6	51	0.17
estado_civil	0	54	0.18
estado_civil	1	13659	45.53
estado_civil	2	15964	53.21
estado_civil	3	323	1.08

As variáveis categóricas do conjunto de dados descrevem características demográficas dos clientes, com distribuições detalhadas na Tabela 3. Observa-se predominância do sexo

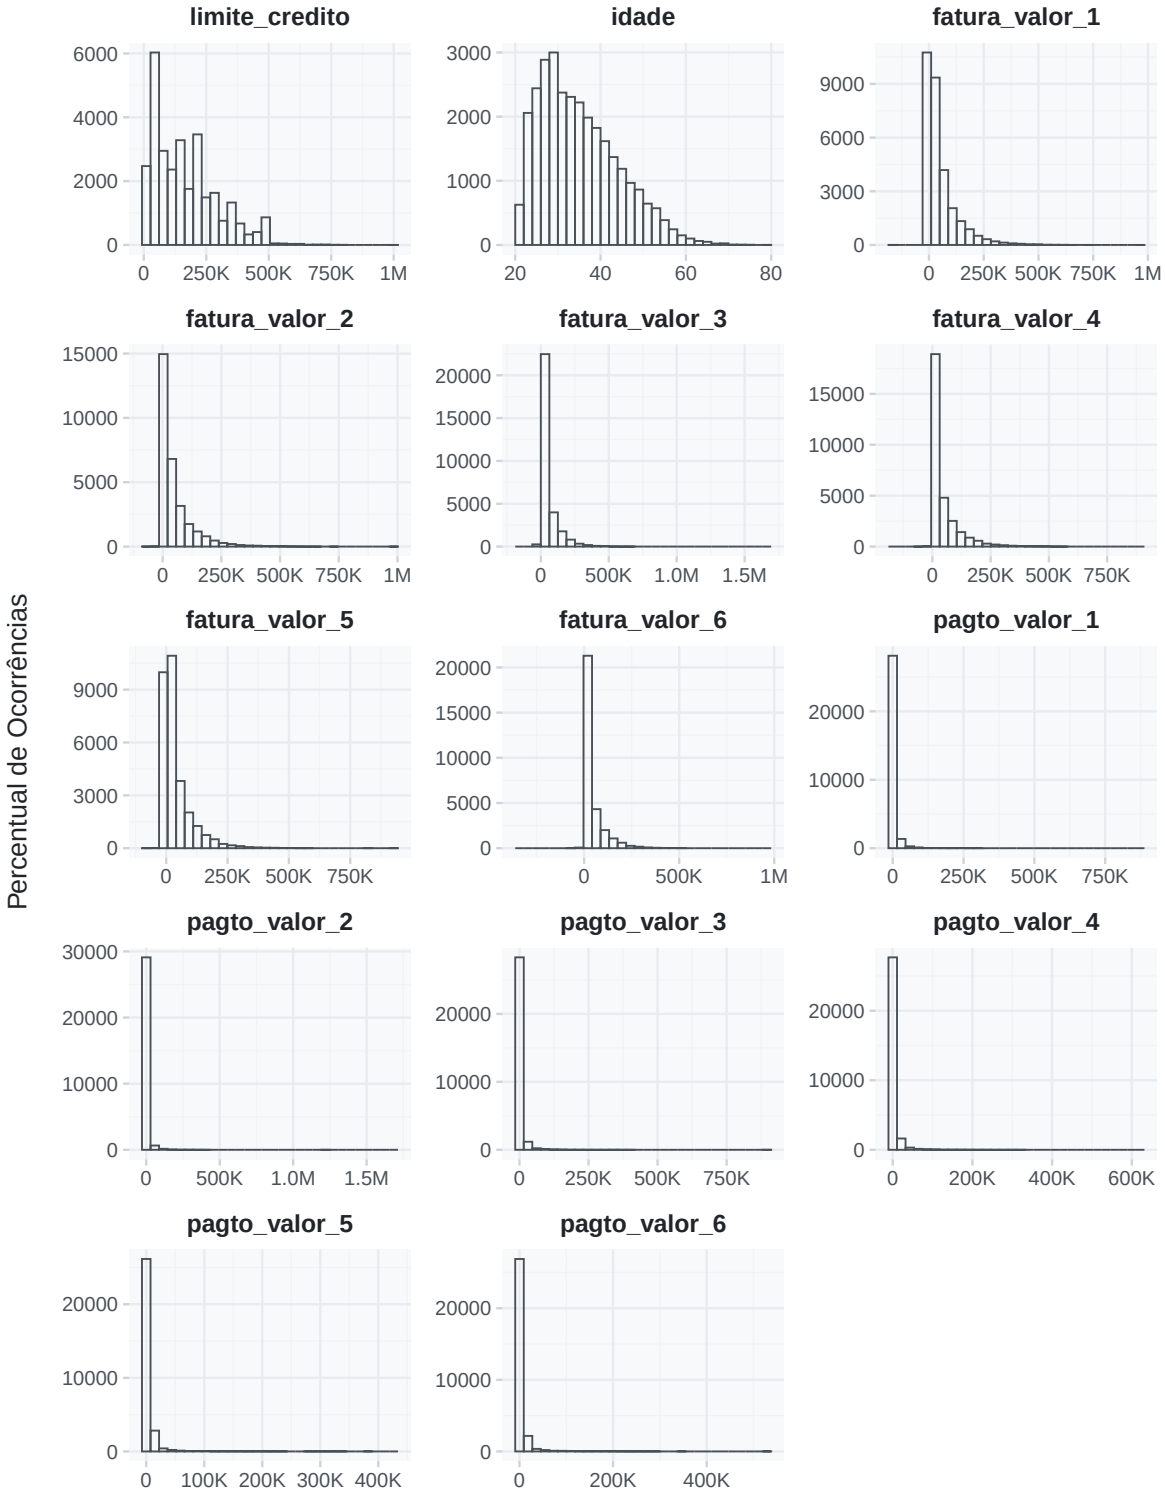


Figura 8: Distribuição das principais variáveis numéricas do conjunto de dados

feminino e concentração nas categorias “solteiro” e “casado” para estado civil. Na escolaridade, predominam os níveis universitário e de pós-graduação, o que pode estar associado a maior estabilidade de renda e menores taxas de inadimplência, embora essa relação deva ser avaliada empiricamente. As subcategorias “Desconhecido 1” e “Desconhecido 2” foram mantidas como categorias distintas, sem agrupamentos ou imputações, para preservar a estrutura original da variável.

4.1.2 Avaliação da variável resposta

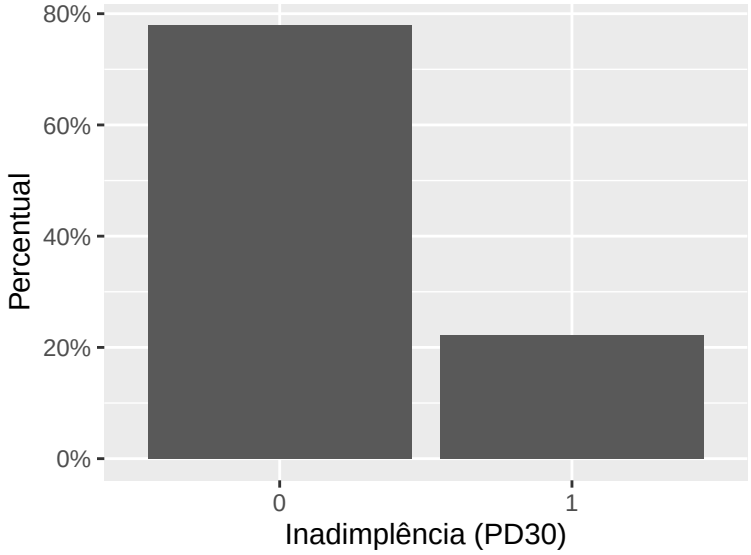


Figura 9: Distribuição da Inadimplência

Na Figura 9, observa-se a distribuição da variável resposta PD30, indicando que aproximadamente 22.12% dos clientes apresentam inadimplência no mês subsequente, enquanto os demais 77.88% correspondem à classe de adimplentes. Esse desbalanceamento de classes é característico de problemas de risco de crédito e deve ser considerado na etapa de modelagem, uma vez que pode influenciar métricas de desempenho e a calibração das probabilidades previstas pelos modelos.

Esse cenário é típico de problemas de credit scoring e caracteriza um contexto de `imbalanced learning`, no qual a classe minoritária (inadimplência) é justamente a de maior interesse analítico.

Nesse tipo de distribuição, métricas globais como acurácia podem ser enganosas, pois modelos que privilegiam a classe majoritária tendem a apresentar desempenho aparentemente

elevado mesmo sem capacidade discriminativa adequada para a classe de interesse. Por essa razão, métricas baseadas em discriminação e equilíbrio entre classes tornam-se mais informativas.

4.1.3 Análise de correlação entre variáveis numéricas

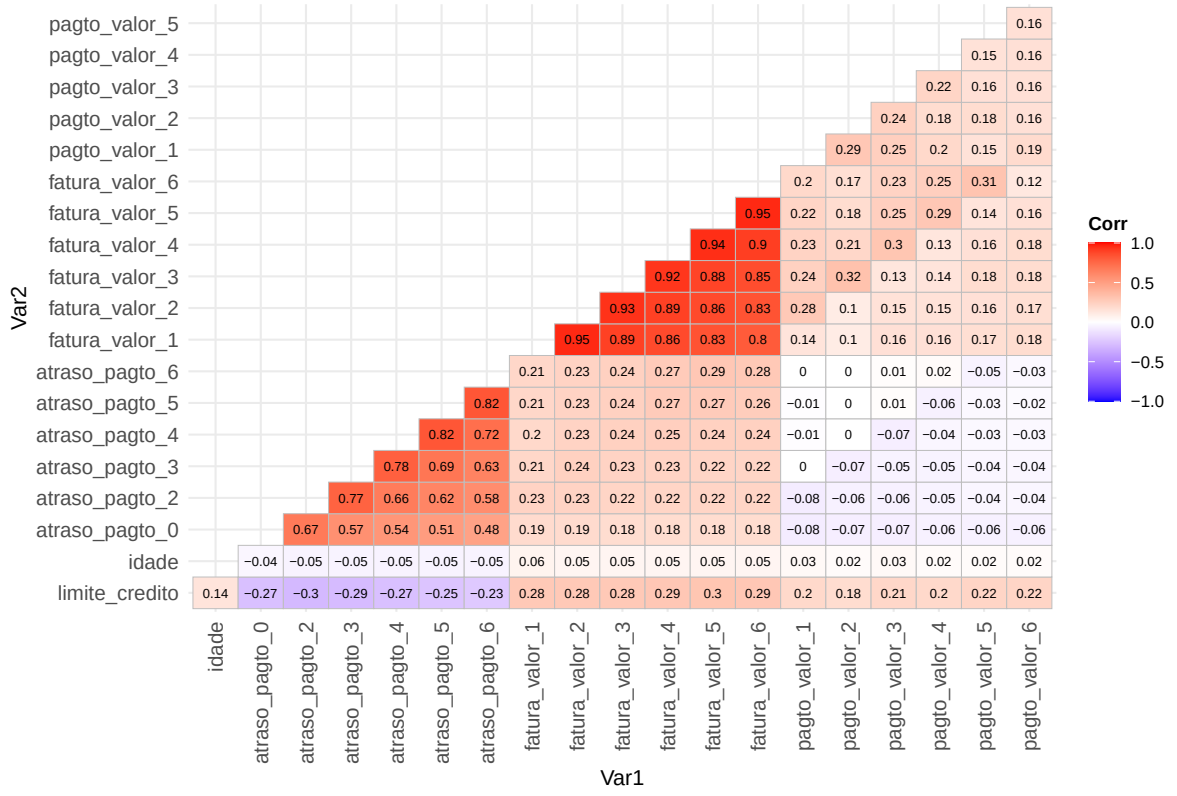


Figura 10: Mapa de calor da correlação entre variáveis numéricas do conjunto de dados de crédito

A Figura 10 evidencia padrões estruturais importantes entre as variáveis numéricas do conjunto de dados. Observa-se uma forte correlação positiva entre os valores de fatura ao longo dos meses (por exemplo, entre `fatura_valor_1` e `fatura_valor_2`, com correlação próxima de 0,95), indicando alta persistência temporal do saldo devedor dos clientes. Esse comportamento é esperado em dados de crédito, onde o saldo de fatura tende a evoluir de forma gradual ao longo do tempo.

De forma semelhante, as variáveis de atraso de pagamento (`atraso_pagto_*`) apresentam correlações moderadas a altas entre si (chegando a valores acima de 0,8), sugerindo forte dependência temporal e possível redundância informacional. Esse padrão é relevante do ponto de vista de modelagem, pois indica potencial multicolinearidade entre variáveis

de comportamento de pagamento, o que pode afetar estimativas em modelos lineares tradicionais e justificar o uso de abordagens regularizadas ou bayesianas mais robustas.

Por outro lado, variáveis como idade e limite de crédito apresentam correlações fracas com a maioria das demais variáveis, sugerindo que carregam informação relativamente independente dentro do conjunto de dados. Já os valores de pagamento (`pagto_valor_*`) mostram correlações baixas entre si e com outras variáveis, indicando maior variabilidade e menor estrutura temporal consistente quando comparados aos saldos de fatura e atrasos de pagamento.

4.1.4 Análise de outliers

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
atraso_pagto_0	3130	0.1043333
atraso_pagto_2	4410	0.1470000
atraso_pagto_3	4209	0.1403000
atraso_pagto_4	3508	0.1169333
atraso_pagto_5	2968	0.0989333
atraso_pagto_6	3079	0.1026333
fatura_valor_1	2400	0.0800000
fatura_valor_2	2395	0.0798333
fatura_valor_3	2469	0.0823000
fatura_valor_4	2622	0.0874000
fatura_valor_5	2725	0.0908333
fatura_valor_6	2693	0.0897667
idade	272	0.0090667
limite_credito	167	0.0055667
pagto_valor_1	2745	0.0915000
pagto_valor_2	2714	0.0904667
pagto_valor_3	2598	0.0866000
pagto_valor_4	2994	0.0998000

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
pagto_valor_5	2945	0.0981667
pagto_valor_6	2958	0.0986000

Os resultados da detecção de outliers (Tabela 4) pelo critério do IQR indicam um padrão bastante consistente com a natureza dos dados financeiros analisados. Observa-se que as variáveis relacionadas ao histórico de atraso de pagamento (`atraso_pagto_*`) apresentam as maiores proporções de outliers, variando aproximadamente entre 9,9% e 14,7% das observações. Esse comportamento é esperado, uma vez que essas variáveis são discretas e assimétricas por construção, refletindo estados de atraso que podem se concentrar em valores extremos (como atrasos elevados em determinados meses).

As variáveis de valores de fatura (`fatura_valor_*`) e de pagamento (`pagto_valor_*`) também apresentam proporções relevantes de outliers, em torno de 8% a 9%. Isso é típico em dados financeiros de crédito, nos quais distribuições são fortemente assimétricas à direita, com uma pequena parcela de clientes concentrando valores elevados de consumo e pagamento. Nesse contexto, esses "outliers" não necessariamente representam erros ou anomalias, mas sim a própria heterogeneidade do comportamento financeiro da população.

Em contraste, variáveis como idade e limite de crédito apresentam proporções muito baixas de outliers (inferiores a 1%), sugerindo distribuições mais estáveis e próximas de um comportamento aproximadamente simétrico ou moderadamente disperso. Esse resultado reforça a importância de interpretar outliers sob uma perspectiva contextual: em dados de crédito, valores extremos frequentemente carregam informação relevante sobre risco e capacidade financeira, não devendo ser removidos automaticamente sem análise substantiva.

4.2 Pré processamento do dataset

Inicialmente, foi realizada a verificação da presença de valores ausentes e observações duplicadas no conjunto de dados analisado. Não foram identificados valores faltantes ou registros duplicados, o que dispensou a aplicação de técnicas de imputação e garantiu a consistência estrutural das bases utilizadas.

Em relação aos outliers, optou-se por não aplicar procedimentos de remoção ou transformação em ambos os conjuntos de dados. A identificação pelo critério do intervalo interquartil (IQR) revelou a presença de valores extremos em variáveis financeiras e comportamentais, o que é esperado em bases de crédito devido à forte assimetria e heterogeneidade dos perfis de clientes. Nesses contextos, valores extremos não são necessariamente indicativos de erro, podendo representar justamente os casos de maior interesse analítico, especialmente em tarefas de modelagem de risco de crédito.

4.2.1 Seleção de variáveis e análise de correlação

A Figura 10 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas dos dois conjuntos de dados analisados. Em ambos os casos, observam-se padrões consistentes de correlação estrutural entre variáveis financeiras, especialmente aquelas relacionadas a renda, patrimônio e exposição de crédito.

Apesar da presença de relações entre variáveis financeiras e comportamentais, optou-se por não realizar remoção de variáveis nesta etapa. Essa decisão foi orientada pelo objetivo de manter comparabilidade entre abordagens de modelagem e preservar o espaço completo de informação para avaliação empírica posterior.

Adicionalmente, a eventual presença de redundância informacional será tratada implicitamente pelos próprios modelos considerados, incluindo regressão logística regularizada e abordagens bayesianas, além de ser avaliada posteriormente por métricas complementares como o Variance Inflation Factor (VIF). Isso permite uma análise mais controlada do impacto da estrutura de dependência entre variáveis sobre desempenho preditivo e interpretabilidade.

4.2.2 Separação treino/teste

Os conjuntos de dados foram divididos aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação às variáveis resposta. Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.3 Modelagem e Avaliação

Após a etapa de pré-processamento, o conjunto de dados de concessão de empréstimos foi utilizado para o ajuste de modelos de regressão logística, com o objetivo de estimar a probabilidade de default (PD30) a partir das características socioeconômicas e financeiras dos clientes. A regressão logística foi escolhida por se tratar de um modelo amplamente utilizado em problemas de classificação binária e por permitir a interpretação dos efeitos das variáveis explicativas sobre as chances do evento de interesse por meio das razões de chances (odds ratios). A partir dessa mesma estrutura de modelagem, foram consideradas as abordagens frequentista e Bayesiana, permitindo comparar não apenas o desempenho preditivo, mas também as diferentes formas de estimação e inferência sobre os parâmetros do modelo.

4.3.1 Modelagem Frequentista

Inicialmente, adotou-se uma abordagem frequentista, com estimação dos parâmetros via máxima verossimilhança. Essa estratégia fornece um ponto de partida robusto para a análise, permitindo avaliar tanto o poder preditivo quanto a contribuição individual das variáveis explicativas.

Com o intuito de investigar a sensibilidade do modelo à especificação das variáveis e à presença de dependências lineares, foram ajustadas diferentes variações do modelo logístico:

- **Modelo completo:** inclui todas as variáveis explicativas disponíveis após o pré-processamento, servindo como especificação de referência para as comparações.
- **Modelo com remoção manual de variáveis altamente correlacionadas:** variáveis com correlação absoluta superior a 75% foram excluídas de forma criteriosa, visando reduzir a redundância informacional e avaliar o impacto dessa simplificação na estabilidade e no desempenho do modelo.
- **Modelo com regularização L1 (Lasso):** incorpora uma penalização baseada na soma dos valores absolutos dos coeficientes, favorecendo a redução de sua magnitude e podendo levar alguns deles a valores exatamente iguais a zero. Dessa forma, além de controlar a complexidade do modelo, essa abordagem pode promover uma seleção implícita de variáveis.
- **Modelo com regularização L2 (Ridge):** utiliza uma penalização baseada na soma dos quadrados dos coeficientes, promovendo sua redução em direção a zero, mas sem anulá-los. Seu objetivo é controlar a magnitude dos parâmetros e reduzir a sensibilidade do modelo a variáveis explicativas correlacionadas.

Quanto ao pré-processamento, a padronização das variáveis numéricas foi aplicada aos modelos com regularização L1 e L2, uma vez que a penalização depende da magnitude dos coeficientes e, portanto, é sensível à escala das variáveis. Nos modelos sem regularização, a padronização não foi aplicada, preservando-se as escalas originais para facilitar a interpretação dos coeficientes.

A comparação entre essas especificações permite avaliar o trade-off entre interpretabilidade, complexidade do modelo e desempenho preditivo, além de fornecer evidências empíricas sobre o papel do score de crédito e da estrutura de correlação das variáveis no processo de decisão de concessão de empréstimos.

Após o pré-processamento, diferentes especificações de modelos de regressão logística foram ajustadas com base em máxima verossimilhança. Todas as especificações propostas foram avaliadas de forma sistemática quanto ao ajuste estatístico e às propriedades inferenciais do modelo, incluindo interpretação dos coeficientes, razões de chances (odds ratios), testes de razão de verossimilhança, critérios de informação (AIC e BIC), diagnóstico de multicolinearidade (VIF) e análise de resíduos.

Tabela 5: Estatísticas de ajuste dos modelos de regressão logística não penalizados

Modelo	Deviance nula	Deviance residual	AIC	BIC	Graus de liberdade residuais
Completo	23779.02	20797.50	20855.50	21088.11	22471
Sem multicolinearidade	23779.02	20848.41	20890.41	21058.85	22479

A comparação das estatísticas de ajuste foi realizada apenas para os modelos de regressão logística não penalizados (Completo e Sem multicolinearidade), uma vez que ambos foram estimados pelo método tradicional de máxima verossimilhança, permitindo a obtenção e a interpretação direta de medidas como a deviance residual, o AIC e o BIC. Os modelos Lasso (L1) e Ridge (L2), por sua vez, incorporam penalizações sobre os coeficientes e são estimados por meio do pacote glmnet, de modo que os critérios tradicionais de informação não são diretamente equivalentes aos calculados para os modelos não penalizados. Por essa razão, a comparação desses modelos foi conduzida principalmente com base nas métricas de desempenho preditivo.

Conforme apresentado na Tabela 5, o modelo Completo apresentou menor deviance residual em relação ao modelo Sem multicolinearidade, além de menores valores de AIC. Esses resultados indicam um melhor ajuste do modelo completo segundo essas medidas. Em contrapartida, o modelo Sem multicolinearidade apresentou menor BIC, favorecendo a especificação mais parcimoniosa, que também possui oito graus de liberdade residuais adicionais, correspondentes a uma estrutura com oito parâmetros a menos.

De modo geral, os resultados apontam para um equilíbrio entre qualidade de ajuste e parcimônia: enquanto o modelo Completo é favorecido pela deviance residual e pelo AIC, o modelo Sem multicolinearidade apresenta vantagem segundo o BIC. Essas diferenças são consideradas em conjunto com os resultados das métricas preditivas, apresentados a seguir.

Tabela 6: Métricas de desempenho do modelo de regressão logística, avaliadas no conjunto de teste.

Métrica	Completo	Sem multicolinearidade	Lasso (L1)	Ridge (L2)
Acurácia	0.811	0.812	0.811	0.807
Acurácia balanceada	0.613	0.613	0.613	0.599
ROC-AUC	0.716	0.714	0.716	0.715
Log-loss	0.470	0.470	0.470	0.469
Sensibilidade	0.259	0.258	0.258	0.226
Especificidade	0.967	0.969	0.968	0.972
Precisão	0.692	0.703	0.695	0.696
F1-score	0.376	0.377	0.376	0.341
MCC	0.340	0.345	0.341	0.318

Tabela 7: Resumo do VIF para os modelos de regressão logística não penalizados.

Modelo	VIF máximo	VIF médio
Completo	41.12	7.80
Sem multicolinearidade	1.84	1.24

As quatro especificações apresentaram desempenho preditivo bastante semelhante (Tabela 6): ROC AUC entre 0,714 e 0,716, log-loss em torno de 0,47 e acurácia entre 0,807 e 0,812. O modelo L2 (Ridge) é a única exceção parcial: apresentou a menor sensibilidade (0,226) e a maior especificidade (0,972), em contraste com os demais modelos, que mantiveram acurácia balanceada próxima de 0,613. As diferenças observadas são pequenas, indicando que a remoção de variáveis correlacionadas ou a aplicação das penalizações não produziu alterações substanciais na capacidade discriminativa.

A análise do VIF (Tabela 7) evidencia uma diferença mais pronunciada entre as especificações: o modelo completo apresentou VIF máximo de 41,12 e médio de 7,80, enquanto o modelo sem multicolinearidade reduziu esses valores para 1,84 e 1,24, respectivamente — redução substancial sem alteração relevante no desempenho preditivo. Os modelos regularizados L1 e L2 não são avaliados por VIF porque a regularização atua sobre os

coeficientes durante a estimação, não sobre a estrutura de correlação dos preditores; assim, são comparados principalmente com base no desempenho preditivo e no comportamento dos coeficientes.

Um aspecto comum às quatro especificações é a elevada especificidade (entre 0,967 e 0,972) acompanhada por baixa sensibilidade (entre 0,226 e 0,259). Esse comportamento indica que os modelos identificam corretamente a grande maioria dos não inadimplentes, mas classificam incorretamente parcela expressiva dos inadimplentes, resultado consistente com o desbalanceamento da variável resposta e que deve ser considerado na interpretação da acurácia global.

4.3.1.1 Comparações de Features L1 vs Remoção de Variáveis Correlacionadas

A comparação entre as estratégias de redução da complexidade revelou uma sobreposição parcial entre as variáveis excluídas pelo procedimento de correlação e aquelas cujos coeficientes foram anulados pela regularização L1. Em particular, a variável `fatura_valor_4` foi removida em ambas as abordagens. Entretanto, o L1 também anulou o coeficiente de `fatura_valor_6`, enquanto o procedimento baseado em correlação excluiu outras variáveis, como `atraso_pagto_3`, `atraso_pagto_4`, `atraso_pagto_5` e `fatura_valor_5`.

Essa sobreposição limitada indica que as estratégias não são equivalentes: enquanto a remoção por correlação considera a associação entre os preditores, a penalização L1 seleciona variáveis com base na contribuição conjunta para o ajuste do modelo, condicionada à penalização aplicada. Assim, embora ambas possam reduzir a complexidade da especificação, seus critérios de seleção produzem conjuntos distintos de variáveis.

4.3.1.2 Seleção da especificação para a análise inferencial

A análise inferencial detalhada será concentrada no modelo sem multicolinearidade. Essa escolha não decorre de superioridade preditiva, uma vez que os quatro modelos apresentaram métricas bastante próximas, mas da combinação entre a redução substancial do VIF (de 41,12 para 1,84) e a manutenção da estrutura convencional da regressão logística estimada por MLE, que viabiliza o uso direto de erros-padrão, intervalos de confiança, testes de significância e razões de chances. A menor multicolinearidade também reduz a

instabilidade das estimativas e facilita a interpretação individual dos coeficientes, condição relevante para a comparação com a abordagem bayesiana.

Os modelos L1 e L2 permanecem como referências na avaliação do desempenho preditivo. Entretanto, a estimação penalizada não fornece erros-padrão convencionais de forma direta, inviabilizando os procedimentos inferenciais usuais; além disso, a penalização L1 pode anular coeficientes, incorporando seleção de variáveis à estimação. Por essas razões, a análise de diagnóstico e interpretação detalhada será conduzida com base no modelo sem multicolinearidade, que preserva a estrutura completa da regressão logística tradicional.

4.3.1.3 Diagnóstico do modelo modelo sem multicolinearidade

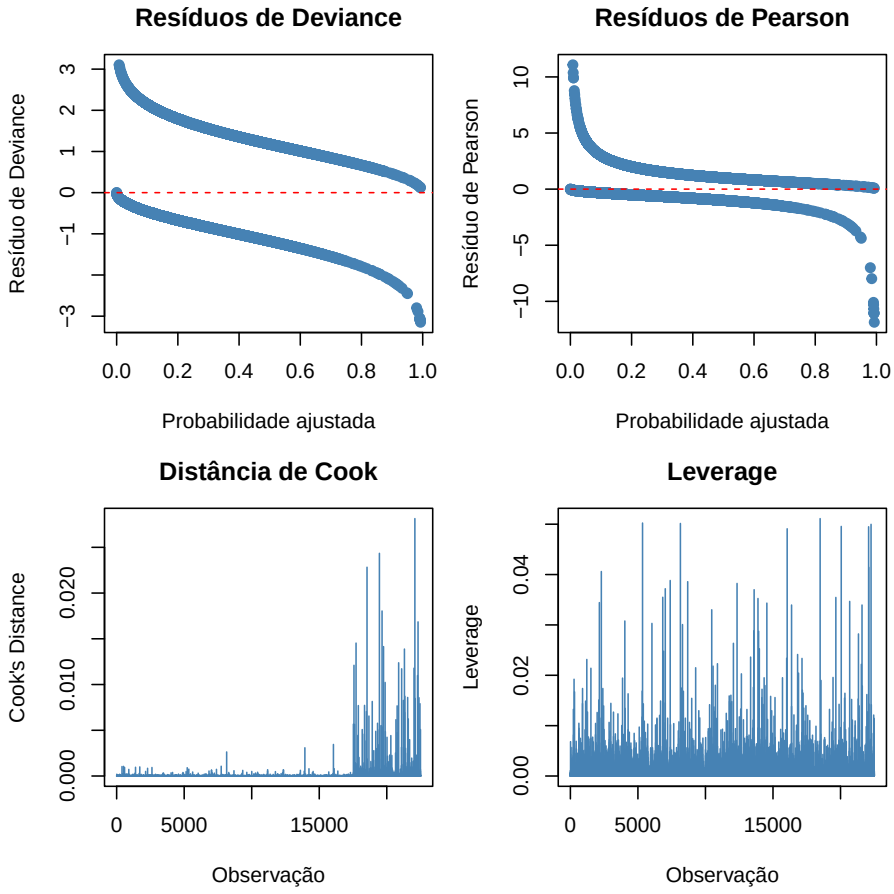


Figura 11: Análise de resíduos do modelo de regressão logística sem multicolinearidade.

A adequação do ajuste foi investigada por meio dos resíduos de Deviance e de Pearson, da distância de Cook e do *leverage*, conforme apresentado na Figura 11. Os gráficos de resíduos apresentam a formação de dois ramos, comportamento esperado em modelos logísticos com resposta binária. Os resíduos de Pearson mostram algumas observações

de maior magnitude nas regiões de probabilidades extremas, compatíveis com a natureza probabilística do modelo.

A distância de Cook apresenta valores próximos de zero para a maior parte das observações, com máximo em torno de 0,028; o *leverage* atinge aproximadamente 0,05 nas observações de maior alavancagem. De modo geral, os diagnósticos não evidenciam padrão generalizado de influência ou inadequação estrutural que comprometa a utilização do modelo.

Tabela 8: Teste da razão de verossimilhanças para a contribuição individual dos termos do modelo.

Variável	Graus de liberdade	Deviance	p-valor
limite_credito	1	16.473	< 0.001
idade	1	7.248	0.0071
atraso_pagto_0	1	864.352	< 0.001
atraso_pagto_2	1	48.532	< 0.001
atraso_pagto_6	1	19.514	< 0.001
fatura_valor_1	1	33.057	< 0.001
pagto_valor_1	1	18.374	< 0.001
pagto_valor_2	1	20.785	< 0.001
pagto_valor_3	1	1.905	0.1675
pagto_valor_4	1	10.725	0.0011
pagto_valor_5	1	6.159	0.0131
pagto_valor_6	1	4.122	0.0423
sexo_Feminino	1	15.050	< 0.001
escolaridade_Universidade	1	3.139	0.0764
escolaridade_EnsinoMedio	1	4.829	0.0280
escolaridade_Outros	1	6.868	0.0088
escolaridade_Desconhecido1	1	47.049	< 0.001
escolaridade_Desconhecido2	1	0.006	0.9392
estado_civil_Solteiro	1	19.567	< 0.001
estado_civil_Outros	1	0.528	0.4674

A contribuição individual dos termos do modelo foi avaliada por meio do teste da razão de

verossimilhanças (Tabela 8), que compara o modelo completo com versões nas quais cada preditor é removido individualmente. `atraso_pagto_0` apresenta a maior contribuição, com redução de 864 unidades na Deviance ($p < 0{,}001$), seguido de `atraso_pagto_2`, `escolaridade_Desconhecido1`, `fatura_valor_1` e demais variáveis de comportamento de pagamento e demográficas, com $p < 0{,}001$ ou $p < 0{,}05$. Quatro termos não atingiram significância ao nível de 5%: `pagto_valor_3`, `escolaridade_Universidade`, `escolaridade_Desconhecido2` e `estado_civil_Outros`.

Cabe observar que a ausência de significância individual não implica irrelevância para o modelo: o teste avalia a contribuição de cada termo condicionada à presença dos demais, e a significância estatística não corresponde, por si só, à magnitude do efeito prático.

Tabela 9: Resultados da estimação do modelo de regressão logística frequentista

term	estimate	std.error	statistic	p.value	OR
(Intercept)	-0.99	0.10	-9.93	0.00	0.37
limite_credito	0.00	0.00	-4.03	0.00	1.00
idade	0.01	0.00	2.70	0.01	1.01
atraso_pagto_0	0.60	0.02	29.41	0.00	1.82
atraso_pagto_2	0.13	0.02	6.99	0.00	1.14
atraso_pagto_6	0.08	0.02	4.41	0.00	1.08
fatura_valor_1	0.00	0.00	-5.67	0.00	1.00
pagto_valor_1	0.00	0.00	-3.74	0.00	1.00
pagto_valor_2	0.00	0.00	-3.93	0.00	1.00
pagto_valor_3	0.00	0.00	-1.32	0.19	1.00
pagto_valor_4	0.00	0.00	-2.97	0.00	1.00
pagto_valor_5	0.00	0.00	-2.31	0.02	1.00
pagto_valor_6	0.00	0.00	-1.94	0.05	1.00
sexo_Feminino	-0.14	0.04	-3.89	0.00	0.87
escolaridade_Universidade	-0.07	0.04	-1.77	0.08	0.93
escolaridade_EnsinoMedio	-0.12	0.06	-2.19	0.03	0.89
escolaridade_Outros	-0.99	0.43	-2.29	0.02	0.37
escolaridade_Desconhecido1	-1.86	0.35	-5.25	0.00	0.15
escolaridade_Desconhecido2	0.03	0.45	0.08	0.94	1.03

Tabela 9: Resultados da estimação do modelo de regressão logística frequentista

term	estimate	std.error	statistic	p.value	OR
estado_civil_Solteiro	-0.18	0.04	-4.42	0.00	0.84
estado_civil_Outros	-0.12	0.16	-0.72	0.47	0.89

A Tabela 9 apresenta os coeficientes estimados, erros-padrão, estatísticas de teste, p-valores e razões de chances (OR). Entre os preditores avaliados, `atraso_pagto_0` destaca-se como a variável de maior impacto positivo, com coeficiente de 0,5984 e OR de 1,82 — mantidos os demais preditores constantes, sua presença está associada a aproximadamente 1,82 vezes as chances de PD30. As variáveis `atraso_pagto_2` e `atraso_pagto_6` também apresentam associações positivas, embora de menor magnitude. Entre os efeitos negativos, `sexo_Feminino` (OR = 0,87; $p < 0,001$) e `estado_civil_Solteiro` (OR = 0,84; $p < 0,001$) estão associados a menores chances de inadimplência. A categoria `escolaridade_Desconhecido1` apresenta o maior efeito negativo (OR = 0,15; $p < 0,001$), embora deva ser interpretada com cautela, pois pode representar ausência de informação no processo de coleta, não um nível substantivo de escolaridade.

Os termos relacionados a valores de fatura, pagamento e limite de crédito apresentam coeficientes numericamente pequenos pelo fato de essas variáveis serem medidas em escala monetária, na qual uma unidade representa variação relativamente pequena. Os coeficientes arredondados a quatro casas decimais aparecem como 0,0000 e ORs como 1,0000, sem que isso implique ausência de efeito — a interpretação adequada considera variações economicamente relevantes na escala original. Nesse grupo, `fatura_valor_1`, `pagto_valor_1`, `pagto_valor_2`, `pagto_valor_4` e `pagto_valor_5` apresentam associação estatisticamente significativa com PD30.

Em conjunto, os coeficientes evidenciam associações de diferentes magnitudes e direções, com destaque para os preditores de comportamento de pagamento. A análise das ORs complementa o teste da razão de verossimilhanças apresentado anteriormente, permitindo caracterizar tanto a direção dos efeitos quanto sua relevância individual no modelo.

4.3.2 Modelagem Bayesiana

Para avaliar a influência da especificação da distribuição a priori sobre as estimativas posteriores, foram consideradas duas distribuições distintas: Normal e Laplace, ambas centradas em zero e com escala igual a um. A distribuição Normal estabelece uma contração contínua e simétrica dos coeficientes, enquanto a distribuição Laplace apresenta maior concentração em torno de zero e caudas mais pesadas, permitindo investigar uma estratégia alternativa de regularização. Em ambos os modelos, foi utilizada uma distribuição Normal com média zero e desvio-padrão cinco para o intercepto, permitindo maior flexibilidade na estimação desse parâmetro.

4.3.2.1 Diagnóstico de multicolinearidade

Tabela 10: Valores máximo e médio dos fatores de inflação da variância (VIF) dos modelos bayesianos.

VIF máximo	VIF médio
25.88	6.08

O diagnóstico de multicolinearidade foi realizado a partir dos fatores de inflação da variância (*Variance Inflation Factor*, VIF) dos preditores utilizados nas especificações bayesianas. Como os modelos com priors Normal e Laplace compartilham a mesma matriz de preditores, os valores de VIF são idênticos para ambas as especificações, sendo apresentados conjuntamente na Tabela 10.

Os resultados revelaram que a multicolinearidade está concentrada principalmente nas variáveis referentes aos valores das faturas mensais (`fatura_valor_1` a `fatura_valor_6`), cujos VIFs variaram entre 14,35 e 25,88. As variáveis relacionadas ao histórico de atrasos (`atraso_pagto`) apresentaram valores intermediários, entre 1,89 e 4,70, enquanto os demais preditores registraram VIFs inferiores a 2.

Esse diagnóstico evidencia a presença de multicolinearidade elevada entre as variáveis referentes aos valores das faturas, indicando que a estrutura de dependência linear entre os preditores permanece nas especificações bayesianas. Ressalta-se, entretanto, que o VIF caracteriza a estrutura dos preditores, não o efeito da regularização sobre as estimativas

Tabela 11: Diagnósticos de convergência do modelo bayesiano com prior Normal.

Diagnóstico	Resultado
Rhat mínimo	1.000
Rhat máximo	1.003
ESS mínimo	2431.418
ESS máximo	7022.087
ESS do log-posterior	1661.953
MCSE do log-posterior	0.095

posteriores. Assim, embora as distribuições a priori possam contribuir para estabilizar os coeficientes, não eliminam a multicolinearidade identificada.

4.3.2.2 Diagnóstico do modelo bayesiano

4.3.2.2.1 Priori Normal

A avaliação da convergência e da qualidade da amostragem posterior do modelo bayesiano com distribuição a priori Normal apresentou resultados satisfatórios. Conforme apresentado na Tabela 11, os valores de $\hat{R}$ permaneceram iguais a 1,000, considerando o arredondamento apresentado, para todos os parâmetros estimados. Esse resultado indica que não foram identificadas diferenças relevantes entre as distribuições amostradas pelas quatro cadeias de Markov, fornecendo evidências favoráveis à convergência do algoritmo.

Os tamanhos efetivos da amostra (*effective sample size*, ESS) também apresentaram valores satisfatórios. Considerando as quatro cadeias, os valores entre os coeficientes variaram de 2.448 a 6.648, indicando que a autocorrelação entre as amostras sucessivas não comprometeu significativamente a eficiência da amostragem. O log-posterior apresentou ESS de 1.599, inferior aos valores observados para os coeficientes, mas ainda indicando uma quantidade efetiva expressiva de amostras. Adicionalmente, os erros-padrão de Monte Carlo foram muito pequenos, sugerindo que o erro numérico decorrente da simulação teve influência reduzida sobre as estimativas apresentadas.

A avaliação também contemplou diagnósticos específicos do algoritmo HMC, responsável pela geração das amostras posteriores. Não foram observadas transições divergentes entre as 4.000 iterações posteriores, resultado importante porque divergências podem indicar dificuldades do algoritmo na exploração de determinadas regiões da distribuição posterior e comprometer a confiabilidade das estimativas. Da mesma forma, nenhuma iteração atingiu

a profundidade máxima da árvore de 15 níveis, não havendo evidências de saturação desse limite durante a amostragem.

Por fim, o E-BFMI não indicou comportamento patológico. Esse indicador avalia a eficiência da exploração da distribuição de energia pelo algoritmo HMC, sendo utilizado para identificar possíveis dificuldades de exploração do espaço posterior. Sua avaliação favorável, em conjunto com a ausência de divergências e de saturação da profundidade da árvore, reforça a adequação do processo de amostragem.

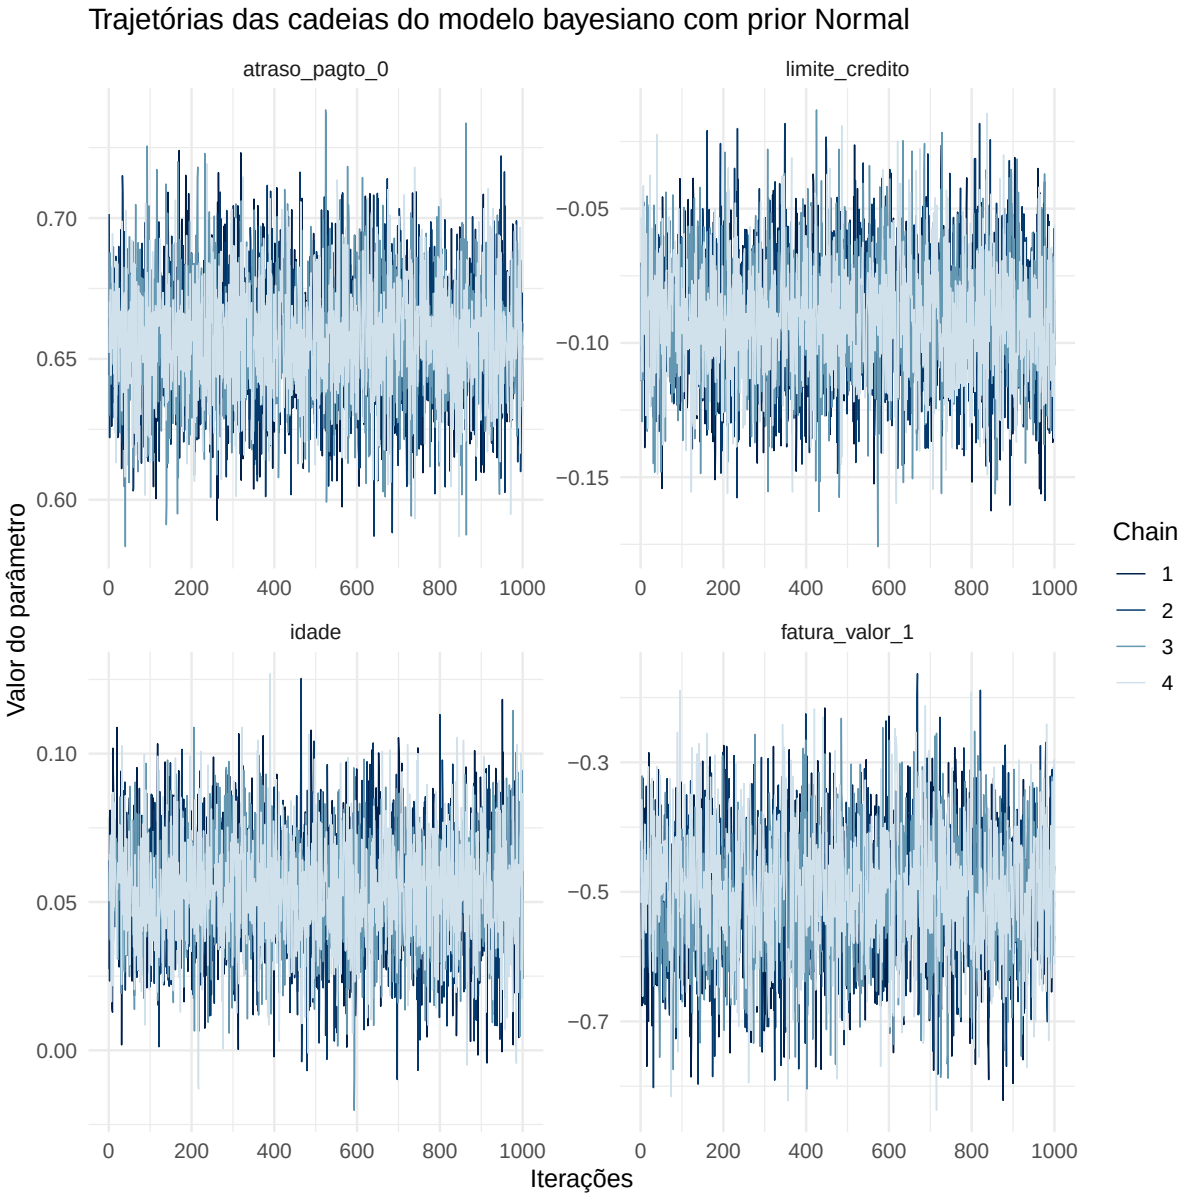


Figura 12: Gráficos de traço das cadeias de Markov Monte Carlo (MCMC) para os coeficientes selecionados do modelo bayesiano com priori Normal.

A inspeção dos *traceplots* (Figura 12) revelou boa sobreposição entre as quatro cadeias,

com oscilações estáveis ao longo das iterações e ausência de tendências persistentes ou padrões de separação, indicando mistura adequada e estacionariedade da amostragem.

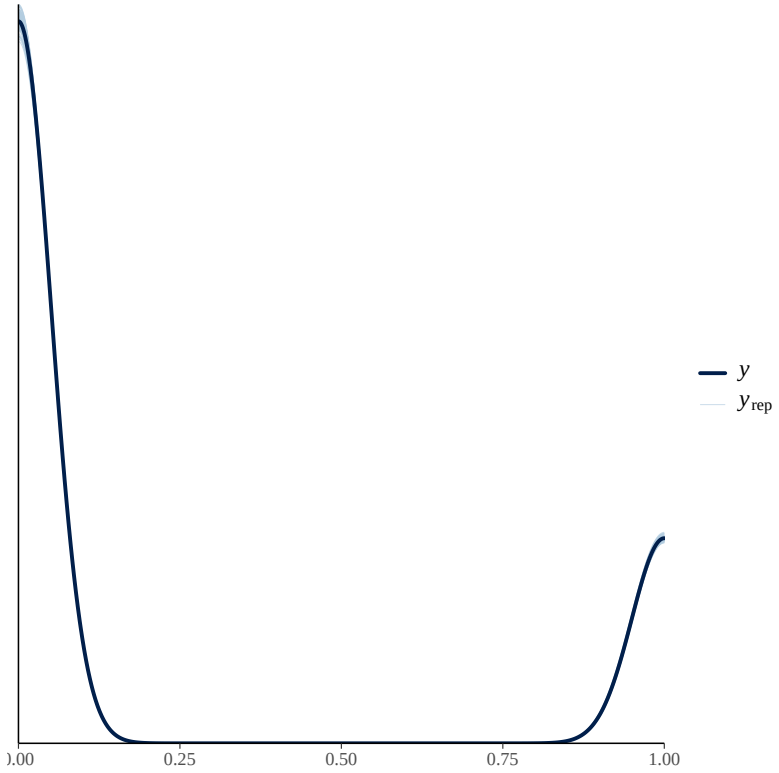


Figura 13: Verificação preditiva posterior para o modelo bayesiano com priori Normal

A PPC (Figura 13) apresentou sobreposição satisfatória entre as distribuições observada e replicada para ambas as categorias, indicando que o modelo reproduz adequadamente a distribuição marginal da variável resposta, incluindo o desbalanceamento entre as classes. Essa verificação não atesta a capacidade discriminativa nem a qualidade das probabilidades individuais, que serão avaliadas pelas métricas de classificação.

Em conjunto, os diagnósticos indicam convergência satisfatória e ausência de problemas relevantes no procedimento de amostragem, tornando as amostras posteriores adequadas para a análise dos parâmetros e do desempenho preditivo do modelo.

4.3.2.2.2 Priori Laplace

A avaliação da convergência do modelo bayesiano com priori Laplace foi realizada por meio de diagnósticos numéricos e da verificação do comportamento das cadeias de Markov. Conforme apresentado na Tabela 12, os valores do fator de redução potencial de escala ($\hat{R}$) variaram entre 1,000 e 1,003, indicando concordância entre as cadeias e ausência de

Tabela 12: Diagnósticos de convergência do modelo bayesiano com prior Laplace.

Diagnóstico	Resultado
Rhat mínimo	1.000
Rhat máximo	1.003
ESS mínimo	2363.451
ESS máximo	5055.712
ESS do log-posterior	855.478
MCSE do log-posterior	0.252

evidências de problemas de convergência. Os tamanhos efetivos da amostra (ESS) dos coeficientes variaram entre 2.363 e 5.056, demonstrando que, apesar da autocorrelação inerente às amostras obtidas por métodos de Monte Carlo via Cadeias de Markov, foi possível obter uma quantidade satisfatória de amostras efetivamente independentes para a estimação dos parâmetros.

O parâmetro associado ao log-posterior apresentou ESS de 855,478 e erro padrão de Monte Carlo (MCSE) de 0,252. Embora esses indicadores sejam menos favoráveis em comparação aos observados para os coeficientes, não constituem, isoladamente, evidências de problemas de convergência, devendo ser interpretados em conjunto com os demais diagnósticos.

Os diagnósticos específicos do algoritmo HMC não identificaram transições divergentes nem saturação da profundidade máxima da árvore de amostragem, e o E-BFMI não indicou comportamento patológico, resultados análogos aos observados para o modelo com priori Normal.

A inspeção dos *traceplots* (Figura 14) evidenciou comportamento semelhante ao observado para o modelo com priori Normal: as quatro cadeias apresentaram boa sobreposição e oscilações estáveis ao longo das iterações, sem tendências persistentes nem padrões de separação, resultado consistente com os diagnósticos numéricos da Tabela 12.

A verificação preditiva posterior (Figura 15) apresentou resultados análogos aos do modelo com priori Normal: boa sobreposição entre a distribuição observada e as replicações posteriores, indicando que o modelo reproduz adequadamente a distribuição marginal da variável resposta.

4.3.2.3 Comparação entre as especificações bayesianas

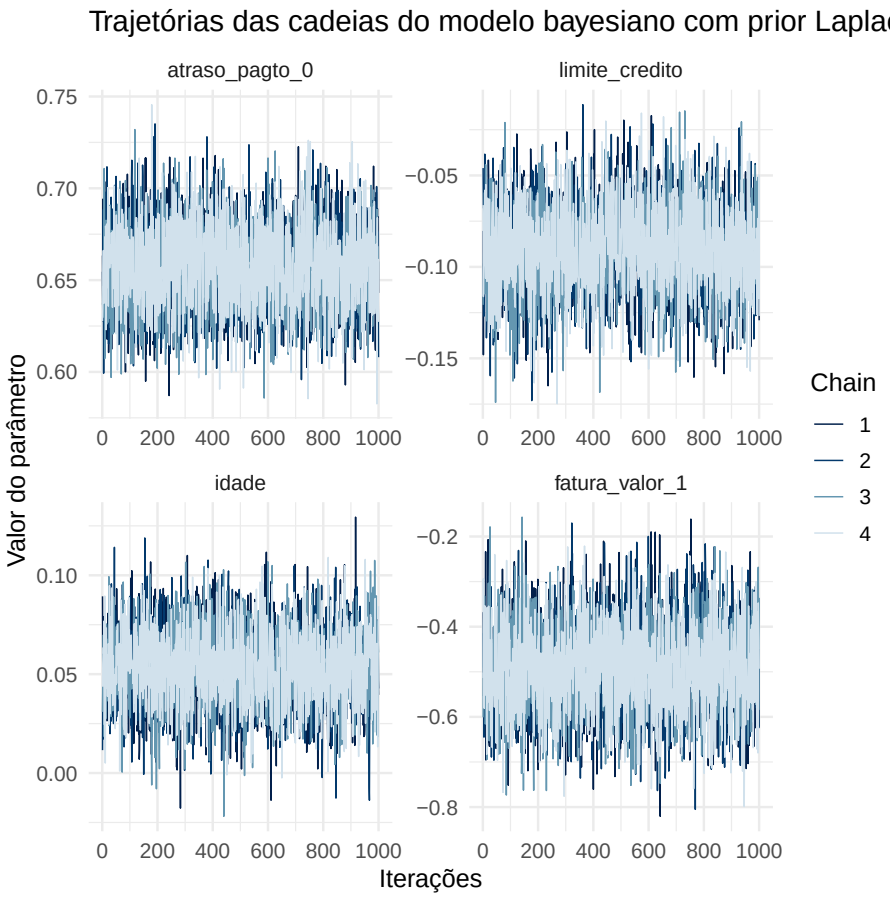


Figura 14: Gráficos de traço das cadeias de Markov Monte Carlo (MCMC) para os coeficientes selecionados do modelo bayesiano com priori Laplace

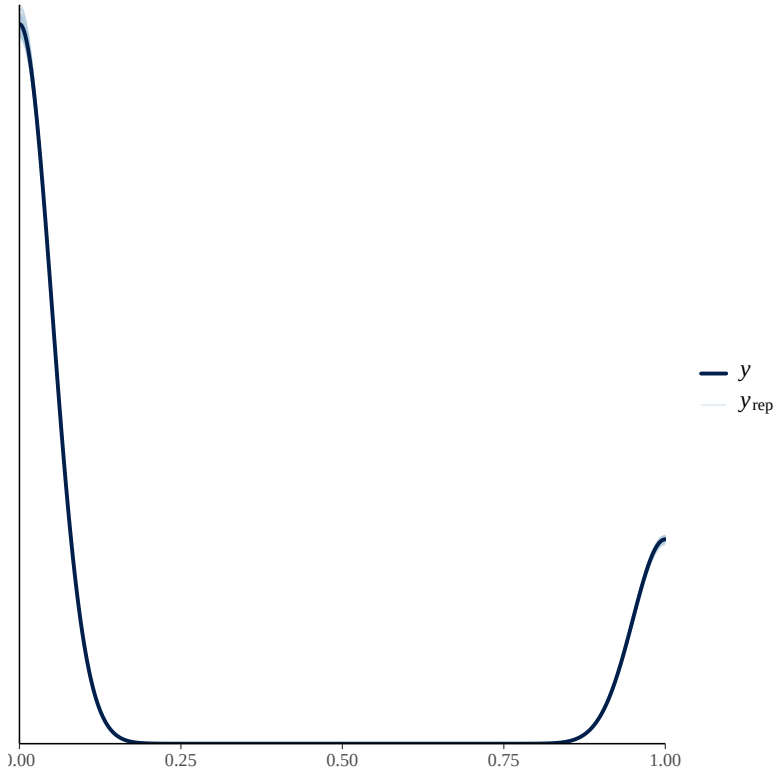


Figura 15: Verificação preditiva posterior para o modelo bayesiano com priori Laplace

Tabela 13: Comparação dos modelos bayesianos com base na diferença de ELPD.

Modelo	Diferença de ELPD	Erro-padrão da diferença
fit_laplace	0.00	0.00
fit_normal	-0.74	0.32

Após a avaliação individual dos modelos bayesianos com priors Normal e Laplace, realizou-se uma comparação complementar de seu desempenho preditivo por meio do WAIC. Para essa finalidade, utilizou-se a diferença de densidade preditiva esperada (ELPD) entre os modelos, conforme apresentado na Tabela 13.

A comparação tomou o modelo com prior Laplace como referência. Esse modelo apresentou WAIC de 20.864,79, ligeiramente inferior ao valor de 20.865,83 obtido pelo modelo com prior Normal. Na comparação baseada na ELPD, o modelo Normal apresentou diferença de $-0{,}74$, com erro-padrão de 0,32. Embora os resultados indiquem uma pequena vantagem relativa do modelo Laplace, a magnitude reduzida da diferença não sugere uma superioridade preditiva expressiva. Além disso, os valores de complexidade efetiva (p_{WAIC})

foram próximos entre as especificações, reforçando a semelhança entre os modelos segundo esse critério.

4.3.2.4 Análise das distribuições a posteriori

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
(Intercept)	-1.484	-1.483	-1.523	-1.445	-1.522	-1.444
atraso_pagto_0	0.657	0.657	0.614	0.701	0.614	0.702
atraso_pagto_2	0.094	0.093	0.039	0.151	0.039	0.150
atraso_pagto_3	0.083	0.083	0.020	0.144	0.022	0.142
atraso_pagto_4	0.053	0.051	-0.013	0.118	-0.015	0.115
atraso_pagto_5	0.031	0.033	-0.038	0.099	-0.032	0.100
atraso_pagto_6	0.001	0.003	-0.056	0.059	-0.055	0.057
escolaridade_Desconhecido1	-0.183	-0.179	-0.257	-0.118	-0.253	-0.118
escolaridade_Desconhecido2	0.001	0.000	-0.038	0.035	-0.039	0.035
escolaridade_EnsinoMedio	-0.046	-0.044	-0.085	-0.006	-0.084	-0.005
escolaridade_Outros	-0.066	-0.064	-0.125	-0.017	-0.126	-0.013
escolaridade_Universidade	-0.038	-0.037	-0.077	0.002	-0.078	0.005
estado_civil_Outros	-0.011	-0.011	-0.046	0.021	-0.045	0.021

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
estado_civil_Solteiro	-0.089	-0.089	-0.127	-0.051	-0.127	-0.049
fatura_valor_1	-0.503	-0.487	-0.708	-0.311	-0.684	-0.295
fatura_valor_2	0.277	0.255	0.037	0.522	0.031	0.497
fatura_valor_3	0.048	0.048	-0.156	0.263	-0.146	0.244
fatura_valor_4	-0.021	-0.021	-0.223	0.174	-0.207	0.172
fatura_valor_5	0.109	0.098	-0.107	0.322	-0.097	0.303
fatura_valor_6	-0.005	0.002	-0.166	0.163	-0.155	0.164
idade	0.053	0.053	0.014	0.092	0.015	0.091
limite_credito	-0.091	-0.090	-0.137	-0.045	-0.138	-0.043
pagto_valor_1	-0.229	-0.225	-0.322	-0.148	-0.311	-0.146
pagto_valor_2	-0.184	-0.183	-0.288	-0.093	-0.282	-0.092
pagto_valor_3	-0.035	-0.036	-0.105	0.032	-0.105	0.026
pagto_valor_4	-0.093	-0.091	-0.163	-0.031	-0.162	-0.028
pagto_valor_5	-0.062	-0.061	-0.128	-0.001	-0.131	-0.002
pagto_valor_6	-0.048	-0.048	-0.105	0.005	-0.108	0.004

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
sexo_Feminino	-0.067	-0.067	-0.101	-0.032	-0.101	-0.034

A comparação das distribuições posteriores evidencia resultados bastante semelhantes entre os modelos especificados com prioris Normal e Laplace. As medianas dos coeficientes apresentam diferenças pequenas, assim como os respectivos intervalos de credibilidade de 95%, conforme apresentado na Tabela 14. Esse comportamento sugere que, para a amostra e as especificações consideradas, as estimativas posteriores são pouco sensíveis à escolha entre essas duas distribuições a priori.

Cabe destacar que os preditores foram padronizados antes do ajuste dos modelos, incluindo as variáveis indicadoras binárias geradas a partir das variáveis categóricas. Dessa forma, os coeficientes representam variações no logaritmo das chances (*log-odds*) de inadimplência associadas ao aumento de um desvio-padrão no respectivo preditor transformado, mantendo-se os demais constantes. Consequentemente, a interpretação dos coeficientes das variáveis indicadoras, como `sexo_Feminino`, deve considerar essa transformação, não correspondendo diretamente à comparação entre as categorias na escala original.

Entre os coeficientes estimados, destacam-se aqueles associados às variáveis `atraso_pagto_0`, `atraso_pagto_2`, `atraso_pagto_3`, `fatura_valor_1`, `fatura_valor_2` e `idade`, cujos intervalos de credibilidade de 95% não incluem zero em ambas as especificações. Também se observam associações negativas para `limite_credito`, `pagto_valor_1`, `pagto_valor_2` e `sexo_Feminino`, cujos intervalos também permanecem abaixo de zero nas duas especificações. A concordância entre os modelos quanto à direção desses efeitos reforça a proximidade das estimativas obtidas sob as diferentes distribuições a priori.

Por outro lado, variáveis como `atraso_pagto_4`, `atraso_pagto_5`, `atraso_pagto_6` e `fatura_valor_3` apresentam intervalos de credibilidade que incluem zero, indicando maior incerteza quanto à direção de seus efeitos. Esse resultado evidencia que nem todos os coeficientes apresentam o mesmo grau de concentração nas distribuições posteriores.

De modo geral, não se observam diferenças expressivas no comportamento dos coeficientes entre os modelos Normal e Laplace. Embora as distribuições a priori possuam formatos distintos, suas variâncias foram igualadas para tornar a comparação mais controlada, permitindo avaliar os efeitos associados às diferenças em suas formas. Para os dados e as especificações analisados, essas diferenças não produziram alterações substanciais nas estimativas posteriores.

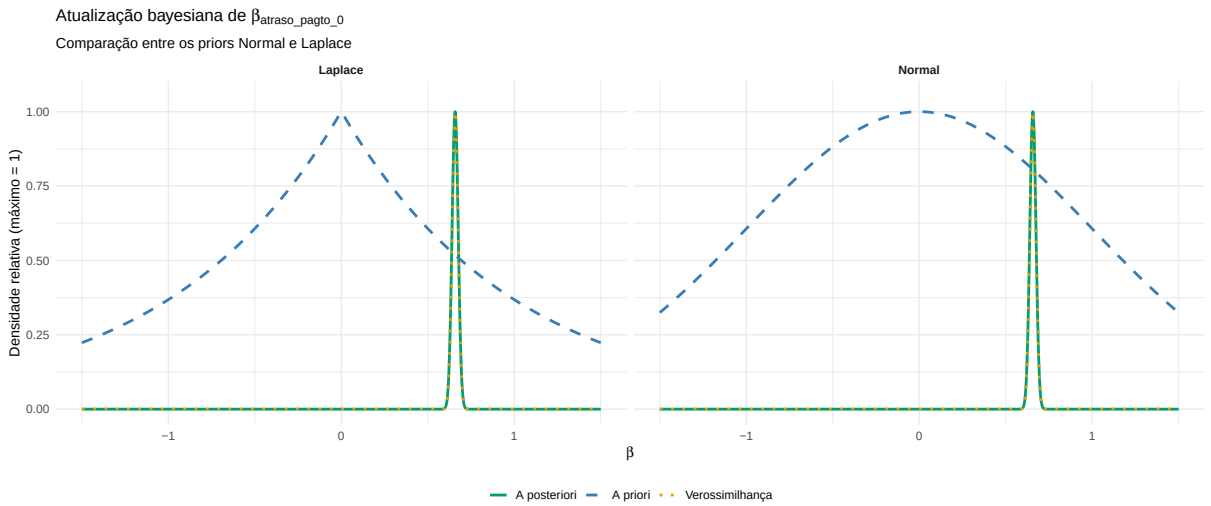


Figura 16: Atualização bayesiana do coeficiente de atraso_pagto_0: comparação entre os priors Normal e Laplace.

A Figura 16 apresenta uma representação da atualização bayesiana do coeficiente associado à variável `atraso_pagto_0`, considerando as especificações com priors Normal e Laplace. Em ambos os painéis, são apresentadas as distribuições a priori, as funções de verossimilhança condicionais e as distribuições a posteriori, permitindo visualizar a contribuição da informação inicial e dos dados para a estimação do parâmetro.

Observa-se que as distribuições a priori possuem formatos distintos, decorrentes das propriedades das distribuições Normal e Laplace. Entretanto, a incorporação da informação amostral conduz a distribuições a posteriori bastante semelhantes, concentradas em torno de valores positivos do coeficiente.

Além disso, nota-se visualmente que a função de verossimilhança possui uma dispersão extremamente restrita em comparação às distribuições a priori, concentrando seu máximo próximo a $\beta \approx 0.7$. Essa alta precisão amostral faz com que a distribuição a posteriori seja quase integralmente moldada pelos dados, sobrepondo-se à verossimilhança e atenuando de forma expressiva a influência inicial das especificações Normal e Laplace.

A concentração das distribuições a posteriori em uma região relativamente estreita indica que, para esse preditor, a informação fornecida pelos dados exerce papel importante na estimação do coeficiente. Assim, apesar das diferenças entre as distribuições a priori, ambas as especificações conduzem a resultados semelhantes após a atualização.

Ressalta-se que a verossimilhança apresentada corresponde a uma avaliação condicional, na qual os demais coeficientes foram mantidos fixos em suas medianas posteriores. Além disso, as curvas foram reescaladas para que seus valores máximos fossem iguais a um, de modo a facilitar a comparação visual de seus formatos. Portanto, a figura possui finalidade ilustrativa e não representa as distribuições marginais completas dos parâmetros.

4.3.2.4.1 Interpretação dos coeficientes e das razões de chances

Na regressão logística, os coeficientes representam a variação no logaritmo das chances (*log-odds*) de ocorrência do evento de interesse, neste caso, a inadimplência ((PD30 = 1)), associada ao aumento de uma unidade no preditor, mantendo-se os demais constantes. Como as variáveis explicativas foram padronizadas antes do ajuste dos modelos, inclusive as variáveis indicadoras binárias, essa interpretação deve considerar a escala padronizada dos preditores. Assim, para as variáveis numéricas, o aumento de uma unidade corresponde a um desvio-padrão na escala original.

Coeficientes positivos indicam associação com o aumento das chances de inadimplência, enquanto coeficientes negativos indicam associação com sua redução. A magnitude dos coeficientes expressa a intensidade dessas associações na escala do logaritmo das chances.

Conforme apresentado na Tabela 14, os modelos com prioris Normal e Laplace apresentam estimativas bastante próximas, sugerindo que a escolha entre essas duas distribuições a priori não produziu alterações expressivas nas conclusões sobre os efeitos dos preditores.

Entre os coeficientes positivos, destaca-se `atraso_pagto_0`, com mediana posterior de 0,657 em ambas as especificações. Esse preditor apresenta a maior estimativa positiva entre as variáveis explicativas, com intervalo de credibilidade de 95% inteiramente acima de zero. Também apresentam associações positivas `atraso_pagto_2`, `atraso_pagto_3`, `fatura_valor_2` e `idade`, cujos intervalos de credibilidade também não incluem zero.

Por outro lado, `fatura_valor_1` apresenta a maior estimativa negativa, com medianas posteriores de -0,503 no modelo Normal e -0,487 no modelo Laplace. Outros efeitos negativos são observados para `pagto_valor_1`, `pagto_valor_2` e `limite_credito`. Também se destacam `escolaridade_Desconhecido1`, `escolaridade_EnsinoMedio`, `escolaridade_Outros`, `estado_civil_Solteiro` e `sexo_Feminino`, cujos intervalos de credibilidade de 95% permanecem abaixo de zero nas duas especificações.

Para facilitar a interpretação dos efeitos estimados na regressão logística, os coeficientes podem ser exponenciados, obtendo-se as razões de chances (*Odds Ratios*, OR). Essa transformação permite expressar os efeitos em termos multiplicativos sobre as chances de inadimplência:

$OR_j = \exp(\beta_j)$.

Valores de OR superiores a 1 indicam aumento nas chances de inadimplência, enquanto valores inferiores a 1 indicam redução. Um OR igual a 1 corresponde à ausência de associação na escala das chances.

Considerando as medianas posteriores, o preditor `atraso_pagto_0` apresenta OR de aproximadamente 1,929 em ambas as especificações. Isso indica que um aumento de uma unidade na escala padronizada desse preditor está associado a chances de inadimplência aproximadamente 92,9% maiores, mantendo-se os demais preditores constantes. Entre os demais efeitos positivos, destacam-se `atraso_pagto_2`, com OR próximo de 1,099 no modelo Normal e 1,098 no Laplace; `atraso_pagto_3`, com OR próximo de 1,087; `fatura_valor_2`, com OR de aproximadamente 1,319 no modelo Normal e 1,290 no Laplace; e `idade`, com OR próximo de 1,054.

Em relação aos efeitos negativos, `fatura_valor_1` apresenta OR de aproximadamente 0,605 no modelo Normal e 0,614 no Laplace. Esses valores correspondem a reduções de cerca de 39,5% e 38,6% nas chances de inadimplência, respectivamente, para um aumento de uma unidade na escala padronizada do preditor. Também se destacam `pagto_valor_1`, com OR próximo de 0,795 no modelo Normal e 0,798 no Laplace; `pagto_valor_2`, com OR próximo de 0,832 e 0,833, respectivamente; e `limite_credito`, com OR próximo de 0,913 e 0,914.

A comparação entre os modelos evidencia que os ORs obtidos são bastante semelhantes.

As pequenas diferenças observadas nas estimativas não alteram a direção dos efeitos nem a identificação dos principais preditores associados à inadimplência.

Ressalta-se que os ORs apresentados foram calculados a partir das medianas posteriores dos coeficientes e se referem a variações de uma unidade na escala padronizada dos preditores. Portanto, não devem ser interpretados diretamente como alterações associadas a uma unidade monetária, a um ano de idade ou à mudança entre categorias originais das variáveis indicadoras. No caso destas últimas, a interpretação também deve considerar a padronização: o coeficiente não representa diretamente a comparação entre as categorias originais, mas a variação associada a uma unidade na escala transformada da variável.

4.3.2.4.2 Intervalos de credibilidade e incerteza das estimativas

Os intervalos de credibilidade de 95% permitem avaliar a incerteza associada às estimativas dos coeficientes, indicando uma faixa de valores que contém 95% da probabilidade posterior do parâmetro, condicionada aos dados observados e à distribuição a priori adotada. Diferentemente dos intervalos de confiança frequentistas, sua interpretação está diretamente relacionada à distribuição posterior do parâmetro.

A análise dos intervalos de credibilidade (Tabela 14) mostra que 16 dos 27 preditores apresentam intervalos inteiramente fora de zero em ambas as especificações, confirmando as direções de efeito identificadas na subseção anterior. Os coeficientes mais bem determinados, como `atraso_pagto_0`, apresentam intervalos relativamente estreitos; variáveis como `fatura_valor_2` a `fatura_valor_5` exibem maior dispersão posterior, indicando maior incerteza sobre a magnitude de seus efeitos. A proximidade entre os limites dos intervalos dos modelos Normal e Laplace indica que a incerteza das estimativas foi semelhante sob as duas especificações de prioris.

4.3.2.5 Avaliação do desempenho preditivo

A avaliação do desempenho preditivo dos modelos foi realizada com base em métricas calculadas sobre o conjunto de teste, permitindo comparar a capacidade de generalização das abordagens frequentista e bayesiana. Foram consideradas métricas relacionadas à classificação, à discriminação entre as classes e à qualidade das probabilidades estimadas,

Tabela 15: Métricas de desempenho dos modelos de regressão logística bayesiano e frequentista para previsão de PD30 no conjunto de teste.

Métrica	Completo	Sem multicol.	L1 (LASSO)	L2 (Ridge)	Bayesiano (Laplace)	Bayesiano (Normal)
Acurácia	0.8105	0.8117	0.8108	0.8069	0.8105	0.8105
Acurácia balanceada	0.6129	0.6135	0.6129	0.5990	0.6127	0.6129
ROC AUC	0.7163	0.7141	0.7161	0.7153	0.7164	0.7165
Log-loss	0.4702	0.4698	0.4699	0.4695	0.4699	0.4699
Sensibilidade	0.2586	0.2580	0.2580	0.2260	0.2580	0.2586
Especificidade	0.9673	0.9690	0.9678	0.9719	0.9675	0.9673
Precisão	0.6919	0.7028	0.6948	0.6957	0.6926	0.6919
F1-score	0.3765	0.3774	0.3763	0.3412	0.3759	0.3765
MCC	0.3405	0.3449	0.3413	0.3181	0.3403	0.3405

de modo a proporcionar uma avaliação mais abrangente do desempenho dos modelos (Tabela 15).

De maneira geral, os resultados evidenciam elevada proximidade entre os modelos avaliados. A acurácia variou entre 0,8069 e 0,8117, indicando que aproximadamente 81% das observações foram classificadas corretamente. Entre as especificações, o modelo frequentista sem multicolinearidade apresentou o maior valor (0,8117), enquanto o modelo Ridge apresentou o menor (0,8069). Os modelos bayesianos, por sua vez, alcançaram acurácia de 0,8105 em ambas as especificações, demonstrando desempenho bastante semelhante ao das alternativas frequentistas.

Entretanto, a interpretação da acurácia deve considerar o desbalanceamento da variável resposta. Aproximadamente 78% das observações pertencem à classe 0, enquanto cerca de 22% correspondem à classe 1. Nesse cenário, a acurácia convencional pode superestimar a qualidade da classificação, uma vez que o desempenho sobre a classe majoritária exerce maior influência sobre seu valor. Essa limitação também pode ser observada nos resultados da acurácia balanceada, que variaram entre 0,5990 e 0,6135. A diferença entre as duas medidas indica que, apesar da proporção relativamente elevada de classificações corretas, os modelos apresentam desempenho desigual na identificação das duas classes.

A análise da sensibilidade e da especificidade reforça essa constatação. Os valores de sensibilidade, entre 0,2260 e 0,2586, revelam uma capacidade limitada de identificar corretamente os clientes inadimplentes. Em contrapartida, a especificidade variou entre 0,9673 e 0,9719, indicando que os modelos identificaram corretamente a grande maioria dos clientes não inadimplentes. Esse comportamento evidencia uma tendência dos classificadores a favorecer a atribuição da classe negativa, resultando em um número expressivo de falsos

negativos e em uma proporção reduzida de inadimplentes corretamente identificados.

A precisão apresentou valores entre 0,6919 e 0,7028, indicando que aproximadamente 69% a 70% das observações classificadas como inadimplentes pertencem efetivamente a essa categoria. O F1-score, por sua vez, variou entre 0,3412 e 0,3774. Por combinar precisão e sensibilidade por meio da média harmônica, essa métrica também evidencia as limitações dos modelos na identificação da classe positiva, especialmente em razão dos baixos valores de sensibilidade.

O MCC apresentou valores entre 0,3181 e 0,3449. Por considerar simultaneamente os verdadeiros e falsos positivos e negativos, essa métrica oferece uma perspectiva mais abrangente do desempenho classificatório, especialmente diante do desbalanceamento observado. Os valores obtidos indicam uma associação positiva, porém relativamente limitada, entre as classificações realizadas pelos modelos e as classes efetivamente observadas.

Em relação à qualidade das probabilidades estimadas, o log-loss apresentou resultados praticamente idênticos entre as seis especificações, variando de 0,4695 a 0,4702. Essa proximidade sugere que as diferentes estratégias de estimação e regularização produziram probabilidades preditas com qualidade semelhante, sem diferenças expressivas nessa dimensão do desempenho.

De forma geral, os resultados apontam para uma elevada semelhança entre as especificações frequentistas e bayesianas quanto ao desempenho preditivo. As diferenças observadas nas métricas são pequenas, sugerindo que a incorporação de distribuições a priori, nas configurações avaliadas, não proporcionou ganhos expressivos em relação às alternativas frequentistas. Ainda assim, a avaliação evidencia uma limitação comum aos modelos: a baixa sensibilidade na identificação dos clientes inadimplentes, apesar da elevada especificidade para a classe de não inadimplência.

A capacidade discriminatória dos modelos foi analisada adicionalmente por meio da área sob a curva ROC (ROC AUC), métrica que avalia a capacidade de distinguir observações pertencentes às diferentes classes ao longo de diversos pontos de corte. Diferentemente das métricas baseadas em classificações binárias, essa medida não depende da adoção de um limiar específico para transformar as probabilidades estimadas em classes.

Os resultados apresentaram valores próximos entre as especificações frequentistas e bayesianas. Enquanto os modelos frequentistas registraram valores de ROC AUC entre 0,7141 e 0,7163, os modelos bayesianos alcançaram 0,7164 e 0,7165, respectivamente para as prioris Laplace e Normal. Essa proximidade indica que as diferentes abordagens produziram capacidades discriminatórias semelhantes, sem evidências de vantagem expressiva de uma delas.

Embora os modelos bayesianos tenham apresentado valores ligeiramente superiores, a magnitude dessa diferença é pequena e não permite concluir que a abordagem bayesiana proporcione uma melhoria relevante na discriminação entre clientes inadimplentes e não inadimplentes. De maneira semelhante, as diferenças entre as especificações frequentistas também foram reduzidas, indicando que as estratégias de regularização e tratamento da multicolinearidade tiveram efeitos limitados sobre essa dimensão do desempenho.

Assim, os resultados sugerem que, para o conjunto de dados e as especificações consideradas, a escolha entre inferência frequentista e bayesiana não alterou substancialmente a capacidade de ordenação dos clientes segundo seu risco de inadimplência.

4.3.2.6 Análise dos erros de classificação

A Figura 17 apresenta as matrizes de confusão dos modelos frequentista (sem multicolinearidade) e bayesiano (priori Normal), avaliados no conjunto de teste com ponto de corte de 0,5. Os resultados mostram padrões praticamente idênticos: o frequentista registrou 1.231 falsos negativos e 181 falsos positivos, enquanto o bayesiano apresentou 1.230 e 191, respectivamente. Aproximadamente 74% dos clientes efetivamente inadimplentes não foram identificados por nenhum dos modelos, refletindo a baixa sensibilidade (~25,8%) já reportada na Tabela 15 e o impacto do desbalanceamento da variável resposta.

A predominância de falsos negativos em relação aos falsos positivos indica que os classificadores tendem a subestimar o risco de inadimplência — clientes que efetivamente inadimplirão são classificados como não inadimplentes, o que pode resultar em concessão indevida de crédito. A adoção do modelo bayesiano não modificou substancialmente esse padrão. A definição de um ponto de corte adequado, considerando os custos relativos de cada tipo de erro e os objetivos institucionais, é retomada na Discussão.

```
  Real Predito Freq                        Modelo
1    0       0 5660 Frequentista (sem multicol.)
2    1       0 1231 Frequentista (sem multicol.)
3    0       1  181 Frequentista (sem multicol.)
4    1       1  428 Frequentista (sem multicol.)
5    0       0 5650           Bayesiano (Normal)
6    1       0 1230           Bayesiano (Normal)
7    0       1  191           Bayesiano (Normal)
8    1       1  429           Bayesiano (Normal)
```

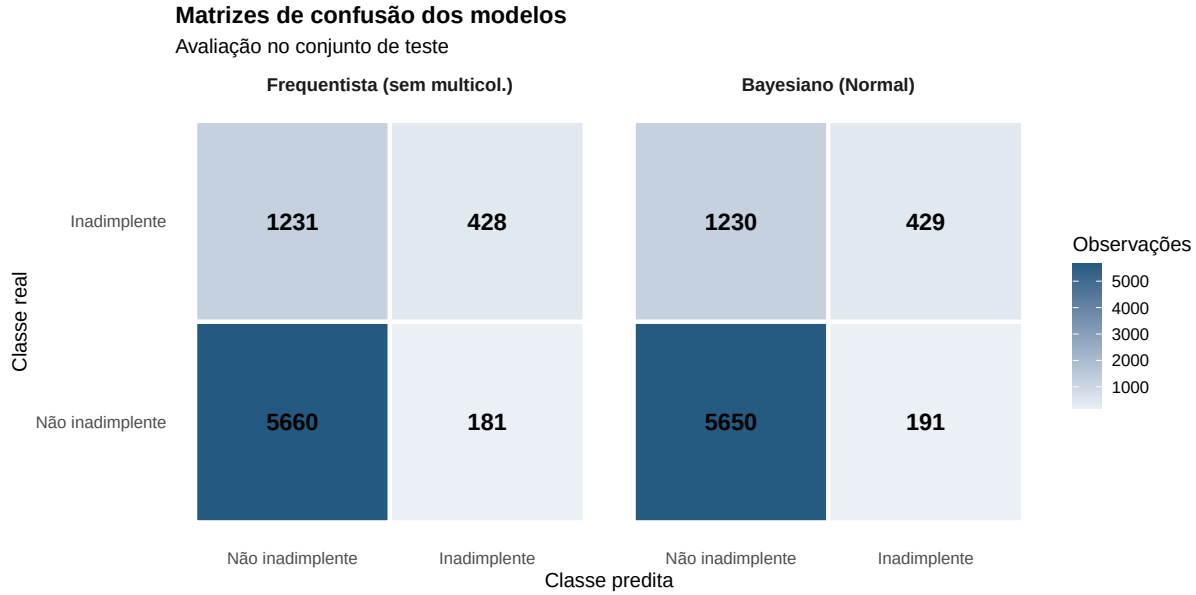


Figura 17: Matrizes de confusão dos modelos frequentista e bayesiano no conjunto de teste.

Tabela 16: Melhores limites de corte com base no índice de Youden

Modelo	.threshold	sensitivity	specificity	youden
Bayesiano (Normal)	0.2548669	0.5623870	0.8127033	0.3750903
Frequentista (Sem Multicol.)	0.2625011	0.5364678	0.8375278	0.3739956

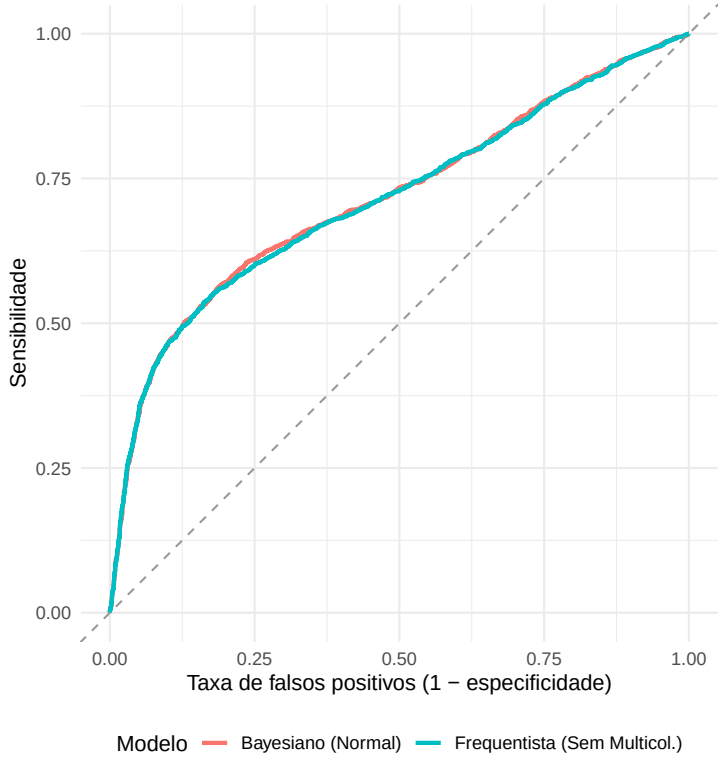


Figura 18: Curvas ROC dos modelos frequentista (Sem Multicol.) e bayesiano (Normal) no conjunto de teste.

4.3.2.7 Análise das curvas ROC

A (**roc-comparacao?**) apresenta as curvas ROC dos modelos frequentista e bayesiano com prior Normal, construídas a partir das probabilidades estimadas no conjunto de teste. A curva ROC permite avaliar a capacidade discriminatória dos modelos para diferentes pontos de corte, relacionando a sensibilidade à taxa de falsos positivos (1 − especificidade).

Observa-se que as duas curvas apresentam trajetórias bastante próximas e praticamente sobrepostas ao longo de sua extensão, indicando comportamento discriminatório semelhante. Esse resultado é consistente com os valores de AUC, de aproximadamente 0,714 para o modelo frequentista e 0,716 para o modelo bayesiano. Embora ambos apresentem desempenho superior ao de um classificador aleatório, cuja AUC corresponde a 0,5, os valores obtidos indicam capacidade discriminatória moderada.

Portanto, a comparação não evidencia vantagem preditiva expressiva de uma abordagem sobre a outra. O modelo bayesiano com prior Normal apresentou uma AUC ligeiramente superior, mas a diferença é pequena e, isoladamente, não permite afirmar que exista

superioridade estatisticamente significativa. Os resultados sugerem, assim, que as abordagens frequentista e bayesiana alcançaram desempenho discriminatório semelhante para o problema de identificação de clientes inadimplentes.

4.3.2.8 Análise do ponto de corte pelo índice de Youden

Como análise complementar, investigou-se a possibilidade de adoção de pontos de corte diferentes do valor convencional de 0,5, considerando o índice de Youden como critério de seleção. Esse índice permite identificar o limiar que maximiza conjuntamente a sensibilidade e a especificidade, atribuindo igual importância à identificação correta das duas classes.

Os resultados indicaram pontos de corte de 0,255 para o modelo bayesiano e 0,263 para o frequentista, com índices de Youden de 0,375 e 0,374, respectivamente. Embora os valores sejam bastante próximos, observa-se que o modelo bayesiano apresentou sensibilidade ligeiramente superior (0,562 contra 0,536), enquanto o frequentista alcançou especificidade um pouco maior (0,838 contra 0,813).

Em comparação com a classificação realizada pelo limiar convencional de 0,5, a adoção dos pontos de corte identificados pelo índice de Youden favorece o equilíbrio entre a identificação de clientes inadimplentes e a identificação de clientes não inadimplentes. Esse comportamento é particularmente relevante diante do desbalanceamento da variável resposta, uma vez que a utilização do limiar convencional pode resultar em menor identificação da classe minoritária.

Apesar dessas diferenças, os índices de Youden praticamente equivalentes reforçam a proximidade entre os desempenhos das abordagens frequentista e bayesiana. Cabe destacar que os limiares apresentados foram identificados a partir do conjunto de teste e, portanto, são utilizados exclusivamente para fins ilustrativos. Considerando que o objetivo deste estudo consiste em comparar as abordagens de inferência frequentista e bayesiana, e não em otimizar os modelos para aplicação prática, essa análise permite demonstrar como a alteração do ponto de corte influencia o equilíbrio entre sensibilidade e especificidade e, consequentemente, as proporções de falsos positivos e falsos negativos. Dessa forma, busca-se evidenciar se as duas abordagens apresentam comportamentos distintos diante de mudanças no critério de classificação, mantendo o foco na comparação de seus resultados preditivos.

5 Discussão

Os resultados obtidos neste estudo evidenciam que, para o conjunto de dados e as especificações avaliadas, as abordagens frequentista e bayesiana produziram desempenho preditivo essencialmente equivalente. Os valores de ROC AUC variaram entre 0,714 e 0,717, enquanto o log-loss permaneceu próximo de 0,470 em todos os modelos. Essa proximidade sugere que, em cenários com amostras de grande dimensão e alta informatividade dos dados, a escolha entre as duas abordagens é pouco determinante para o desempenho classificatório, resultado consistente com a teoria assintótica, que prevê convergência das inferências bayesianas e frequentistas à medida que o tamanho da amostra cresce.

5.1 Sensibilidade às distribuições a priori e o papel do tamanho amostral

A comparação entre as especificações bayesianas com prioris Normal e Laplace revelou estimativas posteriores bastante próximas. As medianas dos coeficientes apresentaram diferenças em geral inferiores a 0,02 unidades, e a comparação pelo WAIC produziu uma diferença de ELPD de $-0{,}52$ com erro-padrão de 0,28, magnitude inferior a dois erros-padrão, indicando que as especificações são essencialmente equivalentes do ponto de vista da capacidade preditiva.

Embora as duas distribuições apresentem formatos distintos, a Normal com caudas mais leves e a Laplace com maior concentração de probabilidade em torno de zero e caudas mais pesadas, a equivalência das variâncias adotadas ($^2 = 1$ em ambas) restringiu o contraste à forma das distribuições, sem explorar diferenças no grau de informativeness. Mais do que isso, o volume de dados disponível exerceu papel determinante sobre esse resultado. Com n = 30.000 observações, a função de verossimilhança apresenta dispersão extremamente restrita, e sua concentração em torno dos valores estimados pelo modelo supera em magnitude a influência de ambas as prioris. A figura de atualização bayesiana do coeficiente `atraso_pagto_0` documenta esse comportamento diretamente: independentemente da especificação adotada, a posteriori foi praticamente moldada pela verossimilhança, convergindo para valores semelhantes em ambos os modelos. Esse fenômeno é fundamentado pelo teorema de Bernstein–von Mises, segundo o qual, sob condições de regularidade, a

distribuição posterior aproxima-se assintoticamente de uma distribuição Normal centrada no estimador de máxima verossimilhança, tornando-se, em primeira ordem, independente da distribuição a priori Vaart (1998).

Essa equivalência observada entre as prioris, e entre as abordagens frequentista e bayesiana em geral, não implica que a escolha da distribuição a priori seja irrelevante em outros contextos. Em situações com amostras de menor dimensão, comuns no início da operação de um produto de crédito, em segmentos de nicho ou em carteiras com baixíssima taxa de inadimplência, a verossimilhança fornece menos informação, e a distribuição a priori passa a exercer influência mais pronunciada sobre as estimativas. Nesse cenário, as diferenças de forma entre as prioris Normal e Laplace poderiam se manifestar de forma mais expressiva: a priori Laplace, por seu comportamento análogo à penalização L1, tenderia a promover contração mais intensa sobre coeficientes de menor magnitude, podendo conduzir estimativas próximas de zero, efeito que a priori Normal, mais suave em sua regularização, não produz com a mesma intensidade. Assim, a abordagem bayesiana com prioris bem especificadas pode oferecer vantagens práticas precisamente nos cenários em que os dados são escassos, seja por incorporar conhecimento prévio sobre os parâmetros de forma explícita e controlada, seja por produzir estimativas mais estáveis do que as obtidas por máxima verossimilhança em amostras pequenas. Essa é, portanto, uma limitação importante deste estudo: os resultados obtidos são específicos ao contexto de grande dimensão amostral e não devem ser generalizados como evidência de equivalência universal entre as abordagens.

5.2 Multicolinearidade: tratamento e implicações

A multicolinearidade constituiu um aspecto central neste estudo, dada a forte correlação entre as variáveis referentes aos valores das faturas mensais (`fatura_valor_1` a `fatura_valor_6`) e, em menor grau, entre as variáveis relacionadas ao histórico de atrasos de pagamento. Conforme apresentado na Tabela 7, o modelo frequentista completo evidenciou multicolinearidade elevada, indicando possível instabilidade dos estimadores e dificuldade na identificação dos efeitos individuais dos preditores. A remoção de variáveis altamente correlacionadas reduziu substancialmente o VIF sem produzir alterações relevantes no desempenho preditivo, resultado que reforça a importância do diagnóstico e do

tratamento da multicolinearidade, especialmente em modelos voltados à interpretação dos efeitos individuais dos preditores.

Na abordagem bayesiana, as distribuições a priori centradas em zero introduzem um mecanismo de regularização que pode contribuir para estabilizar as estimativas em situações de multicolinearidade. Entretanto, conforme a Tabela 10, os valores de VIF observados nas especificações bayesianas evidenciam que a estrutura de dependência linear entre os preditores permanece presente. Isso ocorre porque a regularização atua sobre as estimativas dos parâmetros, mas não modifica a matriz de preditores nem elimina sua dependência linear. Assim, embora a informação a priori possa influenciar a magnitude e a variabilidade das estimativas posteriores, não resolve, por si só, o problema de identificação individual dos efeitos associado à multicolinearidade.

Em conjunto, os resultados sugerem que o tratamento explícito da multicolinearidade, seja por remoção de preditores correlacionados, seja por regularização, permanece uma etapa relevante quando o objetivo é a interpretação inferencial dos coeficientes, independentemente da abordagem de estimação adotada. A vantagem da regularização bayesiana reside menos na eliminação da estrutura de dependência entre os preditores do que na possibilidade de quantificar explicitamente a incerteza remanescente sobre os coeficientes mesmo em presença de alta correlação — o que pode ser particularmente útil quando a remoção de variáveis não é viável por razões substantivas ou quando se deseja preservar a estrutura original do modelo.

5.3 Diferenças inferenciais entre as abordagens

Além do desempenho preditivo, as abordagens frequentista e bayesiana diferem de forma substantiva no que se refere à interpretação e à quantificação da incerteza dos parâmetros. Na abordagem frequentista, a incerteza é expressa por intervalos de confiança, cuja interpretação está ligada ao procedimento de amostragem repetida: um intervalo de 95% indica que, em 95% das amostras hipotéticas extraídas do mesmo processo gerador, o intervalo construído dessa maneira conteria o verdadeiro valor do parâmetro. Na abordagem bayesiana, os intervalos de credibilidade de 95% permitem uma interpretação diretamente probabilística: dado o modelo e os dados observados, existe uma probabilidade de 95% de que o parâmetro pertença ao intervalo obtido. Essa distinção é relevante em aplicações

práticas, nas quais afirmações probabilísticas sobre os parâmetros são frequentemente mais naturais e informativas do que declarações sobre procedimentos amostrais.

Do ponto de vista da interpretação dos coeficientes, ambas as abordagens produziram conclusões consistentes sobre a direção e a relevância dos preditores. A variável `atraso_pagto_0` destacou-se em todos os modelos como o preditor de maior impacto sobre o risco de inadimplência, corroborando estudos prévios na área de credit scoring. As variáveis `fatura_valor_1`, `pagto_valor_1`, `pagto_valor_2` e `limite_credito` apresentaram associações negativas com a inadimplência, enquanto variáveis demográficas como `sexo_Feminino` e `estado_civil_Solteiro` também mostraram associações estatisticamente significativas em ambas as abordagens.

5.4 Desbalanceamento de classes e limitações práticas

Um aspecto comum às duas abordagens foi a baixa sensibilidade na identificação de clientes inadimplentes quando utilizado o ponto de corte convencional de 0,5. A especificidade elevada (aproximadamente 97%), associada à sensibilidade reduzida (cerca de 25%), indica que os modelos tendem a classificar incorretamente uma parcela expressiva dos inadimplentes como não inadimplentes, o que pode comprometer sua utilidade prática para fins de prevenção de perdas. Esse comportamento está relacionado ao desbalanceamento da variável resposta, na qual aproximadamente 22% das observações correspondem a clientes inadimplentes, embora também seja influenciado pela capacidade discriminatória dos modelos e pelo limiar de classificação adotado.

A análise baseada no índice de Youden demonstrou que a utilização de pontos de corte mais baixos (aproximadamente 0,26) poderia elevar a sensibilidade para cerca de 55%, em contrapartida à redução da especificidade para aproximadamente 82% a 84%. A proximidade dos resultados entre os modelos frequentista e bayesiano nessa análise reforça a semelhança de comportamento das duas abordagens diante de alterações no critério de classificação. Ressalta-se, entretanto, que o ponto de corte identificado pelo índice de Youden maximiza o equilíbrio entre sensibilidade e especificidade, não necessariamente o resultado econômico da decisão de concessão de crédito.

Como discutido na análise dos erros de classificação (Seção 4.3.2.6), falsos positivos e falsos

negativos têm consequências econômicas assimétricas: o primeiro tipo está associado à recusa indevida de crédito a bons pagadores, enquanto o segundo representa a concessão de crédito a clientes que virão a inadimplir. A escolha do ponto de corte estabelece um compromisso entre esses dois tipos de erro: reduzir o limiar eleva a sensibilidade mas amplia os falsos positivos; aumentá-lo reduz os falsos positivos mas aumenta os inadimplentes não identificados. A definição do limiar adequado depende, portanto, dos objetivos institucionais e da importância relativa atribuída ao custo de cada tipo de erro.

No presente estudo, essa discussão permite comparar o comportamento classificatório das abordagens frequentista e bayesiana diante de diferentes critérios de decisão. Os resultados indicam que ambas apresentam respostas semelhantes às alterações no ponto de corte, sem evidenciar uma superioridade sistemática de uma abordagem sobre a outra nesse aspecto.

Cabe destacar que o ponto de corte identificado pelo índice de Youden representa o limiar que maximiza a soma da sensibilidade e da especificidade, não necessariamente aquele que proporciona o melhor resultado econômico para a instituição financeira. A escolha do limiar deve considerar os custos relativos dos falsos positivos e falsos negativos, bem como os objetivos da política de concessão de crédito.

Além disso, caso a seleção do ponto de corte seja realizada com base nos resultados do conjunto de teste, há uma limitação metodológica, uma vez que esse conjunto deve ser reservado à avaliação final do desempenho do modelo. Em um cenário de aplicação prática, o limiar seria definido previamente, utilizando dados de treinamento, e posteriormente aplicado às novas observações. Dessa forma, os resultados apresentados para o ponto de corte baseado no índice de Youden devem ser interpretados como uma análise complementar do comportamento classificatório dos modelos, e não como uma definição definitiva do limiar a ser adotado em produção.

6 Conclusão

Este trabalho investigou a aplicação de modelos de regressão logística à previsão de inadimplência em cartões de crédito, comparando as abordagens de inferência frequentista e

bayesiana em termos de desempenho preditivo, interpretação dos parâmetros e quantificação da incerteza.

Do ponto de vista preditivo, as seis especificações avaliadas, quatro frequentistas e duas bayesianas, produziram resultados notavelmente próximos. Os valores de ROC AUC variaram entre 0,714 e 0,717, e o log-loss entre 0,469 e 0,470, indicando que a incorporação de distribuições a priori, nas configurações avaliadas, não proporcionou ganhos expressivos em relação às alternativas frequentistas. Esse resultado é coerente com a teoria, que prevê convergência das inferências à medida que o tamanho da amostra cresce, condição atendida neste estudo com 30.000 observações.

No que tange à inferência, as abordagens se distinguem de forma relevante. A abordagem bayesiana permitiu quantificar a incerteza dos parâmetros por meio de distribuições a posteriori e intervalos de credibilidade, cuja interpretação é mais intuitiva em contextos aplicados do que a dos intervalos de confiança frequentistas. A comparação entre as prioris Normal e Laplace revelou estimativas posteriores praticamente equivalentes, sugerindo que, diante de uma amostra altamente informativa, a forma da distribuição a priori tem impacto limitado sobre as conclusões, embora suas diferenças possam ser mais pronunciadas em contextos com amostras menores ou maior incerteza paramétrica.

Quanto ao tratamento da multicolinearidade, a remoção de preditores altamente correlacionados se mostrou uma estratégia eficaz para reduzir a instabilidade das estimativas sem comprometer o desempenho preditivo. As abordagens de regularização, Lasso (L1), Ridge (L2) e as prioris bayesianas, apresentaram comportamentos análogos do ponto de vista da penalização, sem diferenças expressivas nos resultados obtidos.

Limitações e trabalhos futuros. Este estudo apresenta algumas limitações que devem ser consideradas na interpretação dos resultados. A análise foi restrita a um único conjunto de dados, referente a clientes de cartão de crédito em Taiwan no período de 2005, o que limita a generalização das conclusões para outros mercados, populações e períodos. Além disso, as prioris bayesianas foram especificadas de forma relativamente não informativa, sem incorporação de conhecimento especializado do domínio de crédito. A utilização de prioris informativas baseadas em estudos anteriores ou em julgamentos de especialistas poderia modificar as estimativas e revelar diferenças mais expressivas entre as abordagens. Por fim, estratégias para lidar com o desbalanceamento de classes, como reamostragem,

ajuste de pesos ou limiares de classificação baseados em custos assimétricos, poderiam ser exploradas em trabalhos futuros para melhorar a identificação da classe de inadimplentes.

Em síntese, os resultados obtidos sugerem que, para problemas de classificação binária com amostras de grande dimensão, as abordagens frequentista e bayesiana tendem a produzir resultados preditivos equivalentes. A principal vantagem da abordagem bayesiana reside na riqueza inferencial: a capacidade de expressar diretamente a incerteza sobre os parâmetros e de incorporar informação prévia de forma explícita e controlada. Assim, a escolha entre as duas abordagens deve considerar não apenas o desempenho preditivo esperado, mas também os objetivos da análise, se voltados primariamente à discriminação e previsão, ou à compreensão dos mecanismos associados ao risco de inadimplência e à quantificação da incerteza das estimativas.

Referências

CARPENTER, Bob *et al.* Stan: A Probabilistic Programming Language. **Journal of Statistical Software**, v. 76, n. 1, p. 1–32, 2017.

GOODRICH, Ben *et al.* **rstanarm: Bayesian Applied Regression Modeling via Stan**. *[S.l.: S.n.]*.

KUHN, Max; WICKHAM, Hadley. Tidymodels: A Collection of Packages for Modeling and Machine Learning Using Tidyverse Principles. **Journal of Open Source Software**, v. 5, n. 51, p. 2478, 2020.

LICHMAN, M. **UCI Machine Learning Repository**. University of California, Irvine, School of Information; Computer Science; http://archive.ics.uci.edu/ml, 2013.

TUKEY, John W. **Exploratory Data Analysis**. Reading, MA: Addison-Wesley, 1977.

VAART, A. W. van der. **Asymptotic Statistics**. Cambridge: Cambridge University Press, 1998.

YEH, I.-C.; LIEN, C.-H. **The Default of Credit Card Clients Dataset**. https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients, 2009.