

UNIVERSIDADE FEDERAL DE MINAS GERAIS

Instituto de Ciências Exatas

Departamento de Ciência da Computação e Estatística

Pós-Graduação Lato Sensu em Ciência de Dados

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Binária Aplicada a Risco de Crédito

Ana Beatriz Coelho Rodrigues

Belo Horizonte

Dez/2026

Ana Beatriz Coelho Rodrigues

Uma Análise Comparativa entre Inferência Frequentista e Bayesiana em Modelos de Regressão Binária Aplicada a Risco de Crédito

Monografia apresentada ao Curso de Especialização em Ciência de Dados com Ênfase em Estatística da Universidade Federal de Minas Gerais como requisito parcial para obtenção do grau de Especialista em Ciência de Dados.

Orientador(a): Prof.(a) Dr.(a) Fábio N. Demarqui

Belo Horizonte

Dez/2026

RESUMO

Este trabalho compara as abordagens de inferência frequentista e bayesiana na modelagem da probabilidade de inadimplência em cartões de crédito, utilizando o conjunto de dados *Default of Credit Card Clients*, composto por 30.000 registros de clientes taiwaneses. Foram ajustados modelos de regressão logística sob as duas perspectivas: quatro especificações frequentistas (modelo completo, sem multicolinearidade, com regularização L1 e L2) e dois modelos bayesianos com distribuições a priori Normal e Laplace, igualadas em variância para controlar a comparação.

Do ponto de vista preditivo, todas as especificações apresentaram desempenho semelhante, com ROC AUC entre 0,714 e 0,717, sugerindo que, em amostras de grande dimensão, a escolha entre as abordagens não determina diferenças relevantes na capacidade discriminativa. A variável de maior impacto foi o histórico de atraso de pagamento (`atraso_pagto_0`), com razão de chances superior a 1,82 nas estimativas frequentistas e 1,93 nas bayesianas padronizadas. A remoção de preditores altamente correlacionados reduziu substancialmente a multicolinearidade (VIF de 41,12 para 1,84) sem comprometer o desempenho preditivo.

A comparação entre as prioris Normal e Laplace revelou estimativas posteriores praticamente equivalentes, resultado consistente com o teorema de Bernstein-von Mises: com $n = 30.000$, a verossimilhança domina a distribuição posterior, atenuando a influência da priori. A principal diferença entre as abordagens reside na dimensão inferencial: os intervalos de credibilidade bayesianos permitem interpretação probabilística direta sobre os parâmetros, em contraste com os intervalos de confiança frequentistas.

Palavras-chave: regressão logística; inferência frequentista; inferência bayesiana; risco de crédito; distribuições a priori.

ABSTRACT

This study compares frequentist and Bayesian inference approaches in the modeling of credit card default probability, using the Default of Credit Card Clients dataset, comprising 30,000 records from Taiwanese credit card clients. Logistic regression models were fitted under both perspectives: four frequentist specifications (full model, without multicollinearity, with L1 and L2 regularization) and two Bayesian models with Normal and Laplace prior distributions, matched in variance to enable a controlled comparison.

From a predictive standpoint, all specifications yielded similar performance, with ROC AUC ranging from 0.714 to 0.717, suggesting that, in large samples, the choice between approaches does not lead to relevant differences in discriminative capacity. The most influential predictor was payment delay history (`atraso_pagto_0`), with odds ratios above 1.82 in frequentist estimates and 1.93 in standardized Bayesian estimates. Removal of highly correlated predictors substantially reduced multicollinearity (VIF from 41.12 to 1.84) without compromising predictive performance.

The comparison between Normal and Laplace priors revealed nearly equivalent posterior estimates, consistent with the Bernstein-von Mises theorem: with n = 30,000, the likelihood dominates the posterior distribution, attenuating prior influence. The main distinction between approaches lies in the inferential dimension: Bayesian credibility intervals allow direct probabilistic statements about parameters, in contrast to the repeated-sampling interpretation of frequentist confidence intervals.

Keywords: logistic regression; frequentist inference; Bayesian inference; credit risk; prior distributions.

Índice

1 Introdução **6**

1.1 Probabilidade de Inadimplência (PD) . . . 6

1.2 Regressão Logística na Modelagem do Risco de Crédito . . . 7

1.3 Abordagens Inferenciais na Regressão Logística . . . 7

1.4 Delimitação e Objetivos do Estudo . . . 8

2 Referencial Teórico **9**

2.1 Fundamentos de Probabilidade e Inferência Estatística . . . 9

2.1.1 Variáveis Aleatórias e Distribuições de Probabilidade . . . 9

2.1.2 Inferência Estatística . . . 9

2.1.3 Interpretações da probabilidade . . . 10

2.1.4 Teorema de Bayes . . . 10

2.2 Regressão Logística Frequentista . . . 12

2.2.1 Formulação do modelo . . . 12

2.2.2 Interpretação dos coeficientes . . . 14

2.2.3 Função de verossimilhança e estimação por máxima verossimilhança 16

2.2.4 Diagnóstico e qualidade do ajuste . . . 17

2.2.5 Pressupostos do modelo . . . 21

2.2.6 Regularização e seleção de variáveis . . . 22

2.3 Regressão Logística Bayesiana . . . 24

2.3.1 Escolha de distribuições *a priori* . . . 25

2.3.2 Distribuições *a posteriori* . . . 29

2.3.3 Inferência via MCMC . . . 31

2.4 Avaliação de modelos de classificação . . . 35

2.4.1 Matriz de confusão . . . 35

2.4.2 Comparação entre probabilidades previstas e valores observados . . 37

3 Metodologia **39**

3.1 Descrição dos Dados . . . 39

3.2 Pré-processamento . . . 41

3.2.1 Estrutura de dados e tratamento de valores ausentes . . . 41

3.2.2 Outliers . . . 41
3.2.3 Correlação . . . 42
3.2.4 Padronização de variáveis numéricas . . . 43
3.2.5 Divisão entre treino e teste . . . 43
3.3 Modelos Avaliados . . . 44
3.3.1 Regressão logística frequentista . . . 44
3.3.2 Regressão logística bayesiana . . . 45
3.3.3 Métricas de avaliação . . . 46

4 Resultados **47**
4.1 Análise Exploratória . . . 47
4.1.1 Estatísticas univariadas . . . 48
4.1.2 Avaliação da variável resposta . . . 50
4.1.3 Análise de correlação entre variáveis numéricas . . . 52
4.1.4 Análise de outliers . . . 53
4.2 Pré processamento do dataset . . . 55
4.2.1 Seleção de variáveis e análise de correlação . . . 55
4.2.2 Separação treino/teste . . . 56
4.3 Modelagem e Avaliação . . . 56
4.3.1 Modelagem Frequentista . . . 57
4.3.2 Modelagem Bayesiana . . . 64

5 Discussão **83**
5.1 Sensibilidade às distribuições *a priori* e o papel do tamanho amostral . . . 83
5.2 Multicolinearidade: tratamento e implicações . . . 85
5.3 Diferenças inferenciais entre as abordagens . . . 86
5.4 Desbalanceamento de classes e limitações práticas . . . 86

6 Conclusão **87**

Referências **88**

1 Introdução

A atividade de concessão de crédito envolve decisões tomadas sob incerteza, uma vez que existe sempre a possibilidade de que o tomador não cumpra integralmente suas obrigações financeiras. Esse descumprimento pode manifestar-se na forma de atrasos, pagamentos parciais ou inadimplência total, estando frequentemente associado a mudanças inesperadas nas condições econômicas ou financeiras do indivíduo, como perda de renda, instabilidade profissional ou choques temporários de liquidez. Mesmo tomadores com histórico financeiro consistente não estão imunes a esse tipo de risco ao longo do tempo.

A avaliação do risco de crédito é, portanto, um componente central da gestão financeira das instituições que operam no mercado de empréstimos. Essa avaliação subsidia decisões relacionadas à aprovação ou rejeição de propostas, bem como à definição de condições contratuais compatíveis com o nível de risco assumido. Em uma perspectiva mais ampla, a estimativa da probabilidade de inadimplência permite antecipar perdas potenciais e orientar estratégias de alocação de capital. Uma concentração excessiva de inadimplência pode comprometer a solvência das instituições financeiras, tornando indispensáveis mecanismos preventivos de controle e monitoramento do risco.

Nesse cenário, modelos estatísticos têm sido amplamente empregados como ferramentas para quantificar o risco de crédito a partir de informações observáveis sobre os tomadores. Ao relacionar características socioeconômicas, financeiras e comportamentais com a ocorrência de inadimplência, esses modelos permitem estimar probabilidades individuais de default e identificar padrões relevantes para a gestão das carteiras de crédito. Dessa forma, oferecem suporte à tomada de decisão baseada em evidências, contribuindo para a eficiência e a consistência das políticas de concessão de crédito.

1.1 Probabilidade de Inadimplência (PD)

No contexto da concessão de crédito, a mensuração do risco associado a cada operação exige mais do que a simples distinção entre bons e maus pagadores. É necessário quantificar, de forma probabilística, a chance de que um tomador venha a entrar em inadimplência dentro de um horizonte de tempo específico. Essa medida é conhecida como `Probability of Default` (PD) e constitui um dos pilares centrais da gestão moderna de risco de crédito.

A PD representa a probabilidade de ocorrência de um evento de default previamente definido, como um atraso superior a determinado número de dias ou a incapacidade de honrar os pagamentos. Diferentemente de abordagens puramente classificatórias, sua modelagem fornece uma medida contínua de risco, permitindo ordenar os tomadores segundo sua propensão à inadimplência e estabelecer políticas diferenciadas de concessão, precificação e monitoramento.

1.2 Regressão Logística na Modelagem do Risco de Crédito

A estimação da probabilidade de inadimplência pode ser conduzida por meio de modelos estatísticos que relacionam uma variável resposta binária a um conjunto de variáveis explicativas. Entre as alternativas disponíveis, a regressão logística destaca-se por sua adequação a esse tipo de problema, uma vez que permite modelar diretamente a probabilidade de ocorrência de um evento, restringindo as estimativas ao intervalo entre zero e um.

No contexto do risco de crédito, essa abordagem possibilita investigar como características demográficas, condições financeiras e histórico de pagamentos estão associados à ocorrência de inadimplência. Além da estimativa das probabilidades individuais, a regressão logística oferece parâmetros interpretáveis, cuja análise permite avaliar a direção e a intensidade das associações entre os preditores e o evento de interesse. Dessa forma, o modelo reúne características relevantes tanto para a investigação inferencial quanto para a construção de ferramentas de classificação e previsão de risco.

1.3 Abordagens Inferenciais na Regressão Logística

A estimação dos parâmetros de um modelo de regressão logística pode ser realizada sob diferentes perspectivas inferenciais, entre as quais se destacam as abordagens frequentista e bayesiana. Embora ambas utilizem a informação contida nos dados para produzir estimativas e avaliar a incerteza associada aos parâmetros, fundamentam-se em interpretações distintas da probabilidade e do processo de inferência.

Na perspectiva frequentista, os parâmetros são tratados como quantidades fixas, estimadas por máxima verossimilhança, com a incerteza expressa por intervalos de confiança. Na abordagem bayesiana, por sua vez, os parâmetros são tratados como variáveis aleatórias, e a

inferência combina a verossimilhança com distribuições a priori para produzir distribuições a posteriori. Os fundamentos e as diferenças conceituais entre essas perspectivas são discutidos em detalhe no Referencial Teórico.

A comparação entre essas abordagens é particularmente relevante em problemas de risco de crédito, nos quais a qualidade das estimativas e a quantificação da incerteza podem influenciar a interpretação dos fatores associados à inadimplência. Além disso, a abordagem bayesiana permite investigar como diferentes especificações de distribuições a priori afetam os resultados da inferência.

1.4 Delimitação e Objetivos do Estudo

Diante dessas considerações, este trabalho investiga a aplicação de modelos de regressão logística à previsão de inadimplência em cartões de crédito, sob as perspectivas frequentista e bayesiana. Para isso, utiliza-se a base de dados *Default of Credit Card Clients*, que reúne informações de 30.000 clientes e contempla características demográficas, limite de crédito, valores de faturas e histórico de pagamentos. A variável resposta, denominada *PD30*, identifica a ocorrência de inadimplência no mês subsequente, caracterizando um problema de classificação binária.

A questão que orienta a pesquisa é: em que medida as abordagens frequentista e bayesiana produzem resultados distintos na estimação, interpretação e previsão da inadimplência em cartões de crédito, e como diferentes distribuições a priori influenciam os resultados da inferência bayesiana?

Assim, o objetivo geral deste trabalho é comparar as abordagens frequentista e bayesiana na modelagem da inadimplência em cartões de crédito por meio da regressão logística, considerando aspectos inferenciais e preditivos.

2 Referencial Teórico

2.1 Fundamentos de Probabilidade e Inferência Estatística

2.1.1 Variáveis Aleatórias e Distribuições de Probabilidade

A formalização da incerteza em experimentos aleatórios ocorre por meio de variáveis aleatórias, que associam os resultados de um espaço amostral a valores numéricos. Essa estrutura fundamenta o tratamento quantitativo dos fenômenos aleatórios e a construção de modelos de probabilidade, servindo de base para a inferência estatística.

As variáveis aleatórias são classificadas em discretas ou contínuas, a depender da natureza de seus valores possíveis. As discretas assumem valores em conjuntos finitos ou enumeráveis, como a decisão de aprovação de crédito ou o número de ocorrências de inadimplência. Já as contínuas podem assumir valores em intervalos reais, como a renda dos proponentes, frequentemente tratada como uma variável contínua em modelos estatísticos. A incerteza associada a essas variáveis é representada por distribuições de probabilidade: no domínio discreto, pela função de massa de probabilidade e, no contínuo, pela função densidade de probabilidade. Essas funções permitem caracterizar o comportamento probabilístico das variáveis e calcular medidas fundamentais, como esperança, variância e probabilidades condicionais, essenciais à modelagem estatística.

2.1.2 Inferência Estatística

A inferência estatística reúne os métodos que permitem extrair conclusões sobre uma população a partir de informações obtidas em uma amostra. Quando não é viável observar todos os elementos de uma população, os dados amostrais são utilizados para estimar parâmetros desconhecidos, testar hipóteses e realizar previsões sobre o fenômeno estudado.

O elemento central desse processo é o reconhecimento da incerteza associada às conclusões obtidas. Como diferentes amostras podem produzir resultados distintos, a inferência estatística utiliza modelos probabilísticos para quantificar a variabilidade amostral e avaliar a incerteza das estimativas. Dessa forma, as conclusões não representam certezas

absolutas, mas resultados condicionados às informações disponíveis e às hipóteses assumidas pelo modelo estatístico.

2.1.3 Interpretações da probabilidade

A noção de probabilidade ocupa um papel central na inferência estatística, sendo a base para quantificar e interpretar a incerteza. Nesse contexto, destacam-se dois grandes paradigmas: o frequentista e o bayesiano, que se distinguem essencialmente pela interpretação do conceito de probabilidade e pelo tratamento da incerteza dos parâmetros.

Na abordagem frequentista, a probabilidade é interpretada a partir da frequência relativa de ocorrência de um evento em um grande número de repetições de um experimento sob condições equivalentes. Nessa perspectiva, a probabilidade é uma característica do processo que gera os dados, enquanto os parâmetros do modelo estatístico são considerados valores fixos, embora desconhecidos. Os dados, por sua vez, são tratados como realizações de variáveis aleatórias, e a inferência busca obter informações sobre os parâmetros a partir dessas observações.

Já na abordagem bayesiana, a probabilidade assume um papel mais amplo, sendo interpretada como um grau de crença ou plausibilidade em uma afirmação, condicionado às informações disponíveis. Nesse contexto, probabilidades podem ser atribuídas não apenas a eventos observáveis, mas também a hipóteses e parâmetros do modelo. Os parâmetros desconhecidos são tratados como variáveis aleatórias, cuja incerteza é descrita por distribuições de probabilidade. O conhecimento prévio pode ser incorporado por meio de distribuições a priori e, à medida que novos dados são observados, esse conhecimento é atualizado de forma sistemática pelo Teorema de Bayes, resultando em uma distribuição a posteriori que combina informação prévia e evidência empírica.

2.1.4 Teorema de Bayes

O Teorema de Bayes constitui o fundamento da inferência bayesiana, estabelecendo uma regra para atualizar a distribuição de probabilidade associada a um parâmetro desconhecido à medida que novas evidências são observadas. Diferentemente da abordagem frequentista,

na qual os parâmetros são considerados fixos, a inferência bayesiana representa a incerteza sobre esses parâmetros por meio de distribuições de probabilidade.

Matematicamente, o Teorema de Bayes é expresso por:

$$p(\theta \mid y) = \frac{p(y \mid \theta)\, p(\theta)}{p(y)}, \tag{1}$$

em que:

- $p(\theta \mid y)$ é a **distribuição a posteriori**, representando o conhecimento atualizado sobre o parâmetro θ após a observação dos dados y;
- $p(y \mid \theta)$ é a **função de verossimilhança**, que quantifica a probabilidade de observar os dados para um determinado valor do parâmetro;
- $p(\theta)$ é a **distribuição a priori**, responsável por representar o conhecimento ou as crenças existentes sobre o parâmetro antes da observação dos dados;
- $p(y)$ é a **distribuição marginal dos dados**, também denominada evidência, dada por:

$$p(y) = \int p(y \mid \theta) p(\theta)\, d\theta, \tag{2}$$

considerando parâmetros contínuos. Para parâmetros discretos, a integral é substituída por um somatório. Esse termo garante que a distribuição a posteriori seja devidamente normalizada, isto é, que sua integral (ou soma, no caso discreto) seja igual a um.

Em termos conceituais, o Teorema de Bayes estabelece que a distribuição a posteriori é proporcional ao produto entre a verossimilhança e a distribuição a priori, isto é,

$$p(\theta \mid y) \propto p(y \mid \theta)\, p(\theta), \tag{3}$$

visto que o termo $p(y)$ não depende do parâmetro θ. Na prática, essa representação proporcional é frequentemente utilizada em métodos computacionais de inferência, como os algoritmos de Monte Carlo via Cadeias de Markov (MCMC), que permitem obter amostras

da distribuição a posteriori sem a necessidade de calcular explicitamente sua constante de normalização.

2.2 Regressão Logística Frequentista

Seja Y a variável resposta, assumindo valor $Y = 1$ quando ocorre inadimplência e $Y = 0$ caso contrário. O objetivo consiste em estimar a probabilidade condicional de ocorrência desse evento, representada por $P(Y = 1 \mid \theta)$, em que θ denota a probabilidade de inadimplência associada a um determinado tomador. Assumindo que Y segue uma distribuição de Bernoulli, tem-se que $P(Y = 1 \mid \theta) = \theta$, enquanto a probabilidade de não ocorrência do evento é dada por $P(Y = 0 \mid \theta) = 1 - \theta$. Dessa forma, o parâmetro θ corresponde diretamente à probabilidade de inadimplência, principal quantidade de interesse na modelagem de risco de crédito.

Diversos modelos podem ser utilizados para estimar essa probabilidade em função das características observadas dos tomadores. Neste trabalho, será empregada a regressão logística, por se tratar de um dos modelos mais difundidos para problemas de resposta binária, oferecendo estimativas probabilísticas de fácil interpretação e ampla aplicação em modelos de *credit scoring*.

2.2.1 Formulação do modelo

O objetivo da regressão logística consiste, portanto, em modelar a probabilidade de ocorrência do evento de interesse como uma função das variáveis explicativas observadas. Em vez de considerar uma única probabilidade para toda a população, admite-se que cada observação i possui sua própria probabilidade de inadimplência, denotada por θ_i. Dessa forma,

$$Y_i \mid \theta_i \sim \text{Bernoulli}(\theta_i). \tag{4}$$

onde

$$P(Y_i = 1 \mid \theta_i) = \theta_i \qquad \text{e} \qquad P(Y_i = 0 \mid \theta_i) = 1 - \theta_i. \tag{5}$$

O objetivo da regressão logística é modelar a probabilidade θ_i em função das variáveis explicativas. Entretanto, como probabilidades estão restritas ao intervalo $(0, 1)$, não é adequado modelá-las diretamente por meio de uma combinação linear dos preditores. Para contornar essa limitação, utiliza-se uma função de ligação que transforma a probabilidade em uma quantidade definida em toda a reta real. Na regressão logística, essa transformação é realizada pela função logit, definida por

$$\text{logit}(\theta_i) = \log\left(\frac{\theta_i}{1-\theta_i}\right). \tag{6}$$

A equação acima descreve a transformação da probabilidade para a escala dos logaritmos das chances (*log-odds*). Na regressão logística, essa quantidade é modelada como uma função linear das variáveis explicativas. Como o objetivo é estimar probabilidades, aplica-se, em seguida, a transformação inversa da função logit, denominada função logística (ou função sigmoide). Enquanto a função logit transforma probabilidades em valores pertencentes à reta real, a função logística realiza o processo inverso, convertendo o preditor linear em uma probabilidade restrita ao intervalo $(0, 1)$. Assim, definindo o preditor linear como

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}. \tag{7}$$

em que β_0 representa o intercepto do modelo e β_j $(j = 1, \ldots, p)$ corresponde ao coeficiente associado à variável explicativa x_{ij}. Dessa forma, o preditor linear resume, em um único valor, a contribuição conjunta de todas as covariáveis para a resposta.

A probabilidade de ocorrência do evento é, então, dada por

$$\theta_i = \frac{1}{1+\exp(-\eta_i)}. \tag{8}$$

A Figura 1 ilustra o comportamento da função logística para um modelo com uma única variável preditora, considerando $\beta_0 = 0$ e $\beta_1 = 1$. Observa-se que, à medida que o preditor linear aumenta, a probabilidade do evento cresce, aproximando-se de zero para valores muito negativos e de um para valores muito positivos. O ponto de inflexão da curva ocorre quando $\eta_i = 0$, situação em que a probabilidade do evento é igual a 0,5.

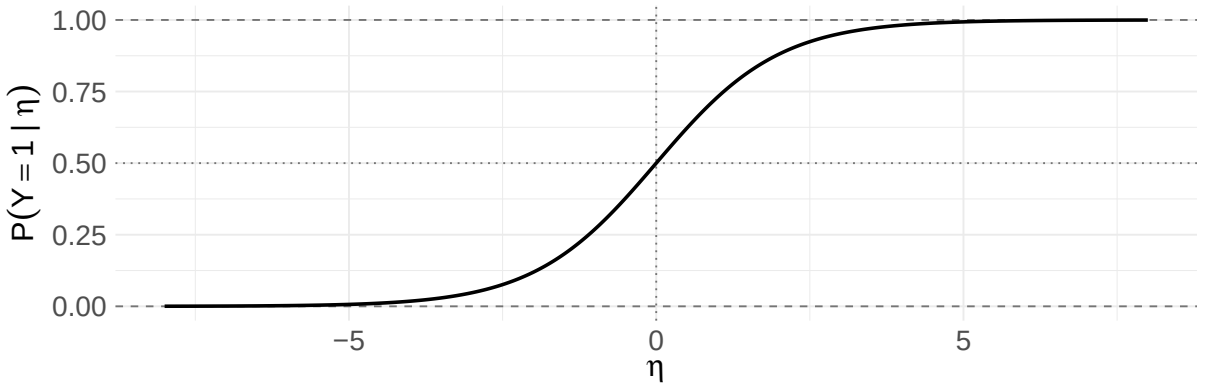


Figura 1: Função logística para um modelo com uma única variável preditora ($\beta_0 = 0$ e $\beta_1 = 1$).

2.2.2 Interpretação dos coeficientes

Como exemplo, considere o seguinte modelo de crédito:

$$\eta = -3 - 0.04 \cdot \text{Score} + 0.8 \cdot \text{Atraso} + 0.2 \cdot \text{Renda}.$$

Para um determinado solicitante, a substituição dos valores observados das variáveis explicativas resulta em um valor para η. Supondo que, para esse indivíduo, obtenha-se $\eta = 1.5$, a função logística fornece a probabilidade estimada de ocorrência do evento como

$$\theta = \frac{1}{1 + \exp(-1.5)} \approx 0.82.$$

Esse exemplo evidencia o funcionamento da regressão logística: inicialmente, as variáveis explicativas são combinadas linearmente para produzir o preditor η; em seguida, a função logística transforma esse valor em uma probabilidade pertencente ao intervalo $(0, 1)$.

Uma das principais vantagens da regressão logística é a possibilidade de interpretar o efeito das variáveis explicativas sobre o risco do evento de interesse. Considerando o preditor linear apresentado na Equação 7, cada coeficiente β_j representa a variação no logaritmo das chances (*log-odds*) associada ao aumento de uma unidade da variável x_j, mantendo as demais variáveis constantes.

No modelo apresentado anteriormente, o coeficiente associado à variável **Score** é igual a -0.04. Isso significa que, para cada aumento de uma unidade no Score, o preditor linear η diminui em 0.04, desde que as demais variáveis permaneçam constantes. De forma análoga, cada atraso adicional aumenta o preditor linear em 0.8 unidades.

Como a função logística é crescente, coeficientes positivos aumentam a probabilidade estimada do evento, enquanto coeficientes negativos a reduzem. Entretanto, esse efeito não corresponde a uma variação constante da probabilidade, pois a relação entre o preditor linear e a probabilidade é não linear.

Para ilustrar esse comportamento, considere novamente o solicitante para o qual foi obtido $\eta = 1.5$. A probabilidade estimada de inadimplência é dada por

$$\theta = \frac{1}{1 + \exp(-1.5)} \approx 0.818.$$

Suponha agora que o Score desse solicitante aumente em uma unidade. Como o coeficiente associado ao Score é igual a -0.04, o novo preditor linear passa a ser

$$\eta' = 1.5 - 0.04 = 1.46.$$

Aplicando novamente a função logística,

$$\theta' = \frac{1}{1 + \exp(-1.46)} \approx 0.812.$$

Observa-se que o aumento de uma unidade no Score reduziu a probabilidade estimada de inadimplência de aproximadamente 81.8% para 81.2%. Esse resultado ilustra como o sinal do coeficiente determina a direção da associação entre a variável explicativa e a probabilidade estimada do evento. A magnitude dessa variação, por sua vez, depende da região da curva logística em que a observação se encontra: alterações no preditor linear tendem a produzir maiores variações na probabilidade quando esta está próxima de 0.5, e menores variações quando se aproxima de 0 ou de 1.

2.2.3 Função de verossimilhança e estimação por máxima verossimilhança

Na abordagem frequentista, os parâmetros da regressão logística são estimados por meio do método de máxima verossimilhança. Esse método consiste em encontrar o conjunto de parâmetros que maximiza a verossimilhança dos dados observados, considerando o modelo probabilístico especificado.

Considerando uma variável resposta binária Y_i, com $Y_i = 1$ representando a ocorrência do evento de interesse (por exemplo, inadimplência), assume-se que cada observação segue uma distribuição Bernoulli:

$$Y_i \sim \text{Bernoulli}(\theta_i). \tag{9}$$

onde θ_i representa a probabilidade de ocorrência do evento para o indivíduo i, estimada pela função logística apresentada na Equação 8.

Sob a hipótese de independência entre as observações, a função de verossimilhança é definida pelo produto das probabilidades individuais:

$$L(\beta \mid y, X) = \prod_{i=1}^{n} \theta_i^{y_i} (1 - \theta_i)^{1-y_i} \tag{10}$$

A estimação por máxima verossimilhança consiste em encontrar o vetor de parâmetros β que maximiza essa função:

$$\hat{\beta} = \arg\max_{\beta} L(\beta \mid y, X). \tag{11}$$

Em outras palavras, os coeficientes estimados são aqueles que tornam os dados observados mais compatíveis com o modelo probabilístico definido.

Na prática, utiliza-se o logaritmo da função de verossimilhança, denominado log-verossimilhança:

$$\ell(\beta) = \log L(\beta \mid y, X). \tag{12}$$

Como o logaritmo é uma função monotônica crescente, sua aplicação não altera o ponto de máximo. Além disso, transforma o produto de probabilidades em uma soma, o que facilita a otimização e evita problemas numéricos decorrentes da multiplicação de valores muito pequenos:

$$\ell(\beta) = \sum_{i=1}^{n} \left[y_i \log(\theta_i) + (1 - y_i) \log(1 - \theta_i) \right]. \tag{13}$$

Essa forma é mais estável numericamente e facilita os procedimentos de otimização utilizados para encontrar os parâmetros do modelo.

A função de verossimilhança também desempenha papel central na inferência Bayesiana, na qual é combinada com a distribuição a priori por meio do Teorema de Bayes para obter a distribuição a posteriori dos parâmetros. Assim, embora ambas as abordagens utilizem a mesma função, diferem na forma como a informação é incorporada à inferência.

Na abordagem frequentista, a incerteza dos parâmetros é avaliada por meio de testes de hipótese e intervalos de confiança. Esses procedimentos permitem investigar a associação entre as variáveis explicativas e o evento de interesse, além de quantificar a incerteza das estimativas.

Entretanto, a interpretação frequentista fundamenta-se no comportamento dos estimadores em amostragens repetidas, não permitindo atribuir diretamente probabilidades aos valores dos parâmetros. Além disso, em determinadas situações, como amostras pequenas ou modelos com muitos parâmetros, a estimação pode apresentar instabilidade. A abordagem Bayesiana oferece uma perspectiva alternativa, permitindo incorporar informações prévias e representar a incerteza dos parâmetros por meio de distribuições a posteriori.

2.2.4 Diagnóstico e qualidade do ajuste

Após a estimação dos parâmetros por máxima verossimilhança, é necessário avaliar se o modelo obtido representa adequadamente os dados observados. A avaliação do modelo normalmente envolve um conjunto de diagnósticos voltados à identificação de observações influentes, problemas de multicolinearidade, adequação do ajuste e comparação entre modelos concorrentes.

2.2.4.1 Análise de resíduos

Embora não se pressuponha que os resíduos da regressão logística sigam uma distribuição normal, diferentes medidas podem ser utilizadas para avaliar a adequação do modelo e identificar observações potencialmente problemáticas. Como a variável resposta é binária, assumindo valores 0 ou 1, enquanto o modelo estima probabilidades de ocorrência do evento, os resíduos na regressão logística procuram quantificar a discrepância entre o resultado observado e a probabilidade estimada para cada observação.

Valores de resíduos próximos de zero indicam menor discrepância entre os valores observados e as probabilidades estimadas, enquanto valores absolutos elevados podem indicar observações mal ajustadas ou possíveis problemas de ajuste ou especificação do modelo. Entretanto, observações discrepantes não devem ser automaticamente removidas, pois podem representar tanto erros nos dados quanto indivíduos com características incomuns, mas relevantes para o fenômeno estudado. Entre as medidas utilizadas para esse diagnóstico destacam-se os resíduos de Pearson e de Deviance.

O resíduo de Pearson mede a diferença entre o valor observado e a probabilidade estimada pelo modelo, padronizada pelo desvio padrão esperado da distribuição Bernoulli:

$$r_i^P = \frac{y_i - \theta_i}{\sqrt{\theta_i(1-\theta_i)}}. \tag{14}$$

onde y_i representa o valor observado da variável resposta e θ_i corresponde à probabilidade estimada para a observação i. A padronização permite comparar observações com diferentes probabilidades estimadas, sendo que valores absolutos elevados indicam possíveis observações incompatíveis com o ajuste do modelo.

O resíduo de Deviance, por sua vez, expressa a contribuição individual de cada observação para a deviance do modelo, medida baseada na função de verossimilhança que quantifica a discrepância entre o modelo ajustado e o modelo saturado. Valores absolutos elevados indicam observações cuja resposta observada apresenta maior discrepância em relação à previsão do modelo.

Enquanto os resíduos avaliam o ajuste individual das observações, a distância de Cook procura identificar observações influentes, ou seja, aquelas cuja influência sobre o ajuste

do modelo pode ser avaliada pela alteração nas estimativas dos coeficientes quando são removidas individualmente. Uma observação influente não necessariamente representa um erro nos dados, podendo indicar um perfil incomum ou pouco representado pelas variáveis explicativas. Em aplicações de crédito, por exemplo, clientes com características atípicas podem refletir situações reais que não devem ser automaticamente excluídas da análise, mas investigadas de forma complementar.

2.2.4.2 Diagnóstico de multicolinearidade

A presença de multicolinearidade entre as variáveis explicativas pode comprometer a interpretação dos coeficientes estimados, aumentando sua variância e tornando as estimativas menos precisas. Embora esse fenômeno não comprometa necessariamente a capacidade preditiva do modelo, pode dificultar a avaliação do efeito individual de cada variável explicativa.

Uma das medidas mais utilizadas para avaliar a multicolinearidade é o `Variance Inflation Factor` (VIF), que quantifica o quanto a variância do coeficiente associado à variável (x_j) é inflada devido à sua correlação linear com as demais variáveis explicativas. O VIF é definido por:

$$VIF_j = \frac{1}{1 - R_j^2} \tag{15}$$

onde R_j^2 corresponde ao coeficiente de determinação obtido ao ajustar uma regressão linear tendo a variável x_j como resposta e as demais variáveis explicativas como preditoras. Esse valor representa a proporção da variabilidade de x_j que pode ser explicada linearmente pelas demais variáveis do modelo. Assim, valores elevados de R_j^2 indicam que x_j contém informações semelhantes às demais variáveis explicativas, resultando em um maior VIF.

Valores de VIF próximos de 1 indicam baixa ou inexistente de multicolinearidade entre a variável e os demais preditores, enquanto valores elevados sugerem maior grau de multicolinearidade. Embora não exista um limite universalmente aceito, valores superiores a 5 costumam indicar um nível moderado de multicolinearidade, ao passo que valores acima de 10 são frequentemente considerados evidências de forte multicolinearidade.

É importante destacar que a presença de multicolinearidade não implica, necessariamente, que o modelo deva ser descartado ou que as variáveis envolvidas precisem ser removidas. Em muitos problemas aplicados, como na análise de crédito, diferentes indicadores financeiros podem representar aspectos semelhantes do perfil do cliente, sendo naturalmente correlacionados. Nesses casos, o diagnóstico deve ser interpretado em conjunto com os objetivos da análise e com as estratégias de modelagem adotadas. Além disso, em modelos que utilizam técnicas de regularização, parte dos efeitos da multicolinearidade pode ser mitigada pelas penalizações impostas aos coeficientes.

2.2.4.3 Avaliação global do ajuste

A deviance é uma medida baseada na verossimilhança que quantifica a discrepância entre o modelo ajustado e o modelo saturado, que reproduz perfeitamente os dados observados. Valores menores indicam melhor ajuste.

Na regressão logística, são apresentadas duas medidas principais: a Null deviance, referente ao modelo contendo apenas o intercepto, e a Residual deviance, referente ao modelo com as variáveis explicativas. A redução da deviance residual em relação à nula indica melhora no ajuste proporcionada pela inclusão dos preditores.

Essa diferença pode ser avaliada pelo teste da razão de verossimilhança, utilizado na comparação de modelos aninhados. Sua estatística é definida por:

$$D = -2\left[\ell_0 - \ell_1\right] \tag{16}$$

onde ℓ_0 representa a log-verossimilhança do modelo restrito e ℓ_1 a log-verossimilhança do modelo completo. Sob as condições usuais, a estatística segue aproximadamente uma distribuição qui-quadrado, cujos graus de liberdade correspondem à diferença entre o número de parâmetros dos modelos.

Os graus de liberdade da deviance residual correspondem à diferença entre o número de observações e o número de parâmetros estimados. Na deviance nula, correspondem ao número de observações menos um, considerando que o modelo contém apenas o intercepto.

2.2.4.4 Critérios de seleção de modelos

Os critérios `Akaike Information Criterion` (AIC) e `Bayesian Information Criterion` (BIC) permitem comparar especificações de modelo considerando simultaneamente a qualidade do ajuste e a complexidade, por meio de uma penalização pelo número de parâmetros estimados.

O AIC é definido por:

$$AIC = -2\ell(\hat{\beta}) + 2k \tag{17}$$

enquanto o BIC é dado por:

$$BIC = -2\ell(\hat{\beta}) + k\log(n) \tag{18}$$

onde $\ell(\hat{\beta})$ representa a log-verossimilhança avaliada nas estimativas de máxima verossimilhança, k corresponde ao número de parâmetros estimados e n representa o tamanho da amostra.

Em ambos os critérios, menores valores indicam modelos preferíveis entre as especificações comparadas. A principal diferença está na penalização da complexidade: o BIC penaliza mais fortemente modelos com maior número de parâmetros, especialmente em amostras grandes, enquanto o AIC aplica uma penalização fixa por parâmetro.

2.2.5 Pressupostos do modelo

A regressão logística, assim como outros modelos estatísticos, depende de um conjunto de hipóteses que garantem a validade das estimativas e das inferências realizadas. Diferentemente da regressão linear, o modelo logístico não assume normalidade dos resíduos ou homocedasticidade, uma vez que a variável resposta é binária. Entretanto, algumas condições são necessárias para que a relação entre as variáveis explicativas e a probabilidade do evento de interesse seja adequadamente representada.

A primeira hipótese está relacionada à independência das observações, assumindo que as respostas dos indivíduos são estatisticamente independentes, condicionadas às variáveis

explicativas incluídas no modelo. No contexto de concessão de crédito, essa hipótese implica que a ocorrência de inadimplência de um cliente não deve apresentar dependência estatística direta em relação à ocorrência do evento para outros clientes da amostra.

Outra hipótese importante é a existência de uma relação linear entre as variáveis explicativas contínuas e o logaritmo das chances (log-odds) do evento. Embora a regressão logística não imponha linearidade entre os preditores e a probabilidade diretamente, ela assume que o logit da probabilidade pode ser representado por uma combinação linear dos preditores, conforme a especificação do modelo. Dessa forma, efeitos não lineares podem exigir transformações das variáveis, inclusão de termos polinomiais ou utilização de outras estruturas de modelagem.

2.2.6 Regularização e seleção de variáveis

Apesar da estimação por máxima verossimilhança fornecer estimativas eficientes sob determinadas condições, modelos com grande número de variáveis explicativas podem apresentar problemas relacionados à multicolinearidade, sobreajuste e dificuldade de interpretação dos coeficientes. Uma alternativa para lidar com esses problemas consiste na utilização de métodos de regularização, que incorporam uma penalização sobre a magnitude dos parâmetros estimados.

Na regressão logística regularizada, a função objetivo deixa de ser apenas a maximização da log-verossimilhança e passa a considerar um termo adicional de penalização:

$$\hat{\beta} = \arg\max_{\beta} \left[\ell(\beta) - \lambda P(\beta)\right] \tag{19}$$

onde $\ell(\beta)$ representa a log-verossimilhança do modelo, λ corresponde ao parâmetro de regularização e $P(\beta)$ representa a penalização aplicada aos coeficientes. Quanto maior o valor de λ, maior a restrição imposta aos parâmetros, reduzindo sua magnitude.

Dois métodos de regularização amplamente utilizados são Ridge e Lasso, que diferem principalmente pelo tipo de penalização aplicada aos coeficientes.

2.2.6.1 Ridge

A regularização Ridge utiliza uma penalização baseada na soma dos quadrados dos coeficientes, também conhecida como penalização L2:

$$P(\beta) = \sum_{j=1}^{p} \beta_j^2 \tag{20}$$

Assim, a estimação Ridge pode ser representada como:

$$\hat{\beta}_{ridge} = \arg\max_{\beta} \left[\ell(\beta) - \lambda \sum_{j=1}^{p} \beta_j^2 \right] \tag{21}$$

A penalização quadrática reduz a magnitude dos coeficientes, tornando as estimativas mais estáveis em situações de alta correlação entre as variáveis explicativas. Entretanto, como a penalização é aplicada de forma contínua, os coeficientes tendem a se aproximar de zero, mas raramente assumem exatamente esse valor. Dessa forma, Ridge reduz a influência das variáveis menos relevantes, mas não realiza seleção automática de variáveis.

2.2.6.2 Lasso

A regularização Lasso utiliza uma penalização baseada na soma dos valores absolutos dos coeficientes, conhecida como penalização L1:

$$P(\beta) = \sum_{j=1}^{p} |\beta_j| \tag{22}$$

A estimação Lasso é dada por:

$$\hat{\beta}_{lasso} = \arg\max_{\beta} \left[\ell(\beta) - \lambda \sum_{j=1}^{p} |\beta_j| \right] \tag{23}$$

A diferença entre as penalizações L1 e L2 pode ser visualizada geometricamente na Figura Figura 2. A penalização Ridge apresenta uma região de restrição circular, enquanto a penalização Lasso possui uma região em formato de losango. Essa diferença geométrica está relacionada ao comportamento dos coeficientes durante a estimação: enquanto a penalização L2 tende a reduzir continuamente a magnitude dos coeficientes, a penalização

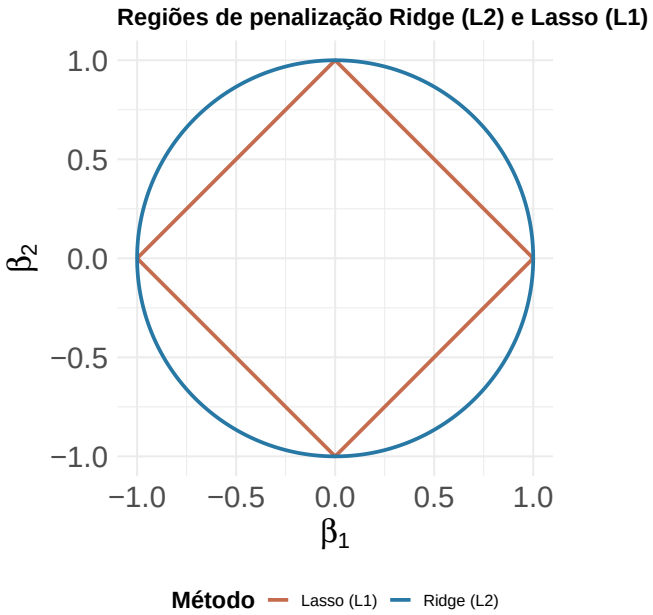


Figura 2: Representação geométrica das regiões de penalização Ridge (L2) e Lasso (L1). A região circular associada à penalização L2 tende a reduzir simultaneamente a magnitude dos coeficientes, enquanto a região em formato de losango da penalização L1 favorece soluções em que alguns coeficientes assumem valor exatamente igual a zero.

L1 favorece soluções em que alguns parâmetros assumem valores exatamente iguais a zero. Dessa forma, o Lasso atua também como um método de seleção de variáveis, removendo preditores com menor contribuição para o modelo.

2.3 Regressão Logística Bayesiana

Enquanto a regressão logística frequentista trata os coeficientes como parâmetros fixos e desconhecidos, a abordagem Bayesiana os considera variáveis aleatórias, permitindo incorporar informações prévias por meio de distribuições *a priori*. Essas informações são combinadas com a verossimilhança dos dados observados, resultando na distribuição *a posteriori*, que representa o conhecimento atualizado sobre os parâmetros e constitui a base para as inferências Bayesianas, como a estimação dos coeficientes, a construção de intervalos de credibilidade e a obtenção de probabilidades preditivas.

2.3.1 Escolha de distribuições *a priori*

Uma das principais características da inferência Bayesiana é a necessidade de especificar distribuições *a priori* para os parâmetros do modelo. Essas distribuições representam o conhecimento disponível sobre os coeficientes antes da observação dos dados e constituem um dos elementos fundamentais da distribuição posterior.

A escolha da distribuição *a priori* depende tanto do conhecimento prévio sobre o problema quanto dos objetivos da análise. Em situações nas quais não há informações prévias relevantes, é comum utilizar distribuições fracamente informativas, que exercem pouca influência sobre as estimativas e permitem que a informação proveniente dos dados tenha maior peso na inferência. Por outro lado, quando existe conhecimento substancial sobre os parâmetros ou quando se deseja incorporar algum tipo de regularização, podem ser utilizadas distribuições com características específicas, capazes de induzir diferentes comportamentos nas estimativas.

Além de representar conhecimento prévio, as distribuições *a priori* desempenham um papel importante na regularização dos modelos Bayesianos. Dependendo da distribuição adotada, pode-se favorecer coeficientes de menor magnitude, reduzir os efeitos da multicolinearidade ou incentivar a seleção automática de variáveis. Dessa forma, a escolha da priori influencia não apenas a inferência estatística, mas também a complexidade e a interpretabilidade do modelo.

2.3.1.1 Priori Normal

Uma das distribuições *a priori* mais utilizadas em regressão logística Bayesiana é a distribuição Normal. Nessa abordagem, assume-se que cada coeficiente do modelo é proveniente de uma distribuição Normal centrada em um valor esperado, geralmente igual a zero:

$$\beta_j \sim \mathcal{N}(\mu, \sigma^2) \tag{24}$$

Na maioria das aplicações, adota-se $\mu = 0$, refletindo a expectativa de que, antes da observação dos dados, não exista evidência de que determinada variável exerça efeito

positivo ou negativo sobre a resposta. O parâmetro σ^2 controla o grau de dispersão da distribuição e, consequentemente, a intensidade da informação prévia incorporada ao modelo.

Valores elevados de σ produzem distribuições mais dispersas, permitindo que a informação proveniente dos dados exerça maior influência sobre a distribuição posterior. Por outro lado, valores reduzidos concentram maior massa de probabilidade em torno de zero, favorecendo coeficientes de menor magnitude e restringindo estimativas extremas. Assim, quanto menor o desvio padrão adotado, maior a intensidade da regularização imposta aos parâmetros.

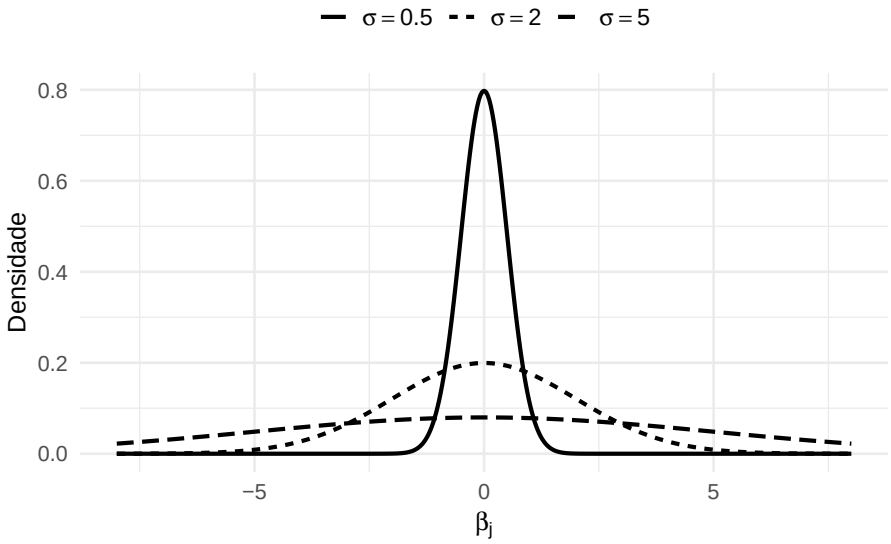


Figura 3: Distribuições Normais a priori com diferentes desvios padrão.

A influência do desvio padrão sobre a distribuição *a priori* pode ser observada na Figura Figura 3. Valores menores de σ concentram maior massa de probabilidade em torno de zero, tornando menos prováveis coeficientes de grande magnitude e aumentando a intensidade da regularização. À medida que o desvio padrão aumenta, a distribuição torna-se mais dispersa, permitindo que os dados exerçam maior influência sobre as estimativas posteriores.

A utilização de uma distribuição Normal como priori estabelece uma relação direta com a regularização Ridge utilizada na abordagem frequentista. Na regressão Ridge, a estimação dos coeficientes é realizada maximizando a função de verossimilhança penalizada, dada pela Equação 21.

Por sua vez, ao assumir uma distribuição *a priori* Normal,

$$\beta_j \sim \mathcal{N}(0, \sigma^2),$$

o logaritmo da densidade da priori pode ser escrito, desprezando constantes, como:

$$\log p(\beta) \propto -\frac{1}{2\sigma^2} \sum_{j=1}^{p} \beta_j^2. \tag{25}$$

Observa-se que tanto a penalização Ridge quanto o logaritmo da priori Normal contêm um termo quadrático envolvendo os coeficientes do modelo. Assim, embora provenientes de interpretações distintas, uma baseada em penalização e outra na incorporação de uma distribuição `a priori`, ambas favorecem coeficientes de menor magnitude. A principal diferença reside na interpretação: na regressão Ridge, o termo quadrático é introduzido como uma penalização na função objetivo, enquanto na abordagem Bayesiana ele decorre da escolha da distribuição `a priori` para os parâmetros.

Nota-se que existe uma relação inversa entre os parâmetros de regularização: valores menores de σ^2 correspondem a uma priori mais concentrada em torno de zero e, consequentemente, a uma regularização mais intensa, desempenhando papel análogo ao parâmetro de penalização λ da regressão Ridge. Assim, reduzir σ^2 equivale a aumentar a intensidade da regularização.

Assim como a penalização Ridge, a priori Normal reduz a magnitude dos coeficientes estimados, mas não realiza seleção automática de variáveis, uma vez que os parâmetros tendem a permanecer diferentes de zero após a estimação.

2.3.1.2 Priori Laplace

Outra distribuição *a priori* amplamente utilizada em regressão logística Bayesiana é a distribuição Laplace, também conhecida como distribuição de dupla exponencial (*double exponential*). Diferentemente da distribuição Normal, a distribuição Laplace apresenta um pico mais acentuado em torno de zero e caudas mais pesadas, favorecendo coeficientes pequenos sem restringir completamente a ocorrência de valores de maior magnitude.

Matematicamente, a priori Laplace pode ser representada por:

$$\beta_j \sim \text{Laplace}(\mu, b) \tag{26}$$

Em geral, adota-se $\mu = 0$, indicando que, antes da observação dos dados, espera-se que os coeficientes estejam concentrados em torno de zero. O parâmetro b controla a dispersão da distribuição: valores menores de b concentram maior massa de probabilidade em torno de zero, intensificando a regularização, enquanto valores maiores tornam a distribuição mais dispersa e reduzem a influência da informação prévia.

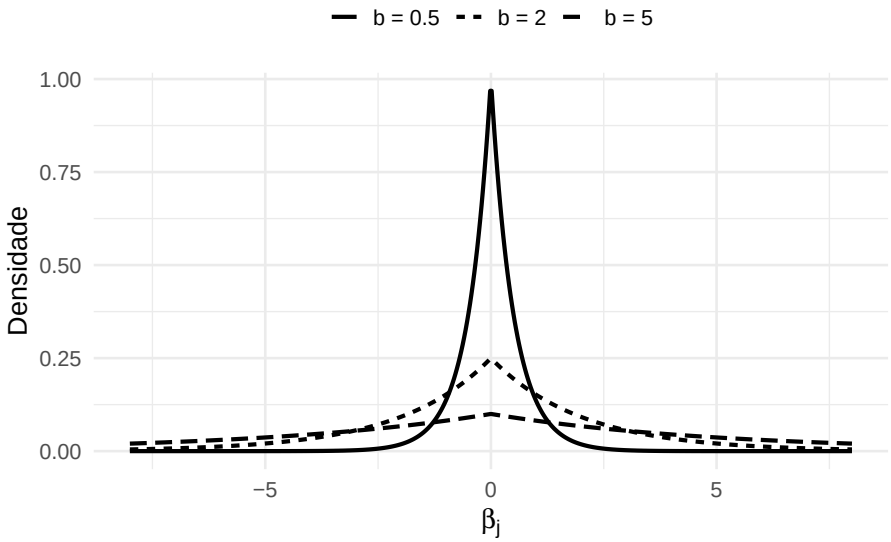


Figura 4: Distribuições Laplace a priori com diferentes parâmetros de escala.

A Figura Figura 4 ilustra o efeito do parâmetro b sobre a distribuição Laplace. À medida que b diminui, a distribuição torna-se mais concentrada em torno de zero, aumentando a probabilidade de coeficientes com pequena magnitude. Em contrapartida, suas caudas permanecem relativamente pesadas quando comparadas às da distribuição Normal, permitindo que coeficientes com efeitos realmente relevantes assumam valores mais elevados quando sustentados pelos dados.

A utilização da distribuição Laplace estabelece uma relação direta com a regularização Lasso empregada na abordagem frequentista. Enquanto o Lasso adiciona uma penalização baseada na soma dos valores absolutos dos coeficientes, conforme apresentado na Equação 23, o logaritmo da densidade da distribuição Laplace pode ser escrito, desprezando constantes, como

$$\log p(\beta) \propto -\frac{1}{b}\sum_{j=1}^{p}|\beta_j|. \tag{27}$$

Observa-se que ambas as expressões apresentam um termo baseado no valor absoluto dos coeficientes. Assim, embora provenientes de interpretações distintas, uma decorrente de uma penalização e outra da especificação de uma distribuição *a priori*, ambas favorecem soluções mais esparsas (*sparse*), nas quais apenas parte das variáveis apresenta efeitos relevantes.

Assim como a regularização Lasso, a priori Laplace promove um encolhimento mais intenso dos coeficientes em direção a zero do que a distribuição Normal. Como consequência, tende a produzir modelos mais parcimoniosos, reduzindo a influência de variáveis com pouca contribuição para a resposta e facilitando a interpretação do modelo.

2.3.2 Distribuições *a posteriori*

Na inferência Bayesiana, a distribuição a posteriori dos parâmetros é obtida pela combinação entre a distribuição a priori e a função de verossimilhança, conforme estabelecido pelo Teorema de Bayes (Seção 2.1.4). Enquanto a priori representa o conhecimento ou as suposições estabelecidas sobre os parâmetros antes da observação dos dados, a verossimilhança incorpora a informação fornecida pela amostra. A posteriori expressa, portanto, o conhecimento atualizado sobre os parâmetros.

Formalmente, essa distribuição pode ser expressa por:

$$p(\beta \mid y, X) = \frac{p(y \mid X, \beta)\, p(\beta)}{p(y \mid X)} \tag{28}$$

em que β representa o vetor de parâmetros do modelo; X, a matriz de variáveis explicativas; e y, o vetor de observações da variável resposta. Além disso, $p(y \mid X, \beta)$ corresponde à função de verossimilhança, $p(\beta)$ à distribuição a priori e $p(y \mid X)$ à distribuição marginal dos dados, também denominada constante de normalização.

Como o denominador não depende dos parâmetros, a distribuição a posteriori pode ser expressa proporcionalmente ao produto entre a verossimilhança e a distribuição a priori:

$$p(\beta \mid y, X) \propto p(y \mid X, \beta)p(\beta). \tag{29}$$

Na regressão logística, essa combinação permite atualizar a informação sobre os coeficientes do modelo a partir das evidências observadas. A influência da distribuição a priori depende de sua especificação e da quantidade de informação disponível nos dados.

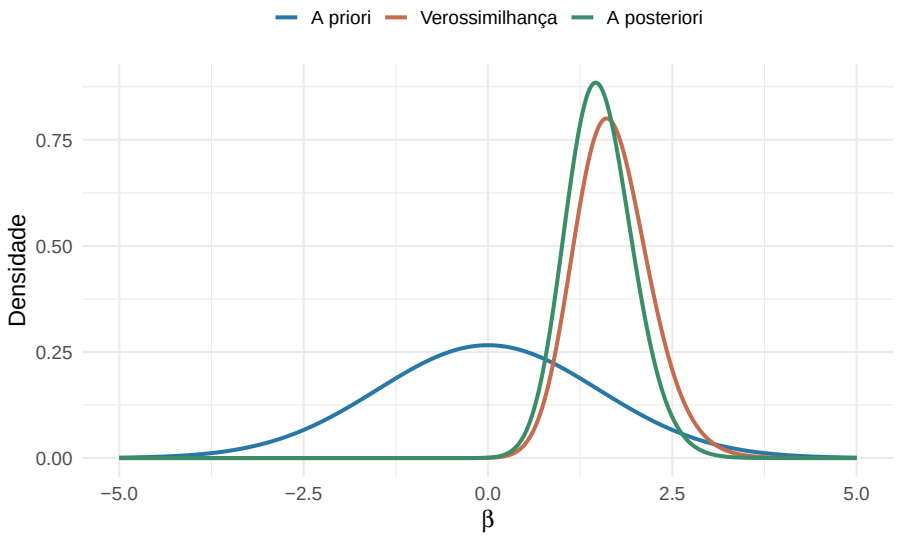


Figura 5: Representação da atualização Bayesiana em um modelo de regressão logística: distribuição a priori, verossimilhança normalizada e distribuição a posteriori.

Para ilustrar esse processo, considere um modelo logístico simplificado, com um único coeficiente β, no qual são observadas 25 ocorrências de determinado evento em uma amostra de 30 observações. Suponha que a distribuição a priori desse coeficiente seja Normal, com média zero e desvio-padrão igual a 1,5. Essa especificação expressa uma expectativa inicial de que o efeito seja próximo de zero, embora permita valores positivos e negativos.

A proporção de ocorrências observada faz com que a verossimilhança favoreça valores positivos do coeficiente. Ao combiná-la com a distribuição a priori, obtém-se a distribuição a posteriori, conforme ilustrado na Figura 5. A distribuição resultante reflete, assim, tanto a informação prévia quanto as evidências fornecidas pela amostra.

Além de atualizar a informação sobre os parâmetros, a distribuição a priori pode afetar a magnitude das estimativas posteriores por meio de um mecanismo de regularização denominado shrinkage, que corresponde à contração dos coeficientes em direção aos valores

favorecidos pela priori. No caso de distribuições centradas em zero, esse mecanismo tende a favorecer estimativas de menor magnitude. A intensidade da contração depende da especificação da priori e da informação fornecida pelos dados.

A comparação entre as prioris Normal e Laplace permite investigar como diferentes especificações influenciam as estimativas dos parâmetros e a incerteza posterior. Cabe destacar que a contração dos coeficientes não implica necessariamente que sejam estimados exatamente como zero, tampouco que ocorra seleção automática de variáveis.

2.3.3 Inferência via MCMC

Embora a distribuição a posteriori seja definida pela combinação entre a distribuição a priori e a função de verossimilhança, sua obtenção analítica nem sempre é possível. Em modelos de regressão logística com múltiplas variáveis explicativas, a constante de normalização da distribuição a posteriori geralmente não possui solução analítica fechada. Nesses casos, métodos computacionais permitem aproximar a distribuição por meio de amostras simuladas.

Neste trabalho, a inferência Bayesiana é realizada por métodos de Monte Carlo via Cadeias de Markov (Markov Chain Monte Carlo, MCMC), implementados pela biblioteca rstanarm do R, que utiliza o Stan como mecanismo de estimação. Esses métodos geram amostras da distribuição a posteriori por meio de cadeias de Markov cuja distribuição estacionária corresponde à distribuição de interesse. A partir dessas amostras, podem ser calculadas medidas como médias, medianas, desvios padrão, intervalos de credibilidade e probabilidades posteriores, permitindo representar a incerteza associada aos parâmetros.

O procedimento utiliza múltiplas cadeias, iniciadas em diferentes valores dos parâmetros. Antes da amostragem utilizada na inferência, realiza-se uma etapa denominada warm-up, durante a qual o algoritmo adapta parâmetros internos para melhorar a eficiência da simulação. Essas iterações são descartadas, e somente as amostras posteriores a essa etapa são utilizadas nos resumos da distribuição a posteriori.

Por exemplo, ao executar quatro cadeias com 2.000 iterações cada, sendo as primeiras 1.000 destinadas ao warm-up, obtêm-se 4.000 amostras posteriores, utilizadas na inferência. A qualidade dessas amostras deve ser avaliada por meio de diagnósticos como o fator de

redução potencial de escala ($\hat{R}$), o tamanho efetivo da amostra (ESS), a inspeção gráfica das trajetórias das cadeias e os diagnósticos específicos do algoritmo utilizado. Adicionalmente, o erro-padrão de Monte Carlo (Monte Carlo Standard Error, MCSE) permite avaliar a precisão numérica das estimativas obtidas a partir das amostras simuladas, considerando sua quantidade e autocorrelação.

O Stan utiliza, por padrão, o algoritmo No-U-Turn Sampler (NUTS), uma extensão adaptativa do método Hamiltonian Monte Carlo (HMC). Diferentemente de algoritmos como Metropolis-Hastings, que utilizam propostas aleatórias para gerar novos estados da cadeia, o HMC emprega o gradiente do logaritmo da distribuição a posteriori para construir trajetórias que exploram o espaço paramétrico de maneira mais eficiente. Essa estratégia permite produzir amostras menos correlacionadas em determinadas condições, favorecendo a exploração de distribuições de alta dimensão.

O NUTS complementa essa abordagem ao determinar automaticamente o comprimento das trajetórias, interrompendo sua expansão quando identifica uma tendência de retorno em direção à região inicial. Durante o warm-up, o algoritmo também ajusta parâmetros como o tamanho do passo (step size) e a matriz de massa (mass matrix), reduzindo a necessidade de ajustes manuais.

Ao final da amostragem, as realizações obtidas para cada parâmetro constituem a base das inferências Bayesianas, incluindo a estimação dos coeficientes, a construção de intervalos de credibilidade e a avaliação da incerteza associada às previsões.

2.3.3.1 Diagnóstico da convergência

Após a obtenção das amostras da distribuição *a posteriori*, é necessário verificar se o processo de amostragem convergiu adequadamente. A convergência indica que as cadeias de Markov passaram a representar a mesma distribuição *a posteriori*, permitindo que as inferências realizadas sejam consideradas confiáveis.

Os *traceplots* apresentam os valores amostrados para cada parâmetro ao longo das iterações. Após o *warm-up*, espera-se que as cadeias apresentem boa mistura (*mixing*), alternando-se em torno de uma mesma região da distribuição *a posteriori*. Tendências persistentes, mudanças abruptas ou cadeias separadas podem indicar problemas de convergência.

A Figura 6 ilustra esses comportamentos: à esquerda, observa-se boa mistura entre as cadeias; à direita, a separação e o comportamento não estacionário indicam que a convergência não foi atingida.

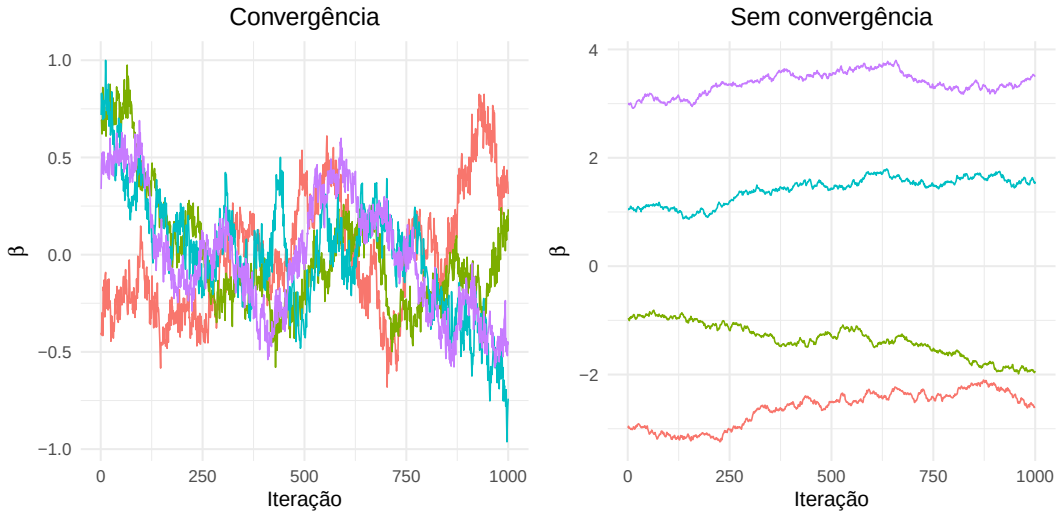


Figura 6: Exemplo ilustrativo de traceplots. À esquerda, cadeias convergidas apresentam boa mistura e exploram a mesma distribuição posterior. À direita, cadeias não convergidas permanecem separadas, indicando problemas de convergência.

O fator de redução potencial, denotado por $\hat{R}$ e originalmente proposto por Gelman; Rubin (1992), compara a variabilidade entre diferentes cadeias com a variabilidade observada dentro de cada cadeia. Quando todas as cadeias convergem para a mesma distribuição, espera-se que essas variabilidades sejam semelhantes, resultando em valores de $\hat{R}$ próximos de 1. Versões aprimoradas desse diagnóstico, como a proposta por Vehtari et al. (2021), incorporam a normalização por postos e são utilizadas nas implementações atuais do Stan. Na prática, valores inferiores a 1,01 são geralmente considerados indicativos de boa convergência.

Outro diagnóstico importante é o tamanho efetivo da amostra (*Effective Sample Size*, ESS). Embora um algoritmo MCMC possa gerar milhares de amostras, elas não são independentes, pois observações consecutivas tendem a apresentar autocorrelação. O ESS estima quantas amostras independentes seriam equivalentes ao conjunto obtido pelo algoritmo. Assim, valores elevados de ESS indicam que a distribuição *a posteriori* foi explorada de forma eficiente, enquanto valores reduzidos sugerem elevada autocorrelação e a necessidade de aumentar o número de iterações ou investigar possíveis problemas na amostragem.

Adicionalmente, o diagnóstico E-BFMI (Energy Bayesian Fraction of Missing Information) avalia a eficiência da exploração da distribuição de energia pelo algoritmo Hamiltoniano, permitindo identificar possíveis dificuldades na exploração do espaço paramétrico. Valores reduzidos podem indicar problemas na amostragem e a necessidade de investigar a parametrização do modelo ou as configurações do algoritmo.

2.3.3.2 Inferência posterior

Após a avaliação da convergência das cadeias, as amostras geradas pelo algoritmo MCMC são utilizadas para resumir a distribuição a posteriori de cada parâmetro. Diferentemente da abordagem frequentista, a inferência Bayesiana considera toda essa distribuição, permitindo quantificar a incerteza associada às estimativas.

A distribuição posterior pode ser resumida por medidas como média e mediana, além de intervalos de credibilidade. Um intervalo de credibilidade de 95% delimita uma região à qual se atribui probabilidade posterior de 95% de conter o parâmetro, dadas a distribuição a priori e as observações disponíveis.

A posição do intervalo em relação a zero também auxilia na interpretação dos coeficientes. Quando todo o intervalo está acima ou abaixo de zero, há evidências de um efeito predominantemente positivo ou negativo, respectivamente. Essa interpretação difere daquela dos intervalos de confiança frequentistas, que não permitem atribuir diretamente probabilidades aos valores dos parâmetros.

A interpretação dos coeficientes permanece análoga à da regressão logística frequentista: cada coeficiente representa a variação no log-odds associada ao aumento de uma unidade na variável explicativa, mantendo-se constantes as demais variáveis.

2.3.3.3 Avaliação do modelo Bayesiano

A adequação dos modelos Bayesianos pode ser examinada por meio de verificações preditivas posteriores (Posterior Predictive Checks, PPC), que comparam características dos dados observados com aquelas de conjuntos de dados simulados a partir da distribuição preditiva posterior.

Para comparar diferentes especificações, pode-se utilizar o Widely Applicable Information Criterion (WAIC), critério que considera a qualidade preditiva e penaliza a complexidade efetiva do modelo. Sua interpretação está relacionada à Expected Log Predictive Density (ELPD), que representa o desempenho preditivo esperado para novas observações.

2.4 Avaliação de modelos de classificação

A avaliação de modelos de classificação binária pode ser realizada por diferentes métricas, cada uma enfatizando um aspecto distinto do desempenho do modelo. Em problemas de concessão de crédito, essa avaliação torna-se particularmente importante, uma vez que diferentes tipos de erro possuem impactos econômicos distintos para a instituição financeira. Dessa forma, a análise do desempenho não deve se restringir a uma única medida, sendo recomendável a utilização de um conjunto de métricas obtidas a partir da matriz de confusão. As métricas abaixo são utilizadas em ambas as abordagens, frequentista e Bayesiana, permitindo comparar o desempenho dos modelos sob diferentes perspectivas.

2.4.1 Matriz de confusão

A matriz de confusão resume a relação entre as classes observadas e as classes previstas pelo modelo, permitindo identificar a quantidade de classificações corretas e incorretas. Para um problema de classificação binária, ela é composta por quatro elementos:

	Classe prevista: Positiva	Classe prevista: Negativa
Classe observada: Positiva	Verdadeiro Positivo (TP)	Falso Negativo (FN)
Classe observada: Negativa	Falso Positivo (FP)	Verdadeiro Negativo (TN)

A partir desses quatro valores, diversas métricas podem ser calculadas para avaliar diferentes características do modelo.

A acurácia corresponde à proporção total de classificações corretas:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{30}$$

Embora seja uma das métricas mais utilizadas, sua interpretação pode ser prejudicada em bases de dados desbalanceadas, nas quais uma das classes é muito mais frequente que a outra.

A sensibilidade (*Recall* ou *True Positive Rate*) mede a capacidade do modelo em identificar corretamente as observações pertencentes à classe positiva:

$$Sensitivity = \frac{TP}{TP + FN} \tag{31}$$

Já a especificidade (*True Negative Rate*) mede a capacidade do modelo em identificar corretamente as observações da classe negativa:

$$Specificity = \frac{TN}{TN + FP} \tag{32}$$

A precisão (*Precision*) representa a proporção de previsões positivas que realmente correspondem à classe positiva:

$$Precision = \frac{TP}{TP + FP} \tag{33}$$

O F1-score combina precisão e sensibilidade por meio da média harmônica entre ambas:

$$F_1 = 2\frac{Precision \times Sensitivity}{Precision + Sensitivity} \tag{34}$$

Como problemas de concessão de crédito frequentemente apresentam desbalanceamento entre clientes adimplentes e inadimplentes, também é comum utilizar a acurácia balanceada, definida como a média entre sensibilidade e especificidade:

$$Balanced\ Accuracy = \frac{Sensitivity + Specificity}{2} \tag{35}$$

Essa métrica atribui o mesmo peso à sensibilidade e à especificidade, reduzindo a influência da frequência relativa das classes sobre a avaliação do desempenho.

Outra medida amplamente utilizada é o `Matthews Correlation Coefficient` (MCC), definido por:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}} \tag{36}$$

O MCC assume valores entre -1 e 1, sendo que valores próximos de 1 indicam classificação perfeita, valores próximos de 0 representam desempenho semelhante ao acaso e valores negativos indicam discordância entre as classes previstas e observadas. Por considerar simultaneamente todos os elementos da matriz de confusão, essa métrica é particularmente útil em problemas com classes desbalanceadas.

2.4.2 Comparação entre probabilidades previstas e valores observados

Embora métricas obtidas a partir da matriz de confusão sejam amplamente utilizadas na avaliação de modelos de classificação, elas dependem da escolha de um ponto de corte para converter probabilidades em classes previstas. Dessa forma, modelos que produzem probabilidades distintas podem apresentar exatamente a mesma matriz de confusão caso utilizem o mesmo limiar de classificação.

Para contornar essa limitação, também são utilizadas métricas que avaliam diretamente as probabilidades estimadas pelo modelo, sem depender de um ponto de corte específico. Entre as mais empregadas destacam-se a curva ROC, a área sob a curva (AUC) e o Log Loss.

2.4.2.1 Curva ROC e AUC

A curva `Receiver Operating Characteristic` (ROC) representa o desempenho do modelo para diferentes valores do ponto de corte utilizado na classificação. Ela é construída relacionando a sensibilidade (*True Positive Rate*) com a taxa de falsos positivos (*False Positive Rate*), definida por:

$$FPR = \frac{FP}{FP + TN} \tag{37}$$

Cada ponto da curva corresponde a um limiar de classificação diferente, permitindo avaliar o compromisso entre identificar corretamente os eventos positivos e evitar classificações incorretas da classe negativa.

Uma forma de resumir a informação da curva ROC é por meio da Área Sob a Curva (*Area Under the Curve*, AUC). Essa medida pode ser interpretada como a probabilidade de o modelo atribuir uma probabilidade de ocorrência maior a uma observação positiva do que a uma observação negativa escolhida aleatoriamente. Valores de AUC próximos de 1 indicam excelente capacidade discriminatória, enquanto valores próximos de 0,5 sugerem desempenho semelhante ao acaso.

2.4.2.2 Log Loss

Enquanto a AUC avalia a capacidade do modelo em discriminar as classes, o Log Loss considera diretamente a qualidade das probabilidades estimadas. Essa métrica é baseada na função de log-verossimilhança e penaliza previsões incorretas, especialmente quando o modelo atribui elevada confiança a uma classificação errada.

O Log Loss é definido por:

$$LogLoss = -\frac{1}{n}\sum_{i=1}^{n}\left[y_i \log(p_i) + (1 - y_i)\log(1 - p_i)\right] \tag{38}$$

onde y_i representa o valor observado da resposta e p_i corresponde à probabilidade prevista para a observação i.

Valores menores de Log Loss indicam melhor desempenho preditivo, refletindo probabilidades mais compatíveis com os resultados observados. Por utilizar diretamente as probabilidades estimadas, essa métrica é particularmente relevante em modelos probabilísticos, como a regressão logística, tanto na abordagem bayesiana quanto na abordagem frequentista.

2.4.2.3 Índice de Youden

O índice de Youden é uma medida utilizada para identificar um ponto de corte que maximize conjuntamente a sensibilidade e a especificidade de um modelo de classificação. Seu cálculo é definido por:

$$J = \text{Sensibilidade} + \text{Especificidade} - 1$$

O índice varia entre 0 e 1, sendo que valores mais elevados indicam melhor equilíbrio entre a identificação correta das classes positiva e negativa. O ponto de corte que maximiza esse índice corresponde ao limiar que apresenta a maior soma entre sensibilidade e especificidade, considerando diferentes possibilidades de classificação.

Neste trabalho, o índice de Youden é utilizado como critério complementar para investigar os efeitos da alteração do ponto de corte sobre o desempenho dos modelos frequentista e bayesiano, permitindo comparar o equilíbrio entre a identificação de clientes inadimplentes e não inadimplentes.

Cabe destacar que esse critério atribui o mesmo peso à sensibilidade e à especificidade, não considerando diretamente os custos associados aos diferentes tipos de erro de classificação.

3 Metodologia

3.1 Descrição dos Dados

Este trabalho utilizou `Default of Credit Card Clients Dataset`, originalmente disponibilizado por Yeh e Lien (Yeh; Lien (2009)) e atualmente mantido no UCI Machine Learning Repository (Lichman (2013)). O conjunto reúne informações de clientes de cartão de crédito em Taiwan, abrangendo o período de abril a setembro de 2005, incluindo variáveis demográficas, dados financeiros, histórico de pagamentos e valores de fatura. A variável alvo é binária, denotada por `PD30` (Probability of Default in 30 days), a qual indica a ocorrência de inadimplência no horizonte de 30 dias, operacionalmente definida, neste conjunto de dados, como a inadimplência observada no mês subsequente. Assim, embora `PD30` seja um conceito probabilístico no contexto de risco de crédito, neste estudo ela é

observada como uma variável indicadora, assumindo valor 1 quando ocorre inadimplência e 0 caso contrário.

A Tabela 1 apresenta uma descrição detalhada das variáveis presentes neste conjunto de dados, incluindo informações demográficas, financeiras e comportamentais dos clientes.

Tabela 1: Descrição das variáveis do dataset de inadimplência

Categoria	Variáveis	Descrição
Identificação	`id_cliente`	Identificador único do cliente.
Perfil demográfico	`sexo`, `escolaridade`, `estado_civil`, `idade`	Informações demográficas do cliente.
Crédito	`limite_credito`	Limite de crédito concedido ao cliente (crédito individual e suplementar).
Histórico de pagamentos	`atraso_pagto_0` a `atraso_pagto_6`	Situação de atraso nos pagamentos entre abril e setembro de 2005. Valores positivos indicam atraso, enquanto valores negativos representam situações especiais, como pagamento antecipado ou ausência de consumo.
Faturas	`fatura_valor_1` a `fatura_valor_6`	Valores das faturas mensais do cartão de crédito, referentes ao período de abril a setembro de 2005 (NT dollar).
Pagamentos	`pagto_valor_1` a `pagto_valor_6`	Valores pagos mensalmente pelo cliente no período de abril a setembro de 2005 (NT dollar).

Categoria	Variáveis	Descrição
Variável resposta	`PD30`	Indicador binário de inadimplência no mês subsequente (1 = inadimplente; 0 = adimplente).

3.2 Pré-processamento

3.2.1 Estrutura de dados e tratamento de valores ausentes

Inicialmente, foi realizada a inspeção da estrutura do banco de dados, com o objetivo de confirmar a consistência dos tipos das variáveis e a adequação do formato dos dados às técnicas de modelagem adotadas. Essa análise compreendeu a identificação das classes das variáveis, a distinção entre atributos numéricos e categóricos e a validação da variável resposta quanto à sua natureza e domínio.

Por fim, a presença de valores ausentes foi avaliada e nenhuma observação faltante foi identificada, eliminando a necessidade de técnicas de imputação e evitando a introdução de incerteza adicional ou viés sistemático no processo de estimação.

3.2.2 Outliers

A identificação de valores atípicos (*outliers*) nas variáveis numéricas foi realizada por meio do critério do intervalo interquartil (*Interquartile Range*, IQR), amplamente utilizado em estatística descritiva por sua robustez em relação a distribuições assimétricas e à presença de valores extremos.

Para cada variável contínua, o primeiro quartil Q_1 e o terceiro quartil Q_3 foram calculados. Definindo o intervalo interquartil como

$$\mathrm{IQR} = Q_3 - Q_1 \tag{39}$$

Os limites inferior e superior para identificação de outliers são definidos como

$$L = Q_1 - 1.5 \cdot \text{IQR} \tag{40}$$

$$U = Q_3 + 1.5 \cdot \text{IQR} \tag{41}$$

Esse procedimento foi empregado exclusivamente com finalidade exploratória, visando caracterizar a distribuição das variáveis e avaliar a presença de valores extremos potencialmente influentes. Não foi realizada a exclusão automática de observações, de modo a preservar a integridade do conjunto de dados e permitir que os modelos estatísticos capturassem adequadamente a heterogeneidade inerente aos dados financeiros.

O fator 1.5 no critério do IQR foi proposto por Tukey (1977) como um compromisso empírico entre robustez e sensibilidade, sendo amplamente adotado por sua boa performance em distribuições assimétricas e com caudas longas, como é típico em dados financeiros.

No contexto de análise de risco de crédito, a presença de valores extremos pode refletir perfis legítimos de alto patrimônio ou elevado risco, sendo crucial que os modelos estatísticos sejam capazes de acomodar essa variabilidade sem que a remoção indiscriminada de outliers elimine informação relevante para a tarefa de classificação.

3.2.3 Correlação

A análise de correlação entre as variáveis numéricas foi conduzida com o objetivo de investigar associações lineares e identificar potenciais indícios de multicolinearidade entre os preditores candidatos ao modelo de regressão logística. As correlações foram estimadas por meio do coeficiente de correlação de Pearson, apropriado para avaliar associações lineares entre variáveis contínuas. O cálculo foi realizado utilizando observações completas.

Os resultados foram sintetizados em uma matriz de correlação, posteriormente representada graficamente por meio de um mapa de calor (*heatmap*), no qual a intensidade e o sinal das correlações são indicados por uma escala de cores contínua. Essa etapa teve caráter exploratório e diagnóstico, servindo como subsídio para a avaliação de possíveis problemas

de multicolinearidade na etapa de modelagem, especialmente no que se refere à estabilidade e interpretação dos coeficientes da regressão logística.

3.2.4 Padronização de variáveis numéricas

Para assegurar a estabilidade numérica dos algoritmos de estimação e permitir a comparabilidade entre os coeficientes do modelo, as variáveis quantitativas foram submetidas ao processo de padronização (*Standardization*). Inicialmente, realizou-se a conversão dos dados para o tipo numérico e, em seguida, aplicou-se a transformação de escala centralizada na média com unidade de desvio padrão. A fórmula utilizada para a padronização de cada variável X é dada por

$$z_i = \frac{x_i - \bar{x}}{S} \tag{42}$$

onde x_i representa o valor original da variável, $\bar{x}$ é a média amostral e S é o desvio padrão amostral. Essa transformação resulta em variáveis com média zero e desvio padrão um. Com todas as variáveis na mesma escala, os coeficientes estimados tornam-se comparáveis entre si, permitindo identificar quais preditores exercem maior impacto relativo sobre a probabilidade de aprovação do empréstimo.

Quanto ao pré-processamento, a padronização das variáveis numéricas foi aplicada aos modelos com regularização L1 e L2, bem como aos modelos bayesianos. No caso dos modelos frequentistas regularizados, a transformação é necessária para evitar que diferenças nas escalas das variáveis influenciem desproporcionalmente a penalização dos coeficientes. Na abordagem bayesiana, a padronização também favorece a estabilidade numérica e permite especificar distribuições *a priori* em uma escala comum para os coeficientes. Os modelos frequentistas sem regularização foram estimados sem essa transformação, preservando as escalas originais das variáveis explicativas.

3.2.5 Divisão entre treino e teste

O conjunto de dados foi particionado em subconjuntos de treino (75%) e teste (25%) por meio de amostragem aleatória estratificada em relação à variável resposta Y=`PD30`. Essa

estratégia assegura que as distribuições marginais das classes sejam preservadas em ambos os subconjuntos, como:

$$\mathbb{P}(Y = 1 \mid \text{treino}) \approx \mathbb{P}(Y = 1 \mid \text{teste}) \approx \mathbb{P}(Y = 1). \tag{43}$$

A preservação das proporções de classe é fundamental em problemas de classificação binária, pois evita distorções na estimação dos parâmetros e na avaliação das funções de decisão, especialmente em cenários com possíveis assimetrias entre as classes.

Os modelos foram estimados exclusivamente com observações do conjunto de treino, enquanto o conjunto de teste foi utilizado apenas para a avaliação do desempenho preditivo fora da amostra. Essa separação garante que as métricas de desempenho estimadas correspondam a uma aproximação não enviesada do erro de generalização, reduzindo o risco de sobreajuste (*overfitting*) e vazamento de informação.

3.3 Modelos Avaliados

3.3.1 Regressão logística frequentista

A modelagem frequentista foi implementada utilizando o ecossistema tidymodels Kuhn; Wickham (2020), um conjunto integrado de pacotes da linguagem R voltado à construção de fluxos de trabalho reprodutíveis para aprendizado estatístico. Essa abordagem permite estruturar de forma padronizada as etapas da modelagem, incluindo o pré-processamento dos dados, a especificação dos modelos, o ajuste, a validação e a avaliação de desempenho.

O pré-processamento foi realizado por meio do pacote recipes, no qual foram definidas as transformações necessárias para cada configuração avaliada. Entre essas etapas destacam-se a codificação das variáveis categóricas em variáveis indicadoras binárias (dummy variables), a normalização dos preditores numéricos quando requerida, a remoção de variáveis específicas e a eliminação de preditores altamente correlacionados. A utilização de recipes garante que as transformações sejam estimadas exclusivamente a partir do conjunto de treinamento e posteriormente aplicadas aos dados de teste, evitando o vazamento de informação.

Os modelos e seus respectivos pré-processamentos foram integrados por meio do pacote workflows, permitindo que cada combinação fosse tratada como um fluxo único de modelagem. Para a regressão logística clássica, estimada por máxima verossimilhança, foram avaliadas diferentes especificações de variáveis explicativas, descritas a seguir: - Modelo completo: utilização de todas as variáveis disponíveis como preditoras; - Modelo sem variáveis altamente correlacionadas: remoção automática de preditores numéricos com correlação absoluta superior a 0,75, visando reduzir problemas associados à multicolinearidade. Além da regressão logística clássica, foram avaliadas versões regularizadas utilizando penalizações Lasso (L1) e Ridge (L2). Nesses modelos, os hiperparâmetros de penalização foram selecionados por meio de um *grid search*, utilizando validação cruzada. O pré-processamento dessas especificações compreendeu a codificação das variáveis categóricas e a normalização dos preditores numéricos. A regularização tem como objetivo controlar a magnitude dos coeficientes, reduzir o sobreajuste e potencialmente melhorar a capacidade de generalização dos modelos, especialmente em cenários com elevado número de preditores ou presença de correlação entre variáveis explicativas.

As diferentes especificações foram utilizadas para avaliar o impacto da seleção de variáveis e da regularização sobre o desempenho preditivo e a interpretabilidade dos coeficientes estimados.

Todas as etapas de treinamento, validação e avaliação foram conduzidas dentro do fluxo de trabalho do tidymodels, buscando garantir consistência entre os modelos comparados e reprodutibilidade dos resultados obtidos.

3.3.2 Regressão logística bayesiana

A regressão logística bayesiana foi implementada utilizando o pacote rstanarm Goodrich et al. (2020), que permite estimar modelos lineares generalizados sob o paradigma bayesiano por meio de MCMC, implementados na plataforma Stan Carpenter et al. (2017). Nesse contexto, a distribuição posterior dos parâmetros é obtida pela combinação entre a verossimilhança dos dados observados e as distribuições a priori especificadas para os coeficientes do modelo.

Os modelos foram ajustados utilizando a função stan_glm(), com família binomial e função de ligação logística (logit). Em todos os ajustes foram utilizadas quatro cadeias

independentes de MCMC, permitindo avaliar a convergência das amostras posteriores por meio de diagnósticos específicos, além de obter estimativas da distribuição posterior dos parâmetros.

Foram consideradas duas especificações de distribuições a priori para os coeficientes das variáveis explicativas: Normal e Laplace, ambas centradas em zero e com variância igual a 1. Para a distribuição Normal, foram definidos localização igual a zero e desvio-padrão igual a 1. Para a distribuição Laplace, o parâmetro de escala foi definido como $(1/\sqrt{2})$, de modo a igualar sua variância à da distribuição Normal, uma vez que a variância da distribuição Laplace é dada por $(2b^2)$, em que (b) representa seu parâmetro de escala.

Para tornar a comparação entre as especificações bayesianas mais controlada, foram adotadas distribuições a priori Normal e Laplace com variâncias equivalentes. Essa escolha busca estabelecer o mesmo nível de dispersão inicial para os coeficientes, permitindo investigar em que medida as diferenças observadas nas distribuições posteriores decorrem do formato das distribuições a priori, e não simplesmente de diferentes escalas de dispersão. Embora apresentem variâncias iguais, as distribuições Normal e Laplace possuem características distintas, especialmente em relação à concentração de probabilidade em torno de zero e ao comportamento das caudas. Essas diferenças podem influenciar o mecanismo de regularização e, consequentemente, a magnitude e a dispersão das estimativas posteriores. Assim, a estratégia permite avaliar como diferentes pressupostos distributivos, mantido constante o nível de variabilidade a priori, afetam a inferência sobre os coeficientes do modelo.

Para o intercepto, foi mantida a mesma distribuição a priori Normal, com localização zero e escala 5, em ambas as especificações.

3.3.3 Métricas de avaliação

3.3.3.1 Métricas de avaliação do ajuste dos modelos

A avaliação do ajuste dos modelos frequentistas foi realizada por meio da deviance residual e nula, dos critérios AIC e BIC, e do teste da razão de verossimilhança, utilizado para comparar especificações aninhadas. A presença de multicolinearidade entre as variáveis explicativas foi investigada por meio do VIF, enquanto a adequação dos modelos também foi

examinada por meio da análise de resíduos e da identificação de observações potencialmente influentes.

Para os modelos bayesianos, a qualidade da amostragem foi avaliada por meio de diagnósticos de convergência e eficiência das cadeias, incluindo o $\hat{R}$, o ESS e a inspeção gráfica dos *traceplots*. Adicionalmente, o MCSE foi utilizado para avaliar a precisão numérica das estimativas posteriores, enquanto o E-BFMI foi considerado na avaliação do comportamento do algoritmo HMC. A adequação dos modelos aos dados observados também foi investigada por meio de PPC. A multicolinearidade entre os preditores foi examinada por meio do VIF, considerando a mesma estrutura de variáveis explicativas utilizada na modelagem.

3.3.3.2 Métricas de avaliação preditiva

A avaliação do desempenho preditivo dos modelos de classificação foi realizada por meio de métricas adequadas a problemas de classificação binária, considerando tanto a capacidade de discriminação quanto a qualidade das probabilidades estimadas e o equilíbrio entre os erros de classificação. Foram utilizadas a área sob a curva ROC (ROC-AUC) e a função de perda logarítmica (*Log Loss*) para avaliar, respectivamente, a capacidade de discriminação e a qualidade das probabilidades previstas. Adicionalmente, foram calculadas a sensibilidade (*Recall*), a especificidade, a acurácia (*Accuracy*), a acurácia balanceada (*Balanced Accuracy*), a precisão (*Precision*), a medida F1 (*F1-score*) e o MCC. A matriz de confusão também foi utilizada para sintetizar os resultados das classificações, permitindo identificar os acertos e erros associados a cada classe.

4 Resultados

4.1 Análise Exploratória

A análise exploratória é fundamental para orientar as decisões de modelagem, especialmente no que tange à escolha de variáveis, tratamento de outliers e seleção de técnicas de modelagem adequadas ao perfil dos dados.

O conjunto de dados de inadimplência é composto por 30000 observações e 24 variáveis, incluindo a variável resposta `PD30`, que indica se As variáveis preditoras incluem informações como renda anual, pontuação de crédito, nível educacional, entre outras características dos solicitantes.

4.1.1 Estatísticas univariadas

A Tabela 2 evidencia uma população heterogênea de clientes de cartão de crédito, com ampla variabilidade tanto nas características demográficas quanto nas variáveis financeiras, o que também pode ser visto no dataset de empretimos. O limite médio de crédito é de aproximadamente NT$ 167 mil, com mediana inferior (NT$ 140 mil), indicando assimetria à direita e a presença de clientes com limites substancialmente mais elevados, o que é reforçado pelo alto desvio padrão. A idade média dos clientes é de cerca de 35 anos, com concentração em adultos jovens e de meia-idade.

No que diz respeito ao comportamento de pagamento, as variáveis de atraso (`atraso_pagto_0` a `atraso_pagto_6`) apresentam médias próximas de zero e medianas iguais a zero, sugerindo que a maioria dos clientes não apresenta atraso significativo nos pagamentos, embora existam casos extremos de inadimplência prolongada (até oito meses). Os valores de fatura e de pagamento exibem grande dispersão (que pode ser vista na Figura 7), com médias substancialmente superiores às medianas, o que indica distribuições fortemente assimétricas e a presença de outliers. Ademais, a ocorrência de valores negativos nas faturas é consistente com ajustes, estornos ou créditos no sistema de faturamento. Em conjunto, esses resultados reforçam a complexidade do perfil financeiro dos clientes e justificam o uso de técnicas de modelagem robustas à assimetria, à presença de valores extremos e à heterogeneidade dos dados monetários expressos em dólares taiwaneses (NT$).

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
limite_credito	167484	140000	10000	1e+06	129748
sexo	1.6	2	1	2	0.49
escolaridade	1.85	2	0	6	0.79

Tabela 2: Estatísticas descritivas das variáveis numéricas do conjunto de dados.

	mean	median	min	max	std
estado_civil	1.55	2	0	3	0.52
idade	35.49	34	21	79	9.22
atraso_pagto_0	-0.02	0	-2	8	1.12
atraso_pagto_2	-0.13	0	-2	8	1.2
atraso_pagto_3	-0.17	0	-2	8	1.2
atraso_pagto_4	-0.22	0	-2	8	1.17
atraso_pagto_5	-0.27	0	-2	8	1.13
atraso_pagto_6	-0.29	0	-2	8	1.15
fatura_valor_1	51223.3	22381.5	-165580	964511	73635.9
fatura_valor_2	49179.1	21200	-69777	983931	71173.8
fatura_valor_3	47013.2	20088.5	-157264	1.66409e+06	69349.4
fatura_valor_4	43262.9	19052	-170000	891586	64332.9
fatura_valor_5	40311.4	18104.5	-81334	927171	60797.2
fatura_valor_6	38871.8	17071	-339603	961664	59554.1
pagto_valor_1	5663.58	2100	0	873552	16563.3
pagto_valor_2	5921.16	2009	0	1.68426e+06	23040.9
pagto_valor_3	5225.68	1800	0	896040	17607
pagto_valor_4	4826.08	1500	0	621000	15666.2
pagto_valor_5	4799.39	1500	0	426529	15278.3
pagto_valor_6	5215.5	1500	0	528666	17777.5

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
sexo	1	11888	39.63
sexo	2	18112	60.37
escolaridade	0	14	0.05
escolaridade	1	10585	35.28
escolaridade	2	14030	46.77

Tabela 3: Distribuição das variáveis categóricas do conjunto de dados.

variavel	categoria	n	percentual (%)
escolaridade	3	4917	16.39
escolaridade	4	123	0.41
escolaridade	5	280	0.93
escolaridade	6	51	0.17
estado_civil	0	54	0.18
estado_civil	1	13659	45.53
estado_civil	2	15964	53.21
estado_civil	3	323	1.08

As variáveis categóricas do conjunto de dados descrevem características demográficas dos clientes, com distribuições detalhadas na Tabela 3. Observa-se predominância do sexo feminino e concentração nas categorias "solteiro" e "casado" para estado civil. Na escolaridade, predominam os níveis universitário e de pós-graduação, o que pode estar associado a maior estabilidade de renda e menores taxas de inadimplência, embora essa relação deva ser avaliada empiricamente. As subcategorias "Desconhecido 1" e "Desconhecido 2" foram mantidas como categorias distintas, sem agrupamentos ou imputações, para preservar a estrutura original da variável.

4.1.2 Avaliação da variável resposta

Na Figura 8, observa-se a distribuição da variável resposta PD30, indicando que aproximadamente 22.12% dos clientes apresentam inadimplência no mês subsequente, enquanto os demais 77.88% correspondem à classe de adimplentes. Esse desbalanceamento de classes é característico de problemas de risco de crédito e deve ser considerado na etapa de modelagem, uma vez que pode influenciar métricas de desempenho e a calibração das probabilidades previstas pelos modelos.

Esse cenário é típico de problemas de credit scoring e caracteriza um contexto de `imbalanced learning`, no qual a classe minoritária (inadimplência) é justamente a de maior interesse analítico.

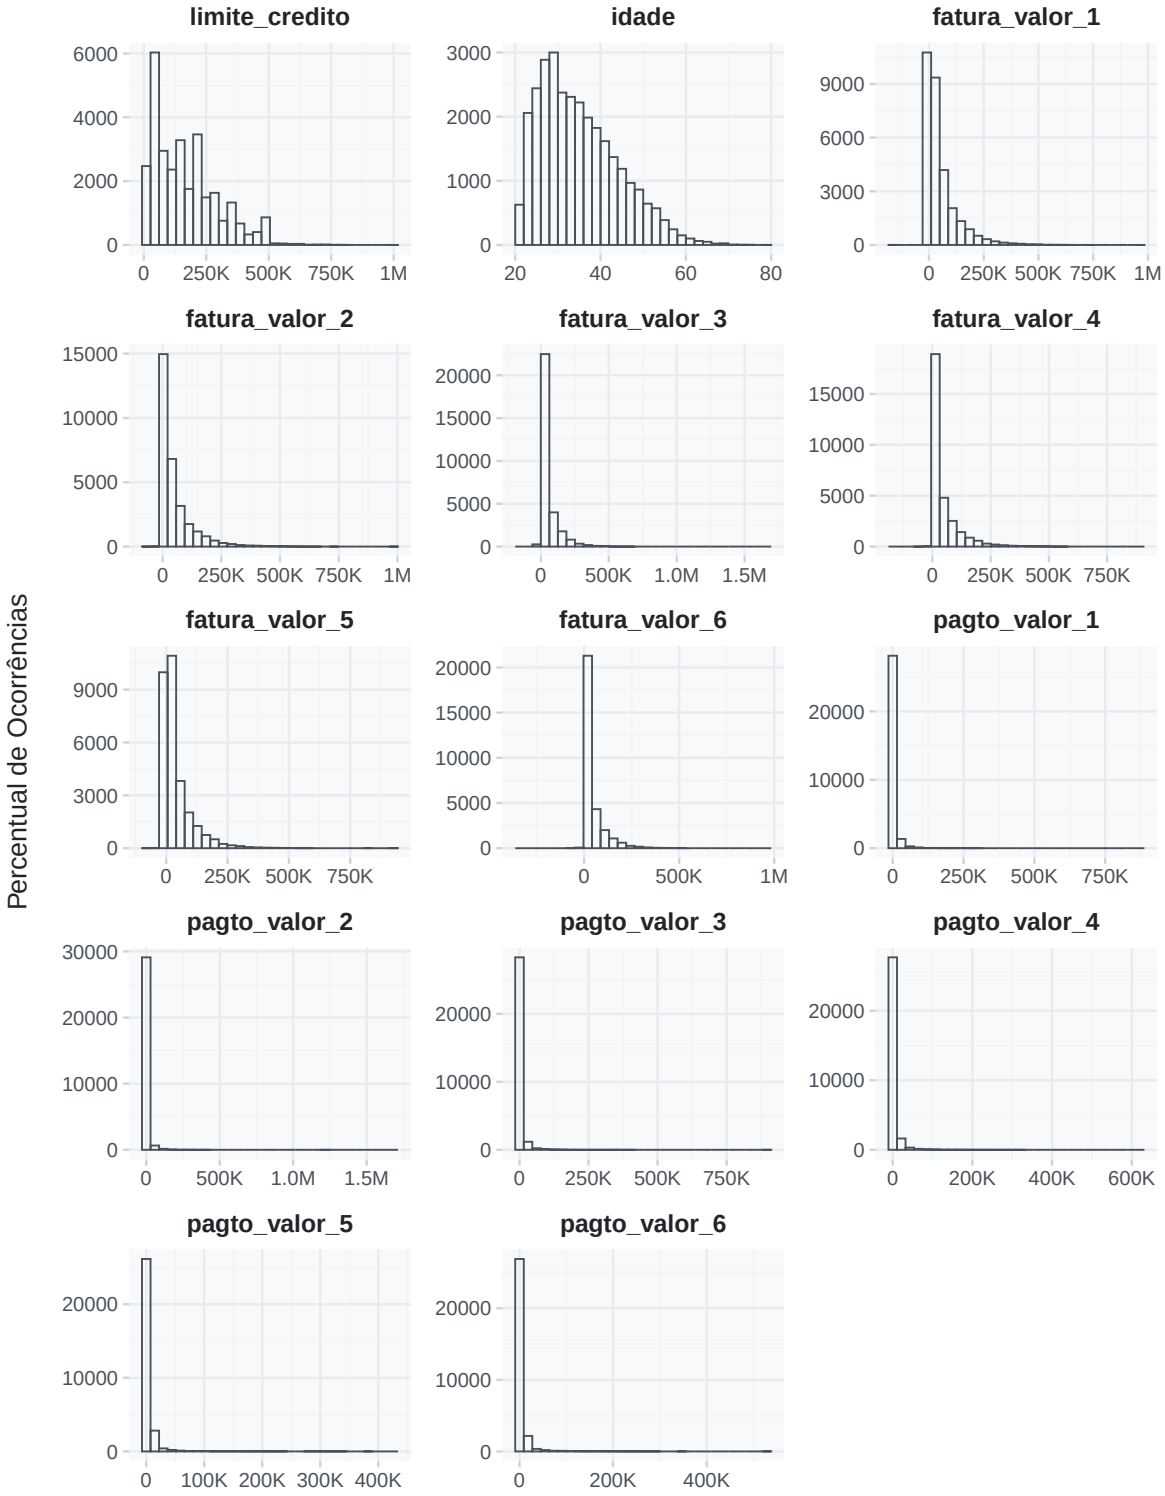


Figura 7: Distribuição das principais variáveis numéricas do conjunto de dados

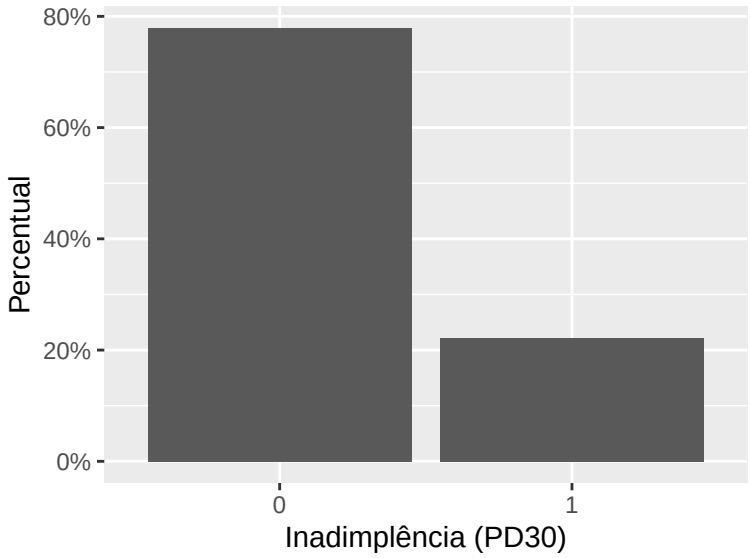


Figura 8: Distribuição da Inadimplência

Nesse tipo de distribuição, métricas globais como acurácia podem ser enganosas, pois modelos que privilegiam a classe majoritária tendem a apresentar desempenho aparentemente elevado mesmo sem capacidade discriminativa adequada para a classe de interesse. Por essa razão, métricas baseadas em discriminação e equilíbrio entre classes tornam-se mais informativas.

4.1.3 Análise de correlação entre variáveis numéricas

A Figura 9 evidencia padrões estruturais importantes entre as variáveis numéricas do conjunto de dados. Observa-se uma forte correlação positiva entre os valores de fatura ao longo dos meses (por exemplo, entre `fatura_valor_1` e `fatura_valor_2`, com correlação próxima de 0,95), indicando alta persistência temporal do saldo devedor dos clientes. Esse comportamento é esperado em dados de crédito, onde o saldo de fatura tende a evoluir de forma gradual ao longo do tempo.

De forma semelhante, as variáveis de atraso de pagamento (`atraso_pagto_*`) apresentam correlações moderadas a altas entre si (chegando a valores acima de 0,8), sugerindo forte dependência temporal e possível redundância informacional. Esse padrão é relevante do ponto de vista de modelagem, pois indica potencial multicolinearidade entre variáveis de comportamento de pagamento, o que pode afetar estimativas em modelos lineares tradicionais e justificar o uso de abordagens regularizadas ou bayesianas mais robustas.

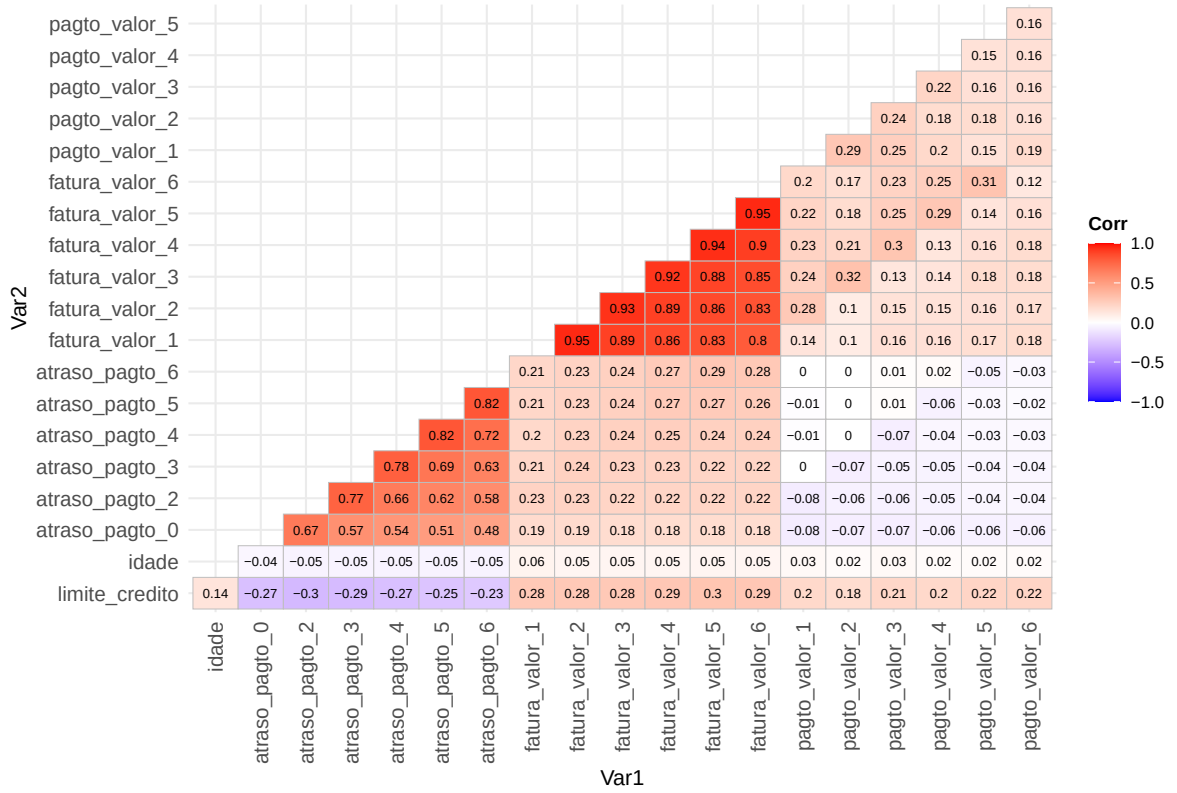


Figura 9: Mapa de calor da correlação entre variáveis numéricas do conjunto de dados de crédito

Por outro lado, variáveis como idade e limite de crédito apresentam correlações fracas com a maioria das demais variáveis, sugerindo que carregam informação relativamente independente dentro do conjunto de dados. Já os valores de pagamento (`pagto_valor_*`) mostram correlações baixas entre si e com outras variáveis, indicando maior variabilidade e menor estrutura temporal consistente quando comparados aos saldos de fatura e atrasos de pagamento.

4.1.4 Análise de outliers

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
atraso_pagto_0	3130	0.1043333
atraso_pagto_2	4410	0.1470000
atraso_pagto_3	4209	0.1403000

Tabela 4: Número e percentual de outliers identificados pelo critério do IQR no conjunto de dados de crédito

Feature	Outliers	Percentual
atraso_pagto_4	3508	0.1169333
atraso_pagto_5	2968	0.0989333
atraso_pagto_6	3079	0.1026333
fatura_valor_1	2400	0.0800000
fatura_valor_2	2395	0.0798333
fatura_valor_3	2469	0.0823000
fatura_valor_4	2622	0.0874000
fatura_valor_5	2725	0.0908333
fatura_valor_6	2693	0.0897667
idade	272	0.0090667
limite_credito	167	0.0055667
pagto_valor_1	2745	0.0915000
pagto_valor_2	2714	0.0904667
pagto_valor_3	2598	0.0866000
pagto_valor_4	2994	0.0998000
pagto_valor_5	2945	0.0981667
pagto_valor_6	2958	0.0986000

Os resultados da detecção de outliers (Tabela 4) pelo critério do IQR indicam um padrão bastante consistente com a natureza dos dados financeiros analisados. Observa-se que as variáveis relacionadas ao histórico de atraso de pagamento (`atraso_pagto_*`) apresentam as maiores proporções de outliers, variando aproximadamente entre 9,9% e 14,7% das observações. Esse comportamento é esperado, uma vez que essas variáveis sãoassimétricas por construção, refletindo estados de atraso que podem se concentrar em valores extremos (como atrasos elevados em determinados meses e raros pagamentos antecipados).

As variáveis de valores de fatura (`fatura_valor_*`) e de pagamento (`pagto_valor_*`) também apresentam proporções relevantes de outliers, em torno de 8% a 9%. Isso é típico em dados financeiros de crédito, nos quais distribuições são fortemente assimétricas

à direita, com uma pequena parcela de clientes concentrando valores elevados de consumo e pagamento. Nesse contexto, esses "outliers" não necessariamente representam erros ou anomalias, mas sim a própria heterogeneidade do comportamento financeiro da população.

Em contraste, variáveis como idade e limite de crédito apresentam proporções muito baixas de outliers (inferiores a 1%), sugerindo distribuições mais estáveis e próximas de um comportamento aproximadamente simétrico ou moderadamente disperso. Esse resultado reforça a importância de interpretar outliers sob uma perspectiva contextual: em dados de crédito, valores extremos frequentemente carregam informação relevante sobre risco e capacidade financeira, não devendo ser removidos automaticamente sem análise substantiva.

4.2 Pré processamento do dataset

Inicialmente, foi realizada a verificação da presença de valores ausentes e observações duplicadas no conjunto de dados analisado. Não foram identificados valores faltantes ou registros duplicados, o que dispensou a aplicação de técnicas de imputação e garantiu a consistência estrutural das bases utilizadas.

Em relação aos outliers, optou-se por não aplicar procedimentos de remoção ou transformação em ambos os conjuntos de dados. A identificação pelo critério do intervalo interquartil (IQR) revelou a presença de valores extremos em variáveis financeiras e comportamentais, o que é esperado em bases de crédito devido à forte assimetria e heterogeneidade dos perfis de clientes. Nesses contextos, valores extremos não são necessariamente indicativos de erro, podendo representar justamente os casos de maior interesse analítico, especialmente em tarefas de modelagem de risco de crédito.

4.2.1 Seleção de variáveis e análise de correlação

A Figura 9 foi utilizada para investigar possíveis relações de dependência linear entre as variáveis numéricas dos dois conjuntos de dados analisados. Em ambos os casos, observam-se padrões consistentes de correlação estrutural entre variáveis financeiras, especialmente aquelas relacionadas a renda, patrimônio e exposição de crédito.

Apesar da presença de relações entre variáveis financeiras e comportamentais, optou-se por não realizar remoção de variáveis nesta etapa. Essa decisão foi orientada pelo objetivo de manter comparabilidade entre abordagens de modelagem e preservar o espaço completo de informação para avaliação empírica posterior.

Adicionalmente, a eventual presença de redundância informacional será tratada implicitamente pelos próprios modelos considerados, incluindo regressão logística regularizada e abordagens bayesianas, além de ser avaliada posteriormente por métricas complementares como o Variance Inflation Factor (VIF). Isso permite uma análise mais controlada do impacto da estrutura de dependência entre variáveis sobre desempenho preditivo e interpretabilidade.

4.2.2 Separação treino/teste

Os conjuntos de dados foram divididos aleatoriamente em subconjuntos de treino (75%) e teste (25%), utilizando amostragem estratificada em relação às variáveis resposta. Essa estratégia assegura que a proporção de observações pertencentes a cada classe seja preservada em ambos os subconjuntos.

O ajuste do modelo foi realizado exclusivamente com o conjunto de treino, enquanto o conjunto de teste foi reservado para a avaliação do desempenho preditivo fora da amostra, assegurando a separação adequada entre as etapas de estimação e validação.

4.3 Modelagem e Avaliação

Após a etapa de pré-processamento, o conjunto de dados de concessão de empréstimos foi utilizado para o ajuste de modelos de regressão logística, com o objetivo de estimar a probabilidade de default (PD30) a partir das características socioeconômicas e financeiras dos clientes. A regressão logística foi escolhida por se tratar de um modelo amplamente utilizado em problemas de classificação binária e por permitir a interpretação dos efeitos das variáveis explicativas sobre as chances do evento de interesse por meio das razões de chances. A partir dessa mesma estrutura de modelagem, foram consideradas as abordagens frequentista e Bayesiana, permitindo comparar não apenas o desempenho preditivo, mas também as diferentes formas de estimação e inferência sobre os parâmetros do modelo.

4.3.1 Modelagem Frequentista

Inicialmente, adotou-se uma abordagem frequentista, com estimação dos parâmetros via máxima verossimilhança. Essa estratégia fornece uma referencia inicial para a análise, permitindo avaliar tanto o poder preditivo quanto a contribuição individual das variáveis explicativas.

Com o intuito de investigar a sensibilidade do modelo à especificação das variáveis e à presença de dependências lineares, foram ajustadas diferentes variações do modelo logístico:

- **Modelo completo:** inclui todas as variáveis explicativas disponíveis após o pré-processamento, servindo como especificação de referência para as comparações.
- **Modelo com remoção manual de variáveis altamente correlacionadas:** variáveis com correlação absoluta superior a 75% foram excluídas de forma criteriosa, visando reduzir a redundância informacional e avaliar o impacto dessa simplificação na estabilidade e no desempenho do modelo.
- **Modelo com regularização L1 (Lasso):** incorpora uma penalização baseada na soma dos valores absolutos dos coeficientes, favorecendo a redução de sua magnitude e podendo levar alguns deles a valores exatamente iguais a zero. Dessa forma, além de controlar a complexidade do modelo, essa abordagem pode promover uma seleção implícita de variáveis.
- **Modelo com regularização L2 (Ridge):** utiliza uma penalização baseada na soma dos quadrados dos coeficientes, promovendo sua redução em direção a zero, mas sem anulá-los. Seu objetivo é controlar a magnitude dos parâmetros e reduzir a sensibilidade do modelo a variáveis explicativas correlacionadas.

Quanto ao pré-processamento, a padronização das variáveis numéricas foi aplicada aos modelos com regularização L1 e L2, uma vez que a penalização depende da magnitude dos coeficientes e, portanto, é sensível à escala das variáveis. Nos modelos sem regularização, a padronização não foi aplicada, preservando-se as escalas originais para facilitar a interpretação dos coeficientes.

A comparação entre essas especificações permite avaliar o trade-off entre interpretabilidade, complexidade do modelo e desempenho preditivo, além de fornecer evidências empíricas sobre o papel do score de crédito e da estrutura de correlação das variáveis no processo de decisão de concessão de empréstimos.

Tabela 5: Estatísticas de ajuste dos modelos de regressão logística não penalizados

Modelo	Deviance nula	Deviance residual	AIC	BIC	Graus de liberdade residuais
Completo	23779.02	20797.50	20855.50	21088.11	22471
Sem multicolinearidade	23779.02	20848.41	20890.41	21058.85	22479

A comparação das estatísticas de ajuste foi realizada apenas para os modelos de regressão logística não penalizados (Completo e Sem multicolinearidade), uma vez que ambos foram estimados pelo método tradicional de máxima verossimilhança, permitindo a obtenção e a interpretação direta de medidas como a deviance residual, o AIC e o BIC. Os modelos Lasso (L1) e Ridge (L2), por sua vez, incorporam penalizações sobre os coeficientes e são estimados por meio do pacote glmnet, de modo que os critérios tradicionais de informação não são diretamente equivalentes aos calculados para os modelos não penalizados. Por essa razão, a comparação desses modelos foi conduzida principalmente com base nas métricas de desempenho preditivo.

Conforme apresentado na Tabela 5, o modelo Completo apresentou menor deviance residual e menor AIC em relação ao modelo sem multicolinearidade, indicando melhor ajuste segundo essas medidas. Em contrapartida, o modelo Sem multicolinearidade apresentou menor BIC, favorecendo a especificação mais parcimoniosa, que possui oito parâmetros a menos, conforme indicado pela diferença nos graus de liberdade residuais.

De modo geral, os resultados evidenciam um equilíbrio entre qualidade de ajuste e parcimônia: enquanto o modelo Completo é favorecido pela deviance residual e pelo AIC, o modelo Sem multicolinearidade apresenta vantagem segundo o BIC. Essas diferenças são consideradas em conjunto com as métricas de desempenho preditivo.

Tabela 6: Métricas de desempenho do modelo de regressão logística, avaliadas no conjunto de teste.

Métrica	Completo	Sem multicolinearidade	Lasso (L1)	Ridge (L2)
Acurácia	0.811	0.812	0.811	0.807
Acurácia balanceada	0.613	0.613	0.613	0.599
ROC-AUC	0.716	0.714	0.716	0.715
Log-loss	0.470	0.470	0.470	0.469
Sensibilidade	0.259	0.258	0.258	0.226
Especificidade	0.967	0.969	0.968	0.972
Precisão	0.692	0.703	0.695	0.696
F1-score	0.376	0.377	0.376	0.341
MCC	0.340	0.345	0.341	0.318

Tabela 7: Resumo do VIF para os modelos de regressão logística não penalizados.

Modelo	VIF máximo	VIF médio
Completo	41.12	7.80
Sem multicolinearidade	1.84	1.24

As quatro especificações apresentaram desempenho preditivo bastante semelhante (Tabela 6): ROC AUC entre 0,714 e 0,716, log-loss em torno de 0,47 e acurácia entre 0,807 e 0,812. O modelo L2 (Ridge) é a única exceção parcial: apresentou a menor sensibilidade (0,226) e a maior especificidade (0,972), em contraste com os demais modelos, que mantiveram acurácia balanceada próxima de 0,613. As diferenças observadas são pequenas, indicando que a remoção de variáveis correlacionadas ou a aplicação das penalizações não produziu alterações substanciais na capacidade discriminativa.

Um aspecto comum às quatro especificações é a elevada especificidade (entre 0,967 e 0,972) acompanhada por baixa sensibilidade (entre 0,226 e 0,259). Esse comportamento indica que os modelos identificam corretamente a grande maioria dos não inadimplentes, mas classificam incorretamente parcela expressiva dos inadimplentes, resultado consistente com

o desbalanceamento da variável resposta e que deve ser considerado na interpretação da acurácia global.

A análise do VIF (Tabela 7) evidencia uma diferença expressiva entre as especificações não penalizadas: o modelo Completo apresentou VIF máximo de 41,12 e médio de 7,80, enquanto o modelo Sem multicolinearidade reduziu esses valores para 1,84 e 1,24, respectivamente. Essa redução indica menor multicolinearidade entre os preditores, sem alteração relevante no desempenho preditivo.

Embora o VIF também possa ser calculado para as especificações regularizadas, a comparação entre L1 e L2 foi direcionada principalmente ao comportamento dos coeficientes e às métricas de desempenho preditivo.

4.3.1.1 Comparações de Features L1 vs Remoção de Variáveis Correlacionadas

A comparação entre as estratégias de redução da complexidade revelou uma sobreposição parcial entre as variáveis excluídas pelo procedimento de correlação e aquelas cujos coeficientes foram anulados pela regularização L1. Em particular, a variável fatura_valor_4 foi removida em ambas as abordagens. Entretanto, o L1 também anulou o coeficiente de fatura_valor_6, enquanto o procedimento baseado em correlação excluiu outras variáveis, como atraso_pagto_3, atraso_pagto_4, atraso_pagto_5 e fatura_valor_5.

Essa sobreposição parcial indica que as estratégias não são equivalentes: enquanto a remoção por correlação considera a associação entre os preditores, a penalização L1 estima os coeficientes considerando simultaneamente o ajuste do modelo e a penalização aplicada, podendo reduzir alguns deles exatamente a zero. Assim, embora ambas possam reduzir a complexidade da especificação, seus critérios produzem conjuntos distintos de variáveis.

4.3.1.2 Diagnóstico do modelo sem multicolinearidade

A análise detalhada será concentrada no modelo sem multicolinearidade. Essa escolha não decorre de superioridade preditiva, uma vez que os quatro modelos apresentaram métricas bastante próximas, mas da redução substancial da multicolinearidade (VIF máximo de 41,12 para 1,84), sem comprometer o desempenho preditivo. Essa especificação também

mantém a estrutura convencional da regressão logística estimada por máxima verossimilhança (MLE), permitindo aplicar diretamente os procedimentos inferenciais usuais e interpretar os coeficientes com menor preocupação quanto à instabilidade decorrente da multicolinearidade.

A partir dessa especificação, serão examinados os resíduos, a deviance e o teste da razão de verossimilhança, além dos coeficientes estimados, respectivos erros-padrão, razões de chances (odds ratios — OR) e valores-p. Os modelos L1 e L2 serão mantidos na comparação do desempenho preditivo, mas não serão aprofundados nessa etapa, pois a estimação penalizada não fornece diretamente os erros-padrão e os testes de significância convencionais.

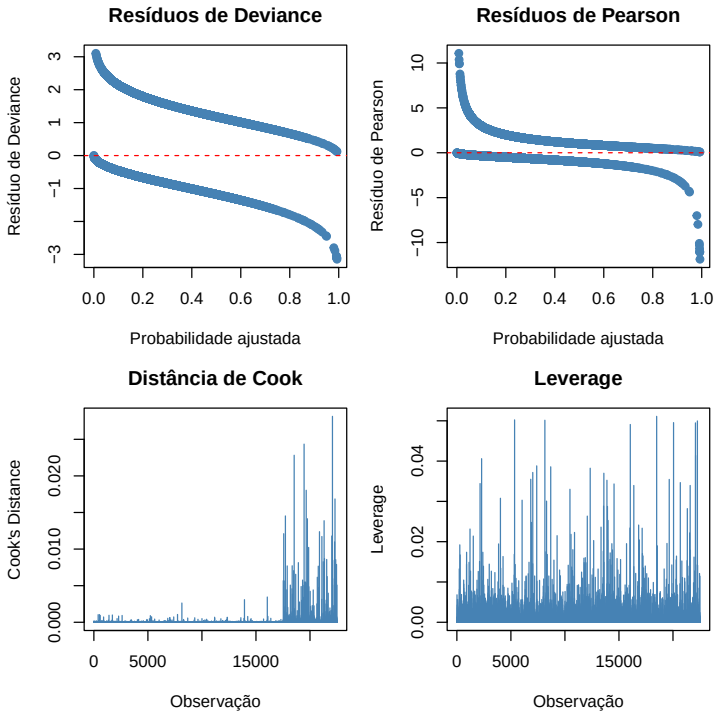


Figura 10: Análise de resíduos do modelo de regressão logística sem multicolinearidade.

A adequação do ajuste foi investigada por meio dos resíduos de Deviance e de Pearson, da distância de Cook e do *leverage*, conforme apresentado na Figura 10. Os gráficos de resíduos apresentam a formação de dois ramos, comportamento esperado em modelos logísticos com resposta binária. Os resíduos de Pearson mostram algumas observações de maior magnitude nas regiões de probabilidades extremas, compatíveis com a natureza probabilística do modelo.

A distância de Cook apresenta valores próximos de zero para a maior parte das observações,

com máximo em torno de 0,028; o *leverage* atinge aproximadamente 0,05 nas observações de maior alavancagem. De modo geral, os diagnósticos não evidenciam padrão generalizado de influência ou inadequação estrutural que comprometa a utilização do modelo.

Tabela 8: Teste da razão de verossimilhanças para a contribuição individual dos termos do modelo.

Variável	Graus de liberdade	Deviance	p-valor
limite_credito	1	16.473	< 0.001
idade	1	7.248	0.0071
atraso_pagto_0	1	864.352	< 0.001
atraso_pagto_2	1	48.532	< 0.001
atraso_pagto_6	1	19.514	< 0.001
fatura_valor_1	1	33.057	< 0.001
pagto_valor_1	1	18.374	< 0.001
pagto_valor_2	1	20.785	< 0.001
pagto_valor_3	1	1.905	0.1675
pagto_valor_4	1	10.725	0.0011
pagto_valor_5	1	6.159	0.0131
pagto_valor_6	1	4.122	0.0423
sexo_Feminino	1	15.050	< 0.001
escolaridade_Universidade	1	3.139	0.0764
escolaridade_EnsinoMedio	1	4.829	0.0280
escolaridade_Outros	1	6.868	0.0088
escolaridade_Desconhecido1	1	47.049	< 0.001
escolaridade_Desconhecido2	1	0.006	0.9392
estado_civil_Solteiro	1	19.567	< 0.001
estado_civil_Outros	1	0.528	0.4674

A contribuição individual dos termos do modelo foi avaliada por meio do teste da razão de verossimilhanças (Tabela 8), que compara o modelo completo com versões nas quais cada preditor é removido individualmente. `atraso_pagto_0` apresenta a maior contribuição, com redução de 864 unidades na Deviance ($p < 0{,}001$), seguido de `atraso_pagto_2`,

`escolaridade_Desconhecido1`, `fatura_valor_1` e demais variáveis de comportamento de pagamento e demográficas, com p $<$ 0,001 ou p $<$ 0,05. Quatro termos não atingiram significância ao nível de 5%: `pagto_valor_3`, `escolaridade_Universidade`, `escolaridade_Desconhecido2` e `estado_civil_Outros`.

Cabe observar que a ausência de significância individual não implica irrelevância para o modelo: o teste avalia a contribuição de cada termo condicionada à presença dos demais, e a significância estatística não corresponde, por si só, à magnitude do efeito prático.

Tabela 9: Resultados da estimação do modelo de regressão logística frequentista

term	estimate	std.error	statistic	p.value	OR
(Intercept)	-0.9902	0.0998	-9.9261	0.0000	0.3715
limite_credito	0.0000	0.0000	-4.0252	0.0001	1.0000
idade	0.0058	0.0022	2.6983	0.0070	1.0058
atraso_pagto_0	0.5984	0.0203	29.4093	0.0000	1.8193
atraso_pagto_2	0.1348	0.0193	6.9868	0.0000	1.1443
atraso_pagto_6	0.0779	0.0177	4.4104	0.0000	1.0810
fatura_valor_1	0.0000	0.0000	-5.6696	0.0000	1.0000
pagto_valor_1	0.0000	0.0000	-3.7367	0.0002	1.0000
pagto_valor_2	0.0000	0.0000	-3.9312	0.0001	1.0000
pagto_valor_3	0.0000	0.0000	-1.3196	0.1870	1.0000
pagto_valor_4	0.0000	0.0000	-2.9735	0.0029	1.0000
pagto_valor_5	0.0000	0.0000	-2.3091	0.0209	1.0000
pagto_valor_6	0.0000	0.0000	-1.9366	0.0528	1.0000
sexo_Feminino	-0.1377	0.0354	-3.8858	0.0001	0.8714
escolaridade_Universidade	-0.0727	0.0410	-1.7728	0.0763	0.9299
escolaridade_EnsinoMedio	-0.1207	0.0550	-2.1922	0.0284	0.8863
escolaridade_Outros	-0.9872	0.4305	-2.2934	0.0218	0.3726
escolaridade_Desconhecido1	-1.8649	0.3549	-5.2545	0.0000	0.1549
escolaridade_Desconhecido2	0.0341	0.4463	0.0765	0.9390	1.0347
estado_civil_Solteiro	-0.1765	0.0399	-4.4224	0.0000	0.8382
estado_civil_Outros	-0.1153	0.1599	-0.7212	0.4708	0.8911

A Tabela 9 apresenta os coeficientes estimados, erros-padrão, estatísticas de teste, p-valores e razões de chances (OR). Entre os preditores avaliados, `atraso_pagto_0` destaca-se como a variável de maior impacto positivo, com coeficiente de 0,5984 e OR de 1,82, mantidos os demais preditores constantes, sua presença está associada a aproximadamente 1,82 vezes as chances de PD30. As variáveis `atraso_pagto_2` e `atraso_pagto_6` também apresentam associações positivas, embora de menor magnitude. Entre os efeitos negativos, `sexo_Feminino` (OR = 0,87; $p < 0,001$) e `estado_civil_Solteiro` (OR = 0,84; $p < 0,001$) estão associados a menores chances de inadimplência. A categoria `escolaridade_Desconhecido1` apresenta o maior efeito negativo (OR = 0,15; $p < 0,001$), embora deva ser interpretada com cautela, pois pode representar ausência de informação no processo de coleta, não um nível substantivo de escolaridade.

Os termos relacionados a valores de fatura, pagamento e limite de crédito apresentam coeficientes numericamente pequenos pelo fato de essas variáveis serem medidas em escala monetária, na qual uma unidade representa variação relativamente pequena. Os coeficientes arredondados a quatro casas decimais aparecem como 0,0000 e ORs como 1,0000, sem que isso implique ausência de efeito, a interpretação adequada considera variações economicamente relevantes na escala original. Nesse grupo, `fatura_valor_1`, `pagto_valor_1`, `pagto_valor_2`, `pagto_valor_4` e `pagto_valor_5` apresentam associação estatisticamente significativa com PD30.

Em conjunto, os coeficientes evidenciam associações de diferentes magnitudes e direções, com destaque para os preditores de comportamento de pagamento. A análise das ORs complementa o teste da razão de verossimilhanças apresentado anteriormente, permitindo caracterizar tanto a direção dos efeitos quanto sua relevância individual no modelo.

4.3.2 Modelagem Bayesiana

Para avaliar a influência da especificação da distribuição a priori sobre as estimativas posteriores, foram consideradas duas distribuições distintas: Normal e Laplace, ambas centradas em zero e com escala igual a um. A distribuição Normal estabelece uma contração contínua e simétrica dos coeficientes, enquanto a distribuição Laplace apresenta maior concentração em torno de zero e caudas mais pesadas, permitindo investigar uma estratégia alternativa de regularização. Em ambos os modelos, foi utilizada uma distribuição Normal

com média zero e desvio-padrão cinco para o intercepto, permitindo maior flexibilidade na estimação desse parâmetro.

4.3.2.1 Diagnóstico de multicolinearidade

Tabela 10: Valores máximo e médio dos fatores de inflação da variância (VIF) dos modelos bayesianos.

VIF máximo	VIF médio
25.88	6.08

O diagnóstico de multicolinearidade foi realizado a partir dos fatores de VIF dos preditores utilizados nas especificações bayesianas. Como os modelos com priors Normal e Laplace compartilham a mesma matriz de preditores, os valores de VIF são idênticos para ambas as especificações, sendo apresentados conjuntamente na Tabela 10.

Os resultados revelaram que a multicolinearidade está concentrada principalmente nas variáveis referentes aos valores das faturas mensais (`fatura_valor_1` a `fatura_valor_6`), cujos VIFs variaram entre 14,35 e 25,88. As variáveis relacionadas ao histórico de atrasos (`atraso_pagto`) apresentaram valores intermediários, entre 1,89 e 4,70, enquanto os demais preditores registraram VIFs inferiores a 2.

Esse diagnóstico evidencia a presença de multicolinearidade elevada entre as variáveis referentes aos valores das faturas, indicando que a estrutura de dependência linear entre os preditores permanece nas especificações bayesianas. Ressalta-se, entretanto, que o VIF caracteriza a estrutura dos preditores, não o efeito da regularização sobre as estimativas posteriores. Assim, embora a regularização induzida pelas distribuições a priori possa atenuar a instabilidade das estimativas, não altera a estrutura de dependência linear identificada entre os preditores.

4.3.2.2 Diagnóstico do modelo bayesiano

4.3.2.2.1 Priori Normal

Tabela 11: Diagnósticos de convergência do modelo bayesiano com prior Normal.

Diagnóstico	Resultado
Rhat mínimo	1.000
Rhat máximo	1.003
ESS mínimo	2431.418
ESS máximo	7022.087
ESS do log-posterior	1661.953
MCSE do log-posterior	0.095

A avaliação da convergência e da qualidade da amostragem posterior do modelo bayesiano com distribuição a priori Normal apresentou resultados satisfatórios. Conforme apresentado na Tabela 11, os valores de $\hat{R}$ permaneceram iguais a 1,000, considerando o arredondamento apresentado, para todos os parâmetros estimados. Esses resultados indicam boa concordância entre as quatro cadeias de Markov, fornecendo evidências favoráveis à convergência do algoritmo.

Os tamanhos efetivos da amostra (*effective sample size*, ESS) também apresentaram valores satisfatórios. Considerando as quatro cadeias, os valores entre os coeficientes variaram de 2.448 a 6.648, indicando uma quantidade efetiva de amostras suficiente para a estimação dos parâmetros, mesmo considerando a autocorrelação entre as iterações. O log-posterior apresentou ESS de 1.599, também indicando uma quantidade efetiva expressiva de amostras. Adicionalmente, os erros-padrão de Monte Carlo foram muito pequenos, sugerindo que o erro numérico decorrente da simulação teve influência reduzida sobre as estimativas apresentadas.

A avaliação também contemplou diagnósticos específicos do algoritmo HMC, responsável pela geração das amostras posteriores. Não foram observadas transições divergentes nas 4.000 iterações posteriores, resultado importante porque divergências podem indicar dificuldades do algoritmo na exploração de determinadas regiões da distribuição posterior e comprometer a confiabilidade das estimativas. Da mesma forma, não houve saturação da profundidade máxima da árvore de 15 níveis, não havendo evidências de saturação desse limite durante a amostragem.

Por fim, o E-BFMI não indicou comportamento patológico, sugerindo que o algoritmo HMC explorou adequadamente a distribuição de energia. Esse resultado, em conjunto com a ausência de divergências e de saturação da profundidade da árvore, reforça a adequação do processo de amostragem.

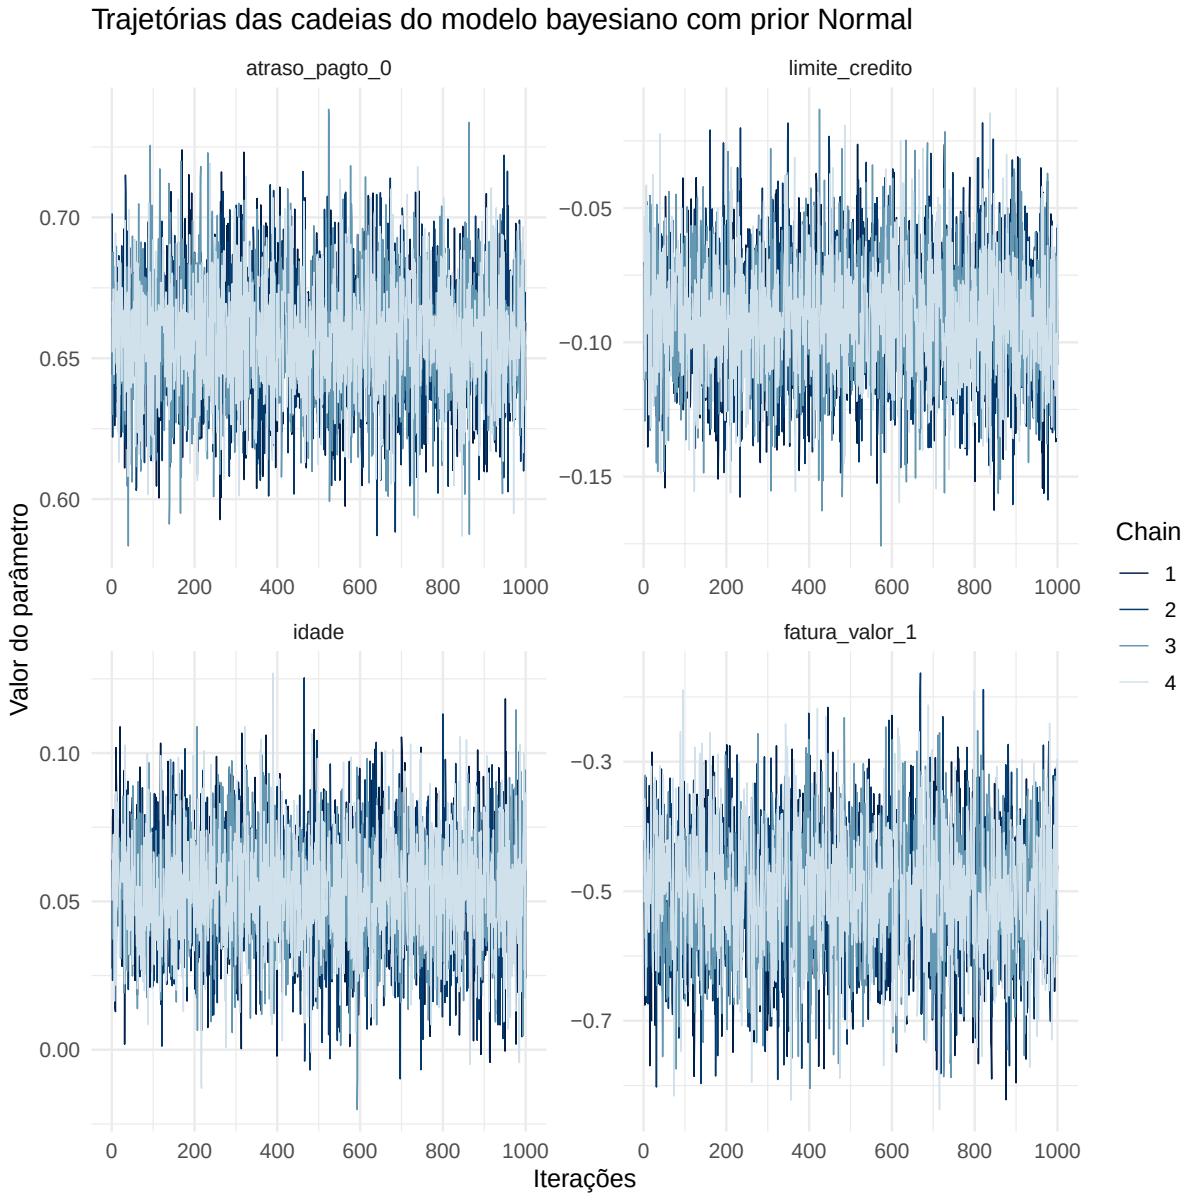


Figura 11: Gráficos de traço das cadeias de Markov Monte Carlo (MCMC) para os coeficientes selecionados do modelo bayesiano com priori Normal.

A inspeção dos *traceplots* (Figura 11) revelou boa sobreposição entre as quatro cadeias, com oscilações estáveis ao longo das iterações e ausência de tendências persistentes ou padrões de separação, sugerindo mistura adequada e comportamento estacionário das cadeias.

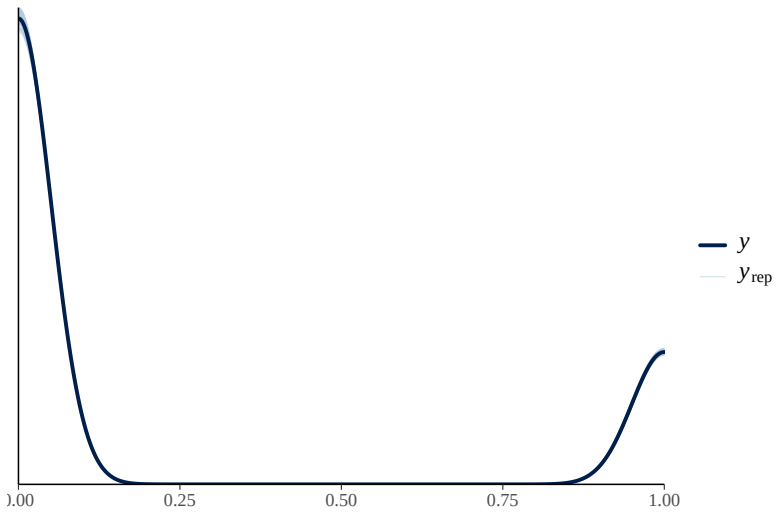


Figura 12: Verificação preditiva posterior para o modelo bayesiano com priori Normal

A PPC (Figura 12) apresentou sobreposição satisfatória entre as distribuições observada e replicada para ambas as categorias, sugerindo que o modelo reproduz satisfatoriamente a distribuição marginal da variável resposta, incluindo o desbalanceamento entre as classes. Essa verificação não avalia diretamente a capacidade discriminativa nem a qualidade das probabilidades individuais, aspectos que serão examinados por meio das métricas de classificação.

Em conjunto, os diagnósticos fornecem evidências favoráveis à convergência e à adequação do processo de amostragem, tornando as amostras posteriores apropriadas para a análise dos parâmetros e do desempenho preditivo do modelo.

4.3.2.2.2 Priori Laplace

A avaliação da convergência do modelo bayesiano com priori Laplace apresentou resultados satisfatórios. Conforme apresentado na Tabela 12, os valores do fator de redução potencial de escala ($\widehat{R}$) variaram entre 1,000 e 1,003, indicando boa concordância entre as quatro cadeias. Os tamanhos efetivos da amostra (ESS) dos coeficientes variaram entre 2.363

Tabela 12: Diagnósticos de convergência do modelo bayesiano com prior Laplace.

Diagnóstico	Resultado
Rhat mínimo	1.000
Rhat máximo	1.003
ESS mínimo	2363.451
ESS máximo	5055.712
ESS do log-posterior	855.478
MCSE do log-posterior	0.252

e 5.056, indicando quantidade efetiva de amostras satisfatória para a estimação dos parâmetros.

O log-posterior apresentou ESS de 855,478 e erro-padrão de Monte Carlo (MCSE) de 0,252. Embora o tamanho efetivo seja inferior ao observado para os coeficientes, esse resultado não constitui, isoladamente, evidência de problemas de convergência, devendo ser considerado em conjunto com os demais diagnósticos.

Os diagnósticos específicos do algoritmo HMC não identificaram transições divergentes nem saturação da profundidade máxima da árvore de amostragem. Além disso, o E-BFMI não indicou comportamento patológico, resultados semelhantes aos observados no modelo com priori Normal.

A inspeção dos traceplots (Figura 13) também revelou boa sobreposição entre as quatro cadeias, com oscilações estáveis ao longo das iterações e ausência de tendências persistentes ou padrões de separação, sugerindo mistura adequada e comportamento estacionário das cadeias.

A verificação preditiva posterior (Figura 14) apresentou sobreposição satisfatória entre a distribuição observada e as replicações posteriores, sugerindo que o modelo reproduz satisfatoriamente a distribuição marginal da variável resposta.

4.3.2.3 Comparação entre as especificações bayesianas

Tabela 13: Comparação dos modelos bayesianos com base na diferença de ELPD.

Modelo	Diferença de ELPD	Erro-padrão da diferença
fit_laplace	0.00	0.00
fit_normal	-0.74	0.32

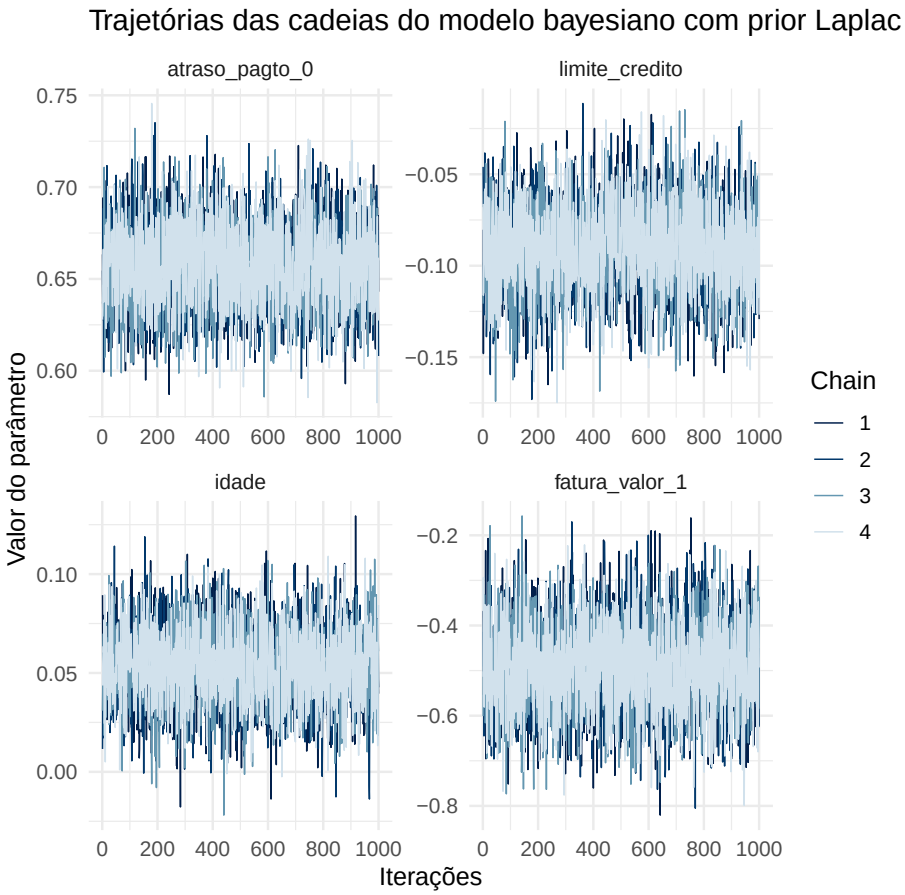


Figura 13: Gráficos de traço das cadeias de Markov Monte Carlo (MCMC) para os coeficientes selecionados do modelo bayesiano com priori Laplace

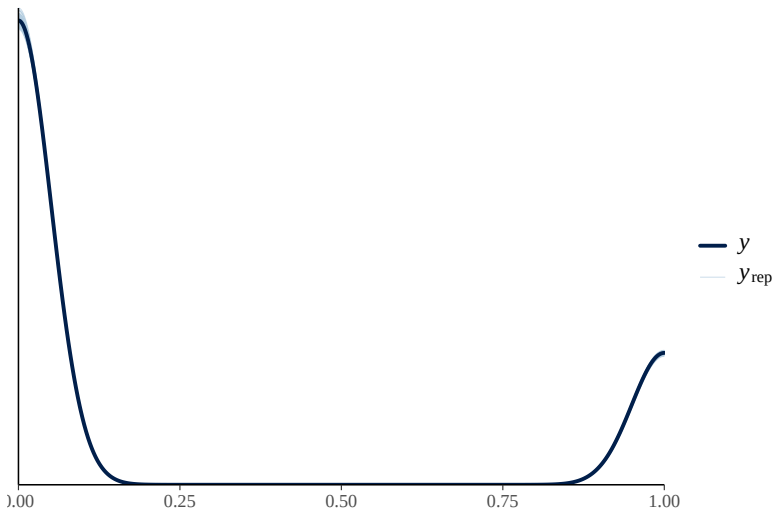


Figura 14: Verificação preditiva posterior para o modelo bayesiano com priori Laplace

Após a avaliação individual dos modelos bayesianos com priors Normal e Laplace, realizou-se uma comparação complementar de seu desempenho preditivo por meio do WAIC e da diferença na densidade preditiva esperada (ELPD), conforme apresentado na Tabela 13.

A comparação tomou o modelo com prior Laplace como referência. Essa especificação apresentou WAIC de 20.864,79, ligeiramente inferior ao valor de 20.865,83 obtido pelo modelo com prior Normal. Na comparação baseada na ELPD, o modelo Normal apresentou diferença de $-0{,}74$, com erro-padrão de 0,32. Esses resultados indicam uma pequena vantagem relativa do modelo Laplace, embora a magnitude da diferença não sugira uma superioridade preditiva expressiva. Além disso, os valores de complexidade efetiva ((p_{WAIC})) foram próximos entre as especificações, reforçando a semelhança entre os modelos segundo esse critério.

4.3.2.4 Análise das distribuições a posteriori

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
(Intercept)	-1.484	-1.483	-1.523	-1.445	-1.522	-1.444
atraso_pagto_0	0.657	0.657	0.614	0.701	0.614	0.702
atraso_pagto_2	0.094	0.093	0.039	0.151	0.039	0.150
atraso_pagto_3	0.083	0.083	0.020	0.144	0.022	0.142
atraso_pagto_4	0.053	0.051	-0.013	0.118	-0.015	0.115
atraso_pagto_5	0.031	0.033	-0.038	0.099	-0.032	0.100
atraso_pagto_6	0.001	0.003	-0.056	0.059	-0.055	0.057
escolaridade_Desconhecido1	-0.183	-0.179	-0.257	-0.118	-0.253	-0.118
escolaridade_Desconhecido2	0.001	0.000	-0.038	0.035	-0.039	0.035

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
escolaridade_Ensino-Medio	-0.046	-0.044	-0.085	-0.006	-0.084	-0.005
escolaridade_Outros	-0.066	-0.064	-0.125	-0.017	-0.126	-0.013
escolaridade_Universidade	-0.038	-0.037	-0.077	0.002	-0.078	0.005
estado_civil_Outros	-0.011	-0.011	-0.046	0.021	-0.045	0.021
estado_civil_Solteiro	-0.089	-0.089	-0.127	-0.051	-0.127	-0.049
fatura_valor_1	-0.503	-0.487	-0.708	-0.311	-0.684	-0.295
fatura_valor_2	0.277	0.255	0.037	0.522	0.031	0.497
fatura_valor_3	0.048	0.048	-0.156	0.263	-0.146	0.244
fatura_valor_4	-0.021	-0.021	-0.223	0.174	-0.207	0.172
fatura_valor_5	0.109	0.098	-0.107	0.322	-0.097	0.303
fatura_valor_6	-0.005	0.002	-0.166	0.163	-0.155	0.164
idade	0.053	0.053	0.014	0.092	0.015	0.091
limite_credito	-0.091	-0.090	-0.137	-0.045	-0.138	-0.043
pagto_valor_1	-0.229	-0.225	-0.322	-0.148	-0.311	-0.146

Tabela 14: Medianas e intervalos de credibilidade de 95% dos coeficientes dos modelos bayesianos com prioris Normal e Laplace.

Variável	Mediana (Normal)	Mediana (Laplace)	ICr 2,5% (Normal)	ICr 97,5% (Normal)	ICr 2,5% (Laplace)	ICr 97,5% (Laplace)
pagto_valor_2	-0.184	-0.183	-0.288	-0.093	-0.282	-0.092
pagto_valor_3	-0.035	-0.036	-0.105	0.032	-0.105	0.026
pagto_valor_4	-0.093	-0.091	-0.163	-0.031	-0.162	-0.028
pagto_valor_5	-0.062	-0.061	-0.128	-0.001	-0.131	-0.002
pagto_valor_6	-0.048	-0.048	-0.105	0.005	-0.108	0.004
sexo_Feminino	-0.067	-0.067	-0.101	-0.032	-0.101	-0.034

A comparação das distribuições posteriores evidencia resultados bastante semelhantes entre os modelos especificados com prioris Normal e Laplace. As medianas dos coeficientes apresentam diferenças pequenas, assim como os respectivos intervalos de credibilidade de 95%, conforme apresentado na Tabela 14. Esse comportamento sugere que, para a amostra e as especificações consideradas, as estimativas posteriores são pouco sensíveis à escolha entre essas duas distribuições a priori.

Cabe destacar que os preditores foram padronizados antes do ajuste dos modelos, incluindo as variáveis indicadoras binárias geradas a partir das variáveis categóricas. Dessa forma, os coeficientes representam variações no logaritmo das chances de inadimplência associadas ao aumento de um desvio-padrão no respectivo preditor original, mantendo-se os demais constantes. No caso das variáveis indicadoras, como sexo_Feminino, essa transformação deve ser considerada na interpretação: o coeficiente não representa diretamente a comparação entre as categorias na escala original.

Conforme apresentado na Tabela 14, 16 dos 27 preditores apresentam intervalos de credibili-

dade de 95% inteiramente fora de zero em ambas as especificações. Entre os efeitos positivos, destacam-se atraso_pagto_0, atraso_pagto_2, atraso_pagto_3, fatura_valor_2 e idade. Entre os negativos, encontram-se escolaridade_Desconhecido1, escolaridade_EnsinoMedio, escolaridade_Outros, estado_civil_Solteiro, fatura_valor_1, limite_credito, pagto_valor_1, pagto_valor_2, pagto_valor_4, pagto_valor_5 e sexo_Feminino. A concordância entre as especificações quanto à direção desses efeitos reforça a semelhança das estimativas obtidas sob as duas distribuições a priori.

Por outro lado, os intervalos de credibilidade dos demais preditores incluem zero, indicando maior incerteza quanto à direção de seus efeitos. Esse resultado evidencia que os coeficientes apresentam diferentes graus de concentração nas distribuições posteriores.

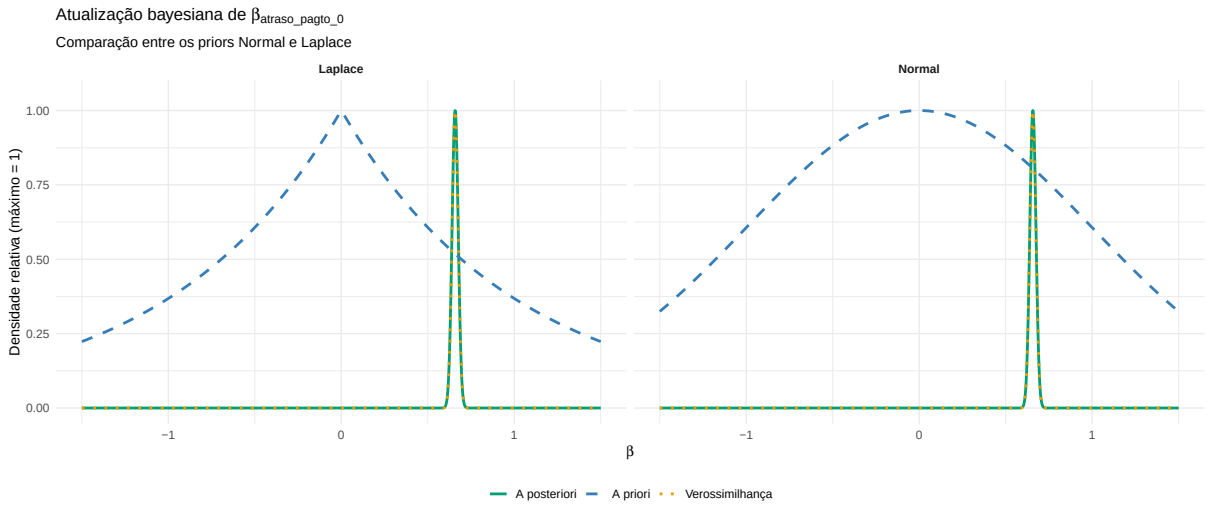


Figura 15: Atualização bayesiana do coeficiente de atraso_pagto_0: comparação entre os priors Normal e Laplace.

A Figura 15 apresenta uma representação da atualização bayesiana do coeficiente associado à variável atraso_pagto_0, considerando as especificações com prioris Normal e Laplace. Em ambos os painéis, são apresentadas as distribuições a priori, as funções de verossimilhança condicionais e as distribuições a posteriori, permitindo visualizar a contribuição da informação inicial e dos dados para a estimação do parâmetro.

Observa-se que as distribuições a priori possuem formatos distintos, decorrentes das propriedades das distribuições Normal e Laplace. Entretanto, a incorporação da informação amostral conduz a distribuições a posteriori bastante semelhantes, concentradas em torno de valores positivos do coeficiente.

A verossimilhança condicional apresenta concentração elevada em torno de seu máximo, próximo a $\beta \approx 0{,}7$, em comparação às distribuições a priori. Esse comportamento sugere que, para esse coeficiente, a informação amostral exerce influência importante na atualização, contribuindo para a semelhança entre as distribuições a posteriori obtidas com as duas especificações.

Ressalta-se que a verossimilhança apresentada corresponde a uma avaliação condicional, na qual os demais coeficientes foram mantidos fixos em suas medianas posteriores. Além disso, as curvas foram reescaladas para que seus valores máximos fossem iguais a um, de modo a facilitar a comparação visual de seus formatos. Portanto, a figura possui finalidade ilustrativa e não representa as distribuições marginais completas dos parâmetros.

4.3.2.4.1 Interpretação dos coeficientes e das razões de chances

Na regressão logística, os coeficientes representam a variação no logaritmo das chances de ocorrência do evento de interesse, neste caso, a inadimplência ($PD30 = 1$), associada ao aumento de uma unidade no preditor, mantendo-se os demais constantes. Como as variáveis explicativas foram padronizadas antes do ajuste dos modelos, inclusive as variáveis indicadoras binárias, essa interpretação deve considerar a escala padronizada dos preditores. Assim, para as variáveis numéricas, o aumento de uma unidade corresponde a um desvio-padrão na escala original. Para as variáveis indicadoras, essa variação não representa diretamente a passagem de uma categoria para outra.

Coeficientes positivos indicam associação com o aumento das chances de inadimplência, enquanto coeficientes negativos indicam associação com sua redução. A magnitude dos coeficientes expressa a intensidade dessas associações na escala do logaritmo das chances.

Entre os coeficientes positivos, destaca-se atraso_pagto_0, com mediana posterior de 0,657 em ambas as especificações. Esse preditor apresenta a maior estimativa positiva entre as variáveis explicativas, com intervalo de credibilidade de 95% inteiramente acima de zero. Também apresentam associações positivas atraso_pagto_2, atraso_pagto_3, fatura_valor_2 e idade, cujos intervalos de credibilidade também não incluem zero.

Por outro lado, fatura_valor_1 apresenta a maior estimativa negativa, com medianas posteriores de -0,503 no modelo Normal e -0,487 no modelo Laplace. Outros efeitos

negativos são observados para pagto_valor_1, pagto_valor_2, limite_credito, entre outros.

Para facilitar a interpretação dos efeitos estimados na regressão logística, os coeficientes podem ser exponenciados, obtendo-se as razões de chances. Essa transformação permite expressar os efeitos em termos multiplicativos sobre as chances de inadimplência:

$$OR_j = \exp(\beta_j).$$

Valores de OR superiores a 1 indicam aumento nas chances de inadimplência, enquanto valores inferiores a 1 indicam redução. Um OR igual a 1 corresponde à ausência de associação na escala das chances.

Considerando as medianas posteriores, o preditor atraso_pagto_0 apresenta OR de aproximadamente 1,929 em ambas as especificações. Isso indica que um aumento de uma unidade na escala padronizada desse preditor está associado a chances de inadimplência aproximadamente 92,9% maiores, mantendo-se os demais preditores constantes. Entre os demais efeitos positivos, destacam-se atraso_pagto_2, com OR próximo de 1,099 no modelo Normal e 1,098 no Laplace; atraso_pagto_3, com OR próximo de 1,087; fatura_valor_2, com OR de aproximadamente 1,319 no modelo Normal e 1,290 no Laplace; e idade, com OR próximo de 1,054.

Em relação aos efeitos negativos, fatura_valor_1 apresenta OR de aproximadamente 0,605 no modelo Normal e 0,614 no Laplace. Esses valores correspondem a reduções de cerca de 39,5% e 38,6% nas chances de inadimplência, respectivamente, para um aumento de uma unidade na escala padronizada do preditor. Também se destacam pagto_valor_1, com OR próximo de 0,795 no modelo Normal e 0,798 no Laplace; pagto_valor_2, com OR próximo de 0,832 e 0,833, respectivamente; e limite_credito, com OR próximo de 0,913 e 0,914.

A comparação entre os modelos evidencia que os ORs obtidos são bastante semelhantes. As pequenas diferenças observadas nas estimativas não alteram a direção dos efeitos nem a identificação dos principais preditores associados à inadimplência.

Tabela 15: Métricas de desempenho dos modelos de regressão logística bayesiano e frequentista para previsão de PD30 no conjunto de teste.

Métrica	Completo	Sem multicol.	L1 (LASSO)	L2 (Ridge)	Bayesiano (Laplace)	Bayesiano (Normal)
Acurácia	0.8105	0.8117	0.8108	0.8069	0.8105	0.8105
Acurácia balanceada	0.6129	0.6135	0.6129	0.5990	0.6127	0.6129
ROC AUC	0.7163	0.7141	0.7161	0.7153	0.7164	0.7165
Log-loss	0.4702	0.4698	0.4699	0.4695	0.4699	0.4699
Sensibilidade	0.2586	0.2580	0.2580	0.2260	0.2580	0.2586
Especificidade	0.9673	0.9690	0.9678	0.9719	0.9675	0.9673
Precisão	0.6919	0.7028	0.6948	0.6957	0.6926	0.6919
F1-score	0.3765	0.3774	0.3763	0.3412	0.3759	0.3765
MCC	0.3405	0.3449	0.3413	0.3181	0.3403	0.3405

Ressalta-se que os ORs apresentados foram calculados a partir das medianas posteriores dos coeficientes e se referem a variações de uma unidade na escala padronizada dos preditores. Portanto, não devem ser interpretados diretamente como alterações associadas a uma unidade monetária, a um ano de idade ou à mudança entre categorias originais das variáveis indicadoras. No caso destas últimas, a interpretação também deve considerar a padronização: o coeficiente não representa diretamente a comparação entre as categorias originais, mas a variação associada a uma unidade na escala transformada da variável.

4.3.2.4.2 Intervalos de credibilidade e incerteza das estimativas

Os intervalos de credibilidade de 95% permitem avaliar a incerteza associada às estimativas dos coeficientes, delimitando uma região que contém 95% da probabilidade posterior do parâmetro, condicionada aos dados observados e à distribuição a priori adotada. Diferentemente dos intervalos de confiança frequentistas, sua interpretação está diretamente relacionada à distribuição posterior do parâmetro.

A amplitude dos intervalos fornece uma indicação da incerteza das estimativas: intervalos mais estreitos indicam maior concentração da distribuição posterior, enquanto intervalos mais amplos refletem maior dispersão e incerteza quanto à magnitude dos coeficientes. A proximidade entre os limites dos intervalos dos modelos Normal e Laplace indica que a incerteza das estimativas foi semelhante sob as duas especificações.

4.3.2.5 Avaliação do desempenho preditivo

A avaliação do desempenho preditivo dos modelos foi realizada com base em métricas calculadas sobre o conjunto de teste, permitindo comparar a capacidade de generalização

das abordagens frequentista e bayesiana. Foram consideradas métricas relacionadas à classificação, à discriminação entre as classes e à qualidade das probabilidades estimadas, de modo a proporcionar uma avaliação mais abrangente do desempenho dos modelos (Tabela 15).

De maneira geral, os resultados evidenciam elevada proximidade entre os modelos avaliados. A acurácia variou entre 0,8069 e 0,8117, indicando que aproximadamente 81% das observações foram classificadas corretamente. Entre as especificações, o modelo frequentista sem multicolinearidade apresentou o maior valor (0,8117), enquanto o modelo Ridge apresentou o menor (0,8069). Os modelos bayesianos alcançaram acurácia de 0,8105 em ambas as especificações, demonstrando desempenho semelhante ao das alternativas frequentistas.

Entretanto, a interpretação da acurácia deve considerar o desbalanceamento da variável resposta. Aproximadamente 78% das observações pertencem à classe 0, enquanto cerca de 22% correspondem à classe 1. Nesse cenário, a acurácia convencional pode superestimar a qualidade da classificação, uma vez que o desempenho sobre a classe majoritária exerce maior influência sobre seu valor. Essa limitação também é evidenciada pela acurácia balanceada, que variou entre 0,5990 e 0,6135. A diferença entre as duas medidas indica um desempenho desigual na identificação das duas classes.

A análise da sensibilidade e da especificidade reforça essa constatação. Os valores de sensibilidade, entre 0,2260 e 0,2586, revelam capacidade limitada de identificar corretamente os clientes inadimplentes. Em contrapartida, a especificidade variou entre 0,9673 e 0,9719, indicando que os modelos identificaram corretamente a grande maioria dos clientes não inadimplentes. Assim, considerando o ponto de corte adotado, aproximadamente 74% a 77% dos clientes inadimplentes não foram identificados como pertencentes à classe positiva. Esse comportamento evidencia uma limitação importante dos classificadores na identificação da classe de interesse.

A precisão apresentou valores entre 0,6919 e 0,7028, indicando que aproximadamente 69% a 70% das observações classificadas como inadimplentes pertencem efetivamente a essa categoria. O F1-score, por sua vez, variou entre 0,3412 e 0,3774. Por combinar precisão e sensibilidade por meio da média harmônica, essa métrica também evidencia as limitações dos modelos na identificação da classe positiva, especialmente em razão dos baixos valores de sensibilidade.

O MCC apresentou valores entre 0,3181 e 0,3449. Por considerar simultaneamente os verdadeiros e falsos positivos e negativos, essa métrica oferece uma perspectiva mais abrangente do desempenho classificatório, especialmente diante do desbalanceamento observado. Os valores obtidos indicam uma associação positiva, mas relativamente limitada, entre as classificações realizadas pelos modelos e as classes efetivamente observadas.

A capacidade discriminatória foi analisada adicionalmente por meio da área sob a curva ROC (ROC AUC), que avalia a capacidade de distinguir observações pertencentes às diferentes classes ao longo de diversos pontos de corte. Diferentemente das métricas baseadas em classificações binárias, essa medida não depende da adoção de um limiar específico para transformar as probabilidades estimadas em classes. Os valores de ROC AUC variaram entre 0,7141 e 0,7165, sendo o maior resultado obtido pelo modelo bayesiano com priori Normal (0,7165), seguido pelo modelo com priori Laplace (0,7164). Essa proximidade indica capacidades discriminatórias semelhantes entre as especificações, sem diferenças expressivas entre as abordagens frequentista e bayesiana.

Em relação à qualidade das probabilidades estimadas, o log-loss apresentou resultados praticamente idênticos entre as seis especificações, variando de 0,4695 a 0,4702. Essa proximidade sugere que as diferentes estratégias de estimação e regularização produziram probabilidades preditas com desempenho semelhante segundo essa métrica.

De forma geral, os resultados apontam para uma elevada semelhança entre as especificações frequentistas e bayesianas quanto ao desempenho preditivo. Embora algumas métricas apresentem pequenas diferenças entre os modelos, não se observa uma vantagem expressiva de uma abordagem sobre a outra. Ainda assim, a avaliação evidencia uma limitação comum às seis especificações: a baixa sensibilidade na identificação dos clientes inadimplentes, apesar da elevada especificidade para a classe de não inadimplência.

4.3.2.6 Análise dos erros de classificação

A Figura 16 apresenta as matrizes de confusão dos modelos frequentista (sem multicolinearidade) e bayesiano (priori Normal), avaliados no conjunto de teste com ponto de corte de 0,5. Os resultados mostram padrões praticamente idênticos: o frequentista registrou 1.231 falsos negativos e 181 falsos positivos, enquanto o bayesiano apresentou 1.230 e 191, respectivamente. Aproximadamente 74% dos clientes efetivamente inadimplentes não

foram identificados por nenhum dos modelos, refletindo a baixa sensibilidade (~25,8%) já reportada na Tabela 15 e o impacto do desbalanceamento da variável resposta.

A predominância de falsos negativos em relação aos falsos positivos indica que os classificadores tendem a subestimar o risco de inadimplência, clientes que efetivamente inadimplirão são classificados como não inadimplentes, o que pode resultar em concessão indevida de crédito. A adoção do modelo bayesiano não modificou substancialmente esse padrão. A definição de um ponto de corte adequado, considerando os custos relativos de cada tipo de erro e os objetivos institucionais, é retomada na Discussão.

	Real	Predito	Freq	Modelo
1	0	0	5660	Frequentista (sem multicol.)
2	1	0	1231	Frequentista (sem multicol.)
3	0	1	181	Frequentista (sem multicol.)
4	1	1	428	Frequentista (sem multicol.)
5	0	0	5650	Bayesiano (Normal)
6	1	0	1230	Bayesiano (Normal)
7	0	1	191	Bayesiano (Normal)
8	1	1	429	Bayesiano (Normal)

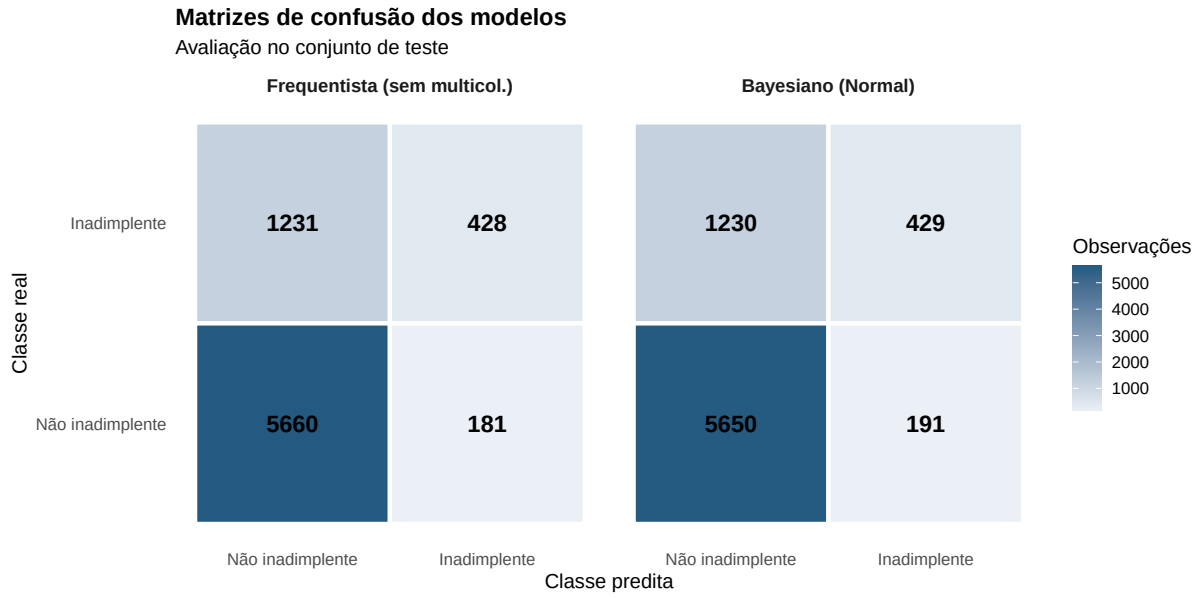


Figura 16: Matrizes de confusão dos modelos frequentista e bayesiano no conjunto de teste.

Tabela 16: Melhores limites de corte com base no índice de Youden

Modelo	.threshold	sensitivity	specificity	youden
Bayesiano (Normal)	0.2548669	0.5623870	0.8127033	0.3750903
Frequentista (Sem Multicol.)	0.2625011	0.5364678	0.8375278	0.3739956

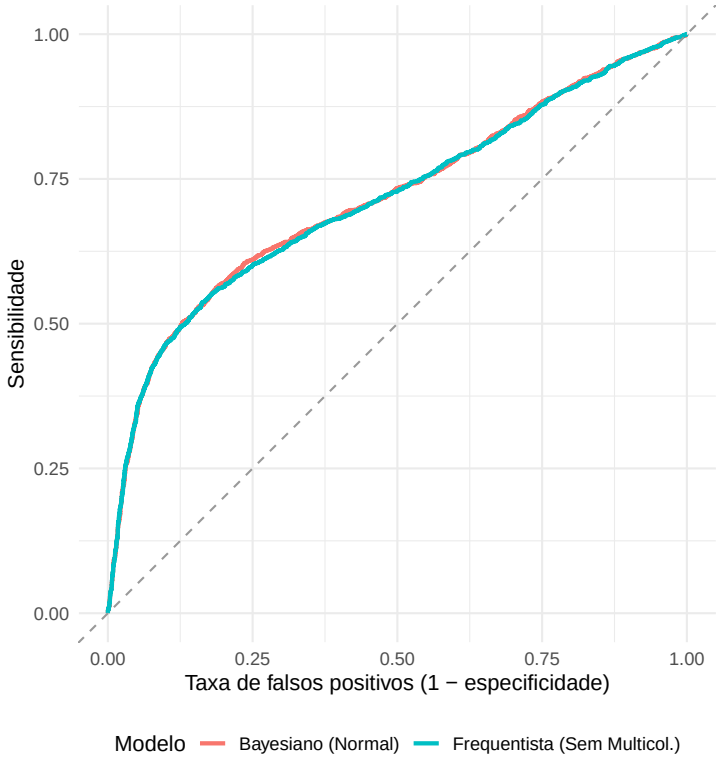


Figura 17: Curvas ROC dos modelos frequentista (Sem Multicol.) e bayesiano (Normal) no conjunto de teste.

4.3.2.7 Análise das curvas ROC

A (**roc-comparacao?**) apresenta as curvas ROC dos modelos frequentista e bayesiano com prior Normal, construídas a partir das probabilidades estimadas no conjunto de teste. A curva ROC permite avaliar a capacidade discriminatória dos modelos para diferentes pontos de corte, relacionando a sensibilidade à taxa de falsos positivos (1 - especificidade).

Observa-se que as duas curvas apresentam trajetórias bastante próximas e praticamente sobrepostas ao longo de sua extensão, indicando comportamento discriminatório semelhante. Esse resultado é consistente com os valores de AUC, de aproximadamente 0,714 para o modelo frequentista e 0,716 para o modelo bayesiano. Embora ambos apresentem

desempenho superior ao de um classificador aleatório, cuja AUC corresponde a 0,5, os valores obtidos indicam capacidade discriminatória moderada.

Portanto, a comparação não evidencia vantagem preditiva expressiva de uma abordagem sobre a outra. O modelo bayesiano com prior Normal apresentou uma AUC ligeiramente superior, mas a diferença é pequena e, isoladamente, não permite afirmar que exista superioridade estatisticamente significativa. Os resultados sugerem, assim, que as abordagens frequentista e bayesiana alcançaram desempenho discriminatório semelhante para o problema de identificação de clientes inadimplentes.

4.3.2.8 Análise do ponto de corte pelo índice de Youden

Como análise complementar, investigou-se a possibilidade de adoção de pontos de corte diferentes do valor convencional de 0,5, considerando o índice de Youden como critério de seleção. Esse índice permite identificar o limiar que maximiza conjuntamente a sensibilidade e a especificidade, atribuindo igual importância à identificação correta das duas classes.

Os resultados indicaram pontos de corte de 0,255 para o modelo bayesiano e 0,263 para o frequentista, com índices de Youden de 0,375 e 0,374, respectivamente. Embora os valores sejam bastante próximos, observa-se que o modelo bayesiano apresentou sensibilidade ligeiramente superior (0,562 contra 0,536), enquanto o frequentista alcançou especificidade um pouco maior (0,838 contra 0,813).

Em comparação com a classificação realizada pelo limiar convencional de 0,5, a adoção dos pontos de corte identificados pelo índice de Youden favorece o equilíbrio entre a identificação de clientes inadimplentes e a identificação de clientes não inadimplentes. Esse comportamento é particularmente relevante diante do desbalanceamento da variável resposta, uma vez que a utilização do limiar convencional pode resultar em menor identificação da classe minoritária.

Apesar dessas diferenças, os índices de Youden praticamente equivalentes reforçam a proximidade entre os desempenhos das abordagens frequentista e bayesiana. Cabe destacar que os limiares apresentados foram identificados a partir do conjunto de teste e, portanto, são utilizados exclusivamente para fins ilustrativos. Considerando que o objetivo deste estudo consiste em comparar as abordagens de inferência frequentista e bayesiana, e não em otimizar os modelos para aplicação prática, essa análise permite demonstrar como

a alteração do ponto de corte influencia o equilíbrio entre sensibilidade e especificidade e, consequentemente, as proporções de falsos positivos e falsos negativos. Dessa forma, busca-se evidenciar se as duas abordagens apresentam comportamentos distintos diante de mudanças no critério de classificação, mantendo o foco na comparação de seus resultados preditivos.

5 Discussão

Os resultados obtidos neste estudo evidenciam que, para o conjunto de dados e as especificações avaliadas, as abordagens frequentista e bayesiana produziram desempenho preditivo essencialmente equivalente. Os valores de ROC AUC variaram entre 0,714 e 0,717, enquanto o log-loss permaneceu próximo de 0,470 em todos os modelos. Essa proximidade sugere que, em cenários com amostras de grande dimensão e alta informatividade dos dados, a escolha entre as duas abordagens é pouco determinante para o desempenho classificatório.

5.1 Sensibilidade às distribuições *a priori* e o papel do tamanho amostral

A comparação entre as especificações bayesianas com prioris Normal e Laplace revelou estimativas posteriores bastante próximas. As medianas dos coeficientes apresentaram diferenças geralmente inferiores a 0,02 unidades. Além disso, a comparação pelo WAIC produziu uma diferença de ELPD de -0,52, com erro-padrão de 0,28. Como essa diferença é inferior a dois erros-padrão, não há evidência clara de uma diferença expressiva na capacidade preditiva das especificações.

Embora as duas distribuições apresentem formatos distintos, a Normal com caudas mais leves e a Laplace com maior concentração de probabilidade em torno de zero e caudas mais pesadas, a igualdade das variâncias adotadas ($\sigma^2 = 1$) em ambas permitiu comparar seus efeitos mantendo constante essa medida de dispersão. O volume de dados disponível também pode ter contribuído para a proximidade dos resultados. Com $n = 30.000$ observações, a informação fornecida pela amostra tende a exercer influência

expressiva sobre as estimativas posteriores. A Figura 15 ilustra esse comportamento: independentemente da especificação adotada, a verossimilhança condicional apresenta formato e concentração bastante próximos aos da distribuição *a posteriori*, que também converge para valores semelhantes nos dois modelos. Essa sobreposição sugere que, para esse coeficiente, a informação amostral exerce influência predominante na atualização, enquanto as diferenças entre as distribuições *a priori* têm efeito limitado sobre o resultado posterior. Esse comportamento é compatível com o teorema de Bernstein–von Mises, segundo o qual, sob determinadas condições de regularidade, a distribuição posterior aproxima-se assintoticamente de uma distribuição Normal centrada no estimador de máxima verossimilhança, tornando-se, em primeira ordem, independente da distribuição *a priori* Vaart (1998).

A semelhança observada entre as prioris, assim como entre os resultados preditivos das abordagens frequentista e bayesiana, não implica que a escolha da distribuição *a priori* seja irrelevante em outros contextos. Em situações com amostras de menor dimensão, comuns no início da operação de um produto de crédito, em segmentos de nicho ou em carteiras com baixíssima taxa de inadimplência, a verossimilhança tende a fornecer menos informação, e a distribuição *a priori* pode exercer influência mais pronunciada sobre as estimativas. Nesse cenário, as diferenças de forma entre as prioris Normal e Laplace poderiam se manifestar de maneira mais expressiva: a priori Laplace, por seu comportamento análogo à penalização L1, tende a promover maior contração dos coeficientes em direção a zero, podendo produzir estimativas de menor magnitude. A priori Normal, por sua vez, apresenta um comportamento de regularização mais suave. Assim, uma abordagem bayesiana com prioris adequadamente especificadas pode oferecer vantagens práticas em cenários com dados escassos, tanto pela possibilidade de incorporar conhecimento prévio sobre os parâmetros de forma explícita quanto pela possibilidade de obter estimativas mais estáveis do que aquelas produzidas pela máxima verossimilhança. Essa é, portanto, uma limitação importante deste estudo: os resultados obtidos são específicos ao contexto de grande dimensão amostral e não devem ser generalizados como evidência de equivalência universal entre as abordagens.

5.2 Multicolinearidade: tratamento e implicações

A multicolinearidade constituiu um aspecto central neste estudo, dada a forte correlação entre as variáveis referentes aos valores das faturas mensais (`fatura_valor_1` a `fatura_valor_6`) e, em menor grau, entre as variáveis relacionadas ao histórico de atrasos de pagamento. Conforme apresentado na Tabela 7, o modelo frequentista completo evidenciou multicolinearidade elevada, indicando possível instabilidade dos estimadores e dificuldade na identificação dos efeitos individuais dos preditores. A remoção de variáveis altamente correlacionadas reduziu substancialmente o VIF sem produzir alterações relevantes no desempenho preditivo, resultado que reforça a importância do diagnóstico e do tratamento da multicolinearidade, especialmente em modelos voltados à interpretação dos efeitos individuais dos preditores.

Na abordagem bayesiana, as distribuições a priori centradas em zero introduzem um mecanismo de regularização que pode contribuir para estabilizar as estimativas em situações de multicolinearidade. Entretanto, conforme apresentado na Tabela 10, os valores de VIF observados nas especificações bayesianas evidenciam que a estrutura de dependência linear entre os preditores permanece presente. Isso ocorre porque a regularização atua sobre as estimativas dos parâmetros, mas não modifica a matriz de preditores nem elimina sua dependência linear. Assim, embora a informação a priori possa influenciar a magnitude e a variabilidade das estimativas posteriores, não resolve, por si só, as dificuldades de identificação individual dos efeitos associadas à multicolinearidade.

Em conjunto, os resultados indicam que o diagnóstico e o tratamento da multicolinearidade permanecem relevantes quando o objetivo é a interpretação inferencial dos coeficientes, independentemente da abordagem de estimação adotada. Enquanto a remoção de preditores correlacionados reduz diretamente a dependência linear entre as variáveis explicativas, a regularização bayesiana oferece uma estratégia alternativa para lidar com seus possíveis efeitos sobre as estimativas, sem alterar a estrutura original dos preditores. Essa característica pode ser particularmente útil quando a remoção de variáveis não é viável por razões substantivas ou quando se deseja preservar a estrutura original do modelo, embora a incerteza associada à identificação individual dos coeficientes permaneça.

5.3 Diferenças inferenciais entre as abordagens

Além do desempenho preditivo, as abordagens frequentista e bayesiana diferem de forma substantiva quanto à interpretação e à quantificação da incerteza dos parâmetros. Na abordagem frequentista, a incerteza é expressa por intervalos de confiança, cuja interpretação está ligada ao procedimento de amostragem repetida: um intervalo de confiança de 95% indica que, em sucessivas amostras hipotéticas extraídas do mesmo processo gerador, 95% dos intervalos construídos pelo mesmo procedimento conteriam o verdadeiro valor do parâmetro. Na abordagem bayesiana, os intervalos de credibilidade de 95% permitem uma interpretação diretamente probabilística: dados o modelo, as observações e a distribuição *a priori* adotada, o parâmetro possui probabilidade posterior de 95% de pertencer ao intervalo obtido. Essa distinção é relevante em aplicações práticas, nas quais a interpretação probabilística direta sobre os parâmetros pode ser particularmente útil.

Do ponto de vista da interpretação dos coeficientes, ambas as abordagens produziram resultados consistentes quanto à direção das associações observadas. A variável `atraso_pagto_0` destacou-se por apresentar associação positiva com a inadimplência nas especificações avaliadas. As variáveis `fatura_valor_1`, `pagto_valor_1`, `pagto_valor_2` e `limite_credito` apresentaram associações negativas, enquanto variáveis demográficas, como `sexo_Feminino` e `estado_civil_Solteiro`, também apresentaram evidências de associação com a ocorrência de inadimplência. Esses resultados devem ser interpretados considerando as diferenças de escala dos preditores entre as especificações frequentistas e bayesianas, especialmente porque as variáveis explicativas foram padronizadas nos modelos bayesianos.

5.4 Desbalanceamento de classes e limitações práticas

Um aspecto comum às duas abordagens foi a baixa sensibilidade na identificação de clientes inadimplentes quando utilizado o ponto de corte convencional de 0,5. A especificidade elevada (aproximadamente 97%), associada à sensibilidade reduzida (cerca de 25%), indica que os modelos deixam de identificar uma parcela expressiva dos inadimplentes, o que pode comprometer sua utilidade prática para fins de prevenção de perdas. Esse comportamento está relacionado ao desbalanceamento da variável resposta, na qual aproximadamente

22% das observações correspondem à classe de inadimplência, mas também à capacidade discriminatória dos modelos e ao limiar de classificação adotado.

A análise baseada no índice de Youden demonstrou que pontos de corte mais baixos (aproximadamente 0,26) poderiam elevar a sensibilidade para cerca de 55%, em contrapartida à redução da especificidade para aproximadamente 82% a 84%. Essa alteração evidencia o compromisso entre os dois tipos de erro de classificação: a redução do limiar permite identificar mais inadimplentes, mas aumenta a ocorrência de falsos positivos, associados à recusa indevida de crédito a bons pagadores. Por outro lado, limiares mais elevados reduzem os falsos positivos, mas ampliam a quantidade de inadimplentes não identificados. Ressalta-se que o índice de Youden busca equilibrar sensibilidade e especificidade, não necessariamente maximizar o resultado econômico da decisão de concessão de crédito, que depende dos custos relativos desses erros e dos objetivos da instituição financeira.

Os resultados indicam que as abordagens frequentista e bayesiana apresentam comportamentos semelhantes diante das alterações no ponto de corte, sem evidenciar superioridade sistemática de uma sobre a outra. Entretanto, caso a seleção do limiar tenha sido realizada com base no conjunto de teste, há uma limitação metodológica, pois esse conjunto deve ser reservado à avaliação final do desempenho dos modelos. Em uma aplicação prática, o ponto de corte deveria ser definido com dados de treinamento e posteriormente aplicado a novas observações. Assim, os resultados baseados no índice de Youden devem ser interpretados como uma análise complementar, e não como uma definição definitiva do limiar a ser adotado em produção.

6 Conclusão

Este trabalho investigou a aplicação de modelos de regressão logística à previsão de inadimplência em cartões de crédito, comparando as abordagens de inferência frequentista e bayesiana quanto ao desempenho preditivo, à interpretação dos parâmetros e à quantificação da incerteza.

Os resultados evidenciaram desempenho preditivo bastante semelhante entre as seis especificações avaliadas, com valores de ROC AUC entre 0,714 e 0,717 e log-loss entre 0,469 e 0,470. Da mesma forma, as prioris Normal e Laplace produziram estimativas posteriores

próximas, sugerindo sensibilidade limitada à escolha entre essas distribuições no contexto analisado. A elevada dimensão amostral pode ter contribuído para esse comportamento, embora tais resultados não permitam estabelecer equivalência geral entre as abordagens.

Quanto à inferência, a abordagem bayesiana permitiu representar a incerteza dos parâmetros por meio de distribuições posteriores e intervalos de credibilidade, além de incorporar informações prévias de maneira explícita. Em relação à multicolinearidade, a remoção de preditores correlacionados reduziu substancialmente os valores de VIF sem comprometer o desempenho preditivo. As estratégias de regularização também ofereceram alternativas para lidar com a complexidade dos modelos, embora não eliminem a dependência linear entre os preditores. Observou-se, ainda, uma limitação comum às duas abordagens na identificação de clientes inadimplentes, evidenciada pelos baixos valores de sensibilidade.

Este estudo apresenta limitações, entre elas a utilização de um único conjunto de dados, referente a clientes de cartão de crédito em Taiwan no período de 2005, e a ausência de conhecimento especializado na especificação das prioris. Trabalhos futuros podem investigar outros conjuntos de dados, prioris informativas fundamentadas em estudos anteriores ou julgamentos de especialistas e estratégias de tratamento do desbalanceamento de classes, incluindo critérios de classificação que considerem os custos assimétricos dos erros.

Em síntese, a escolha entre as abordagens frequentista e bayesiana deve considerar os objetivos da análise. Enquanto ambas apresentaram desempenho preditivo semelhante nas especificações avaliadas, a abordagem bayesiana oferece recursos adicionais para representar a incerteza dos parâmetros e incorporar informações prévias, aspectos relevantes quando o interesse ultrapassa a previsão e envolve a interpretação dos efeitos associados ao risco de inadimplência.

Referências

CARPENTER, Bob *et al.* Stan: A Probabilistic Programming Language. **Journal of Statistical Software**, v. 76, n. 1, p. 1–32, 2017.

GELMAN, Andrew; RUBIN, Donald B. Inference from Iterative Simulation Using Multiple Sequences. **Statistical Science**, v. 7, n. 4, p. 457–472, 1992.

GOODRICH, Ben *et al.* **rstanarm: Bayesian Applied Regression Modeling via Stan**. *[S.l.: S.n.]*.

KUHN, Max; WICKHAM, Hadley. Tidymodels: A Collection of Packages for Modeling and Machine Learning Using Tidyverse Principles. **Journal of Open Source Software**, v. 5, n. 51, p. 2478, 2020.

LICHMAN, M. **UCI Machine Learning Repository**. University of California, Irvine, School of Information; Computer Science; http://archive.ics.uci.edu/ml, 2013.

TUKEY, John W. **Exploratory Data Analysis**. Reading, MA: Addison-Wesley, 1977.

VAART, A. W. van der. **Asymptotic Statistics**. Cambridge: Cambridge University Press, 1998.

VEHTARI, Aki *et al.* Rank-Normalization, Folding, and Localization: An Improved R-hat for Assessing Convergence of MCMC (with Discussion). **Bayesian Analysis**, v. 16, n. 2, p. 667–718, 2021.

YEH, I.-C.; LIEN, C.-H. **The Default of Credit Card Clients Dataset**. https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients, 2009.